

2회차 과제 답안

본 답안은 학생 자율 풀이 후 자기 점검용이다. 시험·평가가 아니다. 강의 시간에 함께 풀이를 검토한다.

본 답안은 본 회차에서 다룬 객체(Euclidean norm $\|\cdot\|_2$ · ℓ_1 · ℓ_∞ ·Dot product·각도 정의·Cauchy-Schwarz inequality·삼각부등식·Orthogonal·Cosine similarity)만 사용한다.

수학 문제

문제 1 답안 (정의·진위)

(a) 참. Euclidean norm의 정의 2.1에 따라 $\|\mathbf{x}\|_2 = \sqrt{x_1^2 + \cdots + x_n^2}$ 이다. 양정성(positive definiteness, B-3)은 두 방향을 모두 보인다.

($\Leftarrow$) $\mathbf{x} = \mathbf{0}$ 이면 모든 $x_i = 0$ 이고 $\sqrt{0 + \cdots + 0} = 0$ 이므로 $\|\mathbf{x}\|_2 = 0$.

($\Rightarrow$) $\|\mathbf{x}\|_2 = 0$ 이면 $\sqrt{\sum x_i^2} = 0$ 이므로 $\sum_{i=1}^n x_i^2 = 0$ 이다. 각 $x_i^2 \geq 0$ 인 실수의 합이 0이라면 모든 $x_i^2 = 0$, 즉 모든 $x_i = 0$ 이어야 한다. 따라서 $\mathbf{x} = \mathbf{0}$.

(b) 참. Cauchy-Schwarz inequality의 등호 조건 $|\mathbf{u} \cdot \mathbf{v}| = \|\mathbf{u}\|_2 \|\mathbf{v}\|_2$ 는 $\mathbf{u}, \mathbf{v}$ 가 **선형 종속**(평행), 즉 어느 한쪽이 다른 쪽의 Scalar 배일 때만 성립한다(정리 2.1, 강의교안 C-4). 본 회차 판별식 풀이의 시작점 $\|\mathbf{u} - t\mathbf{v}\|_2^2 \geq 0$ 에서 등호는 $\mathbf{u} - t\mathbf{v} = \mathbf{0}$, 즉 $\mathbf{u} = t\mathbf{v}$ 일 때만 가능하다(양정성, (a) 결과 활용). 단 $\mathbf{v} = \mathbf{0}$ 이면 $\mathbf{u}$ 가 무엇이든 양변이 모두 0이라 등호가 자명하게 성립한다(이 경우도 평행으로 본다, $\mathbf{0}$ 은 모든 Vector와 평행으로 약속).

(c) 참. Orthogonal 정의 2.4에 따라 $\mathbf{u} \cdot \mathbf{v} = 0$. Dot product의 분배 성질(정의 2.2의 성분별 합에서 직접 도출)을 사용하면

$$\|\mathbf{u} + \mathbf{v}\|_2^2 = (\mathbf{u} + \mathbf{v}) \cdot (\mathbf{u} + \mathbf{v}) = \mathbf{u} \cdot \mathbf{u} + 2\mathbf{u} \cdot \mathbf{v} + \mathbf{v} \cdot \mathbf{v} = \|\mathbf{u}\|_2^2 + 0 + \|\mathbf{v}\|_2^2$$

이다. 본 회차에서 본 **피타고라스 정리의 Vector 일반화**이다.

문제 2 답안 (계산)

$$\mathbf{u} = (1, 2, -2)^{\top}, \mathbf{v} = (3, 0, 4)^{\top} \in \mathbb{R}^3.$$

(a) Norm 계산.

$$\|\mathbf{u}\|_2 = \sqrt{1^2 + 2^2 + (-2)^2} = \sqrt{1 + 4 + 4} = \sqrt{9} = 3$$

$$\|\mathbf{v}\|_2 = \sqrt{3^2 + 0^2 + 4^2} = \sqrt{9 + 0 + 16} = \sqrt{25} = 5$$

$$\|\mathbf{u}\|_1 = |1| + |2| + |-2| = 5 \quad (\text{보 조 노 림 , B-4})$$

$$\|\mathbf{u}\|_\infty = \max(|1|, |2|, |-2|) = 2$$

(b) Dot product와 각도.

$$\mathbf{u} \cdot \mathbf{v} = (1)(3) + (2)(0) + (-2)(4) = 3 + 0 - 8 = -5$$

각도 정의 2.3에 따라

$$\cos \theta = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\|_2 \|\mathbf{v}\|_2} = \frac{-5}{3 \cdot 5} = -\frac{1}{3} \approx -0.3333$$

$$\theta = \arccos\left(-\frac{1}{3}\right) \approx 1.9106 \text{ rad} \approx 109.47^\circ$$

(둔각: Cosine similarity 음수는 두 Vector가 "반대 방향에 가까움"을 의미한다, D 섹션.)

(c) 정규화.

$$\hat{\mathbf{u}} = \frac{\mathbf{u}}{\|\mathbf{u}\|_2} = \frac{1}{3}(1, 2, -2)^\top = \left(\frac{1}{3}, \frac{2}{3}, -\frac{2}{3}\right)^\top$$

검산:

$$\|\hat{\mathbf{u}}\|_2 = \sqrt{\left(\frac{1}{3}\right)^2 + \left(\frac{2}{3}\right)^2 + \left(-\frac{2}{3}\right)^2} = \sqrt{\frac{1+4+4}{9}} = \sqrt{\frac{9}{9}} = 1 \quad \checkmark$$

일반화: 동차성(B-3)에 따라 $\|\alpha \mathbf{x}\|_2 = |\alpha| \|\mathbf{x}\|_2$ 이므로 $\alpha = 1/\|\mathbf{u}\|_2$ 를 대입하면 $\|\hat{\mathbf{u}}\|_2 = 1$ 이 자동으로 따라온다.

(d) Dot product vs Cosine similarity. Cosine similarity는 분모 $\|\mathbf{u}\|_2 \|\mathbf{v}\|_2$ 로 두 Vector의 노름을 나누어 **방향 정보만** 남긴 양이고, Dot product는 분모를 나누지 않아 **방향과 노름 크기가 함께** 반영된 양이다.

문제 3 답안 (증명·응용)

(a) Cauchy-Schwarz inequality 판별식 풀이 증명.

먼저 $\mathbf{v} = \mathbf{0}$ 이면 좌변 $|\mathbf{u} \cdot \mathbf{v}| = 0$, 우변 $\|\mathbf{u}\|_2 \|\mathbf{v}\|_2 = 0$ 로 자명하게 성립한다. 이하 $\mathbf{v} \neq \mathbf{0}$ 이라 가정한다.

양정성(B-3, 문제 1 (a))에 따라 임의의 $t \in \mathbb{R}$ 에 대해

$$\|\mathbf{u} - t\mathbf{v}\|_2^2 \geq 0$$

이고 등호는 $\mathbf{u} - t\mathbf{v} = \mathbf{0}$ 일 때만 성립한다.

좌변을 Dot product로 전개하면(Dot product 분배 성질, 정의 2.2)

$$\|\mathbf{u} - t\mathbf{v}\|_2^2 = (\mathbf{u} - t\mathbf{v}) \cdot (\mathbf{u} - t\mathbf{v}) = \|\mathbf{v}\|_2^2 t^2 - 2(\mathbf{u} \cdot \mathbf{v})t + \|\mathbf{u}\|_2^2$$

이는 t 에 대한 2차식이다($\mathbf{v} \neq \mathbf{0}$ 가정으로 $\|\mathbf{v}\|_2^2 > 0$). 모든 t 에서 0 이상이므로 판별식 $D \leq 0$:

$$D = [-2(\mathbf{u} \cdot \mathbf{v})]^2 - 4\|\mathbf{v}\|_2^2\|\mathbf{u}\|_2^2 = 4(\mathbf{u} \cdot \mathbf{v})^2 - 4\|\mathbf{u}\|_2^2\|\mathbf{v}\|_2^2 \leq 0$$

양변을 4로 나누고 정리하면

$$(\mathbf{u} \cdot \mathbf{v})^2 \leq \|\mathbf{u}\|_2^2 \|\mathbf{v}\|_2^2$$

양변에 제곱근을 취하면(양변 모두 음이 아님)

$$|\mathbf{u} \cdot \mathbf{v}| \leq \|\mathbf{u}\|_2 \|\mathbf{v}\|_2 \quad \blacksquare$$

등호 조건: $D = 0$, 즉 2차식이 중근을 가지는 어떤 $t^* \in \mathbb{R}$ 에서 $\|\mathbf{u} - t^* \mathbf{v}\|_2^2 = 0$ 이 성립할 때이다. 양정성에 따라 이는 $\mathbf{u} - t^* \mathbf{v} = \mathbf{0}$, 즉 $\mathbf{u} = t^* \mathbf{v}$ (평행)와 동치이다. ($\mathbf{v} = \mathbf{0}$ 인 경우는 위 도입부에서 별도 처리; 이 경우도 평행으로 본다.)

(b) 문서 검색에서 Cosine similarity를 쓰는 이유.

문서 임베딩 $\mathbf{d}, \mathbf{q} \in \mathbb{R}^{768}$ 의 노름 $\|\mathbf{d}\|_2$ 는 문서 길이·단어 빈도 분포에 따라 큰 폭으로 달라진다. 길이가 긴 문서는 같은 의미라도 노름이 커지기 쉽고, 이 경우 Dot product $\mathbf{d} \cdot \mathbf{q}$ 는 의미 유사도가 아닌 단순한 노름 크기에 의해 값이 부풀려진다. 반면 Cosine similarity $\frac{\mathbf{d} \cdot \mathbf{q}}{\|\mathbf{d}\|_2 \|\mathbf{q}\|_2}$ 는 분모로 두 Vector의 노름을 나누므로 임의 양의 Scalar $\alpha > 0, \beta > 0$ 에 대해 $\cos \angle(\alpha \mathbf{d}, \beta \mathbf{q}) = \cos \angle(\mathbf{d}, \mathbf{q})$ 를 만족한다(동차성, B-3). 즉 스케일 불변(scale invariance)이라 문서 길이 차이의 영향을 받지 않고 오로지 방향(의미)만 비교한다. Cauchy-Schwarz inequality(정리 2.1)에 의해 값은 항상 $[-1, 1]$ 범위에 들어가 해석도 일관된다(1: 같은 방향, 0: 직교, -1: 반대 방향).

코딩 문제 (선택)

문제 1 답안 (직접 구현)

```
import numpy as np

def my_norm2(x):
    """Euclidean norm 직접 구현 (정의 2.1)"""
    s = 0.0
    for i in range(len(x)):
        s += x[i] * x[i] # x_i^2 누적합
    return float(np.sqrt(s))

def my_dot(u, v):
    """Dot product 직접 구현 (정의 2.2)"""
    assert len(u) == len(v), "차원이 다른 Vector는 Dot product가 정의되지 않음"
    s = 0.0
    for i in range(len(u)):
        s += u[i] * v[i] # u_i v_i 누적합
    return float(s)

def my_cosine(u, v):
    """Cosine similarity 직접 구현 (정의 2.3, my_norm2·my_dot만 사용)"""
    nu = my_norm2(u)
    nv = my_norm2(v)
    assert nu > 0 and nv > 0, "영Vector는 Cosine similarity가 정의되지 않음"
```

```
        return my_dot(u, v) / (nu * nv)

# 검증
np.random.seed(0)
u = np.random.randn(10); v = np.random.randn(10)
assert np.isclose(my_norm2(u), np.linalg.norm(u), atol=1e-8)
assert np.isclose(my_dot(u, v), float(u @ v), atol=1e-8)
ref_cos = (u @ v) / (np.linalg.norm(u) * np.linalg.norm(v))
assert np.isclose(my_cosine(u, v), ref_cos, atol=1e-8)
print("OK: Norm·Dot·Cosine 검증 통과")
```

검증 결과: **OK: Norm·Dot·Cosine 검증 통과** 출력. 본 회차 정의 2.1·2.2·2.3을 그대로 코드로 옮긴 구현이다.

문제 2 답안 (Cosine similarity 검색)

```
from sklearn.datasets import load_digits
import numpy as np

X, y = load_digits(return_X_y=True)

# TODO 1: 숫자 7·1 각각 10장 평균 Vector m7, m1 (Linear combination, 1회차 도구)
# m7 = (1/10) sum_{i=1..10} x_i (계수 균등 Linear combination)
m7 = X[y == 7][:10].mean(axis=0) # shape (64,)
m1 = X[y == 1][:10].mean(axis=0) # shape (64,)

# TODO 2: 새 이미지 한 장 x_new 추출 (예: y==7 11번째)
x_new = X[y == 7][10] # 학습에 쓰지 않은 11번째 7 이미지

# TODO 3: Cosine similarity 두 개 계산 (정의 2.3)
def cosine(a, b):
    return float(a @ b) / (np.linalg.norm(a) * np.linalg.norm(b))

cos7 = cosine(x_new, m7)
cos1 = cosine(x_new, m1)

print(f"cos(x_new, m7) = {cos7:.4f}")
print(f"cos(x_new, m1) = {cos1:.4f}")
```



```
print("후보 클래스:", 7 if cos7 > cos1 else 1)
```

예상 결과: $\cos(x_{\text{new}}, m7)$ 가 $\cos(x_{\text{new}}, m1)$ 보다 큰 값으로 나오고 후보 클래스로 7이 출력된다. 본 회차 Cosine similarity가 곧 "방향이 얼마나 비슷한가"의 척도이며, 같은 클래스 평균 Vector와 새 이미지 사이의 각도가 다른 클래스 평균과의 각도보다 작기 때문이다. 본 절차는 다음 회차 Matrix·Vector 곱으로 일반화되면 가장 단순한 nearest-mean classifier가 된다.

자기 점검 체크리스트 답안

- Norm의 세 성질 — 양정성·동차성·삼각부등식. $\mathbb{R}^n$ 에서 양정성은 문제 1 (a), 동차성은 문제 2 (c) 계산, 삼각부등식은 Cauchy-Schwarz inequality에서 도출(증명은 5회차 또는 자율 학습).
- Cauchy-Schwarz inequality 판별식 풀이 증명 — 문제 3 (a)에서 시작 가정 $\|\mathbf{u} - t\mathbf{v}\|_2^2 \geq 0$ 부터 판별식 $D \leq 0$ 까지의 흐름을 손으로 재현할 수 있다.
- Dot product 값과 Cosine similarity 값의 차이 — 문제 2 (d)의 한 문장 그대로.
- 코딩 진행 시 Cosine similarity 검증 — 문제 1 코드 마지막 `print("OK: ...")` 출력 확인.

다음 회차로 가져갈 질문 안내

본 회차의 Norm·Dot product는 두 Vector 사이의 관계를 다룬다. 다음 회차에서 여러 Vector를 한 객체 Matrix로 묶고, Matrix·Vector 곱 $A\mathbf{x}$ 를 Row picture와 Column picture 두 해석으로 도입한다. Column picture는 1회차에서 본 Linear combination의 직접 연속이다.