# 인공지능 전공자를 위한 선형대수학

## 0 회차 · Introduction

SW·AI 융합대학원 · Part 1·2·3·4 ( 총 28 회차 )

메인 교재 : MML (Deisenroth·Faisal·Ong, *Mathematics for Machine Learning*) · 발췌 : Strang, *Introduction to Linear Algebra* · 시각 : 3Blue1Brown EoLA

**시각 보조 (EoLA):** Essence of Linear Algebra: Preview · 전 과정의 기하적 직관을 한눈에 보여주는 3Blue1Brown 시리즈 개요 .

# 본 회차 학습 목표

이번 회차가 끝나면 학생은 다음을 답할 수 있어야 합니다 .

**왜** AI 대학원에서 Linear Algebra( 선형대수 ) 를 한 학기 다시 배우는지

**무엇을** 28 회차 동안 배우는지 : 수학적 흐름과 CS/AI 흐름의 큰 그림

**어떻게** 배우는지 : MML( 메인 ) / Strang( 발췌 ) / EoLA / NumPy 의 4 단 운영

**결과** : 이 강의를 마치면 어떤 능력이 생기는지

1.한 Definition( 정의 ) 이 코드 한 줄과 그림 한 장으로 어떻게 이어지는지 ( 시그니처 예제 )

# 본 회차 핵심 질문

**수학 정의 한 줄이 어떻게 AI 모델 한 줄이 됩니까 ?**

이 한 질문에 28 회차에 걸쳐 답합니다 .

**본 회차 부분 답** : 가장 단순한 정의 (Vector( 벡터 ) 의 평균 ) 한 줄이 **MNIST 숫자 분류**까지 곧장 이어집니다 (G 시그니처 ).

**학기 전체의 답** : $\mathrm{softmax}(QK^{T}/\sqrt{d_k})V$, Transformer Attention( 어텐션 ) 한 줄을 LA 객체로 완전 분해합니다 (Part 4 7 회차 ).

매 회차 첫 슬라이드에 해당 회차의 핵심 질문이 있습니다 . 강의 중 길을 잃으면 이 한 질문으로 돌아옵니다 .

# 본 회차 수업 흐름

| 순서 | 블록 | 내용 |
|---|---|---|
| ① | A | 오프닝 : 핵심 질문 , 강의 소개 , 전제 |
| ② | B | 왜 Linear Algebra 인가 : 네 가지 동기 |
| ③ | C | 수학적 흐름의 큰 그림 |
| ④ | D | CS·AI 흐름 |
| ⑤ | E | 교재 운용 : MML ( 메인 ) / Strang ( 발췌 ) / EoLA ( 시각 ) |
| ⑥ | F | 이수 후 능력 점검표 |
| ⑦ | G | 시그니처 예제 : MNIST 평균 이미지 |
| ⑧ | H | 클로징 : 1 회차로 가져갈 마무리 문제 , 사전 reading |

**순서의 의미** : 수학 흐름 → CS 흐름 → 두 흐름이 만나는 한 예제 ( 평균 이미지 ) 로 마무리합니다 .

본 회차는 첫 회차이므로 Review 가 없습니다 . 다음 회차부터 표준 사이클 ( 핵심 질문 → Review → 본 강의 → 마무리 문제 → 숙제 ) 을 운영합니다 .

# A-1. 교과 정보

**과목명** : Linear Algebra Part 1 (LA1, 8 회차 ) / Part 2 (LA2, 9 회차 ) / Part 3 (Vector Calculus·Probability, 4 회차 ) / Part 4 (ML·AI 응용 , 7 회차 )

**대상** : SW·AI 융합대학원 1 학년 , **학부 LA 미이수 학생** 표준

**운영** : 총 28 회차 , 1 회차 2 시간 × 28 = 56 시간

**메인 교재** : Deisenroth·Faisal·Ong, *Mathematics for Machine Learning* (MML, 무료 공식 PDF 공개 )

**발췌 교재** : Gilbert Strang, *Introduction to Linear Algebra* (6th ed.), 시그니처 10 개 자산을 본문 발췌 박스로 사용 (Row·Column picture·Cauchy-Schwarz 판별식 ·Elementary matrix·LU·4 fundamental subspaces·Least squares·Gram-Schmidt·Determinant 기하 ·Eigenvalue 응용 ·SVD 기하 ·Eckart-Young)

**시각 보조** : 3Blue1Brown *Essence of Linear Algebra* (EoLA)

# A-2. 운영 방식

| 항목 | 운영 |
| --- | --- |
| 출석 | 자율 ( 대학원생 자체 강의 ) |
| 과제 | 매 회차 수학 문제 , Jupyter 노트북 |
| 코딩 실습 (Google Colab) | 매 회차 필수 X. 회차별 학습 가치에 따라 1-2 개 또는 그 이상으로 운영 . 필요 없으면 수학 정리 · 풀이로 마무리 |
| 종합 문제 풀기 | Part 1 8 회차 ·Part 2 9 회차 ·Part 3 4 회차 ·Part 4 7 회차 마지막에 사전 공개 → 자율 풀이 |

(" 종합 문제 풀기 " 는 각 Part **마지막 회차 전에 사전 공개 → 본인 페이스로 자율 풀이 → 마지막 회차에 함께 Review** 형식의 자기 점검 활동입니다 .)

학부 LA 이수자는 Part 1·2 전반부를 빠르게 통과하고 Part 3·4 응용 부분에 집중합니다 ( 별도 안내 ).

# A-3. 전제 가정

다음은 들어와 있다는 가정으로 진행합니다 .

- 미적분학 · 이산수학 · 확률 기초 ( 학부 또는 자기학습 )
- Python · NumPy 사용 가능
- PyTorch 는 처음이어도 학습 의지

학부 LA 미이수 학생을 표준으로 한 강의입니다 . Part 1·2 에서 Definition·Theorem( 정리 ) 을 천천히 다지고 Part 3·4 에서 응용으로 가속합니다 .

# B-1. 동기 1: AI 논문 한 줄을 읽으려면

다음은 LLM 표준 논문의 한 문장입니다 .

> "Self-attention computes softmax($QK^T$ / $\sqrt{d_k}$)V, where Q, K, V ∈ $\mathbb{R}^{nxd}$."

이 한 줄을 이해하려면 알아야 하는 것 :

$\mathbb{R}^{nxd}$ → **Vector space( 벡터공간 )·Dimension( 차원 )** (6·8 회차 )

$QK^T$ → **모든 쌍의 Inner product( 내적 )** (2 회차 )

$\sqrt{d_k}$ 로 나누는 이유 → **Vector Norm( 노름 ) 의 정규화** (2 회차 )

softmax 후 V → **Matrix( 행렬 )·Vector 곱의 두 해석** (3 회차 )

**직관** : 이 한 줄은 **다섯 핵심 객체 (Vector space·Inner product·Norm·Matrix·Vector 곱 )** 의 구성도 한 장과 같습니다 . 본 회차에서 식 전부를 이해할 필요는 없고 , 다섯 객체가 식의 어느 자리에 위치하는지 ($QK$ softmax $V$) 만 확인하면 됩니다 . 28 회차에 걸쳐 한 객체씩 정식 도입합니다 .

# B-2. 동기 2·3: 데이터는 Matrix, 선형 근사가 비선형을 다룹니다

### 동기 2: 데이터는 Matrix 입니다

| 데이터 | LA 객체 |
|---|---|
| 이미지 (28×28) | $\mathbb{R}^{784}$ Vector |
| 문서 (BERT) | $\mathbb{R}^{768}$ Vector |
| 사용자 × 영화 평점 | $\mathbb{R}^{n \times m}$ Matrix |
| 신경망 한 층 | 가중치 Matrix W + bias b |

### 동기 3: 선형 근사가 비선형 세계를 다룹니다

f 가 미분가능하면 $x_0$ 근방에서

$$f(\mathbf{x}_0 + \mathbf{h}) \approx f(\mathbf{x}_0) + J(\mathbf{x}_0)\,\mathbf{h}$$



연기선 나는 Jacobian( 자코비안 ) 한 Matrix, Backpropagation( 역전파 ) 은 이 식의 반복입니다

# B-3. 동기 4: Decomposition( 분해 ) 으로 구조를 본다

**Matrix Decomposition 의 의미** : 복잡해 보이는 Matrix A 를 구조가 단순한 Matrix 들의 곱 ( 예 : 삼각 · 직교 · 대각 ) 으로 표현하면 , 각 단순 Matrix 가 담당하는 작용 ( 소거 · 회전 · 신축 ) 이 분리되어 드러납니다 . 이렇게 분리된 표현이 곧 Decomposition 입니다 .

| Decomposition | 구조 | 회차 |
|---|---|---|
| $A = LU$ | 하 · 상삼각 | 5 |
| $A = QR$ | 직교 , 상삼각 | Part 2 3 |
| $A = Q\Lambda Q^T$ | 대칭 → 회전 · 신축 | Part 2 5-6 |
| $A = U\Sigma V^T$ (SVD) | 임의 Matrix → 회전 · 신축 · 회전 | Part 2 8-9 |

# C. 수학적 흐름의 큰 그림

"Definition → Theorem → Decomposition → Application( 응용 )" 사이클이 매 회차 반복됩니다 .

매 회차가 다음 네 단계 안에 위치합니다 .

| 단계 | 이름 | 의미 | 예 |
|---|---|---|---|
| ① | Definition | " 이것을 [ 이름 ] 이라 부른다 " | Vector, Norm, Subspace( 부분공간 ) |
| ② | Theorem | " 정의에서 어떤 성질이 따라오는가 " | Cauchy-Schwarz, Dimension Theorem |

# C-1. 4 단 사고 구조 ( 계속 )

| 단계 | 이름 | 의미 | 예 |
|---|---|---|---|
| ③ | Decomposition· 구조 | " 복잡한 객체를 단순한 객체의 합 · 곱으로 " | LU, QR, SVD |
| ④ | Application | " 분해된 구조가 AI 모델에서 어떻게 등장하는가 " | PCA, 회귀 , Attention |

# C-1. 4 단 사고 구조 : 사이클의 의미

**4 단 사이클의 의미** : ① 객체에 이름을 부여 (Definition) → ② 이름으로부터 따라오는 성질 진술 (Theorem) → ③ 복잡한 객체를 단순 객체의 합 · 곱으로 표현 (Decomposition) → ④ 분해된 구조를 AI 모델 안에서 식별 (Application). Definition 이 다른 모든 단계의 출발점입니다 .

# C-2. 수학적 흐름의 5 대 줄기

| 줄기 | 주제 | 의미 | 회차 |
|---|---|---|---|
| 1 | Vector · Matrix | 객체의 정의 | 1·3 |
| 2 | Linear equation ( 선형방정식 ) Ax=b | 연산의 의미 | 4·5 |
| 3 | Space ( 공간 ) | Subspace · Basis( 기저 ) · Dimension | 6·7·8 |
| 4 | Orthogonality( 직교성 ) · Projection( 정사영 ) | 거리 · 각도의 분해 | Part 2 1·2·3 |
| 5 | Decomposition | Determinant( 행렬식 ) · Eigenvalue( 고윳값 ) · SVD | Part 2 4-9 · Part 3·4 전체 |

**Part 1**: 1~3 번 줄기를 단단히 다집니다 (LA1).

**Part 2**: 4 번 줄기와 5 번 줄기 전반부 (LA2, 직교성 · 정사영 · 분해 ).

**Part 3·4**: 미적분 · 확률 · 최적화 도구와 AI 응용으로 나아갑니다 .

# C-3. Part 1 (LA1) 흐름 : 방정식과 공간

| 회차 | 주제 (MML §·Strang Ch 발췌 ) | 단계 |
|---|---|---|
| 1-3 | Vector · Norm · Inner product · Matrix·Vector 곱 (MML §2.1-§2.2·§3.1-§3.4 / Strang Ch 1) | ①·② 토대 |
| 4-5 | Gauss 소거 · 행렬곱 · 역행렬 · LU (MML §2.3 / Strang Ch 2) | ② 풀이 , ③ 첫 분해 |
| 6-7 | Vector space · Subspace · Column space · Rank · 4 fundamental subspaces 도입 (MML §2.4-§2.6 일부 / Strang Ch 3.1-3.4) | ② 구조 · 골격 |
| 8 | Linear independence · Basis · Dimension · 4 fundamental subspaces 정식 , Part 1 종합 문제 풀기 (MML §2.5-§2.6 / Strang Ch 3.4-3.5) | ② 정점 · 종합 |

**핵심 명제** : Ax = b 의 해는 **A 의 4 fundamental subspaces** 로 완전히 결정됩니다 . Part 1 8 회차에서 이 정리가 완성됩니다 .

# C-4. Part 2 (LA2) 흐름 : 직교성과 분해

| 회차 | 주제 (MML §·Strang Ch 발췌 ) | 단계 |
|---|---|---|
| 1 | Orthogonality · Projection (MML §3.6·§3.8 / Strang Ch 4.1-4.2) | ②·③ |
| 2 | Least squares · 정규방정식 · 다중공선성 (MML §3.8 / Strang Ch 4.3) | ③·④ 회귀 |
| 3 | Orthonormal basis · Gram-Schmidt · QR · Rotation (MML §3.5·§3.9 / Strang Ch 4.4) | ③·④ |
| 4 | Determinant (MML §4.1 / Strang Ch 5) | ② 종합 도구 |

# C-4. Part 2 (LA2) 흐름 : 직교성과 분해 ( 계속 )

| 회차 | 주제 (MML §·Strang Ch 발췌 ) | 단계 |
|---|---|---|
| 5-6 | Eigenvalue · Diagonalization · Spectral theorem (MML §4.2·§4.4 / Strang Ch 6.1-6.4) | ③ 정사각 분해 |
| 7 | Positive definite · 이차형식 · Cholesky (MML §4.3 / Strang Ch 6.5) | ③ |
| 8 | SVD 정식 · 기하 해석 (MML §4.5 / Strang Ch 7.1-7.2) | ③ 임의 분해 |
| 9 | Eckart-Young · Matrix Approx · Linear Transformation (MML §4.6·§2.7·§2.8 / Strang Ch 7.3-7.4), Part 2 종합 문제 풀기 | ③·④ 압축 , 종합 |

# C-5. Part 3 흐름 : 벡터 미적분과 확률 (VC + Probability)

| 회차 | 주제 (MML §) | 단계 |
|---|---|---|
| 1 | Vector Calculus 1 (Jacobian · Hessian · Chain rule) (MML §5.1-§5.5) | ④ 신경망 미분 |
| 2 | Vector Calculus 2 (Newton · Backprop 수학 ) (MML §5.6-§5.8) | ④ |
| 3 | Probability · MLE · KL divergence · Cross entropy · MVN (MML §6·§8.3) | ④ LLM·VAE 수학 |
| 4 | Continuous Optimization (Convex · Lagrange · KKT) (MML §7.1-§7.3), Part 3 종합 문제 풀기 | ④ 옵티마이저 · 정규화 , 종합 |

# C-6. Part 4 흐름 : ML 및 AI 의 수학적 응용

| 회차 | 주제 | 단계 |
|---|---|---|
| 1 | Linear Regression (MML Ch 9) | ⑤ ML 응용 |
| 2 | PCA · SVD 동치 (MML Ch 10) | ⑤ |
| 3 | Gaussian Mixture Models · EM (MML Ch 11) | ⑤ |
| 4 | SVM Hard/Soft margin · Hinge · Dual (MML §12.1-§12.3) | ⑤ |
| 5 | Kernel SVM · Kernel trick · RBF · Poly (MML §12.4-§12.5) | ⑤ |
| 6 | CNN · 1D Conv → Toeplitz · 1×1= 행렬곱 ( 자체 교안 ) | ④ 모델 분해 |
| 7 | Attention 분해 · Embedding= 행렬곱 · Multi-head 직관 + Equivariance 직관 한 슬라이드 , Part 4 종합 문제 Review ( 자체 교안 ) | ④ 모델 분해 , 종합 |

**핵심 명제** : 어떤 Matrix 도 **SVD 로 회전 · 신축 · 회전으로 분해**됩니다 . 그 위에 미분 · 확률 · 최적화 도구를 쌓아 **임의 AI 모듈을 선형대수 객체로 환원**할 수 있습니다 .

# D. CS·AI 흐름

수학 5 대 줄기가 컴퓨터와 AI 에서 어디에 등장하는지를 봅니다 .

| CS·AI 객체 | LA 환원 | 회차 |
|---|---|---|
| 이미지 · 텍스트 · 사용자 | $\mathbb{R}^d$ Vector | 1 |
| 데이터셋 (n 개 샘플 ) | $\mathbb{R}^{nxd}$ Matrix | 3 |
| 신경망 한 층 | $x \mapsto Wx + b$ | 3·6 |
| 손실 함수의 미분 | Jacobian / Hessian | Part 3 1-2 |
| 학습 = 최소화 | Least squares · 정규방정식 | Part 2 2 |
| 추론 = Matrix 곱 누적 | BLAS · GPU 병렬화 | 3 |
| 모델 압축 ·Quantization( 양자화 ) | Low-rank Decomposition (SVD·LoRA) | Part 2 8-9 |

# D-2. AI 모델 안의 LA 객체

Transformer 한 블록의 입력 → 출력 흐름 :

| 단계 | 식 | LA 객체 | 회차 |
|---|---|---|---|
| 입력 | $x \in \mathbb{R}^d$ | Vector | 1 |
| Embedding ( 임베딩 ) | $Ex$ | Matrix·Vector 곱 | 3 |
| Attention | $\mathrm{softmax}(QK^T/\sqrt{d})V$ | 모든 쌍의 Inner product | 2 · Part 4 7 |
| FFN | $W_2\,\mathrm{ReLU}(W_1x+b_1)+b_2$ | affine 변환 | 6 |
| 출력 | $\mathrm{softmax}(\cdots)$ | 확률 Vector | · |

각 작업 단계가 회차별 주제와 일대일로 대응합니다 .

# D-3. Decomposition 이 AI 를 만듭니다

| 응용 | Decomposition | 의미 |
|---|---|---|
| PCA ( 차원 축소 ) | SVD / Eigenvalue Decomposition | " 주된 방향 " 만 남깁니다 |
| 회귀 ( 선형 모델 ) | $A^T A$ 풀이 (QR) | " 데이터를 가장 잘 설명하는 선 " |
| LoRA (LLM 효율 미세조정 ) | rank-r Low-rank 근사 | "W 의 변화량을 r- 차원으로 " |
| 추천 시스템 | Matrix Decomposition | " 사용자 · 아이템의 공통 잠재 요인 " |
| 이미지 압축 ·JPEG·MP3 | DCT ( 직교 분해 ) | " 주파수별 에너지 누적 " |
| Whitening · BatchNorm | 공분산 Diagonalization | " 축마다 분산 1 로 " |

Decomposition 이 AI 의 절반입니다 . 이 강의 후반부가 다 이 표 안에 있습니다 .

# E-1. 4 단 운영 모델

| 자료 | 위상 | 사용 시점 | 비유 |
|---|---|---|---|
| MML | 메인 | 정의 · 정리 · 예제 ·ML 응용 (LR·PCA·GMM·SVM) | 지도 |
| Strang | 발췌 | 시그니처 자산 10 개를 본문 발췌 박스로 사용 | 명소 사진첩 |
| 3Blue1Brown | 시각 | 사전 시청 | 위성사진 |
| NumPy / PyTorch | 실습 | 매 회차 ipynb | 탐사 장비 |

**왜 MML 이 메인입니까 ?**

- MML 은 LA 표준 (Vector·Matrix·Linear equation·Subspace·Determinant) 외에도 Vector Calculus·Probability·Optimization·ML 4 대 응용 (LR·PCA·GMM·SVM) 을 한 권에 담아 본 강의의 Part 1·2·3·4 를 모두 커버합니다 .
- 무료 공식 PDF 가 공개되어 있어 학생 모두가 동일 텍스트로 접근할 수 있습니다 .

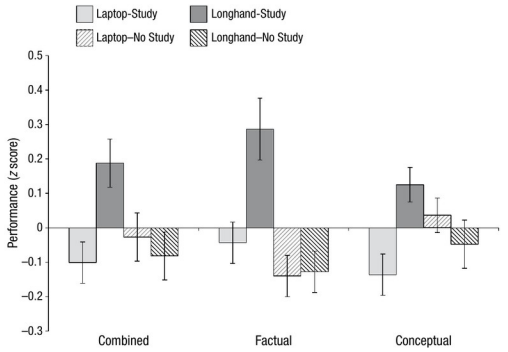
# E-2. 매 회차 reading 패턴

회차 시작 24 시간 전 :
① MML 해당 절 본문 + 예제 ( 메인 )
② Strang 해당 절 발췌 ( 시그니처 자산 회차에 한정 )
③ 3Blue1Brown EoLA 해당 편 1 편

회차 종료 직후 :
④ 강의교안 (07/Part1/N 회차 _*.md) 다시 읽기
⑤ 회차 ipynb (11/Part1/N_*.ipynb) 실행
⑥ 과제 (04_ 과제 /Part1/N 회차 _homework.md) 착수

**24 시간 전 · 직후의 2 회 노출**이 누적 학습 정착의 결정 변수입니다 .

# E-3. 왜 눈이 아니라 손으로 풀어야 합니까




수학은 눈으로 읽으면 아는 것 같고 , **손으로 써서 풀어야 합니다 .**

정의 · 정리는 읽으면 이해된 듯하지만 , 증명을 손으로 따라 쓰고 예제를 직접 계산할 때 개념이 내 것이 됩니다 . 학습과학의 두 계열 증거가 이를 뒷받침합니다 .

**인지심리** : 손글씨 집단이 타이핑보다 **개념 이해 · 적용**에서 일관되게 우세 ( 그림 참고 ). 느린 손글씨가 받아쓰기 ( 얕은 처리 ) 대신 스스로 **요약 · 재구성**하는 생성적 처리를 강제하기 때문입니다 .

# F-1. Part 1 (LA1) 종료 시 (8 회차 후 )

학생은 다음을 할 수 있습니다 .

- [ ] Vector·Matrix·Linear equation Definition 을 정확히 진술하고 손계산할 수 있습니다 .

[ ] Ax = b 의 해 존재 · 유일성을 **4 기본 Subspace** 로 판별할 수 있습니다 .

- [ ] LU Decomposition 을 정의대로 직접 구현할 수 있습니다 .
- [ ] Subspace · Column space · Null space · Rank 의 Definition·Theorem 을 진술할 수 있습니다 .
- [ ] Linear independence · Basis · Dimension · Rank-nullity 정리를 직접 적용할 수 있습니다 .

# F-2. Part 2 (LA2) 종료 시 (9 회차 후 )

- [ ] Orthogonality · Projection · 직교 여공간의 Definition·Theorem 을 진술할 수 있습니다 .

[ ] 정규방정식 $A^T A\hat{\beta} = A^T b$ 로 회귀를 풀 수 있습니다 .

- [ ] Gram-Schmidt·QR Decomposition 을 직접 구현할 수 있습니다 .
- [ ] Determinant 의 정의 · 계산법을 자유롭게 사용할 수 있습니다 .
- [ ] Eigenvalue Decomposition · SVD 의 Definition· 계산법을 자유롭게 사용할 수 있습니다 .

[ ] PCA·Low-rank 근사를 SVD 로 **한 줄에 구현**할 수 있습니다 .

# F-3. Part 3 (VC + Probability) 종료 시 (4 회차 후 )

- [ ] Jacobian·Hessian 으로 신경망 한 층의 미분을 분해할 수 있습니다 .
- [ ] MLE·KL divergence·Cross entropy·MVN 을 자유롭게 다룰 수 있습니다 .
- [ ] Convex·Lagrange·KKT 조건으로 제약 최적화를 풀 수 있습니다 .

# F-4. Part 4 (ML·AI 응용 ) 종료 시 (7 회차 후 )

- [ ] Linear Regression·PCA·GMM·SVM (Kernel 포함 ) 을 LA· 미분 · 확률 도구로 환원해 설명할 수 있습니다 .
- [ ] CNN convolution 을 1D Toeplitz matrix 로 환원하고 1×1 convolution 이 일반 행렬곱임을 설명할 수 있습니다 .

[ ] **Attention softmax($QK^T/\sqrt{d_k}$)V 를 LA 객체로 분해**하고 Embedding 이 행렬곱임을 설명할 수 있습니다 . Equivariance( 등변성 )·Multi-head 의 직관도 한 줄로 정리할 수 있습니다 .

- [ ] 임의의 AI 모델 한 부분을 골라 LA 객체로 환원 · 분해해 설명할 수 있습니다 .

# F-5. 시그니처 능력 : " 수학 → 코드 → 분해 보고 "

| 단계 | 내용 |
|---|---|
| 1 | 논문에서 식을 봅니다 |
| 2 | Definition·Theorem 으로 분해합니다 (" 이건 SVD 다 ", " 이건 4 Subspace 다 ") |
| 3 | NumPy / PyTorch 로 한 줄씩 구현합니다 |
| 4 | 실제 데이터에서 검증합니다 |
| 5 | 보고서로 정리합니다 |

LLM 시대에 LA 를 **다시 배우는 이유** : 라이브러리 호출 한 줄 안에 무엇이 들어 있는지 **알면서 부르는** 사람이 되기 위해서입니다 .

# G. 시그니처 예제 : 손글씨 "7" 의 평균은 어떻게 생겼을까요

지금까지의 수학·CS 흐름이 **가장 친숙한 한 예제**에 모이는 지점입니다 .

손글씨 숫자 데이터 (MNIST) 에서 **숫자 "7" 이라고 적힌 모든 이미지를 평균내면** 어떤 그림이 나올까요 ?

| 직관 후보 | 결과 |
|---|---|
| ( 가 ) 무의미한 잡음 ? | ❌ |
| ( 나 ) 한 사람의 7 만 보임 ? | ❌ |
| ( 다 ) 흐릿한 평균 7 모양 | ✅ |

**직관 ( 표본평균의 의미 )**: n 개 표본 Vector 의 산술평균은 각 표본의 개별 편차가 상쇄되고 공통 성분만 남는다 .
손글씨 7 이미지들의 평균에는 한 사람의 필체가 아니라 모든 표본에 공통된 7 의 형태가 남는다 .

# G-2. 한 줄의 수학

이미지 한 장을 **Vector** $x_i \in \mathbb{R}^{784}$ (28×28 픽셀 ) 로 봅니다 (1 회차 ).

숫자 "7" 인 모든 이미지를 모은 집합 $\{x_1, x_2, \ldots, x_n\}$ 의 **Vector 평균** :

$$\mathbf{m} = \frac{1}{n} \sum_{i=1}^{n} \mathbf{x}_i \in \mathbb{R}^{784}$$

이 식에 담긴 1 회차 내용 :

- " 이미지를 Vector 로 본다 ": Vector 의 Definition
- "Vector 들을 더한다 ": Vector 덧셈

"1/n 을 곱한다 ": Scalar( 스칼라 ) 곱

# G-3. 코드 : 단 한 줄

```
mean_seven = X[y == 7].mean(axis=0).reshape(28, 28)
plt.imshow(mean_seven, cmap='gray')
```

- 수학 정의 1 줄 → 코드 1 줄 → 그림 1 장

이것이 **이 강의 모든 회차의 표준 사이클**입니다

→ 노트북 Colab으로 실행를 함께 실행합니다 .

# G-4. 본 예제에 들어 있는 28 회차의 지점

| 예제의 부분 | 회차 |
|---|---|
| 이미지를 Vector 로 보기 ($\mathbb{R}^{784}$) | 1 |
| Vector 덧셈 ·Scalar 곱 ( 평균 연산 ) | 1 |
| 데이터셋을 Matrix 로 ($\mathbb{R}^{nx784}$) | 3 |
| 평균 Vector· 중심화 ( 데이터의 " 원점 ") | 7 · Part 4 2 |
| 평균을 빼고 본 분산의 주방향 (PCA) | Part 4 2 |
| 분류기로 확장 ( 가장 가까운 평균 ⇒ 클래스 ) | 2 · Part 2 2 |

가장 단순한 수학 (Vector 평균 ) 한 줄이 **28 회차 전체의 입구**입니다 .

# G-5. 노트북에서 봅니다 : 실행 흐름

MNIST 손글씨 로드 (sklearn `fetch_openml`, 28×28): Matrix $X \in \mathbb{R}^{70000 \times 784}$, 레이블 y

한 장을 Vector 로 : `X[0].shape == (784,)` 확인 (1 회차 )

**0~9 각 숫자의 평균 이미지 계산** : `X[y==k].mean(axis=0)` (1 회차 )

1.시각화 : 10 개 평균이 또렷한 0, 1, ..., 9 모양으로 보입니다 .

**응용 한 줄** : 가장 가까운 평균으로 분류만 해도 80% 안팎 ( 거리 · 분류의 정식 정의는 2 회차 ).

# H. 1 회차 사전 reading 안내

**1 회차 주제** : Vector · Linear combination( 선형결합 ) · Span( 생성공간 ), MML §2.1 도입

본 회차에서 본 평균 이미지 예제의 토대로 **Vector 의 Definition·$\mathbb{R}^n$·Linear combination** 을 1 회차에 정식 수학으로 맞춥니다 .

**Norm·Inner product·Cosine similarity 는 2 회차** (MML §3.1-§3.4), Cauchy-Schwarz 까지의 흐름은 2 회차에서 다룹니다 .

# H. 1 회차 사전 reading 안내 ( 계속 )

### 1 회차 시작 24 시간 전까지

[ ] **MML** §2.1 (Vectors): 메인 reading

[ ] **3Blue1Brown EoLA** Ch.1 (Vectors), Ch.2 (Linear combinations, span, basis): 시각 사전 시청

[ ] ( 선택 ) **Strang** Ch 1.1 발췌 : Vector 직관 , 평행사변형 법칙 그림 참조

### 0 회차 종료 후 권장

본 회차에서 본 평균 이미지 예제을 00_Introduction_ 평균이미지 .ipynb 에서 **다른 숫자 ( 예 : 4·8) 로 재실행**해보세요 .

- 어색한 부분을 1 회차 강의에서 질문할 수 있도록 준비합니다 .

# 본 회차 마무리 문제

**본 회차 핵심 질문** : " 수학 정의 한 줄이 어떻게 AI 모델 한 줄이 됩니까 ?"

본 회차에서는 **Vector 의 평균**이라는 가장 단순한 예로 일부 답을 다루었습니다 .

## 1 회차 시작 전 풀어볼 3 문제

본 회차에서 본 핵심 객체 (Vector·Linear combination· 평균 Vector) 만으로 답할 수 있는 두 문제입니다 .

**(a) ( 평균 Vector 표기 )** MNIST 에서 숫자 "7" 인 이미지 n 장 $x_1, \dots, x_n \in \mathbb{R}^{784}$ 이 주어졌다고 하자 . 그 평균 이미지 m 을 **Vector( 벡터 )·Linear combination( 선형결합 )** 두 단어를 모두 사용해 한 줄로 표기하시오 . (Σ 기호 사용 가능 )

# 마무리 문제 운영 원칙 ( 안내 )

매 회차 다음 4 단 사이클로 운영합니다 .

| 단계 | 시점 | 내용 |
|---|---|---|
| ① 핵심 질문 | 회차 시작 ( 오프닝 ) | 해당 회차의 한 질문 |
| ② Review | 회차 시작 (10 분 ) | 지난 차시 숙제 풀이 |
| ③ 본 강의 | 회차 중반 | Definition·Theorem· 유제 |
| ④ 마무리 문제 , 숙제 | 회차 끝 (15 분 ) | 즉석 풀이 , 유사 문제 → 다음 회차 Review 재료 |

본 회차 (0 회차 ) 는 ④의 첫 출발입니다 . 위 문제가 **1 회차 시작 시 Review 문제**가 됩니다 .

# Q & A

본 회차는  Definition· 증명 없이 큰 그림만 다루었습니다 .

**다음 회차부터 본격 수학을 시작합니다 .**

HANDOUT:  본  PDF + 00_Introduction_ 평균이미지 .ipynb