

인공지능 전공자를 위한 선형대수학

0회차 · Introduction

SW·AI 융합대학원 · Part 1·2·3 (총 32회차)

메인 교재: Strang, *Introduction to Linear Algebra* · 보조: MML (Deisenroth et al.) · 시각: 3Blue1Brown EoLA

오늘 회차 학습 목표

이번 회차가 끝나면 학생은 다음을 답할 수 있어야 합니다.

1. 왜 AI 대학원에서 Linear Algebra(선형대수)를 한 학기 다시 배우는지
2. 무엇을 32회차 동안 배우는지 — 수학적 흐름과 CS/AI 흐름의 큰 그림
3. 어떻게 배우는지 — Strang / MML / EoLA / NumPy의 4단 운영
4. 결과 — 이 강의를 마치면 어떤 능력이 생기는지
5. 한 Definition(정의)이 코드 한 줄과 그림 한 장으로 어떻게 이어지는지 (시그니처 예제)

오늘의 핵심 질문

수학 정의 한 줄이 어떻게 AI 모델 한 줄이 됩니까?

이 한 질문에 32회차에 걸쳐 답합니다.

- **오늘의 부분 답:** 가장 단순한 정의(Vector(벡터)의 평균) 한 줄이 **MNIST** 숫자 분류까지 곧장 이어집니다 (G 시그니처).
- **학기 전체의 답:** $\text{softmax}(QK^\top / \sqrt{d_k})V$ — Transformer Attention(어텐션) 한 줄을 LA 객체로 완전 분해합니다 (Part 3 7회차).

매 회차 첫 슬라이드에 그날의 핵심 질문이 있습니다. 강의 중 길을 잃으면 이 한 질문으로 돌아옵니다.

오늘 수업 흐름

순서	블록	내용
①	A	오프닝 — 핵심 질문 + 강의 소개 · 평가 · 전제
②	B	왜 Linear Algebra인가 — 네 가지 동기
③	C	수학적 흐름의 큰 그림
④	D	CS·AI 흐름
⑤	E	교재 운용 — Strang (메인) / MML (보조·확장) / EoLA (시각)
⑥	F	이수 후 능력 점검표
⑦	G	시그니처 시연 — MNIST 평균 이미지
⑧	H	클로징 — 1회차로 가져갈 마무리 문제 + 사전 reading

순서의 의미: 수학 흐름 → CS 흐름 → 두 흐름이 만나는 한 예제(평균 이미지)로 마무리합니다.
오늘은 첫 회차이므로 Review가 없습니다. 다음 회차부터 표준 사이클(핵심 질문 → Review → 본 강의 → 마무리 문제 → 숙제)을 운영합니다.

A-1. 교과 정보

- 과목명: Linear Algebra Part 1 (13회차) / Part 2 (10회차) / Part 3 (9회차)
- 대상: SW·AI 융합대학원 1학년 · 학부 LA 미이수 학생 표준
- 운영: 총 32회차
- 메인 교재: Gilbert Strang, *Introduction to Linear Algebra* (6th ed.)
- 보조·확장 교재: Deisenroth·Faisal·Ong, *Mathematics for Machine Learning* (MML) — Strang 미수록 수학 (Vector Calculus·Probability·Optimization) + ML 응용 (LR·PCA·GMM·SVM)
- 시각 보조: 3Blue1Brown *Essence of Linear Algebra* (EoLA)

A-2. 평가 (Part별)

항목	비율	비고
출석	10%	0회차는 산정 X
과제	20%	매 회차 수학 + Jupyter
중간학습확인평가	30%	6회차, 지필
종합학습확인평가	40%	Part 1: 지필 60% + 실기 40% · Part 2·3: 지필 + Case Study

비고: 대학원생 자체 강의이므로 정식 시험이 아닌 학습 확인 목적의 평가다.

학부 LA 이수자는 Part 1 전반부를 빠르게 통과하고 응용 부분에 집중합니다 (별도 안내).

A-3. 전제 가정

다음은 들어와 있다는 가정으로 진행합니다.

- 미적분학 · 이산수학 · 확률 기초 (학부 또는 자기학습)
- Python · NumPy 사용 가능
- PyTorch는 처음이어도 학습 의지

학부 LA 미이수 학생을 표준으로 한 강의입니다 — Part 1 전반부에서 Definition·Theorem(정리)을 천천히 다지고 Part 2·3에서 응용으로 가속합니다.

B-1. 동기 1 — AI 논문 한 줄을 읽으려면

다음은 LLM 표준 논문의 한 문장입니다.

"Self-attention computes $\text{softmax}(QK^\top / \sqrt{d_k})V$, where $Q, K, V \in \mathbb{R}^{n \times d}$."

이 한 줄을 이해하려면 알아야 하는 것:

- $\mathbb{R}^{n \times d} \rightarrow$ **Vector space**(벡터공간)·**Dimension**(차원) (7·9회차)
- $QK^\top \rightarrow$ 모든 쌍의 **Inner product**(내적) (2회차)
- $\sqrt{d_k}$ 로 나누는 이유 $\rightarrow$ **Vector Norm**(노름)의 정규화 (2회차)
- softmax 후 $V \rightarrow$ **Matrix**(행렬)·**Vector** 곱의 두 해석 (3회차)

💡 파인만식 비유: 이 한 줄은 5층 건물의 청사진 한 장과 같습니다. 오늘 전부 이해할 필요는 없고, 각 층이 뭔지($QK \cdot \text{softmax} \cdot V$)만 알면 됩니다. 32회차에 걸쳐 한 층씩 들어가 봅니다.

B-2. 동기 2·3 — 데이터는 Matrix · 선형 근사가 비선형을 다룹니다

동기 2: 데이터는 Matrix입니다

데이터	LA 객체
이미지 (28×28)	$\mathbb{R}^{784}$ Vector
문서 (BERT)	$\mathbb{R}^{768}$ Vector
사용자×영화 평점	$\mathbb{R}^{n \times m}$ Matrix
신경망 한 층	가중치 Matrix W + bias $\mathbf{b}$

동기 3: 선형 근사가 비선형 세계를 다룹니다

f 가 미분가능하면 $\mathbf{x}_0$ 근방에서

$$f(\mathbf{x}_0 + \mathbf{h}) \approx f(\mathbf{x}_0) + J(\mathbf{x}_0) \mathbf{h}$$

여기서 J 는 Jacobian(자코비안) — 한 **Matrix**. Backpropagation(역전파)은 이 식의 반복입니다.

💡 파인만식 비유: 지구는 둥글지만 동네 마당은 평평하게 본다. 비선형 함수도 한 점 근방에서는 직선처럼 봐도 됩니다. 그 "한 점에서의 평평한 근사"가 곧 **Jacobian**입니다.

B-3. 동기 4 — Decomposition(분해)이 본질을 드러냅니다

💡 파인만식 비유: Decomposition은 카레의 재료 분리와 같습니다. 완성된 카레만 보면 복잡하지만, 양파·당근·고기·향신료로 분리하면 각 재료의 역할이 보입니다. Matrix도 마찬가지입니다 — 복잡해 보이는 Matrix를 단순한 Matrix의 곱으로 분리하면 본질이 드러납니다.

Decomposition	구조	회차
$A = LU$	하·상삼각	4
$A = QR$	직교 · 상삼각	11
$A = Q\Lambda Q^\top$	대칭 → 회전 + 신축	Part 2 1-4
$A = U\Sigma V^\top$ (SVD)	임의 Matrix → 회전+신축+회전	Part 2 5-6

C. 수학적 흐름의 큰 그림

"Definition → Theorem → Decomposition → Application(응용)" 사이클이 매 회차 반복됩니다.

C-1. 4단 사고 구조

매 회차가 다음 네 단계 안에 위치합니다.

단계	이름	의미	예
①	Definition	"이것을 [이름]이라 부른다"	Vector, Norm, Subspace(부분공간)
②	Theorem	"정의에서 어떤 성질이 따라오는가"	Cauchy-Schwarz, Dimension Theorem
③	Decomposition·구조	"복잡한 객체를 단순한 객체의 합·곱으로"	LU, QR, SVD
④	Application	"분해된 구조가 AI 모델에서 어떻게 등장하는가"	PCA, 회귀, Attention

💡 파인만식 비유: ① 재료 이름 익히기 → ② 재료의 성질 알기 → ③ 요리(분해) 기법 배우기 → ④ 실제 식당 메뉴 만들기. 이름을 모르면 요리를 못 합니다.

C-2. 수학적 흐름의 5대 줄기

줄기	주제	의미	회차
1	Vector · Matrix	객체의 정의	1·3
2	Linear equation(선형방정식) $A\mathbf{x} = \mathbf{b}$	연산의 의미	4·5
3	Space(공간)	Subspace · Basis(기저) · Dimension	7·8·9
4	Orthogonality(직교성) · Projection(정사영)	거리·각도의 분해	10·11
5	Decomposition	Determinant(행렬식) · Eigenvalue(고윳값) · SVD	12·Part 2·3 전체

Part 1: 1~4번 줄기를 단단히 다집니다.

Part 2·3: 5번 줄기 + AI 응용으로 나아갑니다.

C-3. Part 1 흐름 — 방정식과 공간

회차	주제 (Strang Ch)	단계
1-3	Vector · Dot product · Matrix·Vector 곱 (Ch 1)	①·② 토대
4-5	Gauss 소거 · Inverse matrix · LU 분해 (Ch 2)	② 풀이 + ③ 첫 분해
6	중간학습확인평가	—
7-9	Vector space · Subspace · 4 fundamental subspaces · Basis · Dimension (Ch 3)	② 구조·골격
10	Orthogonality · Projection (Ch 4.1-4.2)	②·③
11	Least squares · Gram-Schmidt · QR (Ch 4.3-4.4)	③·④ 회귀
12	Determinant + 종합학습확인평가 (Ch 5)	②

핵심 명제: $A\mathbf{x} = \mathbf{b}$ 의 해는 A 의 4 fundamental subspaces로 완전히 결정됩니다.

C-4. Part 2 흐름 — 분해와 수학 도구

회차	주제	단계
1-2	Eigenvalue · Diagonalization · Spectral theorem (Strang Ch 6.1-6.4)	③ 정사각 분해
3	Positive definite · Cholesky (Strang Ch 6.5)	③
4-5	SVD · Eckart-Young · PCA · Linear Transformation (Strang Ch 7-8)	③ 임의 분해 + ④ 압축
6	중간학습확인평가	—
7-8	Vector Calculus (Jacobian · Hessian · Newton) (MML Ch 5)	④ 신경망 미분
9	Probability · MLE · KL divergence · Cross entropy (MML Ch 6 + 8.2)	④ LLM·RLHF·VAE 수학
10	Continuous Optimization (Convex · Lagrange · KKT) (MML Ch 7)	④ 옵티마이저·정규화

C-5. Part 3 흐름 — AI 응용과 모델 분해

회차	주제	단계
1	Linear Regression (MML Ch 9)	⑤ ML 응용
2	PCA 깊이 (MML Ch 10)	⑤
3	Gaussian Mixture Models · EM (MML Ch 11)	⑤
4-5	SVM · Kernel methods (MML Ch 12)	⑤
6	CNN · Conv = Toeplitz 환원 (자체 교안)	④ 모델 분해
7	Attention 분해 · Multi-head (자체 교안)	④ 모델 분해
8	Equivariance · Kronecker — 현대 아키텍처 LA 설계 원리 (자체 교안)	④ 설계 원리
9	종합학습확인평가 + Case Study 발표	—

핵심 명제: 어떤 Matrix도 **SVD**로 회전·신축·회전으로 분해됩니다. 그 위에 미분·확률·최적화 도구를 쌓아 임의 **AI 모듈**을 선형대수 객체로 환원할 수 있습니다.

D. CS·AI 흐름

수학 5대 줄기가 컴퓨터와 AI에서 어디에 등장하는지를 봅니다.

D-1. 데이터·연산의 LA 환원

CS·AI 객체	LA 환원	회차
이미지·텍스트·사용자	$\mathbb{R}^d$ Vector	1
데이터셋 (n 개 샘플)	$\mathbb{R}^{n \times d}$ Matrix	3
신경망 한 층	$\mathbf{x} \mapsto W\mathbf{x} + \mathbf{b}$	3·7
손실 함수의 미분	Jacobian / Hessian	Part 2 7-8
학습 = 최소화	Least squares · 정규방정식	11
추론 = Matrix 곱 누적	BLAS · GPU 병렬화	3
모델 압축·Quantization(양자화)	Low-rank Decomposition (SVD·LoRA)	Part 2 4-5

D-2. AI 모델 안의 LA 객체

Transformer 한 블록의 입력 → 출력 흐름:

단계	식	LA 객체	회차
입력	$\mathbf{x} \in \mathbb{R}^d$	Vector	1
Embedding(임베딩)	$E\mathbf{x}$	Matrix·Vector 곱	3
Attention	$\text{softmax}\left(\frac{QK^\top}{\sqrt{d}}\right)V$	모든 쌍의 Inner product	2 · Part 3 7
FFN	$W_2 \text{ReLU}(W_1\mathbf{x} + \mathbf{b}_1) + \mathbf{b}_2$	affine 변환	7
출력	$\text{softmax}(\cdots)$	확률 Vector	—

각 작업 단계가 회차별 주제와 일대일로 대응합니다.

D-3. Decomposition이 AI를 만듭니다

응용	Decomposition	의미
PCA (차원 축소)	SVD / Eigenvalue Decomposition	"주된 방향" 만 남깁니다
회귀 (선형 모델)	$A^T A$ 풀이 (QR)	"데이터를 가장 잘 설명하는 선"
LoRA (LLM 효율 미세조정)	rank-r Low-rank 근사	" W 의 변화량을 r-차원으로"
추천 시스템	Matrix Decomposition	"사용자·아이템의 공통 잠재 요인"
이미지 압축·JPEG·MP3	DCT (직교 분해)	"주파수별 에너지 누적"
Whitening · BatchNorm	공분산 Diagonalization	"축마다 분산 1로"

Decomposition이 AI의 절반입니다 — 이 강의 후반부가 다 이 표 안에 있습니다.

E-1. 4단 운영 모델

자료	위상	사용 시점	비유
Strang	메인	정의·정리·예제·연습문제	지도
MML	보조·확장	Vector Calculus·Probability·ML 응용 (PCA·LR·GMM·SVM)	지도책
3Blue1Brown	시각	사전 시청	위성사진
NumPy / PyTorch	실습	매 회차 ipynb	탐사 장비

왜 Strang이 메인입니까?

- Strang Ch 1-5가 LA 표준 (Vector·Matrix·Linear equation·Subspace·Determinant)을 정의·정리 위주로 단단히 다룹니다.
- MML은 Strang에 없는 Vector Calculus·Probability·Optimization과 ML 4대 응용(LR·PCA·GMM·SVM)을 Part 2·3 후반에서 확장으로 씁니다.
- EoLA는 직관·시각 잡기에 좋습니다.

E-2. 매 회차 reading 패턴

회차 시작 24시간 전:

- ① Strang 해당 절 본문 + 연습문제 3개 (메인)
- ② MML 해당 절 본문 (참조·확장)
- ③ 3Blue1Brown EoLA 해당 편 1편

회차 종료 직후:

- ④ 강의교안 (07/Part1/N회차_*.md) 다시 읽기
- ⑤ 회차 ipynb (11/Part1/N_*.ipynb) 실행
- ⑥ 과제 (04_과제/Part1/N회차_homework.md) 착수

24시간 전·직후의 2회 노출이 6회차 중간학습확인평가 기억 유지의 결정 변수입니다.

F-1. Part 1 종료 시 (13회차 후)

학생은 다음을 할 수 있습니다.

- [] Vector·Matrix·Linear equation Definition을 정확히 진술하고 손계산할 수 있습니다.
- [] $A\mathbf{x} = \mathbf{b}$ 의 해 존재·유일성을 4 기본 **Subspace**로 판별할 수 있습니다.
- [] LU·QR Decomposition을 정의대로 직접 구현할 수 있습니다.
- [] 정규방정식 $A^\top A \hat{\beta} = A^\top \mathbf{b}$ 로 회귀를 풀 수 있습니다.
- [] Gram-Schmidt를 직접 구현할 수 있습니다.
- [] Subspace · Projection · 직교 여공간의 Definition·Theorem을 진술할 수 있습니다.

F-2. Part 2 종료 시 (10회차 후)

- [] Eigenvalue Decomposition · SVD의 Definition·계산법을 자유롭게 사용할 수 있습니다.
- [] PCA·Low-rank 근사를 SVD로 한 줄에 구현할 수 있습니다.
- [] Jacobian·Hessian으로 신경망 한 층의 미분을 분해할 수 있습니다.

F-3. Part 3 종료 시 (9회차 후)

- [] CNN convolution을 Toeplitz matrix로 환원할 수 있습니다.
- [] **Attention** $\text{softmax}(QK^\top / \sqrt{d_k})V$ 를 LA 객체로 분해할 수 있습니다.
- [] 임의의 AI 모델 한 부분을 골라 LA 분해 보고서를 작성할 수 있습니다 (Case Study).

F-4. 시그니처 능력 — "수학 → 코드 → 분해 보고"

단계	내용
1	논문에서 식을 봅니다
2	Definition·Theorem으로 분해합니다 ("이건 SVD다", "이건 4 Subspace다")
3	NumPy / PyTorch 로 한 줄씩 구현합니다
4	실제 데이터에서 검증합니다
5	보고서로 정리합니다

LLM 시대에 LA를 다시 배우는 이유 — 라이브러리 호출 한 줄 안에 무엇이 들어 있는지 **알면서 부르는** 사람이 되기 위해서입니다.

G. 시그니처 시연 — 손글씨 "7"의 평균은 어떻게 생겼을까요

지금까지의 수학·CS 흐름이 가장 친숙한 한 예제에 모이는 클라이맥스입니다.

G-1. 질문

손글씨 숫자 데이터(MNIST)에서 숫자 "7"이라고 적힌 모든 이미지를 평균내면 어떤 그림이 나올까요?

직관 후보	결과
(가) 무의미한 잡음?	✗
(나) 한 사람의 7만 보임?	✗
(다) "7의 본질" 같은 흐릿한 7 모양	✓

💡 **파인만식 비유:** 100명의 얼굴을 평균하면 한 사람 얼굴이 아니라 "모든 사람의 공통점"이 보입니다. 손글씨 7도 같습니다 — 한 사람의 7이 아니라 "7의 본질"이 평균에 나타납니다.

→ 이 단순한 질문의 답이 **PCA·Embedding·표현 학습**의 출발점입니다.

G-2. 한 줄의 수학

이미지 한 장을 **Vector** $\mathbf{x}_i \in \mathbb{R}^{784}$ (28×28 픽셀)로 봅니다 (1회차).

숫자 "7"인 모든 이미지를 모은 집합 $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ 의 **Vector 평균**:

$$\mathbf{m} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i \in \mathbb{R}^{784}$$

이 한 식 안에 들어 있는 1회차의 모든 것:

- "이미지를 Vector로 본다" — Vector의 Definition
- "Vector들을 더한다" — Vector 덧셈
- " $\frac{1}{n}$ 을 곱한다" — Scalar(스칼라)곱

G-3. 코드 — 단 한 줄

```
mean_seven = X[y == 7].mean(axis=0).reshape(28, 28)
plt.imshow(mean_seven, cmap='gray')
```

- 수학 정의 1줄 → 코드 1줄 → 그림 1장
- 이것이 이 강의 모든 회차의 표준 사이클입니다

→ 노트북 `11_주피터노트북/Part1/00_Introduction_평균이미지.ipynb` 를 함께 실행합니다.

G-4. 이 한 시연에 들어 있는 32회차의 지점

시연의 부분	회차
이미지를 Vector로 보기 ($\mathbb{R}^{784}$)	1
Vector 덧셈·Scalar곱 (평균 연산)	1
데이터셋을 Matrix로 ($\mathbb{R}^{n \times 784}$)	3
평균 Vector·중심화 — 데이터의 "원점"	8 · Part 3 2
평균을 빼고 본 분산의 주방향 — PCA	Part 3 2
분류기로 확장 — 가장 가까운 평균 $\Rightarrow$ 클래스	2·11

가장 단순한 수학(Vector 평균) 한 줄이 32회차 전체의 입구입니다.

G-5. 노트북에서 봅시다 — 실행 흐름

1. MNIST 손글씨 로드 — Matrix $X \in \mathbb{R}^{1797 \times 64}$, 레이블 y
2. 한 장을 Vector로 — `X[0].shape == (64,)` 확인 (1회차)
3. 0~9 각 숫자의 평균 이미지 계산 — `X[y==k].mean(axis=0)` (1회차)
4. 시각화 — 10개 평균이 흐릿한 0, 1, ..., 9 모양으로 보입니다.
5. 응용 — 새 이미지를 가장 가까운 평균으로 분류합니다 (간단한 분류기).
6. 보너스: 평균을 빼면 무엇이 남는가 (PCA 미리보기)

H. 1회차 사전 reading 안내

1회차 주제: Vector · Linear combination(선형결합) · Span(생성공간) — Strang §1.1

오늘 본 평균 이미지 시연의 토대 — **Vector의 Definition· $\mathbb{R}^n$ ·Linear combination**을 1회차에 정식 수학으로 맞춥니다.
Norm·Inner product·Cosine similarity는 2회차 (Strang §1.2), Cauchy-Schwarz까지의 논리 사슬은 2회차에서 봅니다.

1회차 시작 24시간 전까지

- [] **Strang §1.1** (Vectors and Linear Combinations) — 메인 reading
- [] **3Blue1Brown EoLA** Ch.1 (Vectors), Ch.2 (Linear combinations, span, basis) — 시각 사전 시청
- [] (선택) **MML §2.1** (Vectors) — 참조·확장

0회차 종료 후 권장

- 오늘 본 평균 이미지 시연을 `00_Introduction_평균이미지.ipynb` 에서 다른 숫자(예: 4·8)로 재실행해보세요.
- 어색한 부분을 1회차 강의에서 질문할 수 있도록 준비합니다.
- MML, Strang 책 PDF·종이본을 확인합니다 — 매 회차 reading의 시작점입니다.

마무리 — 1회차로 가져갈 질문

오늘의 핵심 질문: "수학 정의 한 줄이 어떻게 AI 모델 한 줄이 됩니까?"

오늘은 **Vector의 평균**이라는 가장 단순한 예로 일부 답을 보았습니다.

1회차 시작 전 풀어볼 1문제

MNIST에서 숫자 "7"인 이미지 1,000장의 평균 Vector를 **m**이라 합니다.

(a) 한 새로운 이미지 **x**가 들어왔을 때, "이게 7과 얼마나 가까운가"를 **거리**로 어떻게 잴 수 있습니까? 두 가지 방법을 제시하세요.

(b) 두 방법은 어떤 면에서 다르니까? — 하나는 길이만 보고, 하나는 방향까지 본다는 직관까지 답해보세요.

→ 1회차에서는 **Vector·Linear combination**으로 평균이 잘 정의되는지를 먼저 단단히 합니다. 두 도구 **Norm**과 **Inner product**는 2회차에서 정식으로 답합니다.

마무리 문제 운영 원칙 (안내)

매 회차 다음 4단 사이클로 운영합니다.

단계	시점	내용
① 핵심 질문	회차 시작 (오프닝)	그날의 한 질문
② Review	회차 시작 (10분)	지난 차시 숙제 풀이
③ 본 강의	회차 중반	Definition·Theorem·유제
④ 마무리 문제 + 숙제	회차 끝 (15분)	즉석 풀이 + 유사 문제 → 다음 회차 Review 재료

오늘(0회차)은 ④의 첫 출발입니다 — 위 1문제가 **1회차 시작 시 Review** 문제가 됩니다.

Q & A

오늘은 Definition·증명 없이 큰 그림만 보았습니다.
다음 회차부터 본격 수학을 시작합니다.

HANDOUT : 본 PDF + 00_Introduction_평균이미지.ipynb