

## Part 1 1회차

### Vector(벡터)· $\mathbb{R}^n$ ·Linear combination(선형결합)

---

MML §2.1 (메인) · Strang Ch 1.1 (발췌) · [EoLA Ch.1: Vectors](#) · [EoLA Ch.2: Linear combinations, span, basis](#) · Part 1 (LA1)

**Part 1 (LA1) 첫 회차**,  $\mathbb{R}^n$  위에서 가장 단순한 두 연산 (덧셈·Scalar곱)부터 시작합니다.

$\mathbb{R}^n$ 은  $n$ 개 실수를 한 묶음으로 본 공간입니다 (정확한 정의는 B-2).

## Review: 지난 회차 마무리 문제

지난 회차에서 제기한 두 문제 (0회차 객체만으로 답합니다):

- (a) MNIST 숫자 "7" 이미지  $n$ 장  $\mathbf{x}_1, \dots, \mathbf{x}_n$ 의 평균 이미지  $\mathbf{m}$ 을 Vector-Linear combination 두 단어로 한 줄로 표기.
- (b) 평균 이미지  $\mathbf{m}$ 이 다시  $\mathbb{R}^{784}$  안의 Vector가 되는 이유를 한 줄로.

## Review: 답

- (a) 평균 Vector의 정의식

$$\mathbf{m} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i = \frac{1}{n} \mathbf{x}_1 + \frac{1}{n} \mathbf{x}_2 + \cdots + \frac{1}{n} \mathbf{x}_n.$$

각 이미지를  $\frac{1}{n}$  배율로 합친 **Linear combination**(선형결합)이며, 결과는 또 하나의 Vector  $\in \mathbb{R}^{784}$ 이다.

- (b)  $\mathbf{m}$ 이  $\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^{784}$ 의 **Linear combination**이고,  $\mathbb{R}^{784}$ 는 Vector를 Linear combination해도 Vector 그대로이기 때문 (오늘 정식화할 핵심 사실).

## Review: 핵심 관찰

(a)의 한 줄은 본 회차에서 정식화될 모든 객체를 담고 있다:  $\mathbb{R}^{784}$  Vector, 두 연산(덧셈·Scalar곱), 그리고 둘을 합친 Linear combination. 평균 이미지가 다시 이미지인 이유는 "Vector를 Linear combination해도 Vector이다"라는 본 회차 핵심 사실에서 비롯된다.

본 회차는 그 토대인 **Vector**· $\mathbb{R}^n$ ·**Linear combination**을 정식으로 도입한다. 평균 Vector **m**의 정의에 본 회차 핵심 객체가 모두 포함된다.

## 본 회차 핵심 질문

---

"수의 묶음"을 한 객체로 본다는 것은 무엇이고, 그 객체로 무엇을 할 수 있습니까?

이 질문 하나가 본 회차를 끌고 간다. 길을 잃으면 이 질문으로 돌아온다. 아래 흐름표가 답의 지도이다.

## 학습 목표

---

이번 회차가 끝나면 학생은 다음을 답할 수 있어야 합니다.

1. **Vector**의 수학적 정의와 그 의미를 물리·대수·데이터 세 관점에서 설명할 수 있습니다.
2.  $\mathbb{R}^n$ 에서의 덧셈·**Scalar**곱 두 연산을 손계산으로 자유롭게 수행할 수 있습니다.
3. **Linear combination**(선형결합)의 정의와 "선형(linear)"이라는 명칭의 이유를 설명할 수 있습니다.
4. **Span**(생성공간)의 직관, 주어진 Vector들로 만들 수 있는 모든 결과의 집합을 설명할 수 있습니다.
5. MNIST 이미지를  $\mathbb{R}^{784}$  **Vector**로 보는 환원·평균 이미지 계산을 NumPy로 수행할 수 있습니다.

## 본 회차 학습 흐름

표의 식들 ( $\alpha_1 \mathbf{v}_1 + \dots$ ,  $\text{span}$  등)은 C 섹션에서 정식 도입됩니다. 표는 학습 흐름 안내입니다.

| 질문              | 답 (이 강의의 답)                             | 도구                                                      |
|-----------------|-----------------------------------------|---------------------------------------------------------|
| "수의 묶음"을 한 객체로? | <b>Vector</b> 의 정의                      | $\mathbf{x} \in \mathbb{R}^n$                           |
| 그 객체에 가능한 두 연산? | 덧셈·Scalar곱                              | $\mathbf{x} + \mathbf{y}, \alpha \mathbf{x}$            |
| 두 연산을 섞으면?      | <b>Linear combination</b>               | $\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k$ |
| 모든 결과의 집합?      | <b>Span</b> (직관)                        | $\text{span}(\dots)$                                    |
| 가장 친숙한 예?       | <b>MNIST 이미지</b> $\in \mathbb{R}^{784}$ | 평균 이미지                                                  |
| 다음 회차로?         | 길이·각도                                   | Norm · Inner product (2회차)                              |

추상 정의(Vector space 8 axioms·Subspace·일차독립)는 6·7·8회차에서 정식 도입한다. 본 회차 내내 "정식은 N회차" 안내는 이 한 줄로 갈음한다.

## 수업 흐름

| 순서 | 블록 | 내용                                                          |
|----|----|-------------------------------------------------------------|
| ①  | A  | 오프닝: 핵심 질문 + 0회차 Review + 본 회차 학습 흐름                        |
| ②  | B  | Vector: 동기 3가지 + $\mathbb{R}^n$ 정의 + 두 연산 + 직관 예제           |
| ③  | C  | Linear combination · Span(직관) + 3회차 미리보기                    |
| ④  | D  | CS·AI 적용: MNIST·텍스트·임베딩                                     |
| ⑤  | E  | 코딩 실습(필요 시) + 클로징: NumPy · $\mathbb{R}^2$ Span 시각화 · 마무리 문제 |

B와 C가 본 회차의 핵심. 표준 사이클: 핵심 질문 → Review → 본 강의 → 마무리 문제 → 숙제(= 다음 회차 Review).



## B. Vector: 동기와 정의

"왜 Vector가 필요한가?" 세 가지 동기로 시작합니다.

### B-1. Vector가 왜 생겼는가: 세 가지 동기

(i) 물리적 동기: 크기 + 방향이 필요한 양 (변위·속도·힘)


- "북쪽 3 m"와 "동쪽 3 m"는 다릅니다, 같은 크기지만 방향이 다르면 다른 양.
- 두 변위의 합 = **평행사변형 법칙**.

(ii) 대수적 동기: 동시에 여러 양을 다루기

- $\begin{cases} 2x + 3y = 5 \\ x - y = 1 \end{cases}$  —  $(x, y)$ 를 한 묶음으로 봅니다.
- 미지수가 100개라면 묶음 없이는 식조차 쓸 수 없습니다.

## B-1 (i) 물리적 동기: 평행사변형 법칙

두 벡터  $\mathbf{u}$ ,  $\mathbf{v}$ 를 평행이동해 만든 평행사변형의 대각선이 곧 합  $\mathbf{u} + \mathbf{v}$ 이다. 합 연산이 두 벡터의 순서에 의존하지 않는다는 사실 (교환법칙) 이 그림에서 바로 보인다.



# B-1 (ii) 대수적 동기: $A\mathbf{x} = \mathbf{b}$

5개 방정식·5개 미지수를 하나의 행렬 방정식으로 압축한다. 미지수가 100개·1000개로 늘어나도 같은 한 줄 표기  $A\mathbf{x} = \mathbf{b}$ 가 유지된다.

대수적 동기: 여러 식·여러 미지수를 하나의 객체로

5개 방정식·5개 미지수행렬 형태  $A\mathbf{x} = \mathbf{b}$

$2x_1 + 1x_2 - 1x_3 + 0x_4 + 3x_5 = 5$

$1x_1 - 3x_2 + 2x_3 + 1x_4 + 0x_5 = 1$

$0x_1 + 2x_2 + 1x_3 - 1x_4 + 2x_5 = 4$

$3x_1 + 0x_2 + 1x_3 + 2x_4 - 1x_5 = 2$

$1x_1 + 1x_2 + 0x_3 + 3x_4 + 1x_5 = 7$

$A \in \mathbb{R}^{5 \times 5}$

|   |    |    |    |    |
|---|----|----|----|----|
| 2 | 1  | -1 | 0  | 3  |
| 1 | -3 | 2  | 1  | 0  |
| 0 | 2  | 1  | -1 | 2  |
| 3 | 0  | 1  | 2  | -1 |
| 1 | 1  | 0  | 3  | 1  |

$\mathbf{x} \in \mathbb{R}^5$

|       |
|-------|
| $x_1$ |
| $x_2$ |
| $x_3$ |
| $x_4$ |
| $x_5$ |

$\mathbf{b} \in \mathbb{R}^5$

|   |
|---|
| 5 |
| 1 |
| 4 |
| 2 |
| 7 |

$=$

계수 25개·미지수 5개·우변 5개를 하나의 행렬 방정식으로 압축

### (iii) 데이터적 동기 (AI): 측정값의 묶음

- 이미지 한 장 = 픽셀 784개의 묶음
- 문서 한 개 = Embedding 좌표 768개의 묶음
- 사용자 한 명 = 영화 평점 100개의 묶음

Embedding(임베딩)은 단어·문장을 수의 묶음 (Vector)으로 바꾼 좌표입니다. 정식 등장은 D-4.

세 동기 모두 **벡터**와 **Scalar** 곱이 자연스러운 두 연산입니다.


**Strang Ch 1.1 발췌:** 두 Vector  $\mathbf{v}$ ,  $\mathbf{w}$ 에 대해 모든 Linear combination  $c\mathbf{v} + d\mathbf{w}$  ( $c, d \in \mathbb{R}$ )의 집합이 LA의 출발점이라는 사실을 강조한다. 평행사변형 법칙과 같은 직관 그림이 본 회차 B-4·C-4의 토대이다.

# B-1 (iii-a) 이미지 한 장 = $\mathbb{R}^{784}$ 벡터

$28 \times 28$  픽셀 격자를 한 줄로 펼쳐 길이 784 벡터로 본다. 픽셀 인덱스  $(i, j)$ 는 1차원 인덱스  $k = 28i + j$ 로 재배열된다.

데이터적 동기 (1): 이미지 한 장 =  $\mathbb{R}^{784}$  벡터


벡터 표현  $\mathbf{x} \in \mathbb{R}^{784}$



Flatten  
(펼치기)



$$k = 28i + j$$




784개 픽셀값을 한 줄로 늘어놓은 1차원 벡터

# B-1 (iii-b) 문서 한 개 = $\mathbb{R}^{768}$ 벡터

BERT 같은 언어 모델은 문서를  $\mathbb{R}^{768}$ 의 한 점으로 매핑한다. 숫자 768개가 그 문서의 의미 좌표가 된다.


데이터적 동기 (2): 문서 1개 =  $\mathbb{R}^{768}$  벡터



# B-1 (iii-c) 사용자 한 명 = $\mathbb{R}^{100}$ 벡터

영화 100편 평점을 한 줄로 모으면 사용자가  $\mathbb{R}^{100}$ 의 한 점이 된다. 평점이 비슷한 사용자끼리는 이 공간 안에서 가깝다 (다음 회차 코사인 유사도).

데이터적 동기 (3): 사용자 한 명 =  $\mathbb{R}^{100}$  벡터 (영화 100편 평점 묶음)



## B-2. $\mathbb{R}^n$ 의 Vector: 형식적 정의

---

### 정의 1.1 ( $\mathbb{R}^n$ 의 Vector)

$n$ 개 실수 순서쌍이다. 본 강의의 기본 표기는 **Column vector**(열벡터)이다.

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^n, \quad \mathbf{x}^\top = (x_1, x_2, \dots, x_n)$$

- $x_i \in \mathbb{R}$ 를 성분(component) 또는 좌표(coordinate)라 부른다.
- $n$ 을 차원(dimension)이라 부른다.  $\mathbb{R}^3$ 의 Vector는 좌표 3개를 가진 한 점이다.
- 표기 관례: Vector는 굵게 ( $\mathbf{x}$ ), Scalar는 보통체 ( $\alpha, x_i$ ).



## Row vector vs Column vector

- $\mathbf{x}$  = 세로 묶음 (Column),  $\mathbf{x}^\top$  = 가로 묶음 (Row).
- LA의 표준은 Column. Matrix·Vector 곱  $A\mathbf{x}$ 가 Column 기준으로 정의된다.

표기  $^\top$  (전치)과  $A\mathbf{x}$  (Matrix·Vector 곱)의 정식 정의는 3회차.

## B-3. 두 연산 — 덧셈 · Scalar곱

---

### 정의 1.2 (덧셈)

같은 차원의 두 Vector의 합은 성분별 합입니다.

$$\mathbf{x} + \mathbf{y} = \begin{pmatrix} x_1 + y_1 \\ x_2 + y_2 \\ \vdots \\ x_n + y_n \end{pmatrix}$$

차원이 다르면 합이 정의되지 않습니다 ( $\mathbb{R}^3$  Vector +  $\mathbb{R}^4$  Vector는 X).

### 정의 1.3 (Scalar 곱)

실수  $\alpha \in \mathbb{R}$ 와 Vector  $\mathbf{x} \in \mathbb{R}^n$ 의 곱은 성분별 **Scalar 곱**입니다.

$$\alpha \mathbf{x} = \begin{pmatrix} \alpha x_1 \\ \alpha x_2 \\ \vdots \\ \alpha x_n \end{pmatrix}$$

- $\alpha > 0$ : 같은 방향, 크기  $\alpha$ 배
- $\alpha < 0$ : 반대 방향, 크기  $|\alpha|$ 배
- $\alpha = 0$ : 영Vector  $\mathbf{0} = (0, 0, \dots, 0)^\top$

## B-4. 두 연산의 직관: 그림으로

**직관 (수치 측정의 묶음):** Vector는 한 객체를 기술하는 여러 측정값의 묶음이다. 한 환자의 (혈압, 맥박, 체온) =  $(120, 72, 36.5)^T \in \mathbb{R}^3$ 는 한 Vector이다. **Scalar곱:** 모든 측정값을 같은 비율로 확대·축소 (단위 변환). **덧셈:** 같은 종류의 두 묶음을 성분별로 합산 (두 측정 결과의 누적). 두 연산이 모두 성분별로 정의된다는 점이 정의 1.2·1.3의 핵심이다.

### 그림 직관 ( $\mathbb{R}^2$ )

- $\mathbf{x} + \mathbf{y}$ :  $\mathbf{x}$ 의 끝에서  $\mathbf{y}$ 를 이어 붙이기 = **평행사변형 법칙**
- $\alpha \mathbf{x}$  ( $\alpha > 1$ ):  $\mathbf{x}$ 를 같은 방향으로 늘리기
- $-\mathbf{x}$ :  $\mathbf{x}$ 를 뒤집기 (반대 방향)
- $\mathbf{0}$ : 원점 (모든 성분 0)

### 예제

$$\mathbf{u} = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \mathbf{v} = \begin{pmatrix} 3 \\ 1 \end{pmatrix} \text{일 때}$$

$$\mathbf{u} + \mathbf{v} = \begin{pmatrix} 4 \\ 3 \end{pmatrix}, \quad 2\mathbf{u} = \begin{pmatrix} 2 \\ 4 \end{pmatrix}, \quad \mathbf{u} - \mathbf{v} = \begin{pmatrix} -2 \\ 1 \end{pmatrix}$$

## B-5. 두 연산이 잘 동작합니다 (6회차에서 정식화)

---

$\mathbb{R}^n$ 에서 덧셈·Scalar곱이 가진 자연스러운 성질들:

- $\mathbf{u} + \mathbf{v} = \mathbf{v} + \mathbf{u}$  (교환법칙)
- $(\mathbf{u} + \mathbf{v}) + \mathbf{w} = \mathbf{u} + (\mathbf{v} + \mathbf{w})$  (결합법칙)
- $\mathbf{u} + \mathbf{0} = \mathbf{u}$  (덧셈 항등원)
- $\mathbf{u} + (-\mathbf{u}) = \mathbf{0}$  (역원)
- $\alpha(\beta\mathbf{u}) = (\alpha\beta)\mathbf{u}$
- $\alpha(\mathbf{u} + \mathbf{v}) = \alpha\mathbf{u} + \alpha\mathbf{v}$  등 분배법칙

이 성질들을 한 데 묶어 **Vector space의 8 axioms** (공리)이라 부른다. 정식 정의는 6회차에서 도입한다. 그때까지는  $\mathbb{R}^n$ 이 위 성질을 모두 만족한다는 사실만 받아들인다.

## B-6. 영Vector와 표준 단위Vector

### 영Vector

$$\mathbf{0} = (0, 0, \dots, 0)^\top \in \mathbb{R}^n$$

모든 Vector  $\mathbf{x}$ 에 대해  $\mathbf{x} + \mathbf{0} = \mathbf{x}$ ,  $0 \cdot \mathbf{x} = \mathbf{0}$ . 원점에 해당한다.

### 표준 단위Vector (Standard basis vector)

$\mathbb{R}^n$ 에서  $i$ 번째 성분만 1이고 나머지는 0인 Vector:

$$\mathbf{e}_1 = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \mathbf{e}_2 = \begin{pmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{pmatrix}, \dots, \mathbf{e}_n = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{pmatrix}$$

관찰: 임의의  $\mathbf{x} = (x_1, \dots, x_n)^\top$ 를

$$\mathbf{x} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2 + \dots + x_n \mathbf{e}_n$$

으로 쓸 수 있다. 모든 Vector가  $\mathbf{e}_1, \dots, \mathbf{e}_n$ 의 Linear combination이며, 이것이 C 섹션의 핵심 출발점이다.

## 잠깐 풀어보기: Vector와 두 연산

옆 사람과 5분 토의 후 답을 종이에 적어보세요.

### 문제 1 (계산)

$\mathbf{u} = (1, -2, 3)^\top$ ,  $\mathbf{v} = (2, 0, -1)^\top$ 일 때 다음을 계산하시오.

- (a)  $\mathbf{u} + \mathbf{v}$
- (b)  $2\mathbf{u} - 3\mathbf{v}$
- (c)  $\mathbf{u}$ 와 같은 방향이지만 크기가 절반인 Vector

### 문제 2 (개념)

$\mathbb{R}^3$ 에서  $\mathbf{x} = 2\mathbf{e}_1 - 3\mathbf{e}_2 + 5\mathbf{e}_3$ 를 성분 표기  $(x_1, x_2, x_3)^\top$ 로 적으시오.

힌트:  $\mathbf{e}_i$ 는  $i$ 번째 성분만 1인 Vector이다. 각 항이 어느 성분에 기여하는지만 보면 된다.

## 잠깐 풀어보기: 답

---

### 문제 1

- (a)  $\mathbf{u} + \mathbf{v} = (1 + 2, -2 + 0, 3 + (-1))^{\top} = (3, -2, 2)^{\top}$
- (b)  $2\mathbf{u} = (2, -4, 6)^{\top}, 3\mathbf{v} = (6, 0, -3)^{\top}. 2\mathbf{u} - 3\mathbf{v} = (-4, -4, 9)^{\top}$
- (c)  $\frac{1}{2}\mathbf{u} = (0.5, -1, 1.5)^{\top}$ . Scalar  $\alpha = 1/2$ 로 곱한다.

### 문제 2

$$\mathbf{x} = 2\mathbf{e}_1 - 3\mathbf{e}_2 + 5\mathbf{e}_3 = (2, -3, 5)^{\top}$$

메시지: 표준 단위Vector를 사용한 표현이 곧 성분 표기이다. 거꾸로 모든 성분 표기는  $\mathbf{e}_i$ 의 Linear combination으로 풀어쓸 수 있다. C 섹션에서 본격 사용한다.



## C. Linear combination · Span (직관)

본 회차의 두 번째 핵심이다. 두 연산을 섞어 쓰면 무엇이 만들어지는가.

### C-1. Linear combination: 정의

#### 정의 1.4 (Linear combination)

Vector  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in \mathbb{R}^n$ , Scalar  $\alpha_1, \alpha_2, \dots, \alpha_k \in \mathbb{R}$ 에 대해

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k \in \mathbb{R}^n$$

를 **Linear combination**(선형결합)이라 부릅니다.  $\alpha_i$ 를 **계수**(coefficient)라 합니다.

#### 예제

- $\mathbf{v}_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}, \mathbf{v}_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$ 이면
  - $3\mathbf{v}_1 + 2\mathbf{v}_2 = \begin{pmatrix} 3 \\ 2 \end{pmatrix}$
  - $-1\mathbf{v}_1 + 5\mathbf{v}_2 = \begin{pmatrix} -1 \\ 5 \end{pmatrix}$

## C-1. Linear combination: 계수의 의미

---

- 계수  $(\alpha_1, \alpha_2)$ 를 바꿀 때마다 다른 Vector가 나옵니다.

**직관 (계수의 의미):** 주어진 Vector  $\mathbf{v}_1, \dots, \mathbf{v}_k$ 를 고정하고 계수  $(\alpha_1, \dots, \alpha_k)$ 를 바꾸는 일이 곧 Linear combination이다. 계수 묶음  $(\alpha_1, \dots, \alpha_k) \in \mathbb{R}^k$  한 점이 결과 Vector  $\mathbf{v} = \sum_i \alpha_i \mathbf{v}_i$  한 점에 대응한다. 따라서 모든 Linear combination을 모은 집합 (Span) 은  $\mathbb{R}^k \rightarrow \mathbb{R}^n$  한 선형사상의 상 (image) 이다.

계수  $\alpha_i$ 는 양수·음수·0 어느 것이든 가능하다. 모두 0이면 결과는 영Vector **0**이다.

## C-2. "선형(linear)"의 의미

"Linear"는 덧셈과 Scalar곱이라는 두 연산만 사용한다는 뜻이다.

표 안의  $\| \cdot \|$ 은 Vector의 길이(Norm)로, 정식 도입은 2회차입니다. 여기서는 "길이 계산이 들어간 표현"이라는 직관만 챙기면 됩니다.

| 허용 (linear)                                                    | 금지 (비선형)                                |
|----------------------------------------------------------------|-----------------------------------------|
| $\alpha \mathbf{v} + \beta \mathbf{w}$                         | $v_1 \cdot w_1$ (성분끼리 곱)                |
| $-\mathbf{v}$                                                  | $v_1^2$ (성분 제곱)                         |
| $\mathbf{v} + \mathbf{w} + \mathbf{u}$                         | $\exp(v_1), \sin(v_1)$                  |
| $\frac{1}{3}(\mathbf{v}_1 + \mathbf{v}_2 + \mathbf{v}_3)$ (평균) | $\ \mathbf{v}\ ^2 \mathbf{w}$ (Norm 사용) |

**제한의 의미:** 두 연산만 쓰면 **수학적 분석이 가능하다**. 비선형이 들어가면 대수 구조가 깨져 일반 이론이 어렵다. 그래서 LA는 "Linear"라는 한 단어에 모든 것이 응축된다.

**AI 모델의 비선형성:** 신경망의 **활성화 함수** (ReLU·sigmoid 등)가 비선형 부분을 담당합니다. 가중치 곱·합은 linear, 활성화는 비선형, 두 부분이 분리되어 있어 각각을 따로 분석할 수 있습니다 (5회차·Part 2 2회차). 예: ReLU는  $\max(0, x)$ , sigmoid는  $1/(1 + e^{-x})$ .

## C-3. Span (직관): 만들 수 있는 모든 Vector의 집합

### 정의 1.5 (Span, 직관적 정의)

Vector  $\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^n$ 이 주어졌을 때, 가능한 모든 계수  $\alpha_1, \dots, \alpha_k$ 에 대한 Linear combination의 집합:

$$\text{span}(\mathbf{v}_1, \dots, \mathbf{v}_k) = \{\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k : \alpha_i \in \mathbb{R}\}$$

이를  $\mathbf{v}_1, \dots, \mathbf{v}_k$ 의 **Span** (생성공간)이라 부른다. 즉 "주어진 Vector로 만들 수 있는 모든 결과의 묶음"이다.

**직관 (도달 범위):** Span은 주어진 Vector들이 **도달 가능한 모든 점**이고, 그 범위는 Vector들의 **방향**이 정한다 (개수가 아니라). 평행하면 도달 범위가 직선으로 좁아진다 — C-4에서 그림으로 본다.

정식 정의는 8회차(Subspace·Basis·Dimension과 함께). 본 회차는 "만들 수 있는 모든 결과의 집합" 직관까지.

## C-4. Span의 직관: 그림으로

---

### $\mathbb{R}^2$ 의 예

- $\text{span}((1, 0)^\top) = x\text{축 직선}$  (모든  $\alpha(1, 0)^\top = (\alpha, 0)$ )
- $\text{span}((1, 0)^\top, (0, 1)^\top) = \mathbb{R}^2 \text{ 전체}$  (모든 점이  $\alpha\mathbf{e}_1 + \beta\mathbf{e}_2$ 로 표현됨)
- $\text{span}((1, 1)^\top, (2, 2)^\top) = (1, 1)^\top \text{ 방향 직선}$  (두 Vector가 평행이므로 새 방향 정보 없음)

### $\mathbb{R}^3$ 의 예

- $\text{span}((1, 0, 0)^\top) = x\text{축 직선}$
- $\text{span}((1, 0, 0)^\top, (0, 1, 0)^\top) = xy \text{ 평면}$
- $\text{span}((1, 0, 0)^\top, (0, 1, 0)^\top, (0, 0, 1)^\top) = \mathbb{R}^3 \text{ 전체}$



### 핵심 관찰

**Vector 개수  $\neq$  Span의 차원이다.**  $(1, 1)^\top$ 과  $(2, 2)^\top$ 는 두 개지만 Span은 1차원 직선이다. "진짜 다른 방향"이 몇 개인가가 차원이다. 8회차에서 **Linear independence**로 정식화한다.

# C-4 그림으로: $\mathbb{R}^2$ 의 Span

왼쪽: 표준 단위벡터  $\mathbf{e}_1, \mathbf{e}_2$ 의 모든 선형결합  $\alpha\mathbf{e}_1 + \beta\mathbf{e}_2$ 가 격자로 평면을 채운다. 오른쪽: 비평행 두 벡터  $\mathbf{v}_1, \mathbf{v}_2$ 의 격자도 (모양은 비스듬해이지만) 같은 평면 전체를 채운다. 두 벡터의 방향이 달라도, 평행만 아니면  $\mathbb{R}^2$  전체를 Span한다.

$\mathbb{R}^2$ 의 Span: 두 비평행 벡터의 모든 선형결합이 평면을 채운다



## C-5. 표준 단위Vector의 Span은 $\mathbb{R}^n$ 전체

---

B-6에서 본 바와 같이 임의의  $\mathbf{x} \in \mathbb{R}^n$ 가

$$\mathbf{x} = x_1\mathbf{e}_1 + x_2\mathbf{e}_2 + \cdots + x_n\mathbf{e}_n$$

으로 표현된다. 따라서

$$\text{span}(\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n) = \mathbb{R}^n$$

→  $\mathbb{R}^n$  전체가  $n$ 개 표준 단위Vector의 Span이다. 이것이  $\mathbb{R}^n$ 이라는 공간을 " $n$ 차원"이라 부르는 이유이다.

### 일반화: Basis의 직관

$\mathbb{R}^n$ 을 Span하는 "최소한의 Vector 집합"이 곧 **Basis**(기저)이고,  $\{\mathbf{e}_1, \dots, \mathbf{e}_n\}$ 이 **표준 Basis**이다 (정식은 8회차).

## C-6. Linear combination = Matrix·Vector 곱 (3회차 미리보기)

본 회차에서 본 Linear combination은 곧 **Matrix·Vector 곱**과 같은 것이다.

표기  $\mathbb{R}^{m \times n}$ 은  $m$ 행  $n$ 열 실수 Matrix의 공간입니다. 정식 도입은 3회차.

$A \in \mathbb{R}^{m \times n}, \mathbf{x} \in \mathbb{R}^n$ .  $A$ 의 열을  $\mathbf{a}_1, \dots, \mathbf{a}_n$ 이라 쓰면

$$A\mathbf{x} = x_1\mathbf{a}_1 + x_2\mathbf{a}_2 + \dots + x_n\mathbf{a}_n$$

**Matrix·Vector 곱** =  $A$ 의 열들의 **Linear combination**이다 (Column picture 해석).

예시

$$A = \begin{pmatrix} 1 & 3 \\ 2 & 4 \end{pmatrix}, \mathbf{x} = \begin{pmatrix} 5 \\ 6 \end{pmatrix}$$

$$A\mathbf{x} = 5 \begin{pmatrix} 1 \\ 2 \end{pmatrix} + 6 \begin{pmatrix} 3 \\ 4 \end{pmatrix} = \begin{pmatrix} 5 \\ 10 \end{pmatrix} + \begin{pmatrix} 18 \\ 24 \end{pmatrix} = \begin{pmatrix} 23 \\ 34 \end{pmatrix}$$

→ 지금은 "Matrix·Vector 곱이 곧 Linear combination"이라는 사실만 챙긴다 (Row/Column 두 해석은 3회차).



## 잠깐 풀어보기: Linear combination·Span

### 문제 1 (계산)

$\mathbf{v}_1 = (1, 1)^\top$ 과  $\mathbf{v}_2 = (1, -1)^\top$ 이 주어졌다.  $(3, 5)^\top$ 을 두 Vector의 Linear combination  $\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2$ 로 표현하시오.

### 문제 2 (개념)

다음 Span을 그림 또는 말로 묘사하시오 (직선·평면·공간 전체·한 점 중 어느 것?).

- (i)  $\text{span}((1, 0)^\top, (0, 1)^\top, (1, 1)^\top) \subset \mathbb{R}^2$
- (ii)  $\text{span}((1, 2, 0)^\top, (2, 4, 0)^\top) \subset \mathbb{R}^3$
- (iii)  $\text{span}(\mathbf{0}) \subset \mathbb{R}^n$

힌트: 두 Vector가 평행하면 Span은 한 직선에 머문다.  $\mathbf{0}$ 만으로는 자기 자신밖에 만들 수 없다.

## 잠깐 풀어보기: 답

### 문제 1

$$\alpha_1 + \alpha_2 = 3, \alpha_1 - \alpha_2 = 5 \rightarrow \alpha_1 = 4, \alpha_2 = -1.$$

$$\therefore (3, 5)^\top = 4(1, 1)^\top - 1(1, -1)^\top$$

$$\text{검증: } 4(1, 1)^\top - (1, -1)^\top = (4, 4)^\top - (1, -1)^\top = (3, 5)^\top \checkmark$$

### 문제 2

- (i)  $(1, 1)^\top = (1, 0)^\top + (0, 1)^\top$ 이므로 셋째 Vector는 처음 둘의 Linear combination이다. 처음 두 Vector만으로 이미  $\mathbb{R}^2$  전체를 Span한다.  $\rightarrow \mathbb{R}^2$  전체 (평면 전체).
- (ii)  $(2, 4, 0)^\top = 2 \cdot (1, 2, 0)^\top$ 이므로 두 Vector가 평행하다.  $\rightarrow xy$ 평면 위의 한 직선  $((1, 2, 0)^\top$  방향).
- (iii)  $\alpha \cdot \mathbf{0} = \mathbf{0}$ 이므로 어떤  $\alpha$ 를 잡아도  $\mathbf{0}$ 이다.  $\rightarrow$  원점 한 점만.

(ii)가 보여주듯 평행한 두 Vector의 Span은 직선이다 — \*\*C-4의 "개수  $\neq$  차원"이 그대로 적용된다.

# D. CS·AI 적용: 데이터를 Vector로

본 회차에서 본 수학이 AI에서 어디에 등장하는가.

## D-1. 이미지를 Vector로: MNIST

손글씨 숫자 데이터셋 **MNIST**: 28×28 픽셀 흑백 이미지 70,000장.

| 표현              | 객체               | 차원                                 |
|-----------------|------------------|------------------------------------|
| 이미지 한 장         | 28×28 픽셀 격자      | 2D 배열                              |
| 펼친 형태 (flatten) | 길이 784 Vector    | $\mathbb{R}^{784}$                 |
| 데이터셋 전체         | $n \times 784$ 표 | $\mathbb{R}^{n \times 784}$ Matrix |

**펼치는 이유**: 픽셀의 공간 구조는 **CNN** (Part 4 6회차)에서 다시 살린다. 우선은 "한 장 = 한 Vector" 로 보는 것이 LA의 표준 환원이다.

**직관 (Flatten의 의미)**:  $28 \times 28$  격자 픽셀을  $\mathbb{R}^{784}$  Vector로 펼치는 일은 2차원 인덱스  $(i, j)$ 를 1차원 인덱스  $k = 28i + j$ 로 재배열하는 일이다. 픽셀 값 자체는 보존되지만 행·열 인접 관계 (공간 구조) 는 인덱스 안에 암묵화된다. 이 표현이 LA의 표준 환원이며, 공간 구조를 명시적으로 활용하는 표현은 Part 4 6회차 CNN·Toeplitz에서 다시 도입한다.

## D-2. MNIST 평균 이미지: 두 연산만으로

0회차 시그니처 예제를 재해석한다.

숫자 "7"인 이미지 1,000장  $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_{1000} \in \mathbb{R}^{784}$ 의 **평균 Vector**:

$\sum_{i=1}^k$ 는  $i = 1$ 부터  $k$ 까지의 항을 모두 더하라는 표기입니다.

$$\mathbf{m} = \frac{1}{1000} \sum_{i=1}^{1000} \mathbf{x}_i = \frac{1}{1000} (\mathbf{x}_1 + \mathbf{x}_2 + \dots + \mathbf{x}_{1000})$$

이 한 식 안에 본 회차 내용이 모두 들어 있다:

- "이미지를 Vector로 본다", B 섹션 (Vector 정의)
- "Vector들을 더한다", B 섹션 (덧셈)
- " $\frac{1}{1000}$  을 곱한다", B 섹션 (Scalar곱)
- " $\frac{1}{n} \sum$  자체", C 섹션 (계수가 모두  $\frac{1}{1000}$ 인 Linear combination)

→ 평균 이미지 = 모든 이미지의 **Linear combination** (계수가 균등). 결과는 "7의 본질" 같은 흐릿한 7 모양으로 나타난다 (0회차에서 본 그림).

### D-3. 텍스트·문서·사용자도 Vector로

이미지뿐 아니라 모든 데이터가 Vector로 환원된다.

| 데이터                        | Vector 표현         | 차원                           |
|----------------------------|-------------------|------------------------------|
| 이미지 (MNIST)                | 픽셀 펼치기            | $\mathbb{R}^{784}$           |
| 이미지 (ImageNet 224×224 RGB) | 픽셀 펼치기            | $\mathbb{R}^{150,528}$       |
| 단어 (Word2Vec)              | Embedding(임베딩) 좌표 | $\mathbb{R}^{300}$           |
| 문장 (BERT)                  | Embedding 좌표      | $\mathbb{R}^{768}$           |
| 문장 (GPT-4)                 | Embedding 좌표      | $\mathbb{R}^{3072}$ (추정)     |
| 사용자 (Netflix)              | 영화별 평점            | $\mathbb{R}^{17,000}$ (영화 수) |
| 유전자 발현                     | 유전자별 발현량          | $\mathbb{R}^{20,000}$        |

약어 안내: CNN(Convolutional Neural Network, 이미지 등 격자형 입력 신경망), Word2Vec·BERT·GPT-4는 대표적 단어·문장 임베딩·언어 모델. 정식 분해는 Part 4.

모든 AI 모델의 입력 =  $\mathbb{R}^d$  Vector이다. 이미지는 작은  $d$ , 텍스트는 중간, 유전자는 큰  $d$ 이다.

## D-4. Embedding(임베딩): 의미를 Vector로

**직관 (Embedding의 의미):** Embedding은 단어·문장 등 비수치 객체를  $\mathbb{R}^d$ 의 한 점으로 보내는 함수이다. 의미적으로 가까운 객체는  $\mathbb{R}^d$  안에서 거리가 작도록, 의미적으로 먼 객체는 거리가 크도록 학습한다. 이렇게 얻은 좌표 위에서는 Norm·Inner product (2회차)가 곧바로 의미 유사도의 척도가 된다.

### Embedding의 한 줄 정의

문장·이미지·사용자 등 임의 객체를  $\mathbb{R}^d$  Vector로 보내는 함수, 학습으로 얻는다.

### Vector여야 하는 이유

- Vector면 덧셈·Scalar곱이 정의됨 → 평균·차이 등 계산 가능
- 다음 회차의 Norm·Inner product가 정의됨 → 거리·각도 계산 가능
- Matrix 곱 (3회차) → 신경망 한 층 통과 가능

→ AI 모델은 모든 입력을 Vector로 바꾸는 것에서 시작한다. 이것이 본 회차의 결론이다.

# D-4 그림으로: 단어 임베딩 2D 시각화

같은 의미 그룹 (인물·동물·과일) 안의 단어들이 평면 위에서 **가까운 점**으로 모인다. 단어 사이 거리는 곧 의미 거리이다. 거리 ( $\|\mathbf{x} - \mathbf{y}\|$ ) 와 각도 (코사인 유사도) 의 정식 정의는 2회차에서 도입한다.



## D-5. 신경망 한 뉴런 미리보기

---

가장 간단한 인공 뉴런:

$$y = w_1x_1 + w_2x_2 + \cdots + w_nx_n + b$$

여기서  $\mathbf{x} = (x_1, \dots, x_n)^\top$  = 입력 Vector,  $\mathbf{w} = (w_1, \dots, w_n)^\top$  = 가중치 Vector.

이 식의 본질:

- $w_ix_i$ 의 합 = 가중치 Vector와 입력 Vector의 곱셈 합  $\rightarrow$  Inner product (2회차)
- 더 일반화:  $\mathbf{y} = \mathbf{W}\mathbf{x} + \mathbf{b} \rightarrow$  Matrix·Vector 곱 (3회차)

**b**는 Bias(편향): 출력을 평행이동시키는 상수 Vector이다 (5회차·Part 2 2회차에서 본격).

$\rightarrow$  본 회차에서 본 Vector 정의 + 두 연산이 곧 신경망의 한 줄이다. 뉴런 한 개의 출력 = 입력 Vector의 한 가지 Linear combination + Bias.



## E-1. 코딩 실습 (필요 시): 골자

→ [Colab](#)으로 실행

**Colab 실습 정책:** 매 회차 필수 X. 회차별 학습 가치에 따라 1-2개 또는 그 이상으로 운영한다. 본 회차는 0회차에서 이미 MNIST 평균을 다뤘으니  $\mathbb{R}^2$  Span 시각화가 가장 유의미한 활동이다. 시간이 부족하면 수학 정리·마무리 문제로 마치고 코딩은 과제로 돌릴 수 있다.

### 핵심 활동: $\mathbb{R}^2$ Span 시각화

1. 두 비평행 Vector  $\mathbf{v}_1, \mathbf{v}_2 \in \mathbb{R}^2$ 를 정한다.
2. 격자 계수  $(\alpha, \beta) \in [-2, 2] \times [-2, 2]$ 에 대해  $\alpha\mathbf{v}_1 + \beta\mathbf{v}_2$ 를 그린다.
3. 평면 전체가 채워짐을 눈으로 확인한다 ( $\text{span}(\mathbf{v}_1, \mathbf{v}_2) = \mathbb{R}^2$ ).
4.  $\mathbf{v}_2$ 를  $2\mathbf{v}_1$ 로 바꿨을 때 한 직선으로 무너짐도 비교 (평행하면 차원이 줄어든다).

### 보조 활동 (시간 남으면)

- NumPy로 Vector 만들기·두 연산·표준 단위 Vector·Linear combination 계산
- MNIST 1장 reshape·시각화 (0회차 예제의 한 장 단위 재현)

## E-2. NumPy 핵심 패턴

```
import numpy as np

# Vector 만들기
u = np.array([1.0, -2.0, 3.0])
v = np.array([2.0, 0.0, -1.0])

# 두 연산
print(u + v)          # 덧셈
print(2 * u - 3 * v)  # Linear combination

# 표준 단위Vector
e = np.eye(3)          # 3x3 단위Matrix의 각 열이 e1, e2, e3
e1 = e[:, 0]           # (1, 0, 0)

# Linear combination을 한 줄로
vs = np.array([[1, 0], [0, 1], [1, 1]]) # 3개 Vector를 행으로
coefs = np.array([2, 3, -1])
result = coefs @ vs    # = 2*v1 + 3*v2 - v3

# MNIST → 784차원 Vector
from sklearn.datasets import load_digits
data = load_digits()
X = data.data          # (1797, 64) - 한 행이 한 이미지의 64차원 Vector
y = data.target        # (1797,) - 레이블
mean_seven = X[y == 7].mean(axis=0)    # (64,) - 7의 평균 Vector
```

### E-3. 차원·자료형 주의

NumPy에서 흔히 만나는 함정:

| 함정                                                  | 증상                                          | 해결                                           |
|-----------------------------------------------------|---------------------------------------------|----------------------------------------------|
| <code>np.array([1, 2]) + np.array([1, 2, 3])</code> | shape 불일치 에러                                | 차원 맞춘 뒤 덧셈                                   |
| 정수 Vector에 <code>0.5</code> 곱                       | dtype에 따라 잘림                                | <code>.astype(float)</code> 명시               |
| Row vector vs Column vector                         | <code>(n,)</code> vs <code>(n, 1)</code> 혼동 | LA에선 Column 표준, <code>.reshape(-1, 1)</code> |
| MNIST 픽셀 0~255 정수                                   | 평균에서 오버플로 가능성                               | <code>.astype(np.float32) / 255.0</code>     |

0회차 노트북에서 `astype(float)` 을 한 이유: 픽셀 평균을 계산할 때 정수형은 Scalar 곱이 깔끔하게 떨어지지 않습니다. Vector space의 두 연산이 잘 동작하려면 실수 자료형이 자연스럽습니다.

## E-4. 본 회차 핵심 5개

---

1. **Vector** = 같은 차원 실수들의 순서 묶음 ( $\mathbb{R}^n$ ) + 두 연산 (덧셈·Scalar곱).
2. 두 연산은 그림으로는 평행사변형 법칙과 늘이기·뒤집기이다. 성분별로 자연스럽게 동작한다.
3. **Linear combination** = 두 연산을 섞은 일반 식  $\sum \alpha_i \mathbf{v}_i$ . "선형"은 두 연산만 쓴다는 뜻이다.
4. **Span (직관)** = 주어진 Vector로 만들 수 있는 모든 결과의 집합. Vector 개수  $\neq$  차원 (평행하면 차원이 줄어든다).
5. **MNIST 이미지 1장** =  $\mathbb{R}^{784}$  **Vector**. 모든 AI 모델의 입력은 결국 Vector로 환원된다. 평균 이미지 = 계수 균등한 Linear combination.

## E-5. 자기 점검 질문

---

- $\mathbf{u} = (1, 2, 3)^\top, \mathbf{v} = (-1, 0, 1)^\top$ 일 때  $3\mathbf{u} - 2\mathbf{v}$ 는?
- $\text{span}((2, 4)^\top, (1, 2)^\top)$ 의 모양은 (직선·평면·한 점 중)?
- $\mathbb{R}^n$ 의 임의 Vector가 표준 단위 Vector  $\mathbf{e}_1, \dots, \mathbf{e}_n$ 의 Linear combination으로 쓰이는 이유는?
- MNIST 28×28 이미지를 Vector로 만들면 차원은? 1,000장 데이터셋은 어떤 Matrix?
- "선형(linear)"이란 단어의 정확한 의미는 무엇입니까? 무엇이 허용되고 무엇이 금지됩니까?

## 본 회차 마무리 문제 (즉석 풀이)

본 회차 학습 흐름 (Vector → 두 연산 → Linear combination → Span → MNIST)을 한 문제로 종합합니다.

$\mathbf{v}_1 = (1, 0, 1)^\top$ ,  $\mathbf{v}_2 = (0, 1, 1)^\top$ ,  $\mathbf{v}_3 = (1, 1, 2)^\top$ 가  $\mathbb{R}^3$ 에 주어졌다.

- (a)  $\mathbf{w} = 2\mathbf{v}_1 + 3\mathbf{v}_2 - \mathbf{v}_3$ 를 계산하시오.
- (b)  $\mathbf{v}_3$ 를  $\mathbf{v}_1, \mathbf{v}_2$ 의 Linear combination으로 표현할 수 있는가? 가능하면 계수를 구하시오.
- (c)  $\text{span}(\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3)$ 는  $\text{span}(\mathbf{v}_1, \mathbf{v}_2)$ 와 같은 집합인가? 그 이유는?
- (d)  $\text{span}(\mathbf{v}_1, \mathbf{v}_2)$ 는  $\mathbb{R}^3$ 의 어떤 모양인가 (직선·평면·전체 중)?

## 본 회차 마무리 문제: 답

- (a)  $2\mathbf{v}_1 = (2, 0, 2)^\top$ ,  $3\mathbf{v}_2 = (0, 3, 3)^\top$ ,  $-\mathbf{v}_3 = (-1, -1, -2)^\top$   
 합:  $(2 - 1, 0 + 3 - 1, 2 + 3 - 2)^\top = (1, 2, 3)^\top$
- (b)  $\mathbf{v}_3 = (1, 1, 2)^\top = (1, 0, 1)^\top + (0, 1, 1)^\top = \mathbf{v}_1 + \mathbf{v}_2$ . 가능하며, 계수 (1, 1).
- (c) 같은 집합이다.  $\mathbf{v}_3$ 가  $\mathbf{v}_1, \mathbf{v}_2$ 의 Linear combination이므로  $\mathbf{v}_3$ 를 추가해도 새로 만들 수 있는 Vector가 없다. ( $\alpha_1\mathbf{v}_1 + \alpha_2\mathbf{v}_2 + \alpha_3\mathbf{v}_3 = (\alpha_1 + \alpha_3)\mathbf{v}_1 + (\alpha_2 + \alpha_3)\mathbf{v}_2$ 로 정리 가능)
- (d)  $\mathbf{v}_1, \mathbf{v}_2$ 는 평행이 아니다 (한쪽이 다른 쪽의 Scalar 배가 아니다). 따라서  $\mathbb{R}^3$ 의 한 평면 (원점을 지나는).

핵심: (b)·(c)처럼 한 Vector가 나머지의 LC이면 Span에 기여하지 않는다 — \*\*C-4의 "개수 ≠ 차원"의 3차원 사례이고, 8회차 일차독립으로 이어진다.

## 다음 회차 Review용 숙제

위 마무리 문제의 유사 문제이다. 강의 후 풀어 와서 2회차 Review 시간에 비교한다.

$\mathbf{u}_1 = (1, 2)^\top$ ,  $\mathbf{u}_2 = (3, 4)^\top$ ,  $\mathbf{u}_3 = (5, 6)^\top$  이  $\mathbb{R}^2$ 에 주어졌다.

- (a)  $\mathbf{w} = \mathbf{u}_1 - 2\mathbf{u}_2 + \mathbf{u}_3$ 를 계산하시오.
- (b)  $\mathbf{u}_3$ 를  $\mathbf{u}_1, \mathbf{u}_2$ 의 Linear combination으로 표현할 수 있는가? 가능하면 계수를 구하시오. (힌트: 연립방정식)
- (c)  $\text{span}(\mathbf{u}_1, \mathbf{u}_2, \mathbf{u}_3)$ 는  $\mathbb{R}^2$ 의 어떤 모양인가?
- (d) MNIST 한 장의 이미지를  $\mathbb{R}^{784}$  Vector  $\mathbf{x}$ 로 펼쳤다. 표준 단위 Vector  $\mathbf{e}_1, \dots, \mathbf{e}_{784}$  ( $\mathbf{e}_i$  = 위치  $i$ 만 1, 나머지 0)의 Linear combination으로  $\mathbf{x}$ 를 표현하는 식을 한 줄로 적으시오. (각 픽셀을 손으로 다 풀어쓰라는 것이 아니라, 시그마 한 줄로 충분합니다.)
  - 답 형태 안내:  $\mathbf{x} = \sum_{i=1}^{784} x_i \mathbf{e}_i$ , 여기서  $x_i$ 는  $i$ 번째 픽셀 값.

### 자기 점검

- (b)의 계수를 구하는 과정이 어떤 연립 1차방정식으로 환원되는지 확인한다. → 4회차 가우스 소거의 출발점.
- (d)에서 픽셀값  $x_i$ 가 곧 표준 단위 Vector  $\mathbf{e}_i$ 의 계수이다. 모든 이미지는 결국 픽셀별 단위 Vector의 Linear combination이다. 식 한 줄에 본 회차 모든 객체 (Vector·Scalar곱·합·Linear combination)가 들어 있다.



## E-6. 과제 안내

---

04\_과제/Part1/01회차\_homework.md — 마감: 2회차 시작 전

### 수학 30점

- 두 연산 계산 (덧셈·Scalar곱·Linear combination), 5문제
- Span의 모양 식별 (직선·평면·전체), 3문제
- 한 Vector가 다른 Vector들의 Linear combination인지 판정, 3문제 (연립방정식 풀기)
- 표준 단위Vector  $\mathbf{e}_i$ 를 사용한 분해, 2문제

### 코딩 20점

- NumPy로 Vector 생성·두 연산·Linear combination 구현
- MNIST 한 장  $\rightarrow$  784차원 Vector로 reshape, 시각화로 원본 복원 확인
- 0~9 각 숫자의 평균 이미지 10장 계산·시각화
- 보너스: 새 이미지를 가장 가까운 평균과 비교하여 분류 (다음 회차 Norm으로 자연스럽게 이어짐)

## E-7. 다음 회차 (2회차) 예고

---

주제: Length(길이, Norm) · Dot product(내적) · 각도 · Cauchy-Schwarz · Cosine similarity

연결: 본 회차에서 본 Vector와 두 연산만으로는 "두 Vector가 얼마나 비슷한가"를 잴 수 없습니다. 2회차에서 **Norm**(길이)과 **Inner product**(내적)라는 두 도구를 도입하여 거리·각도·코사인 유사도를 정의합니다. 0회차 Review에서 가져온 "MNIST 숫자 7과 새 이미지의 가까움"이 수학적으로 정의됩니다.

3회차 예고: 본 회차에서 본 Linear combination = Matrix·Vector 곱의 Column picture (3회차에서 본격).

사전 reading:

- MML §3.1-§3.4 (Norms · Inner Products · Lengths and Distances · Angles and Orthogonality), 메인
- Strang Ch 1.2 발췌 (Cauchy-Schwarz 판별식 풀이), 본문 박스로 가져옴
- 3Blue1Brown EoLA Ch.9 (Dot products and duality)

# 부록: MML §2.1 · Strang Ch 1.1 추천 연습문제

본 회차에서 다룬 내용을 손으로 더 다루어 보고 싶은 학생을 위한 안내입니다 (모두 자율).

| 교재                                                               | 주제                                                 | 난도  |
|------------------------------------------------------------------|----------------------------------------------------|-----|
| MML §2.1 Exercise: Vector· $\mathbb{R}^n$ ·linear combination 기초 | $\mathbb{R}^n$ 두 연산·linear combination 계산          | 하·중 |
| Strang Ch 1.1 Problem 1-3                                        | 평행사변형 법칙·두 Vector 합                                | 하   |
| Strang Ch 1.1 Problem 5-8                                        | Linear combination 계수 구하기                          | 중   |
| Strang Ch 1.1 Problem 11-13                                      | $\mathbb{R}^3$ 에서 Span의 모양 식별                      | 중   |
| Strang Ch 1.1 Problem 17-20                                      | 표준 단위Vector·임의 Vector 분해                           | 중   |
| Strang Ch 1.1 Problem 23, 25                                     | "두 Vector의 모든 Linear combination이 평면을 이룬다"의 직관적 증명 | 상   |

MML §2.1은 정식 정의를 다지고, Strang Ch 1.1 연습문제는 개념 검증용 + 손계산용이 섞여 있습니다. 본문을 읽고 3~5문제를 풀면 다음 회차 진입이 부드러워집니다.

## Q & A

본 회차 학습 흐름:

**Vector ( $\mathbb{R}^n$ )** → 두 연산 (덧셈·Scalar곱) → Linear combination → Span(직관) → MNIST 이미지 Vector

핵심 한 줄: 모든 데이터는  $\mathbb{R}^d$  Vector로 환원되고, 두 연산이 그 데이터를 다루는 모든 일의 출발점이다.

다음 회차의 출발 문제:

두 Vector의 길이와 각도를 어떻게 정의하면 자연스러운가?

**HANDOUT** : 본 PDF + 01\_벡터\_선형결합.ipynb