Part 1 1 회차

Vector(벡터)·$\mathbb{R}^n$·Linear combination(선형결합)

MML §2.1 (메인) · Strang Ch 1.1 (발췌) · EoLA Ch.1: Vectors · EoLA Ch.2: Linear combinations, span, basis · Part 1 (LA1)

Part 1 (LA1) 첫 회차 , $\mathbb{R}^n$ 위에서 가장 단순한 두 연산 (덧셈 ·Scalar 곱) 부터 시작합니다 .

$\mathbb{R}^n$ 은 n 개 실수를 한 묶음으로 본 공간입니다 (정확한 정의는 B-2).

Review: 지난 회차 마무리 문제

지난 회차에서 제기한 두 문제 (0 회차 객체만으로 답합니다):

(a) MNIST 숫자 "7" 이미지 n 장 $x_1, \ldots, x_n$ 의 평균 이미지 m 을 Vector·Linear combination 두 단어로 한 줄로 표기 .

(b) 평균 이미지 m 이 다시 $\mathbb{R}^{784}$ 안의 Vector 가 되는 이유를 한 줄로 .

Review: 답

(a) 평균 Vector 의 정의식

$$\mathbf{m} = \frac{1}{n}\sum_{i=1}^{n}\mathbf{x}_i = \frac{1}{n}\mathbf{x}_1 + \frac{1}{n}\mathbf{x}_2 + \cdots + \frac{1}{n}\mathbf{x}_n.$$

각 이미지를 1/n 배율로 합친 **Linear combination**(선형결합) 이며 , 결과는 또 하나의 Vector $\in \mathbb{R}^{784}$ 이다 .

(b) m 이 $x_1, \ldots, x_n$ $\mathbb{R}^{784}$ 의 **Linear combination** 이고 , $\mathbb{R}^{784}$ 는 Vector 를 Linear combination 해도 Vector 그대로이기 때문 (오늘 정식화할 핵심 사실).

Review: 핵심 관찰

(a) 의 한 줄은 본 회차에서 정식화될 모든 객체를 담고 있다 : $\mathbb{R}^{784}$ Vector, 두 연산 (덧셈 ·Scalar 곱), 그리고 둘을 합친 Linear combination. 평균 이미지가 다시 이미지인 이유는 "Vector 를 Linear combination 해도 Vector 이다 " 라는 본 회차 핵심 사실에서 비롯된다 .

본 회차는 그 토대인 **Vector·$\mathbb{R}^n$·Linear combination** 을 정식으로 도입한다 . 평균 Vector m 의 정의에 본 회차 핵심 객체가 모두 포함된다 .

본 회차 핵심 질문

" 수의 묶음 " 을 한 객체로 본다는 것은 무엇이고 , 그 객체로 무엇을 할 수 있습니까 ?

이 질문 하나가 본 회차를 끌고 간다 . 길을 잃으면 이 질문으로 돌아온다 . 아래 흐름표가 답의 지도이다 .

학습 목표

이번 회차가 끝나면 학생은 다음을 답할 수 있어야 합니다 .

Vector 의 수학적 정의와 그 의미를 물리 · 대수 · 데이터 세 관점에서 설명할 수 있습니다 .

$\mathbb{R}^n$ 에서의 **덧셈 ·Scalar 곱** 두 연산을 손계산으로 자유롭게 수행할 수 있습니다 .

Linear combination(선형결합) 의 정의와 " 선형 (linear)" 이라는 명칭의 이유를 설명할 수 있습니다 .

Span(생성공간) 의 직관 , 주어진 Vector 들로 만들 수 있는 모든 결과의 집합을 설명할 수 있습니다 .

MNIST 이미지를 $\mathbb{R}^{784}$ **Vector 로** 보는 환원 · 평균 이미지 계산을 NumPy 로 수행할 수 있습니다 .

본 회차 학습 흐름

표의 식들 ($\alpha_1 v_1 + \cdots$, span 등) 은 C 섹션에서 정식 도입됩니다. 표는 학습 흐름 안내입니다.

질문	답 (이 강의의 답)	도구
" 수의 묶음 " 을 한 객체로 ?	Vector 의 정의	$x \in \mathbb{R}^n$
그 객체에 가능한 두 연산 ?	덧셈 ·Scalar 곱	$x+y$, αx
두 연산을 섞으면 ?	Linear combination	$\alpha_1 v_1 + \cdots + \alpha_k v_k$
모든 결과의 집합 ?	Span (직관)	span(…)
가장 친숙한 예 ?	MNIST 이미지 $\in \mathbb{R}^{784}$	평균 이미지
다음 회차로 ?	길이 · 각도	Norm · Inner product (2 회차)

추상 정의 (Vector space 8 axioms·Subspace· 일차독립) 는 6·7·8 회차에서 정식 도입한다. 본 회차 내내 " 정식은 N 회차 " 안내는 이 한 줄로 갈음한다.

B. Vector: 동기와 정의

" 왜 Vector 가 필요한가 ?" 세 가지 동기로 시작합니다 .

(i) 물리적 동기 : 크기 + 방향이 필요한 양 (변위 · 속도 · 힘)

- " 북쪽 3 m" 와 " 동쪽 3 m" 는 다릅니다 , 같은 크기지만 방향이 다르면 다른 양 .

두 변위의 합 = **평행사변형 법칙** .

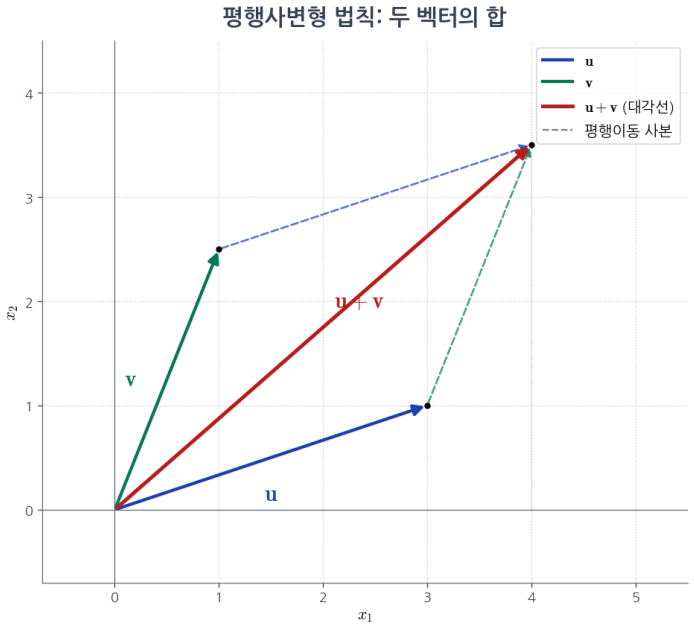
(ii) 대수적 동기 : 동시에 여러 양을 다루기

2x + 3y = 5 , x - y = 1 — (x, y) 를 한 묶음으로 봅니다 .

- 미지수가 100 개라면 묶음 없이는 식조차 쓸 수 없습니다 .

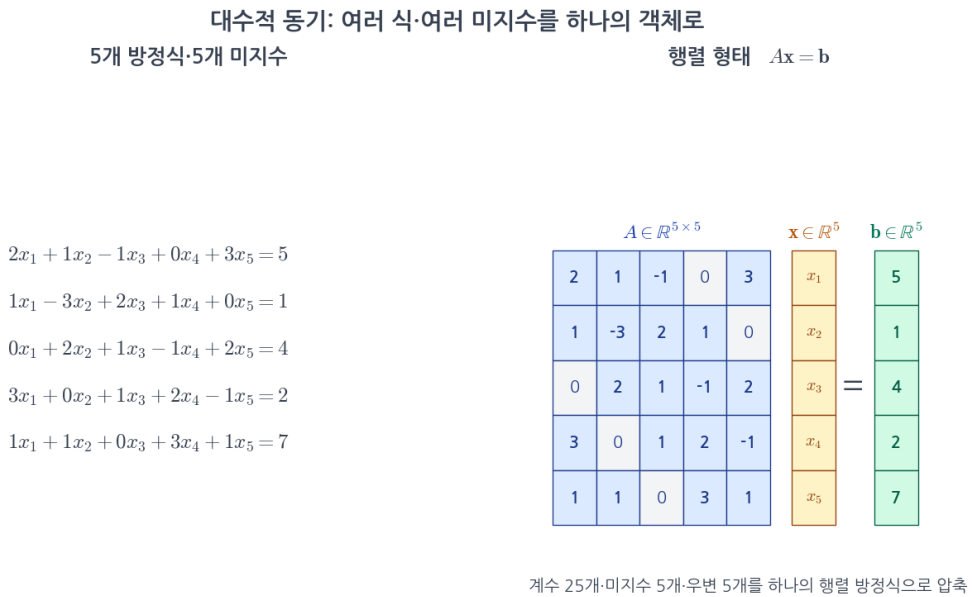
B-1 (i) 물리적 동기 : 평행사변형 법칙

두 벡터 u, v 를 평행이동해 만든 평행사변형의 **대각선**이 곧 합 u+v 이다 . 합 연산이 두 벡터의 순서에 의존하지 않는다는 사실 (교환법칙) 이 그림에서 바로 보인다 .



B-1 (ii) 대수적 동기 : Ax=b

5 개 방정식 ·5 개 미지수를 **하나의 행렬 방정식**으로 압축한다 . 미지수가 100 개 ·1000 개로 늘어나도 같은 한 줄 표기 Ax=b 가 유지된다 .



(iii) 데이터적 동기 (AI): 측정값의 묶음

- 이미지 한 장 = 픽셀 784 개의 묶음
- 문서 한 개 = Embedding 좌표 768 개의 묶음
- 사용자 한 명 = 영화 평점 100 개의 묶음

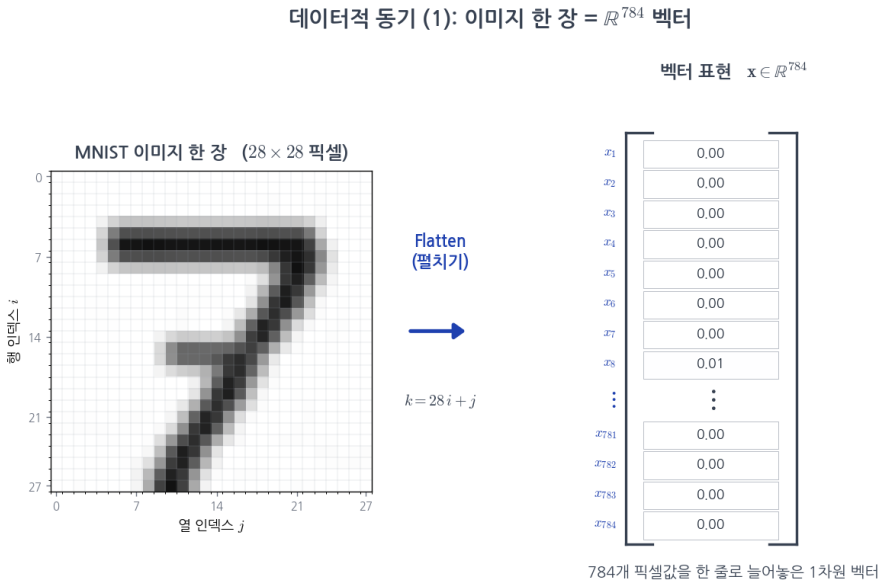
Embedding(임베딩) 은 단어 · 문장을 수의 묶음 (Vector) 으로 바꾼 좌표입니다 . 정식 등장은 D-4.

세 동기 모두 **덧셈과 Scalar 곱**이 자연스러운 두 연산입니다 .

Strang Ch 1.1 발췌 : 두 Vector v, w 에 대해 모든 Linear combination cv + dw (c, d ∈ ℝ) 의 집합이 LA 의 출발점이라는 사실을 강조한다 . 평행사변형 법칙과 같은 직관 그림이 본 회차 B-4·C-4 의 토대이다 .

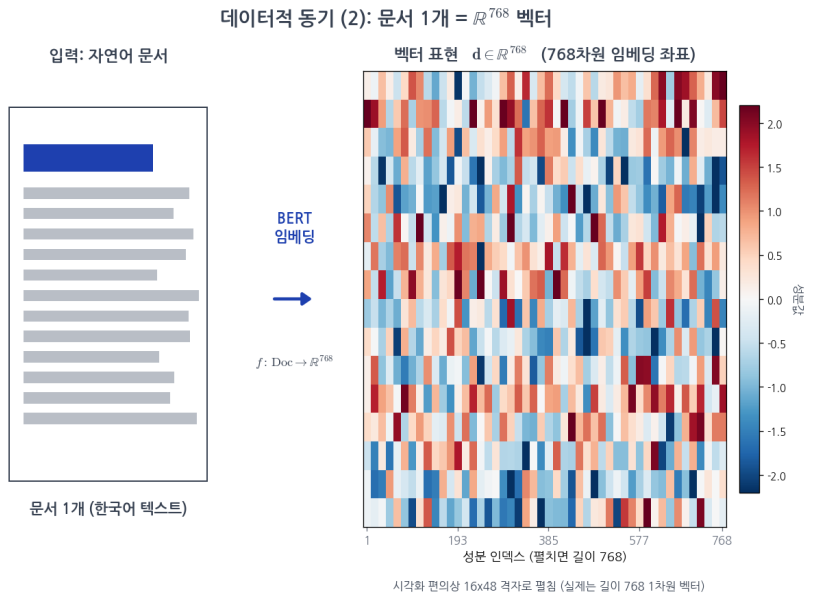
B-1 (iii-a) 이미지 한 장 = $\mathbb{R}^{784}$ 벡터

28× 28 픽셀 격자를 한 줄로 펼쳐 **길이 784 벡터**로 본다 . 픽셀 인덱스 (i,j) 는 1 차원 인덱스 k=28i+j 로 재배열된다 .



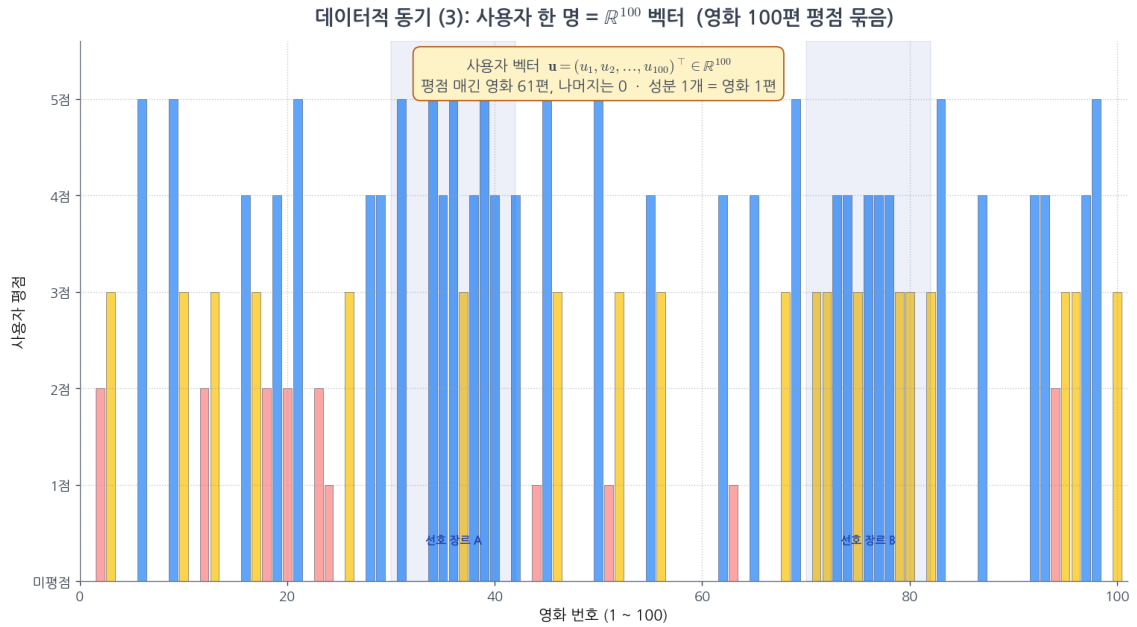
B-1 (iii-b) 문서 한 개 = $\mathbb{R}^{768}$ 벡터

BERT 같은 언어 모델은 문서를 $\mathbb{R}^{768}$의 한 점으로 매핑한다. **숫자 768 개**가 그 문서의 의미 좌표가 된다.



B-1 (iii-c) 사용자 한 명 = $\mathbb{R}^{100}$ 벡터

영화 100 편 평점을 한 줄로 모으면 사용자가 $\mathbb{R}^{100}$의 한 점이 된다 . 평점이 비슷한 사용자끼리는 이 공간 안에서 가깝다 (다음 회차 코사인 유사도).



B-2. $\mathbb{R}^n$ 의 Vector: 형식적 정의

정의 1.1 ($\mathbb{R}^n$ 의 Vector)

n 개 실수 순서쌍이다 . 본 강의의 기본 표기는 **Column vector**(열벡터) 이다 .

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^n, \qquad \mathbf{x}^\top = (x_1, x_2, \ldots, x_n)$$

$x_i \in \mathbb{R}$ 를 **성분** (component) 또는 **좌표** (coordinate) 라 부른다 .

n 을 **차원** (dimension) 이라 부른다 . $\mathbb{R}^3$ 의 Vector 는 좌표 3 개를 가진 한 점이다 .

표기 관례 : Vector 는 **굵게** (x), Scalar 는 보통체 (α, x_i).

Row vector vs Column vector

x = 세로 묶음 (Column), x^T = 가로 묶음 (Row).

LA 의 표준은 Column. Matrix·Vector 곱 Ax 가 Column 기준으로 정의된다 .

표기 ^{T}(전치) 과 Ax(Matrix·Vector 곱) 의 정식 정의는 3 회차 .

B-3. 두 연산 — 덧셈 · Scalar 곱

정의 1.2 (덧셈)

같은 차원의 두 Vector 의 합은 **성분별 합**입니다 .

$$\mathbf{x} + \mathbf{y} = \begin{pmatrix} x_1 + y_1 \\ x_2 + y_2 \\ \vdots \\ x_n + y_n \end{pmatrix}$$

차원이 다르면 합이 정의되지 않습니다 ($\mathbb{R}^3$ Vector + $\mathbb{R}^4$ Vector 는 X).

정의 1.3 (Scalar 곱)

실수 $\alpha \in \mathbb{R}$ 와 Vector $x \in \mathbb{R}^n$ 의 곱은 **성분별 Scalar 곱**입니다 .

$$\alpha \mathbf{x} = \begin{pmatrix} \alpha x_1 \\ \alpha x_2 \\ \vdots \\ \alpha x_n \end{pmatrix}$$

$\alpha > 0$: 같은 방향 , 크기 α 배

$\alpha < 0$: **반대 방향** , 크기 $|\alpha|$ 배

$\alpha = 0$: **영 Vector** $0 = (0, 0, \ldots, 0)^T$

B-4. 두 연산의 직관 : 그림으로

직관 (수치 측정의 묶음): Vector 는 한 객체를 기술하는 **여러 측정값의 묶음**이다 . 한 환자의 (혈압 , 맥박 , 체온) = $(120, 72, 36.5)^T \in \mathbb{R}^3$ 는 한 Vector 이다 . **Scalar 곱** : 모든 측정값을 같은 비율로 확대 · 축소 (단위 변환). **덧셈** : 같은 종류의 두 묶음을 성분별로 합산 (두 측정 결과의 누적). 두 연산이 모두 성분별로 정의된다는 점이 정의 1.2·1.3 의 요점이다 .

그림 직관 ($\mathbb{R}^2$)

x + y: x 의 끝에서 y 를 이어 붙이기 = **평행사변형 법칙**

αx (α > 1): x 를 같은 방향으로 **늘리기**

-x: x 를 **뒤집기** (반대 방향)

0: **원점** (모든 성분 0)

예제

B-5. 두 연산이 잘 동작합니다 (6 회차에서 정식화)

$\mathbb{R}^n$ 에서 덧셈 ·Scalar 곱이 가진 자연스러운 성질들 :

u + v = v + u (교환법칙)

(u + v) + w = u + (v + w) (결합법칙)

u + 0 = u (덧셈 항등원)

u + (-u) = 0 (역원)

- α(βu) = (αβ)u

α(u + v) = αu + αv 등 분배법칙

이 성질들을 한 데 묶어 **Vector space 의 8 axioms** (공리) 이라 부른다 . **정식 정의는 6 회차에서 도입**한다 . 그때까지는 $\mathbb{R}^n$

이 위 성질을 모두 만족한다는 사실만 받아들인다 .

B-6. 영 Vector 와 표준 단위 Vector

영 Vector

$$\mathbf{0} = (0, 0, \ldots, 0)^\top \in \mathbb{R}^n$$

모든 Vector x 에 대해 x + 0 = x, 0 · x = 0. **원점에 해당**한다 .

표준 단위 Vector (Standard basis vector)

$\mathbb{R}^n$ 에서 i 번째 성분만 1 이고 나머지는 0 인 Vector:

$$\mathbf{e}_1 = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix},\ \mathbf{e}_2 = \begin{pmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{pmatrix},\ \ldots,\ \mathbf{e}_n = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{pmatrix}$$

관찰: 임의의 $x = (x_1, \ldots, x_n)^\top$ 를

잠깐 풀어보기 : Vector 와 두 연산

옆 사람과 5 분 토의 후 답을 종이에 적어보세요 .

문제 1 (계산)

$u = (1, -2, 3)^T$, $v = (2, 0, -1)^T$ 일 때 다음을 계산하시오 .

(a) $u + v$

(b) $2u - 3v$

(c) u 와 같은 방향이지만 크기가 절반인 Vector

문제 2 (개념)

$\mathbb{R}^3$ 에서 $x = 2e_1 - 3e_2 + 5e_3$ 를 성분 표기 $(x_1, x_2, x_3)^T$ 로 적으시오 .

잠깐 풀어보기 : 답

문제 1

(a) $u + v = (1+2, -2+0, 3+(-1))^T = (3, -2, 2)^T$

(b) $2u = (2, -4, 6)^T$, $3v = (6, 0, -3)^T$. $2u - 3v = (-4, -4, 9)^T$

(c) $1/2u = (0.5, -1, 1.5)^T$. Scalar $\alpha = 1/2$ 로 곱한다 .

문제 2

$x = 2e_1 - 3e_2 + 5e_3 = (2, -3, 5)^T$

메시지 : 표준 단위 Vector 를 사용한 표현이 곧 **성분 표기**이다 . 거꾸로 모든 성분 표기는 e_i 의 Linear combination 으로 풀어쓸 수 있다 . C 섹션에서 본격 사용한다 .

C. Linear combination · Span (직관)

본 회차의 두 번째 핵심이다 . 두 연산을 **섞어 쓰면** 무엇이 만들어지는가 .

정의 1.4 (Linear combination)

Vector $v_1, v_2, \dots, v_k \in \mathbb{R}^n$, Scalar $\alpha_1, \alpha_2, \dots, \alpha_k \in \mathbb{R}$ 에 대해

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \cdots + \alpha_k \mathbf{v}_k \ \in \ \mathbb{R}^n$$

를 **Linear combination**(선형결합) 이라 부릅니다 . α_i 를 **계수** (coefficient) 라 합니다 .

C-1. Linear combination: 예제

예제

$v_1 = (1 , 0)$, $v_2 = (0 , 1)$ 이면

- $3v_1 + 2v_2 = (3 , 2)$
- $-1v_1 + 5v_2 = (-1 , 5)$

C-1. Linear combination: 계수의 의미

계수 (α_1, α_2) 를 바꿀 때마다 다른 Vector 가 나옵니다 .

직관 (계수의 의미): 주어진 Vector $v_1, \ldots, v_k$ 를 고정하고 계수 $(\alpha_1, \ldots, \alpha_k)$ 를 바꾸는 일이 곧 Linear combination 이다 . 계수 묶음 $(\alpha_1, \ldots, \alpha_k) \in \mathbb{R}^k$ 한 점이 결과 Vector $v = \Sigma_i \alpha_i v_i$ 한 점에 대응한다 . 따라서 모든 Linear combination 을 모은 집합 (Span) 은 $\mathbb{R}^k \to \mathbb{R}^n$ 한 선형사상의 상 (image) 이다 .

계수 α_i 는 양수 · 음수 · 0 어느 것이든 가능하다 . 모두 0 이면 결과는 영 Vector 0 이다 .

C-2. " 선형 (linear)" 의 의미

"Linear" 는 **덧셈과 Scalar 곱이라는 두 연산만 사용**한다는 뜻이다 .

> 표 안의 ‖ ·‖ 은 Vector 의 길이 (Norm) 로 , 정식 도입은 2 회차입니다 . 여기서는 " 길이 계산이 들어간 표현 " 이라는 직관만 챙기면 됩니다 .

허용 (linear)	금지 (비선형)
$\alpha v + \beta w$	$v_1 \cdot w_1$ (성분끼리 곱)
$-v$	v_1^2 (성분 제곱)
$v + w + u$	$\exp(v_1)$, $\sin(v_1)$
$1/3(v_1 + v_2 + v_3)$ (평균)	$\|v\|^2 w$ (Norm 사용)

제한의 의미 : 두 연산만 쓰면 **수학적 분석이 가능**하다 . 비선형이 들어가면 대수 구조가 깨져 일반 이론이 어렵다 . 그래서 두 연산만 쓰는 구조를 "Linear" 라 부른다 .

C-3. Span (직관): 만들 수 있는 모든 Vector 의 집합

정의 1.5 (Span, 직관적 정의)

Vector $v_1, \ldots, v_k$ $\mathbb{R}^n$ 이 주어졌을 때 , 가능한 **모든** 계수 $\alpha_1, \ldots, \alpha_k$ 에 대한 Linear combination 의 집합 :

$$\operatorname{span}(\mathbf{v}_1, \ldots, \mathbf{v}_k) = \{\alpha_1 \mathbf{v}_1 + \cdots + \alpha_k \mathbf{v}_k \ : \ \alpha_i \in \mathbb{R}\}$$

이를 **$v_1, \ldots, v_k$ 의 Span** (생성공간) 이라 부른다 . 즉 " 주어진 Vector 로 **만들 수 있는 모든 결과**의 묶음 " 이다 .

C-3. Span (직관): 도달 범위

직관 (도달 범위): Span 은 주어진 Vector 들이 **도달 가능한 모든 점**이고 , 그 범위는 Vector 들의 **방향**이 정한다 (개수가 아니라). 평행하면 도달 범위가 직선으로 좁아진다 — C-4 에서 그림으로 본다 .

정식 정의는 8 회차 (Subspace·Basis·Dimension 과 함께). 본 회차는 " 만들 수 있는 모든 결과의 집합 " 직관까지 .

C-4. Span 의 직관 : 그림으로

$\mathbb{R}^2$ 의 예

$\text{span}((1, 0)^T)$ = **x 축 직선** (모든 $\alpha(1,0)^T = (\alpha, 0)$)

$\text{span}((1, 0)^T, (0, 1)^T) = \mathbb{R}^2$ **전체** (모든 점이 $\alpha e_1 + \beta e_2$ 로 표현됨)

$\text{span}((1, 1)^T, (2, 2)^T)$ = **$(1,1)^T$ 방향 직선** (두 Vector 가 평행이므로 새 방향 정보 없음)

$\mathbb{R}^3$ 의 예

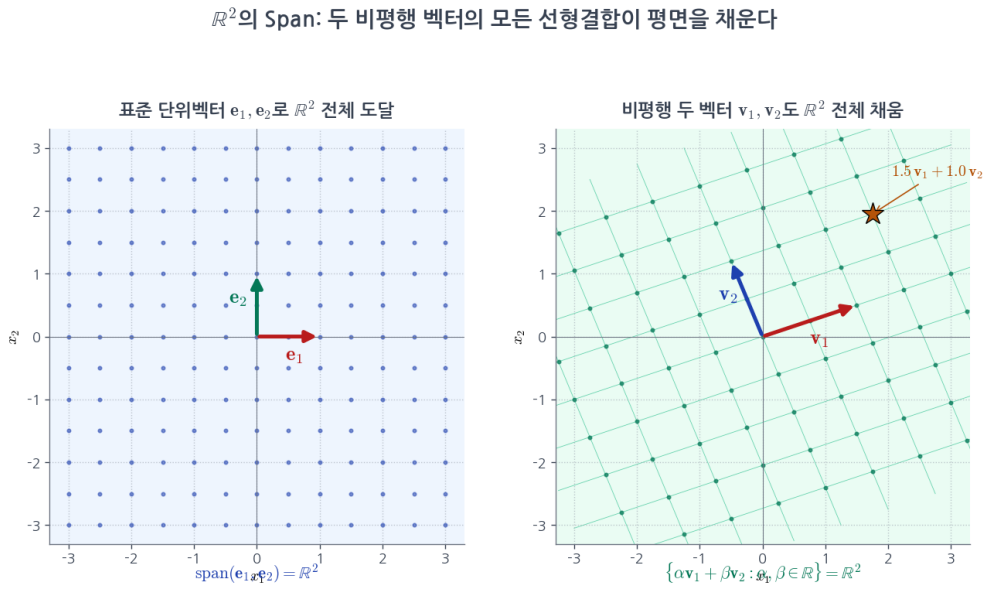
$\text{span}((1, 0, 0)^T)$ = x 축 직선

$\text{span}((1, 0, 0)^T, (0, 1, 0)^T)$ = xy 평면

$\text{span}((1, 0, 0)^T, (0, 1, 0)^T, (0, 0, 1)^T) = \mathbb{R}^3$ 전체

C-4 그림으로 : $\mathbb{R}^2$ 의 Span

왼쪽 : 표준 단위벡터 e_1, e_2 의 모든 선형결합 $\alpha e_1 + \beta e_2$ 가 격자로 평면을 채운다 . 오른쪽 : 비평행 두 벡터 v_1, v_2 의 격자도 (모양은 비스듬해지지만) 같은 평면 전체를 채운다 . **두 벡터의 방향이 달라도 , 평행만 아니면 $\mathbb{R}^2$ 전체를 Span 한다 .**



C-5. 표준 단위 Vector 의 Span 은 $\mathbb{R}^n$ 전체

B-6 에서 본 바와 같이 임의의 $x \in \mathbb{R}^n$ 가

$$\mathbf{x} = x_1\mathbf{e}_1 + x_2\mathbf{e}_2 + \cdots + x_n\mathbf{e}_n$$

으로 표현된다 . 따라서

$$\text{span}(\mathbf{e}_1, \mathbf{e}_2, \ldots, \mathbf{e}_n) = \mathbb{R}^n$$

→ $\mathbb{R}^n$ **전체가 n 개 표준 단위 Vector 의 Span** 이다 . 이것이 $\mathbb{R}^n$ 이라는 공간을 "n 차원 " 이라 부르는 이유이다 .

일반화 : Basis 의 직관

$\mathbb{R}^n$ 을 Span 하는 " 최소한의 Vector 집합 " 이 곧 **Basis**(기저) 이고 , $\{e_1, \ldots, e_n\}$ 이 **표준 Basis** 이다 (정식은 8 회차).

C-6. Linear combination = Matrix·Vector 곱 (3 회차 미리보기)

본 회차에서 본 Linear combination 은 곧 **Matrix·Vector 곱**과 같은 것이다 .

> 표기 $\mathbb{R}^{mxn}$ 은 m 행 n 열 실수 Matrix 의 공간입니다 . 정식 도입은 3 회차 .

$A \in \mathbb{R}^{mxn}$, $x \in \mathbb{R}^{n}$. A 의 열을 $a_1, \ldots, a_n$ 이라 쓰면

$$A\mathbf{x} = x_1\mathbf{a}_1 + x_2\mathbf{a}_2 + \cdots + x_n\mathbf{a}_n$$

Matrix·Vector 곱 = A 의 열들의 Linear combination 이다 (Column picture 해석).

예시

A = (1 3 , 2 4), x = (5 , 6)

$$A\mathbf{x} = 5\begin{pmatrix}1\\2\end{pmatrix} + 6\begin{pmatrix}3\\4\end{pmatrix} = \begin{pmatrix}5\\10\end{pmatrix} + \begin{pmatrix}18\\24\end{pmatrix} = \begin{pmatrix}23\\34\end{pmatrix}$$

잠깐 풀어보기 : Linear combination·Span

문제 1 (계산)

$v_1 = (1, 1)^T$ 과 $v_2 = (1, -1)^T$ 이 주어졌다 . $(3, 5)^T$ 을 두 Vector 의 Linear combination $\alpha_1 v_1 + \alpha_2 v_2$ 로 표현하시오 .

문제 2 (개념)

다음 Span 을 그림 또는 말로 묘사하시오 (직선 · 평면 · 공간 전체 · 한 점 중 어느 것 ?).

(i) $\text{span}((1, 0)^T, (0, 1)^T, (1, 1)^T) \subset \mathbb{R}^2$

(ii) $\text{span}((1, 2, 0)^T, (2, 4, 0)^T) \subset \mathbb{R}^3$

(iii) $\text{span}(0) \subset \mathbb{R}^n$

잠깐 풀어보기 : 답

문제 1

$\alpha_1 + \alpha_2 = 3$, $\alpha_1 - \alpha_2 = 5 \rightarrow \alpha_1 = 4$, $\alpha_2 = -1$.

$$\therefore (3,5)^\top = 4\,(1,1)^\top - 1\,(1,-1)^\top$$

검증 : $4(1,1)^T - (1,-1)^T = (4,4)^T - (1,-1)^T = (3,5)^T$ ✓

문제 2

(i) $(1,1)^T = (1,0)^T + (0,1)^T$ 이므로 셋째 Vector 는 처음 둘의 Linear combination 이다 . 처음 두 Vector 만으로 이미 $\mathbb{R}^2$ 전체를 Span 한다 . → $\mathbb{R}^2$ **전체** (평면 전체).

(ii) $(2, 4, 0)^T = 2 \cdot (1, 2, 0)^T$ 이므로 두 Vector 가 평행하다 . → **xy 평면 위의 한 직선** ($(1, 2, 0)^T$ 방향).

D. CS·AI 적용 : 데이터를 Vector 로

본 회차에서 본 수학이 AI 에서 어디에 등장하는가 .

손글씨 숫자 데이터셋 **MNIST**: 28×28 픽셀 흑백 이미지 70,000 장 .

표현	객체	차원
이미지 한 장	28×28 픽셀 격자	2D 배열
펼친 형태 (flatten)	길이 784 Vector	$\mathbb{R}^{784}$
데이터셋 전체	n × 784 표	$\mathbb{R}^{n \times 784}$ Matrix

펼치는 이유 : 픽셀의 공간 구조는 **CNN** (Part 4 6 회차) 에서 다시 살린다 . 우선은 **" 한 장 = 한 Vector"** 로 보는 것이 LA 의 표준 환원이다 .

D-1. 이미지를 Vector 로 : Flatten 의 의미

직관 (Flatten 의 의미): 28 × 28 격자 픽셀을 $\mathbb{R}^{784}$ Vector 로 펼치는 일은 2 차원 인덱스 (i, j) 를 1 차원 인덱스 k = 28i + j 로 재배열하는 일이다 . 픽셀 값 자체는 보존되지만 행 · 열 인접 관계 (공간 구조) 는 인덱스 안에 암묵화된다 . 이 표현이 LA 의 표준 환원이며 , 공간 구조를 명시적으로 활용하는 표현은 Part 4 6 회차 CNN·Toeplitz 에서 다시 도입한다 .

D-2. MNIST 평균 이미지 : 두 연산만으로

0 회차 시그니처 예제을 재해석한다 .

숫자 "7" 인 이미지 1,000 장 $x_1, x_2, \ldots, x_{1000} \in \mathbb{R}^{784}$ 의 **평균 Vector**:

$\Sigma_{i=1}^{k}$ 는 i=1 부터 k 까지의 항을 모두 더하라는 표기입니다 .

$$\mathbf{m} = \frac{1}{1000}\sum_{i=1}^{1000}\mathbf{x}_i = \frac{1}{1000}(\mathbf{x}_1 + \mathbf{x}_2 + \cdots + \mathbf{x}_{1000})$$

이 식에 본 회차 내용이 담긴다 :

" 이미지를 Vector 로 본다 ", **B 섹션 (Vector 정의)**

"Vector 들을 더한다 ", **B 섹션 (덧셈)**

"1/1000 을 곱한다 ", **B 섹션 (Scalar 곱)**

D-3. 텍스트 · 문서 · 사용자도 Vector 로

이미지뿐 아니라 모든 데이터가 Vector 로 환원된다 .

데이터	Vector 표현	차원
이미지 (MNIST)	픽셀 펼치기	$\mathbb{R}^{784}$
이미지 (ImageNet 224×224 RGB)	픽셀 펼치기	ℝ^150,528
단어 (Word2Vec)	Embedding(임베딩) 좌표	$\mathbb{R}^{300}$
문장 (BERT)	Embedding 좌표	$\mathbb{R}^{768}$
문장 (GPT-4)	Embedding 좌표	$\mathbb{R}^{3072}$ (추정)
사용자 (Netflix)	영화별 평점	ℝ^17,000 (영화 수)
유전자 발현	유전자별 발현량	ℝ^20,000

약어 안내 : CNN(Convolutional Neural Network, 이미지 등 격자형 입력 신경망), Word2Vec·BERT·GPT-4 는 대표적 단어 · 문장 임베딩 · 언어 모델 . 정식 분해는 Part 4.

D-4. Embedding(임베딩): 의미를 Vector 로

직관 (Embedding 의 의미): Embedding 은 단어 · 문장 등 비수치 객체를 $\mathbb{R}^d$ 의 한 점으로 보내는 함수이다 . 의미적으로 가까운 객체는 $\mathbb{R}^d$ 안에서 거리가 작도록 , 의미적으로 먼 객체는 거리가 크도록 학습한다 . 이렇게 얻은 좌표 위에서는 Norm·Inner product (2 회차) 가 곧바로 의미 유사도의 척도가 된다 .

Embedding 의 한 줄 정의

문장 · 이미지 · 사용자 등 임의 객체를 $\mathbb{R}^d$ Vector 로 보내는 함수 , 학습으로 얻는다 .

Vector 여야 하는 이유

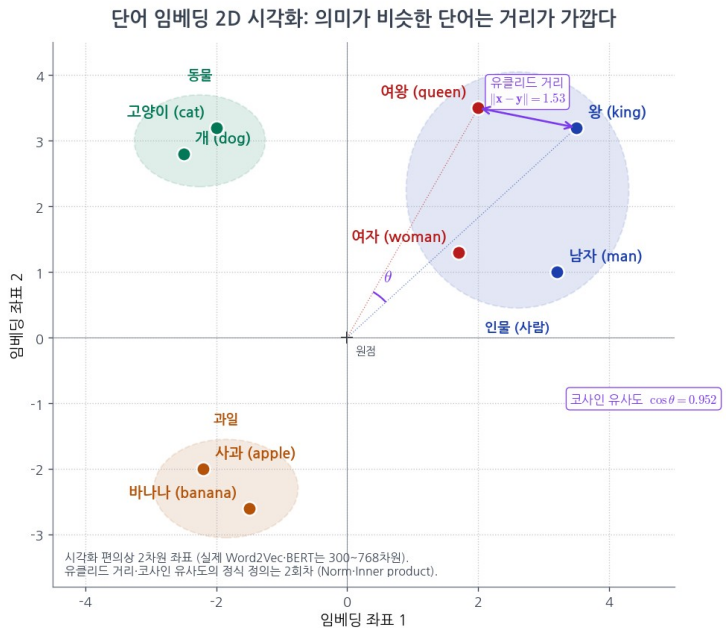
Vector 면 **덧셈 ·Scalar 곱**이 정의됨 → 평균 · 차이 등 계산 가능

다음 회차의 **Norm·Inner product** 가 정의됨 → 거리 · 각도 계산 가능

Matrix 곱 (3 회차) → **신경망 한 층 통과** 가능

D-4 그림으로 : 단어 임베딩 2D 시각화

같은 의미 그룹 (인물 · 동물 · 과일) 안의 단어들이 평면 위에서 **가까운 점**으로 모인다 . 단어 사이 거리는 곧 의미 거리이다 . 거리 (‖x-y‖) 와 각도 (코사인 유사도) 의 정식 정의는 2 회차에서 도입한다 .



D-5. 신경망 한 뉴런 미리보기

가장 간단한 인공 뉴런 :

$$y = w_1 x_1 + w_2 x_2 + \cdots + w_n x_n + b$$

여기서 $x = (x_1, \ldots, x_n)^T$ = 입력 Vector, $w = (w_1, \ldots, w_n)^T$ = 가중치 Vector.

D-5. 신경망 한 뉴런 : 두 연산과의 연결

이 식의 의미 :

w_i x_i 의 합 = **가중치 Vector 와 입력 Vector 의 곱셈 합** → **Inner product** (2 회차)

더 일반화 : y = Wx + b → **Matrix·Vector 곱** (3 회차)

b 는 Bias(편향): 출력을 평행이동시키는 상수 Vector 이다 (5 회차 ·Part 2 2 회차에서 본격).

→ 본 회차에서 본 Vector 정의 + 두 연산이 곧 **신경망의 한 줄**이다 . 뉴런 한 개의 출력 = 입력 Vector 의 한 가지 Linear combination + Bias.

E-1. 코딩 실습 (필요 시): 골자

→ Colab으로 실행

Colab 실습 정책 : 매 회차 필수 X. 회차별 학습 가치에 따라 1-2 개 또는 그 이상으로 운영한다 . 본 회차는 0 회차에서 이미 MNIST 평균을 다뤘으니 $\mathbb{R}^2$ **Span 시각화**가 가장 유의미한 활동이다 . 시간이 부족하면 수학 정리 · 마무리 문제로 마치고 코딩은 과제로 돌릴 수 있다 .

핵심 활동 : $\mathbb{R}^2$ Span 시각화

두 비평행 Vector $v_1, v_2 \in \mathbb{R}^2$ 를 정한다 .

격자 계수 $(\alpha, \beta) \in [-2, 2] \times [-2, 2]$ 에 대해 $\alpha v_1 + \beta v_2$ 를 그린다 .

평면 전체가 채워짐을 눈으로 확인한다 ($\text{span}(v_1, v_2) = \mathbb{R}^2$).

v_2 를 $2v_1$ 로 바꿨을 때 **한 직선으로 무너짐**도 비교 (평행하면 차원이 줄어든다).

보조 활동 (시간 남으면)

E-2. NumPy 핵심 패턴

```
import numpy as np

# Vector 만들기
u = np.array([1.0, -2.0, 3.0])
v = np.array([2.0, 0.0, -1.0])

# 두 연산
print(u + v)        # 덧셈
print(2 * u - 3 * v)  # Linear combination

# 표준 단위 Vector
e = np.eye(3)       # 3×3 단위 Matrix 의 각 열이 e1, e2, e3
e1 = e[:, 0]        # (1, 0, 0)

# Linear combination 을 한 줄로
vs = np.array([[1, 0], [0, 1], [1, 1]])  # 3 개 Vector 를 행으로
coefs = np.array([2, 3, -1])
result = coefs @ vs   # = 2*v1 + 3*v2 - v3

# MNIST → 784 차원 Vector
from sklearn.datasets import load_digits
data = load_digits()
X = data.data       # (1797, 64) — 한 행이 한 이미지의 64 차원 Vector
y = data.target     # (1797,) — 레이블
mean_seven = X[y == 7].mean(axis=0)  # (64,) — 7 의 평균 Vector
```

E-3. 차원 · 자료형 주의

NumPy 에서 흔히 만나는 함정 :

함정	증상	해결
np.array([1, 2]) + np.array([1, 2, 3])	shape 불일치 에러	차원 맞춘 뒤 덧셈
정수 Vector 에 0.5 곱	dtype 에 따라 잘림	.astype(float) 명시
Row vector vs Column vector	(n,) vs (n, 1) 혼동	LA 에선 Column 표준 , .reshape(-1, 1)
MNIST 픽셀 0~255 정수	평균에서 오버플로 가능성	.astype(np.float32) / 255.0

0 회차 노트북에서 `astype(float)` 을 한 이유 : 픽셀 평균을 계산할 때 정수형은 Scalar 곱이 깔끔하게 떨어지지 않습니다 . Vector space 의 두 연산이 잘 동작하려면 **실수 자료형**이 자연스럽습니다 .

E-4. 본 회차 핵심 5 개

Vector = 같은 차원 실수들의 순서 묶음 ($\mathbb{R}^n$) + **두 연산** (덧셈 ·Scalar 곱).

두 연산은 그림으로는 평행사변형 법칙과 늘이기 · 뒤집기이다 . **성분별**로 자연스럽게 동작한다 .

Linear combination = 두 연산을 섞은 일반 식 $\Sigma\, \alpha_i\, v_i$. " 선형 " 은 두 연산만 쓴다는 뜻이다 .

Span (직관) = 주어진 Vector 로 만들 수 있는 **모든 결과의 집합** . Vector 개수 ≠ 차원 (평행하면 차원이 줄어든다).

MNIST 이미지 1 장 = $\mathbb{R}^{784}$ **Vector**. 모든 AI 모델의 입력은 결국 Vector 로 환원된다 . 평균 이미지 = 계수 균등한 Linear combination.

E-5. 자기 점검 질문

$u = (1, 2, 3)^T$, $v = (-1, 0, 1)^T$ 일 때 $3u - 2v$ 는 ?

$\mathrm{span}((2, 4)^T, (1, 2)^T)$ 의 모양은 (직선 · 평면 · 한 점 중)?

$\mathbb{R}^n$ 의 임의 Vector 가 표준 단위 Vector $e_1, \ldots, e_n$ 의 Linear combination 으로 쓰이는 이유는 ?

- MNIST 28×28 이미지를 Vector 로 만들면 차원은 ? 1,000 장 데이터셋은 어떤 Matrix?
- " 선형 (linear)" 이란 단어의 정확한 의미는 무엇입니까 ? 무엇이 허용되고 무엇이 금지됩니까 ?

본 회차 마무리 문제 (즉석 풀이)

본 회차 학습 흐름 (Vector → 두 연산 → Linear combination → Span → MNIST) 을 **한 문제**로 종합합니다 .

$v_1 = (1, 0, 1)^T$, $v_2 = (0, 1, 1)^T$, $v_3 = (1, 1, 2)^T$ 가 $\mathbb{R}^3$에 주어졌다 .

(a) $w = 2v_1 + 3v_2 - v_3$ 를 계산하시오 .

(b) v_3 를 v_1, v_2 의 Linear combination 으로 표현할 수 있는가 ? 가능하면 계수를 구하시오 .

(c) $\text{span}(v_1, v_2, v_3)$ 는 $\text{span}(v_1, v_2)$ 와 같은 집합인가 ? 그 이유는 ?

(d) $\text{span}(v_1, v_2)$ 는 $\mathbb{R}^3$의 어떤 모양인가 (직선 · 평면 · 전체 중)?

본 회차 마무리 문제 : 답

(a) $2v_1 = (2, 0, 2)^T$, $3v_2 = (0, 3, 3)^T$, $-v_3 = (-1, -1, -2)^T$

합 : $(2-1, 0+3-1, 2+3-2)^T = (1, 2, 3)^T$

(b) $v_3 = (1, 1, 2)^T = (1, 0, 1)^T + (0, 1, 1)^T = v_1 + v_2$. 가능하며 , **계수 (1, 1)**.

(c) 같은 집합이다 . v_3 가 v_1, v_2 의 Linear combination 이므로 v_3 를 추가해도 새로 만들 수 있는 Vector 가 없다 . ($\alpha_1v_1 + \alpha_2v_2 + \alpha_3v_3 = (\alpha_1+\alpha_3)v_1 + (\alpha_2+\alpha_3)v_2$ 로 정리 가능)

(d) v_1, v_2 는 평행이 아니다 (한쪽이 다른 쪽의 Scalar 배가 아니다). 따라서 $\mathbb{R}^3$의 **한 평면** (원점을 지나는).

다음 회차 Review 용 숙제

위 마무리 문제의 **유사 문제**이다 . 강의 후 풀어 와서 **2 회차 Review 시간**에 비교한다 .

$u_1 = (1, 2)^T$, $u_2 = (3, 4)^T$, $u_3 = (5, 6)^T$ 이 $\mathbb{R}^2$에 주어졌다 .

(a) $w = u_1 - 2u_2 + u_3$ 를 계산하시오 .

(b) u_3 를 u_1, u_2 의 Linear combination 으로 표현할 수 있는가 ? 가능하면 계수를 구하시오 . (힌트 : 연립방정식)

(c) span(u_1, u_2, u_3) 는 $\mathbb{R}^2$의 어떤 모양인가 ?

(d) MNIST 한 장의 이미지를 $\mathbb{R}^{784}$ Vector x 로 펼쳤다 . 표준 단위 Vector e_1, …, e_{784} (e_i = 위치 i 만 1, 나머지 0) 의 Linear combination 으로 x 를 표현하는 식을 **한 줄로** 적으시오 . (각 픽셀을 손으로 다 풀어쓰라는 것이 아니라 , 시그마 한 줄로 충분합니다 .)

E-6. 과제 안내

04_ 과제 /Part1/01 회차 _homework.md — 마감 : 2 회차 시작 전

수학

- 두 연산 계산 (덧셈 ·Scalar 곱 ·Linear combination), 5 문제
- Span 의 모양 식별 (직선 · 평면 · 전체), 3 문제
- 한 Vector 가 다른 Vector 들의 Linear combination 인지 판정 , 3 문제 (연립방정식 풀기)

표준 단위 Vector e_i 를 사용한 분해 , 2 문제

코딩

- NumPy 로 Vector 생성 · 두 연산 ·Linear combination 구현

E-7. 다음 회차 (2 회차) 예고

주제 : Length(길이 , Norm) · Dot product(내적) · 각도 · Cauchy-Schwarz · Cosine similarity

연결 : 본 회차에서 본 Vector 와 두 연산만으로는 " 두 Vector 가 얼마나 비슷한가 " 를 잴 수 없습니다 . 2 회차에서 **Norm**(길이) 과 **Inner product**(내적) 라는 두 도구를 도입하여 거리 · 각도 · 코사인 유사도를 정의합니다 . 0 회차 Review 에서 가져온 "MNIST 숫자 7 과 새 이미지의 가까움 " 이 수학적으로 정의됩니다 .

3 회차 예고 : 본 회차에서 본 Linear combination = Matrix·Vector 곱의 Column picture (3 회차에서 본격).

사전 reading:

부록 : MML §2.1 · Strang Ch 1.1 추천 연습문제

본 회차에서 다룬 내용을 손으로 더 다루어 보고 싶은 학생을 위한 안내입니다 (모두 자율).

교재	주제	난도
MML §2.1 Exercise: Vector·$\mathbb{R}^n$·linear combination 기초	$\mathbb{R}^n$ 두 연산 ·linear combination 계산	하 · 중
Strang Ch 1.1 Problem 1-3	평행사변형 법칙 · 두 Vector 합	하
Strang Ch 1.1 Problem 5-8	Linear combination 계수 구하기	중
Strang Ch 1.1 Problem 11-13	$\mathbb{R}^3$ 에서 Span 의 모양 식별	중
Strang Ch 1.1 Problem 17-20	표준 단위 Vector· 임의 Vector 분해	중
Strang Ch 1.1 Problem 23, 25	" 두 Vector 의 모든 Linear combination 이 평면을 이룬	상

MML §2.1 은 정식 정의를 다지고 , Strang Ch 1.1 연습문제는 **개념 검증용 + 손계산용**이 섞여 있습니다 . 본문을 읽고 3~5 문제를 풀면 다음 회차 진입이 부드러워집니다 .

Q & A

본 회차 학습 흐름 :

Vector ($\mathbb{R}^n$) → 두 연산 (덧셈 ·Scalar 곱) → Linear combination → Span(직관) → MNIST 이미지 Vector

요약 : **데이터는 $\mathbb{R}^d$ Vector 로 표현되고 , 두 연산이 그 위의 기본 도구다 .**

다음 회차의 출발 문제 :

두 Vector 의 **길이**와 **각도**를 어떻게 정의하면 자연스러운가 ?

HANDOUT: 본 PDF + 01_ 벡터 _ 선형결합 .ipynb