

1회차

Vector(벡터)· $\mathbb{R}^n$ ·Linear combination(선형결합)

Strang §1.1 · EoLA Ch.1 · (MML 참조 X)

Part 1 첫 회차 — $\mathbb{R}^n$ 위에서 가장 단순한 두 연산(덧셈·Scalar곱)부터 시작합니다.

$\mathbb{R}^n$ 은 n 개 실수를 한 묶음으로 본 공간입니다 (정확한 정의는 B-2).

Review — 0회차 마무리 문제

지난 회차 마지막에 가져갔던 세 문제 (0회차 객체만으로 답합니다):

- (a) MNIST 숫자 "7" 이미지 n 장 $\mathbf{x}_1, \dots, \mathbf{x}_n$ 의 평균 이미지 $\mathbf{m}$ 을 Vector·Linear combination 두 단어를 모두 써서 한 줄로 표기.
- (b) Self-attention $\text{softmax}(QK^\top / \sqrt{d_k})V$ 의 5층 건물 매핑 중 두 층.
- (c) 30회차 강좌 구조 (Part 1·2·3 회차 수와 1회차당 시간).

답

- (a) 평균 Vector의 정의식

$$\mathbf{m} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i = \frac{1}{n} \mathbf{x}_1 + \frac{1}{n} \mathbf{x}_2 + \dots + \frac{1}{n} \mathbf{x}_n.$$

"각 이미지를 $\frac{1}{n}$ 배율로 합친" **Linear combination(선형결합)** 이고, 그 결과 자체가 또 하나의 **Vector(벡터)** $\in \mathbb{R}^{784}$ 입니다.

- (b) 5층 건물 매핑 예시 (둘 중 어느 쪽이든 가능):
 - **Vector·Matrix 곱**: $QK^\top$, $\text{softmax}(\cdot)$ V 가 모두 Matrix·Vector 곱(또는 Matrix·Matrix 곱). 3회차의 주제.
 - **Inner product(내적)**: $QK^\top$ 의 각 원소가 Q 의 한 행과 K 의 한 행의 내적(Dot product). 2회차의 주제.
 - (참고: Vector space는 1회차, Norm은 2회차, Matrix·Vector 곱은 3회차에 정식 도입됩니다.)

오늘의 핵심 질문

"수의 묶음"을 한 객체로 본다는 것은 무엇이고, 그 객체로 무엇을 할 수 있습니까?

이 한 질문에 답하려면 세 단계가 필요합니다.

1. **Vector**가 무엇이고 어떤 공간 $\mathbb{R}^n$ 에 살고 있는지
2. 두 연산 — 덧셈·Scalar(스칼라)곱 — 이 자연스럽다는 사실
3. **Linear combination(선형결합) · Span(생성공간)** — 두 연산이 만들어내는 모든 결과의 집합

오늘 회차의 모든 것이 이 사슬 위에 있습니다. 강의 중간에 길을 잃으면 이 질문으로 돌아옵니다.

학습 목표

이번 회차가 끝나면 학생은 다음을 답할 수 있어야 합니다.

1. **Vector**의 수학적 정의 + "왜 그렇게 생겼는지"를 물리·대수·데이터 세 관점에서 설명할 수 있습니다.
2. $\mathbb{R}^n$ 에서의 덧셈·**Scalar**곱 두 연산을 손계산으로 자유롭게 수행할 수 있습니다.
3. ****Linear combination(선형결합)****의 정의 + "왜 '선형(linear)'이라 부르는가"를 설명할 수 있습니다.
4. **Span(생성공간)**의 직관 — 주어진 Vector들로 만들 수 있는 모든 결과의 집합 — 을 설명할 수 있습니다.
5. **MNIST** 이미지를 $\mathbb{R}^{784}$ **Vector**로 보는 환원·평균 이미지 계산을 NumPy로 수행할 수 있습니다.

오늘의 논리 사슬

표의 식들($\alpha_1 \mathbf{v}_1 + \cdots$, span 등)은 C 섹션에서 정식 도입됩니다. 표는 오늘 사슬의 지도로 보시면 됩니다.

질문	답 (이 강의의 답)	도구
"수의 묶음"을 한 객체로?	Vector 의 정의	$\mathbf{x} \in \mathbb{R}^n$
그 객체에 가능한 두 연산?	덧셈·Scalar곱	$\mathbf{x} + \mathbf{y}, \alpha \mathbf{x}$
두 연산을 섞으면?	Linear combination	$\alpha_1 \mathbf{v}_1 + \cdots + \alpha_k \mathbf{v}_k$
모든 결과의 집합?	Span (직관)	$\text{span}(\cdots)$
가장 친숙한 예?	MNIST 이미지 $\in \mathbb{R}^{784}$	평균 이미지
다음 회차로?	길이·각도	Norm · Inner product (2회차)

이 사슬을 한 회차에 완주합니다. 추상 정의(Vector space 8 axioms · Subspace 정식 정의 · 일차독립)는 의도적으로 미룹니다 — 7~9 회차에서 정식 도입합니다.

수업 흐름

순서	블록	내용
①	A	오프닝 — 핵심 질문 + 0회차 Review + 오늘의 사슬
②	B	Vector — 동기 3가지 + $\mathbb{R}^n$ 정의 + 두 연산 + 직관 예제
③	C	Linear combination · Span(직관) + 3회차 미리보기
④	D	CS·AI 적용 — MNIST·텍스트·임베딩
⑤	E	코딩 실습 + 클로징 — NumPy · MNIST 1장 · 마무리 문제

표준 사이클: 핵심 질문 → Review → 본 강의 → 마무리 문제 → 숙제(=다음 회차 Review)

B와 C가 오늘의 심장입니다.

B. Vector — 동기와 정의

"왜 Vector가 필요한가?" 세 가지 동기로 시작합니다.

B-1. Vector가 왜 생겼는가 — 세 가지 동기

(i) 물리적 동기: 크기 + 방향이 필요한 양 (변위·속도·힘)

- "북쪽 3 m"와 "동쪽 3 m"는 다릅니다 — 같은 크기지만 방향이 다르면 다른 양.
- 두 변위의 합 = **평행사변형 법칙**.

(ii) 대수적 동기: 동시에 여러 양을 다루기

- $\begin{cases} 2x + 3y = 5 \\ x - y = 1 \end{cases}$ — (x, y) 를 한 묶음으로 봅니다.
- 미지수가 100개라면 묶음 없이는 식조차 쓸 수 없습니다.

(iii) 데이터적 동기 (AI): 측정값의 묶음

- 이미지 한 장 = 픽셀 784개의 묶음
- 문서 한 개 = Embedding 좌표 768개의 묶음
- 사용자 한 명 = 영화 평점 100개의 묶음

Embedding(임베딩)은 단어·문장을 수의 묶음(Vector)으로 바꾼 좌표입니다. 정식 등장은 D-4.

세 동기 모두 **벡터 + Scalar** 곱이 자연스러운 두 연산입니다.

B-2. $\mathbb{R}^n$ 의 Vector — 형식적 정의

정의 1.1 ($\mathbb{R}^n$ 의 Vector)

n 개 실수 순서쌍입니다 — 이 강의의 기본 표기는 **Column vector(열벡터)**입니다.

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^n, \quad \mathbf{x}^\top = (x_1, x_2, \dots, x_n)$$

- $x_i \in \mathbb{R}$ 를 **성분(component)** 또는 **좌표(coordinate)**라 부릅니다.
- n 을 **차원(dimension)**이라 부릅니다 — $\mathbb{R}^3$ 의 Vector는 좌표 3개를 가진 한 점.
- 표기 관례: Vector는 굵게($\mathbf{x}$), Scalar는 보통체(α, x_i).

Row vector vs Column vector

표기 T ('transpose', 전치)는 세로 묶음을 가로 묶음으로 뒤집는 기호입니다. 정식 정의는 3회차.

- $\mathbf{x}$ = 세로 묶음 (Column), $\mathbf{x}^T$ = 가로 묶음 (Row).
- LA의 표준은 Column. Matrix·Vector 곱 $A\mathbf{x}$ 가 Column 기준으로 정의됩니다 (3회차).

표기 $A\mathbf{x}$ 는 Matrix와 Vector의 곱입니다. 정식 정의는 3회차.

B-3. 두 연산 — 덧셈 · Scalar곱

정의 1.2 (덧셈)

같은 차원의 두 Vector의 합은 성분별 합입니다.

$$\mathbf{x} + \mathbf{y} = \begin{pmatrix} x_1 + y_1 \\ x_2 + y_2 \\ \vdots \\ x_n + y_n \end{pmatrix}$$

차원이 다르면 합이 정의되지 않습니다 ($\mathbb{R}^3$ Vector + $\mathbb{R}^4$ Vector는 X).

정의 1.3 (Scalar 곱)

실수 $\alpha \in \mathbb{R}$ 와 Vector $\mathbf{x} \in \mathbb{R}^n$ 의 곱은 성분별 **Scalar 곱**입니다.

$$\alpha \mathbf{x} = \begin{pmatrix} \alpha x_1 \\ \alpha x_2 \\ \vdots \\ \alpha x_n \end{pmatrix}$$

- $\alpha > 0$: 같은 방향, 크기 α 배
- $\alpha < 0$: 반대 방향, 크기 $|\alpha|$ 배
- $\alpha = 0$: 영Vector $\mathbf{0} = (0, 0, \dots, 0)^\top$

B-4. 두 연산의 직관 — 그림으로

💡 파인만식 비유: Vector는 한 음식의 재료 묶음입니다. 햄버거 한 개를 (빵 2, 패티 1, 피클 5)로 적습니다 — 한 음식이 한 묶음 = 한 Vector. 두 개를 만들면 $2 \cdot (2, 1, 5)^T = (4, 2, 10)^T$ (Scalar곱). 다른 메뉴(샌드위치)와 함께 주문하면 두 묶음의 합으로 총 재료 수가 나옵니다 (덧셈). 즉 한 음식 = 한 Vector, 음식 개수·합치기가 곧 두 연산입니다.

그림 직관 ($\mathbb{R}^2$)

- $\mathbf{x} + \mathbf{y}$: $\mathbf{x}$ 의 끝에서 $\mathbf{y}$ 를 이어 붙이기 = 평행사변형 법칙
- $\alpha \mathbf{x}$ ($\alpha > 1$): $\mathbf{x}$ 를 같은 방향으로 늘리기
- $-\mathbf{x}$: $\mathbf{x}$ 를 뒤집기 (반대 방향)
- $\mathbf{0}$: 원점 (모든 성분 0)

예제

$\mathbf{u} = (1, 2)^T, \mathbf{v} = (3, 1)^T$ 일 때

$\mathbf{u} + \mathbf{v} = (4, 3)^T, 2\mathbf{u} = (2, 4)^T, \mathbf{u} - \mathbf{v} = (-2, 1)^T$

B-5. 두 연산이 잘 동작합니다: 6회차에서 정식화

$\mathbb{R}^n$ 에서 덧셈·Scalar곱이 가진 자연스러운 성질들:

- $\mathbf{u} + \mathbf{v} = \mathbf{v} + \mathbf{u}$ (교환법칙)
- $(\mathbf{u} + \mathbf{v}) + \mathbf{w} = \mathbf{u} + (\mathbf{v} + \mathbf{w})$ (결합법칙)
- $\mathbf{u} + \mathbf{0} = \mathbf{u}$ (덧셈 항등원)
- $\mathbf{u} + (-\mathbf{u}) = \mathbf{0}$ (역원)
- $\alpha(\beta\mathbf{u}) = (\alpha\beta)\mathbf{u}$
- $\alpha(\mathbf{u} + \mathbf{v}) = \alpha\mathbf{u} + \alpha\mathbf{v}$ 등 분배법칙

이 성질들을 한 데 묶어 **Vector space의 8 axioms(공리)**이라 부릅니다. 정식 정의는 6회차에서 도입합니다. 그때까지는 $\mathbb{R}^n$ 이 위 성질을 모두 만족한다는 사실만 받아들입니다.

왜 미루는가? 1~5회차는 $\mathbb{R}^n$ 이라는 친숙한 공간에서 충분히 손계산·시각화를 한 뒤, 6회차에서 "이 모든 성질을 가진 객체를 일반적으로 Vector space라 부르자"는 추상화로 자연스럽게 넘어가는 것이 학부 미이수자에게 가장 큰 부담이 적습니다.

B-6. 영Vector와 표준 단위Vector

영Vector

$$\mathbf{0} = (0, 0, \dots, 0)^\top \in \mathbb{R}^n$$

모든 Vector $\mathbf{x}$ 에 대해 $\mathbf{x} + \mathbf{0} = \mathbf{x}$, $0 \cdot \mathbf{x} = \mathbf{0}$. 원점에 해당합니다.

표준 단위Vector (Standard basis vector)

$\mathbb{R}^n$ 에서 i 번째 성분만 1이고 나머지는 0인 Vector:

$$\mathbf{e}_1 = \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \mathbf{e}_2 = \begin{pmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{pmatrix}, \dots, \mathbf{e}_n = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{pmatrix}$$

관찰: 임의의 $\mathbf{x} = (x_1, \dots, x_n)^\top$ 를

$$\mathbf{x} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2 + \dots + x_n \mathbf{e}_n$$

으로 쓸 수 있습니다 — 모든 Vector가 $\mathbf{e}_1, \dots, \mathbf{e}_n$ 의 Linear combination입니다. C 섹션의 핵심 출발점.

잠깐 풀어보기 — Vector·두 연산

옆 사람과 5분 토의 후 답을 종이에 적어보세요.

문제 1 (계산)

$\mathbf{u} = (1, -2, 3)^\top$, $\mathbf{v} = (2, 0, -1)^\top$ 일 때 다음을 계산하세요.

- (a) $\mathbf{u} + \mathbf{v}$
- (b) $2\mathbf{u} - 3\mathbf{v}$
- (c) $\mathbf{u}$ 와 같은 방향이지만 크기가 절반인 Vector

문제 2 (개념)

$\mathbb{R}^3$ 에서 $\mathbf{x} = 2\mathbf{e}_1 - 3\mathbf{e}_2 + 5\mathbf{e}_3$ 를 성분 표기 $(x_1, x_2, x_3)^\top$ 로 적으세요.

힌트: $\mathbf{e}_i$ 는 i 번째 성분만 1인 Vector. 각 항이 어느 성분에 기여하는지만 보면 됩니다.

잠깐 풀어보기 — 답

문제 1

- (a) $\mathbf{u} + \mathbf{v} = (1 + 2, -2 + 0, 3 + (-1))^{\top} = (3, -2, 2)^{\top}$
- (b) $2\mathbf{u} = (2, -4, 6)^{\top}, 3\mathbf{v} = (6, 0, -3)^{\top}. 2\mathbf{u} - 3\mathbf{v} = (-4, -4, 9)^{\top}$
- (c) $\frac{1}{2}\mathbf{u} = (0.5, -1, 1.5)^{\top}$ — Scalar $\alpha = 1/2$ 로 곱하면 됩니다.

문제 2

$$\mathbf{x} = 2\mathbf{e}_1 - 3\mathbf{e}_2 + 5\mathbf{e}_3 = (2, -3, 5)^{\top}$$

메시지: 표준 단위Vector를 사용한 표현이 곧 성분 표기입니다. 거꾸로 모든 성분 표기는 $\mathbf{e}_i$ 의 Linear combination으로 풀어쓸 수 있습니다 — C 섹션에서 본격 사용합니다.

C. Linear combination · Span (직관)

오늘 회차의 두 번째 심장. 두 연산을 섞어 쓰면 무엇이 만들어지는가.

C-1. Linear combination — 정의

정의 1.4 (Linear combination)

Vector $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_k \in \mathbb{R}^n$, Scalar $\alpha_1, \alpha_2, \dots, \alpha_k \in \mathbb{R}$ 에 대해

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k \in \mathbb{R}^n$$

를 **Linear combination(선형결합)**이라 부릅니다. α_i 를 **계수(coefficient)**라 합니다.

예제

- $\mathbf{v}_1 = (1, 0)^\top, \mathbf{v}_2 = (0, 1)^\top$ 이면
 - $3\mathbf{v}_1 + 2\mathbf{v}_2 = (3, 2)^\top$
 - $-1\mathbf{v}_1 + 5\mathbf{v}_2 = (-1, 5)^\top$
- 계수 (α_1, α_2) 를 바꿀 때마다 다른 Vector가 나옵니다.

💡 **파인만식 비유:** Linear combination은 여러 메뉴를 비율로 섞어 한 도시락 만들기입니다. 햄버거($\mathbf{v}_1$) 비중 $\alpha_1 = 2$, 샌드위치($\mathbf{v}_2$) 비중 $\alpha_2 = 1$, 샐러드($\mathbf{v}_3$) 비중 $\alpha_3 = 0.5$ 로 한 도시락이 나옵니다. 비율(계수)만 바꾸면 다른 도시락이 됩니다.

계수 α_i 가 양수·음수·0 어느 것이든 가능합니다. 모두 0이면 결과는 영Vector $\mathbf{0}$.

C-2. "선형(linear)"이 무엇입니까

"Linear"는 덧셈과 Scalar곱이라는 두 연산만 사용한다는 뜻입니다.

표 안의 $\| \cdot \|$ 은 Vector의 길이(Norm)로, 정식 도입은 2회차입니다. 여기서는 "길이 계산이 들어간 표현"이라는 직관만 챙기면 됩니다.

허용 (linear)	금지 (비선형)
$\alpha \mathbf{v} + \beta \mathbf{w}$	$v_1 \cdot w_1$ (성분끼리 곱)
$-\mathbf{v}$	v_1^2 (성분 제곱)
$\mathbf{v} + \mathbf{w} + \mathbf{u}$	$\exp(v_1), \sin(v_1)$
$\frac{1}{3}(\mathbf{v}_1 + \mathbf{v}_2 + \mathbf{v}_3)$ (평균)	$\ \mathbf{v}\ ^2 \mathbf{w}$ (Norm 사용)

왜 이렇게 제한합니까? 두 연산만 쓰면 수학적 분석이 가능합니다. 비선형이 들어가면 대수 구조가 깨져 일반 이론이 어렵습니다. 그래서 LA는 "Linear"라는 한 단어에 모든 것이 응축됩니다.

AI 모델의 비선형성은? 신경망의 활성화 함수(ReLU·sigmoid 등)가 비선형 부분을 담당합니다. 가중치 곱·합은 linear, 활성화는 비선형, 두 부분이 분리되어 있어 각각을 따로 분석할 수 있습니다 (5·10회차). 예: ReLU는 $\max(0, x)$, sigmoid는 $1/(1 + e^{-x})$.

C-3. Span (직관) — 만들 수 있는 모든 Vector의 집합

정의 1.5 (Span, 직관적 정의)

Vector $\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^n$ 이 주어졌을 때, 가능한 모든 계수 $\alpha_1, \dots, \alpha_k$ 에 대한 Linear combination의 집합:

$$\text{span}(\mathbf{v}_1, \dots, \mathbf{v}_k) = \{\alpha_1 \mathbf{v}_1 + \dots + \alpha_k \mathbf{v}_k : \alpha_i \in \mathbb{R}\}$$

이를 **$\mathbf{v}_1, \dots, \mathbf{v}_k$ 의 Span(생성공간)**이라 부릅니다, "주어진 Vector로 만들 수 있는 모든 결과의 묶음".

💡 **파인만식 비유:** Span은 주어진 메뉴로 만들 수 있는 모든 도시락 묶음의 집합입니다. 햄버거·샌드위치·샐러드 세 메뉴가 있으면 그 세 메뉴의 비율을 바꾸며 무한히 많은 도시락을 만들 수 있지만, 본래 메뉴에 없는 재료(예: 카레)는 절대 만들 수 없습니다. 가진 메뉴가 도시락 영역을 결정합니다.

정식 정의는 8회차로 미룹니다, Subspace·Basis·Dimension과 함께 한꺼번에 다루는 것이 가장 자연스럽습니다. 오늘은 **"만들 수 있는 모든 결과의 집합"**이라는 직관까지만 챙기면 충분합니다.

C-4. Span의 직관 — 그림으로

$\mathbb{R}^2$ 의 예

- $\text{span}((1, 0)^\top) = x\text{축 직선}$ (모든 $\alpha(1, 0)^\top = (\alpha, 0)$)
- $\text{span}((1, 0)^\top, (0, 1)^\top) = \mathbb{R}^2 \text{ 전체}$ (모든 점이 $\alpha\mathbf{e}_1 + \beta\mathbf{e}_2$ 로 표현됨)
- $\text{span}((1, 1)^\top, (2, 2)^\top) = (1, 1)^\top \text{ 방향 직선}$ (두 Vector가 평행, 같은 메뉴를 두 번 든 셈)

$\mathbb{R}^3$ 의 예

- $\text{span}((1, 0, 0)^\top) = x\text{축 직선}$
- $\text{span}((1, 0, 0)^\top, (0, 1, 0)^\top) = xy \text{ 평면}$
- $\text{span}((1, 0, 0)^\top, (0, 1, 0)^\top, (0, 0, 1)^\top) = \mathbb{R}^3 \text{ 전체}$

핵심 관찰

Vector 개수 $\neq$ Span의 차원입니다. $(1, 1)^\top$ 과 $(2, 2)^\top$ 는 두 개지만 Span은 1차원 직선. "진짜 다른 방향"이 몇 개인가가 차원입니다, 8 회차에서 **Linear independence**로 정식화합니다.

C-5. 표준 단위Vector의 Span은 $\mathbb{R}^n$ 전체

B-6에서 봤듯 임의의 $\mathbf{x} \in \mathbb{R}^n$ 가

$$\mathbf{x} = x_1\mathbf{e}_1 + x_2\mathbf{e}_2 + \cdots + x_n\mathbf{e}_n$$

으로 표현됩니다. 따라서

$$\text{span}(\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n) = \mathbb{R}^n$$

→ $\mathbb{R}^n$ 전체가 n 개 표준 단위Vector의 Span입니다. 이것이 $\mathbb{R}^n$ 이라는 공간을 가장 자연스럽게 " n 차원"이라 부르는 이유입니다.

일반화 — Basis의 직관

$\mathbb{R}^n$ 을 Span하는 "최소한의 Vector 집합"이 곧 **Basis(기저)**입니다. 표준 단위Vector $\{\mathbf{e}_1, \dots, \mathbf{e}_n\}$ 이 **표준 Basis**.

Basis·Dimension의 정식 정의는 8회차입니다. 오늘은 " $\mathbf{e}_1, \dots, \mathbf{e}_n$ 로 $\mathbb{R}^n$ 전체를 만들 수 있다"는 직관만 챙깁니다.

C-6. Linear combination = Matrix·Vector 곱 (3회차 미리보기)

오늘 본 Linear combination은 곧 **Matrix·Vector 곱**과 같은 것입니다.

표기 $\mathbb{R}^{m \times n}$ 은 m 행 n 열 실수 Matrix의 공간입니다. 정식 도입은 3회차.

$A \in \mathbb{R}^{m \times n}, \mathbf{x} \in \mathbb{R}^n$. A 의 열을 $\mathbf{a}_1, \dots, \mathbf{a}_n$ 이라 쓰면

$$A\mathbf{x} = x_1\mathbf{a}_1 + x_2\mathbf{a}_2 + \dots + x_n\mathbf{a}_n$$

Matrix·Vector 곱 = A 의 열들의 **Linear combination**입니다 (Column picture 해석).

예시

$$A = \begin{pmatrix} 1 & 3 \\ 2 & 4 \end{pmatrix}, \mathbf{x} = \begin{pmatrix} 5 \\ 6 \end{pmatrix}$$

$$A\mathbf{x} = 5 \begin{pmatrix} 1 \\ 2 \end{pmatrix} + 6 \begin{pmatrix} 3 \\ 4 \end{pmatrix} = \begin{pmatrix} 5 \\ 10 \end{pmatrix} + \begin{pmatrix} 18 \\ 24 \end{pmatrix} = \begin{pmatrix} 23 \\ 34 \end{pmatrix}$$

→ 3회차에서 **Row picture**와 **Column picture** 두 해석을 정식 도입합니다. 오늘은 "Matrix·Vector 곱이 사실 Linear combination이더라"라는 사실만 미리 봅니다.

잠깐 풀어보기 — Linear combination · Span

문제 1 (계산)

$\mathbf{v}_1 = (1, 1)^\top$ 과 $\mathbf{v}_2 = (1, -1)^\top$ 이 주어졌습니다. $(3, 5)^\top$ 을 두 Vector의 Linear combination $\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2$ 로 표현하세요.

문제 2 (개념)

다음 Span을 그림 또는 말로 묘사하세요 (직선·평면·공간 전체·한 점 중 어느 것?).

- (i) $\text{span}((1, 0)^\top, (0, 1)^\top, (1, 1)^\top) \subset \mathbb{R}^2$
- (ii) $\text{span}((1, 2, 0)^\top, (2, 4, 0)^\top) \subset \mathbb{R}^3$
- (iii) $\text{span}(\mathbf{0}) \subset \mathbb{R}^n$

힌트: 두 Vector가 평행하면 Span은 한 직선에 머물립니다. $\mathbf{0}$ 만으로는 자기 자신밖에 못 만듭니다.

잠깐 풀어보기 — 답

문제 1

$$\alpha_1 + \alpha_2 = 3, \alpha_1 - \alpha_2 = 5 \rightarrow \alpha_1 = 4, \alpha_2 = -1.$$

$$\therefore (3, 5)^\top = 4(1, 1)^\top - 1(1, -1)^\top$$

$$\text{검증: } 4(1, 1)^\top - (1, -1)^\top = (4, 4)^\top - (1, -1)^\top = (3, 5)^\top \checkmark$$

문제 2

- (i) $(1, 1)^\top = (1, 0)^\top + (0, 1)^\top$ 이라 셋째 Vector는 처음 둘의 Linear combination. 처음 두 Vector만으로 이미 $\mathbb{R}^2$ 전체를 Span. $\rightarrow \mathbb{R}^2$ 전체 (평면 전체).
- (ii) $(2, 4, 0)^\top = 2 \cdot (1, 2, 0)^\top$ 이라 두 Vector가 평행. $\rightarrow$ xy평면 위의 한 직선 $((1, 2, 0)^\top$ 방향).
- (iii) $\alpha \cdot \mathbf{0} = \mathbf{0}$ 이라 어떤 α 를 잡아도 $\mathbf{0}$. $\rightarrow$ 원점 한 점만.

메시지: Vector 개수 = Span 차원이 아닙니다. "진짜 다른 방향" 개수가 차원입니다. 8회차에서 **Linear independence**로 정식화합니다.

D. CS·AI 적용 — 데이터를 Vector로

오늘 본 수학이 AI에서 어디에 등장하는가.

D-1. 이미지를 Vector로 — MNIST

손글씨 숫자 데이터셋 **MNIST**: 28×28 픽셀 흑백 이미지 70,000장.

표현	객체	차원
이미지 한 장	28×28 픽셀 격자	2D 배열
펼친 형태 (flatten)	길이 784 Vector	$\mathbb{R}^{784}$
데이터셋 전체	$n \times 784$ 표	$\mathbb{R}^{n \times 784}$ Matrix

왜 펼칩니까? 픽셀의 공간 구조는 **CNN(Part 3 6회차)**에서 다시 살립니다. 우선은 **"한 장 = 한 Vector"**로 보는 것이 LA의 표준 환원입니다.

 **파인만식 비유:** 28×28 이미지를 펼치는 것은 책장을 한 줄로 늘어놓는 것과 같습니다. 책장에서는 어떤 책이 위·아래 칸인지 보였지만, 한 줄로 늘어놓으면 그 정보가 사라집니다. 공간 정보는 일부 잃지만 대신 "한 묶음의 수"라는 단순한 객체가 됩니다. AI 학습 초기엔 이 단순함이 더 큰 무기입니다, 모든 모델·연산을 통일된 객체로 처리할 수 있기 때문입니다.

D-2. MNIST 평균 이미지 — 두 연산만으로

0회차 시그니처 시연 재해석:

숫자 "7"인 이미지 1,000장 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_{1000} \in \mathbb{R}^{784}$ 의 **평균 Vector**:

$\sum_{i=1}^k$ 는 $i = 1$ 부터 k 까지의 항을 모두 더하라는 표기 (고교 시그마).

$$\mathbf{m} = \frac{1}{1000} \sum_{i=1}^{1000} \mathbf{x}_i = \frac{1}{1000} (\mathbf{x}_1 + \mathbf{x}_2 + \dots + \mathbf{x}_{1000})$$

이 한 식 안에 오늘 배운 모든 것:

- "이미지를 Vector로 본다" — B 섹션 (Vector 정의)
- "Vector들을 더한다" — B 섹션 (덧셈)
- " $\frac{1}{1000}$ 을 곱한다" — B 섹션 (Scalar곱)
- " $\frac{1}{n} \sum$ 자체" — C 섹션 (계수가 모두 $\frac{1}{1000}$ 인 Linear combination)

→ 평균 이미지 = 모든 이미지의 **Linear combination** (계수가 균등). 결과는 "7의 본질" 같은 흐릿한 7 모양으로 나타납니다 (0회차에서 본 그림).

D-3. 텍스트·문서·사용자도 Vector로

이미지뿐 아니라 모든 데이터가 Vector로 환원됩니다.

데이터	Vector 표현	차원
이미지 (MNIST)	픽셀 펼치기	$\mathbb{R}^{784}$
이미지 (ImageNet 224×224 RGB)	픽셀 펼치기	$\mathbb{R}^{150,528}$
단어 (Word2Vec)	Embedding(임베딩) 좌표	$\mathbb{R}^{300}$
문장 (BERT)	Embedding 좌표	$\mathbb{R}^{768}$
문장 (GPT-4)	Embedding 좌표	$\mathbb{R}^{3072}$ (추정)
사용자 (Netflix)	영화별 평점	$\mathbb{R}^{17,000}$ (영화 수)
유전자 발현	유전자별 발현량	$\mathbb{R}^{20,000}$

약어 안내: CNN(Convolutional Neural Network, 이미지 등 격자형 입력 신경망), Word2Vec·BERT·GPT-4는 대표적 단어·문장 임베딩·언어 모델. 정식 분해는 Part 3.

모든 AI 모델의 입력 = $\mathbb{R}^d$ Vector입니다. 이미지는 작은 d , 텍스트는 중간, 유전자는 큰 d .

D-4. Embedding(임베딩) — 의미를 Vector로

💡 파인만식 비유: Embedding은 단어를 지도 위의 한 점으로 옮기는 일입니다. "강아지"와 "개"는 지도에서 가까이, "강아지"와 "비행기"는 멀리 놓습니다. 의미적 거리 = 공간적 거리가 되도록 좌표를 학습합니다. 그러면 의미를 비교하는 일이 곧 Vector 거리를 재는 일이 됩니다.

Embedding의 한 줄 정의

문장·이미지·사용자 등 임의 객체를 $\mathbb{R}^d$ Vector로 보내는 함수, 학습으로 얻습니다.

왜 Vector여야 합니까?

- Vector면 덧셈·Scalar곱이 정의됨 → 평균·차이 등 계산 가능
- 다음 회차의 Norm·Inner product가 정의됨 → 거리·각도 계산 가능
- Matrix 곱 (3회차) → 신경망 한 층 통과 가능

→ AI 모델은 모든 입력을 Vector로 바꾸는 것에서 시작합니다. 이것이 오늘 회차의 결론.

D-5. 신경망 한 뉴런 미리보기

가장 간단한 인공 뉴런:

$$y = w_1x_1 + w_2x_2 + \cdots + w_nx_n + b$$

여기서 $\mathbf{x} = (x_1, \dots, x_n)^\top$ = 입력 Vector, $\mathbf{w} = (w_1, \dots, w_n)^\top$ = 가중치 Vector.

이 식의 본질:

- w_ix_i 의 합 = 가중치 Vector와 입력 Vector의 곱셈 합 $\rightarrow$ Inner product (2회차)
- 더 일반화: $\mathbf{y} = \mathbf{W}\mathbf{x} + \mathbf{b} \rightarrow$ Matrix·Vector 곱 (3회차)

b는 Bias(편향): 출력을 평행이동시키는 상수 Vector입니다 (5·10회차에서 본격).

$\rightarrow$ 오늘 본 Vector 정의 + 두 연산이 곧 **신경망의 한 줄**입니다. 뉴런 한 개의 출력 = 입력 Vector의 한 가지 Linear combination + Bias.

E-1. 코딩 실습 + 클로징 — 골자

→ 11_주피터노트북/Part1/01_벡터_R^n_MNIST.ipynb

1. NumPy로 Vector 만들기: `np.array([1, 2, 3])`, 차원 확인 (`.shape`, `.ndim`)
2. 덧셈·Scalar곱: `u + v`, `2 * u - 3 * v`
3. 표준 단위Vector: `np.eye(n)` 로 한 번에, 또는 `np.zeros(n)` + 인덱싱
4. Linear combination: 여러 Vector + 계수로 한 결과 만들기
5. MNIST 1장 로드: `sklearn.datasets.load_digits()` (8×8) 또는 `keras.datasets.mnist.load_data()` (28×28)
6. 이미지 → 784차원 Vector: `image.reshape(-1)` 또는 `image.flatten()`
7. 숫자별 평균 이미지: `X[y == k].mean(axis=0)` (0회차 시연 재현)

E-2. NumPy 핵심 패턴

```
import numpy as np

# Vector 만들기
u = np.array([1.0, -2.0, 3.0])
v = np.array([2.0, 0.0, -1.0])

# 두 연산
print(u + v)          # 덧셈
print(2 * u - 3 * v)  # Linear combination

# 표준 단위Vector
e = np.eye(3)          # 3x3 단위Matrix의 각 열이 e1, e2, e3
e1 = e[:, 0]           # (1, 0, 0)

# Linear combination을 한 줄로
vs = np.array([[1, 0], [0, 1], [1, 1]]) # 3개 Vector를 행으로
coefs = np.array([2, 3, -1])
result = coefs @ vs    # = 2*v1 + 3*v2 - v3

# MNIST → 784차원 Vector
from sklearn.datasets import load_digits
data = load_digits()
X = data.data          # (1797, 64) - 한 행이 한 이미지의 64차원 Vector
y = data.target        # (1797,) - 레이블
mean_seven = X[y == 7].mean(axis=0)    # (64,) - 7의 평균 Vector
```

E-3. 차원·자료형 주의

NumPy에서 흔히 만나는 함정:

함정	증상	해결
<code>np.array([1, 2]) + np.array([1, 2, 3])</code>	shape 불일치 에러	차원 맞춘 뒤 덧셈
정수 Vector에 <code>0.5</code> 곱	dtype에 따라 잘림	<code>.astype(float)</code> 명시
Row vector vs Column vector	<code>(n,)</code> vs <code>(n, 1)</code> 혼동	LA에선 Column 표준, <code>.reshape(-1, 1)</code>
MNIST 픽셀 0~255 정수	평균에서 오버플로 가능성	<code>.astype(np.float32) / 255.0</code>

0회차 노트북에서 `astype(float)` 을 한 이유: 픽셀 평균을 계산할 때 정수형은 Scalar 곱이 깔끔하게 안 떨어집니다. Vector space의 두 연산이 잘 동작하려면 실수 자료형이 자연스럽습니다.

E-4. 오늘 회차 핵심 5개

1. **Vector** = 같은 차원 실수들의 순서 묶음 ($\mathbb{R}^n$) + **두 연산**(덧셈·Scalar곱).
2. 두 연산은 그림으로는 평행사변형 법칙과 늘이기·뒤집기. **성분별로** 자연스럽게 동작합니다.
3. **Linear combination** = 두 연산을 섞은 일반 식 $\sum \alpha_i \mathbf{v}_i$. "선형"은 두 연산만 쓴다는 뜻.
4. **Span (직관)** = 주어진 Vector로 만들 수 있는 **모든 결과의 집합**. Vector 개수 $\neq$ 차원 (평행하면 차원이 줄어듦).
5. **MNIST 이미지 1장** = $\mathbb{R}^{784}$ **Vector**. 모든 AI 모델의 입력은 결국 Vector로 환원됩니다. 평균 이미지 = 계수 균등한 Linear combination.

E-5. 자기 점검 질문

- $\mathbf{u} = (1, 2, 3)^\top, \mathbf{v} = (-1, 0, 1)^\top$ 일 때 $3\mathbf{u} - 2\mathbf{v}$ 는?
- $\text{span}((2, 4)^\top, (1, 2)^\top)$ 의 모양은 (직선·평면·한 점 중)?
- $\mathbb{R}^n$ 의 임의 Vector가 표준 단위 Vector $\mathbf{e}_1, \dots, \mathbf{e}_n$ 의 Linear combination으로 쓰이는 이유는?
- MNIST 28×28 이미지를 Vector로 만들면 차원은? 1,000장 데이터셋은 어떤 Matrix?
- "선형(linear)"이란 단어의 정확한 의미는 무엇입니까? 무엇이 허용되고 무엇이 금지됩니까?

오늘의 마무리 문제 — 즉석 풀이

오늘의 사슬(Vector → 두 연산 → Linear combination → Span → MNIST)을 한 문제로 종합합니다.

$\mathbf{v}_1 = (1, 0, 1)^\top$, $\mathbf{v}_2 = (0, 1, 1)^\top$, $\mathbf{v}_3 = (1, 1, 2)^\top$ 가 $\mathbb{R}^3$ 에 주어졌습니다.

- (a) $\mathbf{w} = 2\mathbf{v}_1 + 3\mathbf{v}_2 - \mathbf{v}_3$ 를 계산하세요.
- (b) $\mathbf{v}_3$ 를 $\mathbf{v}_1, \mathbf{v}_2$ 의 Linear combination으로 표현할 수 있습니까? 가능하면 계수를 구하세요.
- (c) $\text{span}(\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3)$ 는 $\text{span}(\mathbf{v}_1, \mathbf{v}_2)$ 와 같은 집합입니까? 그 이유는?
- (d) $\text{span}(\mathbf{v}_1, \mathbf{v}_2)$ 는 $\mathbb{R}^3$ 의 어떤 모양입니까 (직선·평면·전체 중)?

오늘의 마무리 문제 — 답

- (a) $2\mathbf{v}_1 = (2, 0, 2)^\top$, $3\mathbf{v}_2 = (0, 3, 3)^\top$, $-\mathbf{v}_3 = (-1, -1, -2)^\top$
 합: $(2 - 1, 0 + 3 - 1, 2 + 3 - 2)^\top = (1, 2, 3)^\top$
- (b) $\mathbf{v}_3 = (1, 1, 2)^\top = (1, 0, 1)^\top + (0, 1, 1)^\top = \mathbf{v}_1 + \mathbf{v}_2$. 가능합니다, 계수 (1, 1).
- (c) 같은 집합입니다. $\mathbf{v}_3$ 가 $\mathbf{v}_1, \mathbf{v}_2$ 의 Linear combination이므로 $\mathbf{v}_3$ 를 추가해도 새로 만들 수 있는 Vector가 없습니다. ($\alpha_1\mathbf{v}_1 + \alpha_2\mathbf{v}_2 + \alpha_3\mathbf{v}_3 = (\alpha_1 + \alpha_3)\mathbf{v}_1 + (\alpha_2 + \alpha_3)\mathbf{v}_2$ 로 정리 가능)
- (d) $\mathbf{v}_1, \mathbf{v}_2$ 는 평행이 아닙니다 (한쪽이 다른 쪽의 Scalar 배가 아님). 따라서 $\mathbb{R}^3$ 의 한 평면 (원점을 지나는).

핵심: 세 Vector 중 하나가 나머지의 Linear combination이면 Span에 기여하지 않습니다, "진짜 다른 방향" 개수가 차원입니다. 8회차 Linear independence의 핵심 직관.

다음 회차 Review용 숙제

위 마무리 문제의 유사 문제입니다. 강의 후 풀어 와서 **2회차 Review** 시간에 비교합니다.

$\mathbf{u}_1 = (1, 2)^\top$, $\mathbf{u}_2 = (3, 4)^\top$, $\mathbf{u}_3 = (5, 6)^\top$ 이 $\mathbb{R}^2$ 에 주어졌습니다.

- (a) $\mathbf{w} = \mathbf{u}_1 - 2\mathbf{u}_2 + \mathbf{u}_3$ 를 계산하세요.
- (b) $\mathbf{u}_3$ 를 $\mathbf{u}_1, \mathbf{u}_2$ 의 Linear combination으로 표현할 수 있습니까? 가능하면 계수를 구하세요. (힌트: 연립방정식)
- (c) $\text{span}(\mathbf{u}_1, \mathbf{u}_2, \mathbf{u}_3)$ 는 $\mathbb{R}^2$ 의 어떤 모양입니까?
- (d) MNIST 한 장의 이미지를 펼쳐 $\mathbb{R}^{784}$ Vector로 만든 뒤, 그것이 픽셀 위치별 표준 단위Vector $\mathbf{e}_1, \dots, \mathbf{e}_{784}$ 의 Linear combination으로 표현됨을 한 줄로 적으세요.

자기 점검

- (b)의 계수를 구하는 과정이 어떤 **연립 1차방정식**으로 환원되는지 의식하세요. → 4회차 가우스 소거의 출발점.
- (d)에서 픽셀값이 곧 계수입니다, 모든 이미지는 결국 픽셀별 단위Vector의 Linear combination.

E-6. 과제 안내

04_과제/Part1/01회차_homework.md — 마감: 2회차 시작 전

수학 30점

- 두 연산 계산 (덧셈·Scalar곱·Linear combination), 5문제
- Span의 모양 식별 (직선·평면·전체), 3문제
- 한 Vector가 다른 Vector들의 Linear combination인지 판정, 3문제 (연립방정식 풀기)
- 표준 단위Vector $\mathbf{e}_i$ 를 사용한 분해, 2문제

코딩 20점

- NumPy로 Vector 생성·두 연산·Linear combination 구현
- MNIST 한 장 $\rightarrow$ 784차원 Vector로 reshape, 시각화로 원본 복원 확인
- 0~9 각 숫자의 평균 이미지 10장 계산·시각화
- 보너스: 새 이미지를 가장 가까운 평균과 비교하여 분류 (다음 회차 Norm으로 자연스럽게 이어짐)

E-7. 다음 회차 (2회차) 예고

주제: Length(길이, Norm) · Dot product(내적) · 각도 · Cauchy-Schwarz · Cosine similarity

연결: 오늘 본 Vector·두 연산만으로는 "두 Vector가 얼마나 비슷한가"를 잴 수 없습니다. 2회차에서 ****Norm(길이)****과 ****Inner product(내적)****라는 두 도구를 도입하여 거리·각도·코사인 유사도를 정의합니다. 0회차 Review에서 가져온 "MNIST 숫자 7과 새 이미지의 가까움"이 마침내 수학적으로 정의됩니다.

3회차 예고: 오늘 본 Linear combination = Matrix·Vector 곱의 Column picture (3회차에서 본격).

사전 reading:

- Strang §1.2 (Lengths and Dot Products)
- MML §3.1 (Norms), §3.2 (Inner Products), 참조
- 3Blue1Brown EoLA Ch.9 (Dot products and duality)

부록 — Strang §1.1 추천 연습문제

오늘 다룬 내용을 손으로 더 골려보고 싶은 학생을 위한 안내입니다 (모두 자율).

Strang §1.1	주제	난도
Problem 1-3	평행사변형 법칙·두 Vector 합	하
Problem 5-8	Linear combination 계수 구하기	중
Problem 11-13	$\mathbb{R}^3$ 에서 Span의 모양 식별	중
Problem 17-20	표준 단위Vector·임의 Vector 분해	중
Problem 23, 25	"두 Vector의 모든 Linear combination이 평면을 이룬다", 직관적 증명	상

Strang은 매 절 끝 연습문제가 개념 검증용 + 손계산용이 섞여 있습니다. 본문을 읽고 3~5문제를 풀면 다음 회차 진입이 한결 부드러워집니다.

Q & A

오늘의 사슬:

Vector ($\mathbb{R}^n$) → 두 연산 (덧셈·Scalar곱) → Linear combination → Span(직관) → MNIST 이미지 Vector

핵심 한 줄: 모든 데이터는 $\mathbb{R}^d$ Vector로 환원되고, 두 연산이 그 데이터를 다루는 모든 일의 출발점입니다.

다음 회차로 가져갈 한 질문:

두 Vector의 길이와 각도를 어떻게 정의하면 자연스러운가?

HANDOUT : 본 PDF + 01_벡터_ $\mathbb{R}^n$ _MNIST.ipynb