

# 1회차

## Vector·Linear combination·Norm·Inner product·Cosine similarity

---

MML §2.1, §3.1, §3.2 · Strang §1.1, §1.2 · EoLA Ch.1, Ch.2

## Review — 0회차 마무리 문제

지난 회차 마지막에 가져갔던 문제:

MNIST에서 숫자 "7"인 이미지 1,000장의 평균 Vector(벡터)를  $\mathbf{m}$ 이라 합니다.

(a) 새 이미지  $\mathbf{x}$ 가 7과 얼마나 가까운가를 **거리**로 어떻게 잴 수 있는지 두 가지 방법.

(b) 두 방법은 어떤 면에서 다른가?

### 답의 윤곽

| 방법                        | 식                                                              | 의미                               |
|---------------------------|----------------------------------------------------------------|----------------------------------|
| (i) Norm(노름) 기반           | $ \mathbf{x} - \mathbf{m} _2$                                  | 두 점 사이 <b>직선 거리</b> — 길이까지 봅니다   |
| (ii) Inner product(내적) 기반 | $\frac{\mathbf{x}^\top \mathbf{m}}{ \mathbf{x}   \mathbf{m} }$ | 두 화살표의 <b>방향 일치도</b> — 길이는 무시합니다 |

(b) **차이**: (i)은 크기 차이도 거리로 잡고, (ii)는 방향만 봅니다. 글자가 굵게 써져 픽셀 평균이 커도 (ii)는 같은 7로 봅니다.

→ 오늘 이 두 도구(Norm·Inner product)를 수학적으로 만들어냅니다.

## 오늘의 핵심 질문

두 Vector의 길이와 각도를 어떻게 정의해야  $\cos \theta$ 가 자연스럽게 등장합니까?

이 한 질문에 답하려면 네 단계가 필요합니다.

1. **Vector**가 무엇인지부터 (8 axioms(공리))
2. **Norm**(길이)의 명세 (3 axioms)
3. **Inner product**(관계)의 명세 (3 axioms)
4. **\*\*Cauchy-Schwarz inequality(코시-슈바르츠 부등식)\*\***가  $\cos \theta \in [-1, 1]$ 을 보장한다는 Theorem(정리)

오늘 회차의 모든 것이 이 사슬 위에 있습니다. 강의 중간에 길을 잃으면 이 질문으로 돌아옵니다.

## 학습 목표

---

1. **Vector**의 수학적 정의 + "왜 그렇게 생겼는지"를 물리·대수·데이터 세 관점에서 설명할 수 있습니다.
2. **Vector space(벡터공간)** 8 axioms를 진술하고  $\mathbb{R}^n$ 이 axioms를 만족함을 검증할 수 있습니다.
3. **\*\*Linear combination(선형결합) · Span(생성공간)\*\***의 정의와 Subspace(부분공간) 판단을 할 수 있습니다.
4. **Norm의 3 axioms**가 왜 그렇게 정해졌는지 +  $\ell_1, \ell_2, \ell_\infty$ 를 손계산할 수 있습니다.
5. **Inner product 정의**가 왜 자연스러운지 + Inner product에서 Norm이 유도되는 과정 + **Cauchy-Schwarz**로 Cosine similarity가  $[-1, 1]$ 임을 보일 수 있습니다.

# 오늘의 논리 사슬

| 질문                         | 답 (이 강의의 답)               | 도구                        |
|----------------------------|---------------------------|---------------------------|
| "수의 묶음"을 한 객체로?            | Vector의 정의                | 덧셈·Scalar(스칼라)곱           |
| 그게 정말 잘 동작하는가?             | Vector space 8 axioms     | (V1)~(V8)                 |
| 한 집합에서 만들어지는 공간?           | Linear combination · Span | span                      |
| 두 Vector의 거리를 어떻게?         | Norm 3 axioms             | (N1)·(N2)·(N3)            |
| **두 Vector의 관계(각도)**를 어떻게? | Inner product + Norm 유도   | $\mathbf{u}^T \mathbf{v}$ |
| 각도가 $[-1, 1]$ 임을 보장?       | Cauchy-Schwarz            | 이차식 판별식                   |

이 사슬을 한 회차에 완주합니다.

## 수업 흐름 (120분)

| 시간      | 블록 | 내용                                                                         |
|---------|----|----------------------------------------------------------------------------|
| 0~15    | A  | 오프닝 — 핵심 질문 + 0회차 Review                                                   |
| 15~35   | B  | Vector의 동기와 정의 (물리·대수·데이터 + 8 axioms)                                      |
| 35~55   | C  | Linear combination · Span                                                  |
| 55~75   | D  | Norm (3 axioms 동기·세 표준)                                                    |
| 75~95   | E  | Inner product · 각도 · Cosine similarity (axioms · Norm 유도 · Cauchy-Schwarz) |
| 95~105  | F  | CS·AI 적용                                                                   |
| 105~120 | G  | 클로징 — 코딩 실습 + 마무리 문제 + 숙제                                                  |

표준 사이클: 핵심 질문 → Review → 본 강의 → 마무리 문제 → 숙제(=다음 회차 Review)

## B. 수학 1 — Vector의 동기와 정의

## B-1. Vector가 왜 생겼는가 — 세 가지 동기

---

(i) 물리적 동기: 크기 + 방향이 필요한 양 (변위·속도·힘)

- "북쪽 3 m"와 "동쪽 3 m"는 다릅니다.
- 두 변위의 합 = **평행사변형 법칙**.

(ii) 대수적 동기: 동시에 여러 양을 다루기

- $\begin{cases} 2x + 3y = 5 \\ x - y = 1 \end{cases}$  —  $(x, y)$ 를 한 묶음으로 봅니다.
- 미지수가 100개라면 묶음 없이는 식조차 쓸 수 없습니다.

(iii) 데이터적 동기 (AI): 측정값의 묶음

- 이미지 = 픽셀 784개의 묶음
- 문서 = Embedding 좌표 768개의 묶음

세 동기 모두 **벡터** + **Scalar** 곱이 자연스러운 두 연산입니다.

## B-2. 형식적 정의

### 정의 1.1 ( $\mathbb{R}^n$ 의 Vector)

$n$ 개 실수 순서쌍입니다 — 이 강의 기본은 **\*\*Column vector(열벡터)\*\***입니다.

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^n, \quad \mathbf{x}^\top = (x_1, x_2, \dots, x_n)$$

### 정의 1.2 (두 연산)

$$\mathbf{x} + \mathbf{y} = \begin{pmatrix} x_1 + y_1 \\ \vdots \\ x_n + y_n \end{pmatrix}, \quad \alpha \mathbf{x} = \begin{pmatrix} \alpha x_1 \\ \vdots \\ \alpha x_n \end{pmatrix}$$

각 성분에 대해 실수의 연산을 그대로 적용합니다.

💡 **파인만식 비유**: Vector는 **한 음식의 재료 묶음**입니다. 햄버거 한 개는 (빵 2, 패티 1, 피클 5)로 적습니다 — 한 음식이 한 묶음 = 한 Vector. **두 개를 만들면**  $2 \cdot (2, 1, 5)^\top = (4, 2, 10)^\top$  (Scalar곱). **다른 메뉴(샌드위치)와 함께 주문하면** 두 묶음의 합으로 총 재료 수가 나옵니다 (덧셈). 즉 **한 음식 = 한 Vector**. 음식 개수 합치기가 곧 두 연산입니다.

## B-3. Vector space 8 axioms — 자연스러움의 명세

💡 **파인만식 비유**: 8 axioms는 음식 묶음이 "**음식 묶음답기**" 위해 지켜야 할 규칙 8조입니다. (빵+패티)+피클 = 빵+(패티+피클) — 묶는 순서 무관(V1), 빈 음식 묶음 **0**이 있다(V3) 등. 이 8조를 지키면 픽셀 묶음·다항식·함수도 모두 "음식 묶음처럼" 다룰 수 있습니다 → **추상화의 힘**.

### 덧셈 4 axioms

- (V1) 결합:  $(\mathbf{u} + \mathbf{v}) + \mathbf{w} = \mathbf{u} + (\mathbf{v} + \mathbf{w})$
- (V2) 교환:  $\mathbf{u} + \mathbf{v} = \mathbf{v} + \mathbf{u}$
- (V3) 영원소:  $\mathbf{u} + \mathbf{0} = \mathbf{u}$
- (V4) 역원:  $\mathbf{u} + (-\mathbf{u}) = \mathbf{0}$

### Scalar곱 4 axioms

- (V5) 결합:  $\alpha(\beta\mathbf{u}) = (\alpha\beta)\mathbf{u}$
- (V6) 분배(Scalar):  $(\alpha + \beta)\mathbf{u} = \alpha\mathbf{u} + \beta\mathbf{u}$
- (V7) 분배(Vector):  $\alpha(\mathbf{u} + \mathbf{v}) = \alpha\mathbf{u} + \alpha\mathbf{v}$
- (V8) 단위원:  $1 \cdot \mathbf{u} = \mathbf{u}$

## B-4. "Vector가 아닌 것"의 반례

---

### 반례 1: 양의 실수 $\mathbb{R}_{>0}$ + 보통 덧셈

영원소 (V3) 없음 —  $0 \notin \mathbb{R}_{>0}$ .

### 반례 2: 정수 픽셀값 $\{0, 1, \dots, 255\}$

Scalar곱이 닫혀 있지 않습니다 —  $0.7 \cdot 100 = 70$ 이 정수지만  $0.001 \cdot 100$ 같이 일반  $\alpha$ 에선 깨집니다.

→ 0회차 노트북에서 `astype(float)` 을 한 이유입니다.

### 명제 1.1

$(\mathbb{R}^n, +, \cdot)$ 은 8 axioms를 모두 만족합니다.

**증명 골자.**  $\mathbb{R}$ 의 덧셈·곱셈 성질이 성분별로 적용됩니다. 예: (V2)  $x_i + y_i = y_i + x_i$ . ■

## 잠깐 풀어보기 — Vector·8 axioms

옆 사람과 5분 토의 후 답을 종이에 적어보세요.

### 문제 1 (계산)

$\mathbf{u} = (1, -2, 3)^\top$ ,  $\mathbf{v} = (2, 0, -1)^\top$  일 때  $2\mathbf{u} - 3\mathbf{v}$ 를 계산하세요.

### 문제 2 (개념)

다음 집합이  $\mathbb{R}^2$ 의 부분집합으로서 Vector space 조건(특히 V3, V4, 덧셈 닫힘)을 만족합니까? 안 되면 어느 axiom이 깨집니까?

- (i)  $S_1 = \{\mathbf{x} \in \mathbb{R}^2 : x_1 + x_2 = 0\}$
- (ii)  $S_2 = \{\mathbf{x} \in \mathbb{R}^2 : x_1 + x_2 = 1\}$

**힌트:**  $\mathbf{0}$ 이 그 집합 안에 있는지, 두 원소의 합이 다시 그 집합인지 검사합니다.

## 잠깐 풀어보기 — 답

### 문제 1

$$2\mathbf{u} - 3\mathbf{v} = (2, -4, 6)^\top - (6, 0, -3)^\top = (-4, -4, 9)^\top$$

### 문제 2

- (i)  $S_1$  — OK:  $\mathbf{0} \in S_1$  (V3),  $\mathbf{x}, \mathbf{y} \in S_1$ 이면  $(x_1 + y_1) + (x_2 + y_2) = 0$ 이라 덧셈이 닫힙니다. Subspace ✓
- (ii)  $S_2$  — 깨집니다:  $\mathbf{0} \notin S_2$  (V3 위배). 두 원소  $\mathbf{x}, \mathbf{y} \in S_2$ 의 합도  $(x_1 + y_1) + (x_2 + y_2) = 2 \neq 1$ 이라 닫힘도 깨집니다.

**메시지:**  $S_1$ 은 직선(원점 지나는),  $S_2$ 는 직선(원점 안 지나는)입니다. **원점이 핵심.**

## C. 수학 2 — Linear combination · Span

## C-1. Linear combination

### 정의 1.4 (Linear combination)

Vector  $\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathbb{R}^n$ , Scalar  $\alpha_1, \dots, \alpha_k \in \mathbb{R}$ 에 대해

$$\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2 + \dots + \alpha_k \mathbf{v}_k$$

를 Linear combination이라 합니다.

💡 **파인만식 비유:** Linear combination은 **여러 메뉴를 비율로 섞어 한 도시락 만들기**입니다. 햄버거( $\mathbf{v}_1$ ) 비중 200, 샌드위치( $\mathbf{v}_2$ ) 비중 100, 샐러드( $\mathbf{v}_3$ ) 비중 50으로 한 도시락이 나옵니다 ( $200\mathbf{v}_1 + 100\mathbf{v}_2 + 50\mathbf{v}_3$ ). 비율만 바꾸면 다른 도시락이 됩니다.

### 왜 "선형(linear)"입니까?

- 덧셈·Scalar곱이라는 두 선형 연산만 사용하기 때문입니다.
- 비선형 연산 ( $x_i x_j$ ,  $\exp(x_i)$  등)이 들어가지 않아 분석이 가능합니다.

## C-2. Span (Span)

### 정의 1.5 (Span)

$$\text{span}(\mathbf{v}_1, \dots, \mathbf{v}_k) = \left\{ \sum_{i=1}^k \alpha_i \mathbf{v}_i : \alpha_i \in \mathbb{R} \right\}$$

💡 **파인만식 비유**: Span은 **주어진 메뉴로 만들 수 있는 모든 도시락 묶음의 집합**입니다. 햄버거·샌드위치·샐러드 세 메뉴가 있으면 그 세 메뉴의 비율을 바꾸며 무한히 많은 도시락을 만들 수 있지만, 본래 메뉴에 없는 재료(예: 카레)는 절대 만들 수 없습니다. **가진 메뉴가 도시락 영역을 결정합니다.**

### 명제 1.2

$\text{span}(\dots)$ 은  $\mathbb{R}^n$ 의 **Subspace**입니다 (5회차 정식 정의). 즉 덧셈·Scalar곱에 닫혀 있습니다.

### 예제

- $\text{span}((1, 0)^\top, (0, 1)^\top) = \mathbb{R}^2$
- $\text{span}((1, 1)^\top, (2, 2)^\top) = \text{span}((1, 1)^\top)$  — **1차원 직선** (두 Vector가 평행 — 같은 재료를 두 번 든 셈)

### C-3. Linear combination = Matrix·Vector 곱 (2회차 미리보기)

---

$A \in \mathbb{R}^{m \times n}$ ,  $\mathbf{x} \in \mathbb{R}^n$ ,  $A$ 의 열을  $\mathbf{a}_1, \dots, \mathbf{a}_n$ 이라 쓰면

$$A\mathbf{x} = x_1\mathbf{a}_1 + x_2\mathbf{a}_2 + \dots + x_n\mathbf{a}_n$$

Matrix·Vector 곱 =  $A$ 의 열들의 Linear combination입니다.

→ 2회차에서 행 방식·열 방식 두 해석으로 본격 진행합니다.

## 잠깐 풀어보기 — Linear combination · Span

### 문제 1 (계산)

$\mathbf{v}_1 = (1, 1)^\top$  과  $\mathbf{v}_2 = (1, -1)^\top$  이 주어졌습니다.  $(3, 5)^\top$  을 두 Vector의 Linear combination  $\alpha_1 \mathbf{v}_1 + \alpha_2 \mathbf{v}_2$  로 표현하세요.

### 문제 2 (개념)

다음 Span의 차원은 얼마입니까?

- (i)  $\text{span}((1, 0)^\top, (0, 1)^\top, (1, 1)^\top) \subset \mathbb{R}^2$
- (ii)  $\text{span}((1, 2, 0)^\top, (2, 4, 0)^\top) \subset \mathbb{R}^3$

**힌트:** 세 Vector 중 하나가 나머지의 Linear combination이면 그 Vector는 Span에 기여하지 않습니다.

## 잠깐 풀어보기 — 답

### 문제 1

$$\alpha_1 + \alpha_2 = 3, \alpha_1 - \alpha_2 = 5 \rightarrow \alpha_1 = 4, \alpha_2 = -1.$$

$$\therefore (3, 5)^\top = 4(1, 1)^\top - 1(1, -1)^\top$$

### 문제 2

- (i)  $(1, 1)^\top = (1, 0)^\top + (0, 1)^\top$  이라 셋째 Vector는 처음 둘의 Linear combination입니다. 따라서 Span은 처음 두 Vector로 충분  $\rightarrow$  **2차원** ( $\mathbb{R}^2$  전체).
- (ii)  $(2, 4, 0)^\top = 2 \cdot (1, 2, 0)^\top$  이라 두 Vector가 평행합니다  $\rightarrow$  **1차원** ( $\mathbb{R}^3$ 의 한 직선).

**메시지:** "Vector 개수 = 차원"이 아닙니다. **일차독립인 Vector 개수**가 차원입니다 (8회차).

## D. 수학 3 — Norm: "거리"의 정확한 명세

## D-1. 왜 거리를 axiom화합니까

💡 **파인만식 비유**: Norm은 한 음식의 '**크기**'를 재는 **잣대**입니다. 같은 햄버거라도 재료 총 개수로 잴 수 있고, 무게로 잴 수도 있고, 가장 비싼 재료의 가격만 볼 수도 있습니다. 어떤 잣대를 쓰느냐에 따라 다른 숫자가 나옵니다. "잣대다운 잣대"가 되려면 어떤 성질이 있어야 하는가? — 이것이 Norm의 3 axioms입니다.

### 거리의 직관 4가지:

1. 비음수
2. 자기 자신과의 거리 = 0
3. 양방향성 같음
4. 직진  $\leq$  우회 (Triangle inequality(삼각부등식))

### 정의 3.1 (Norm)

함수  $\| \cdot \| : \mathbb{R}^n \rightarrow \mathbb{R}_{\geq 0}$ 이

- (N1) **양의 정부호**:  $\|\mathbf{x}\| \geq 0$ ,  $\|\mathbf{x}\| = 0 \iff \mathbf{x} = \mathbf{0}$
- (N2) **양의 동차**:  $\|\alpha\mathbf{x}\| = |\alpha| \|\mathbf{x}\|$
- (N3) **Triangle inequality**:  $\|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$

## D-2. 3 axioms의 동기

---

(N1) 양의 정부호 — 거리는 음수일 수 없고, "거리 0 = 같은 점"입니다.

(N2) 양의 동차 —  $\alpha$ 배로 늘리면 길어도  $|\alpha|$ 배입니다 (반대 방향이라도 길이는 양수).

(N3) Triangle inequality — "두 변의 합  $\geq$  한 변", 가장 오래된 기하 사실입니다.

### 정리 3.1 (역삼각부등식)

$$| \|x\| - \|y\| | \leq \|x - y\|$$

**증명 골자:** (N3)으로  $\|x\| \leq \|x - y\| + \|y\|$ . 대칭으로 반대도 얻습니다. ■

→ axiom 3개에서 모든 Norm의 일반 성질이 따라옵니다.

### D-3. 세 가지 표준 Norm

| Norm          | 정의                    | 동기·응용                      |
|---------------|-----------------------|----------------------------|
| $\ell_1$      | $\sum_i  x_i $        | 격자 도시(택시) · Lasso (sparse) |
| $\ell_2$      | $\sqrt{\sum_i x_i^2}$ | 피타고라스 · 거의 모든 LA · Ridge   |
| $\ell_\infty$ | $\max_i  x_i $        | 최악 경우 · 안정성 분석             |

💡 **파인만식 비유:** 세 가지 음식 크기 잣대입니다. 햄버거 (빵 2, 패티 1, 피클 5) 기준 —  $\ell_1$  = **재료 총 개수** (2+1+5=8),  $\ell_2$  = **재료 분산을 반영한 무게감** ( $\sqrt{4 + 1 + 25} = \sqrt{30}$ ),  $\ell_\infty$  = **가장 양 많은 단일 재료** (피클 5). 같은 한 음식도 잣대마다 다른 크기 숫자.

### 예제

$\mathbf{a} = (3, 1, -2, 4)^\top: \|\mathbf{a}\|_1 = 10, \|\mathbf{a}\|_2 = \sqrt{30} \approx 5.48, \|\mathbf{a}\|_\infty = 4$

## D-4. Unit ball(단위구)의 모양과 정규화

$\mathbb{R}^2$ 의 Unit ball  $\{\mathbf{x} : \|\mathbf{x}\| = 1\}$ :

| Norm          | 모양               |
|---------------|------------------|
| $\ell_1$      | 마름모 (꼭짓점이 좌표축 위) |
| $\ell_2$      | 원                |
| $\ell_\infty$ | 정사각형             |

### AI 응용 — 정규화 종류와 Unit ball

- $\ell_2$  (Ridge): 가중치를 균등하게 줄입니다.
- $\ell_1$  (Lasso): 일부 가중치를 **정확히 0**으로 보냅니다 (특징 선택).

이유:  $\ell_1$  Unit ball의 꼭짓점이 좌표축 위에 있어 최적화가 자주 거기 닿습니다 (11회차).

## 잠깐 풀어보기 — Norm

### 문제 1 (계산)

$\mathbf{x} = (2, -3, 1, -4)^\top$ 의  $\ell_1, \ell_2, \ell_\infty$ 를 각각 구하세요.

### 문제 2 (개념)

$\mathbb{R}^2$ 의 다음 함수가 Norm입니까 (N1·N2·N3) 각각 검사하세요.

- (i)  $f(\mathbf{x}) = x_1^2 + x_2^2$
- (ii)  $g(\mathbf{x}) = |x_1| + 2|x_2|$

**힌트:** (N2) 양의 동차성  $\|\alpha \mathbf{x}\| = |\alpha| \|\mathbf{x}\|$  검사가 가장 빠른 판별입니다.

## 잠깐 풀어보기 — 답

### 문제 1

- $\|\mathbf{x}\|_1 = 2 + 3 + 1 + 4 = 10$
- $\|\mathbf{x}\|_2 = \sqrt{4 + 9 + 1 + 16} = \sqrt{30} \approx 5.48$
- $\|\mathbf{x}\|_\infty = 4$

### 문제 2

- (i)  $f$  — Norm이 아닙니다. (N2) 위배:  $f(2\mathbf{x}) = 4(x_1^2 + x_2^2) = 4f(\mathbf{x})$ 인데  $|2| f(\mathbf{x}) = 2f(\mathbf{x})$ . 즉  $\ell_2$ 의 제곱은 Norm이 아닙니다 (제곱근을 빼먹으면 안 됨).
- (ii)  $g$  — Norm입니다. 가중치 다른  $\ell_1$  변형입니다. (N1)  $\sum a_i |x_i| \geq 0$  ✓, (N2)  $g(\alpha\mathbf{x}) = |\alpha| g(\mathbf{x})$  ✓, (N3) Triangle inequality ✓.

**메시지:** Norm의 세 axioms는 그냥 외우는 것이 아니라 **검사 도구**입니다. 새 함수를 마주치면 세 axioms로 즉시 검증합니다.

## E. 수학 4 — Inner product: 각도의 일반화

## E-1. 왜 Inner product가 필요합니까

Norm = 한 Vector의 크기.

하지만 우리가 알고 싶은 것: 두 Vector가 얼마나 같은 방향인가? 직각인가?

💡 **파인만식 비유:** Inner product는 **재료 단가와 음식 재료의 곱셈 합 = 한 음식의 총 원가**입니다. 단가  $\mathbf{u} = (\text{빵 } 800\text{원}, \text{패티 } 2000\text{원}, \text{피클 } 100\text{원})$ , 햄버거 재료  $\mathbf{v} = (\text{빵 } 2, \text{패티 } 1, \text{피클 } 5)$ 이면  $\mathbf{u}^T \mathbf{v} = 800 \cdot 2 + 2000 \cdot 1 + 100 \cdot 5 = 4,100\text{원} = \text{햄버거 한 개 원가}$ . **두 Vector를 곱해 한 Scalar가 나오는 이유** — 가격×수량으로 합산한 총액입니다.

2차원의 코사인을 100차원으로 확장하려면 → Inner product.

## E-2. Inner product의 정의

---

### 정의 4.1 ( $\mathbb{R}^n$ 의 표준 Inner product)

$$\mathbf{u} \cdot \mathbf{v} = \mathbf{u}^\top \mathbf{v} = \sum_{i=1}^n u_i v_i \in \mathbb{R}$$

### 정의 4.2 (일반 Inner product의 axioms)

$$\langle \cdot, \cdot \rangle : V \times V \rightarrow \mathbb{R}$$

- (I1) **대칭**:  $\langle \mathbf{u}, \mathbf{v} \rangle = \langle \mathbf{v}, \mathbf{u} \rangle$
- (I2) **선형**:  $\langle \alpha \mathbf{u} + \beta \mathbf{w}, \mathbf{v} \rangle = \alpha \langle \mathbf{u}, \mathbf{v} \rangle + \beta \langle \mathbf{w}, \mathbf{v} \rangle$
- (I3) **양의 정부호**:  $\langle \mathbf{u}, \mathbf{u} \rangle \geq 0, = 0 \iff \mathbf{u} = \mathbf{0}$

### 명제 4.1

$\mathbb{R}^n$ 의  $\mathbf{u}^\top \mathbf{v}$ 는 (I1·I2·I3)를 만족합니다.

## E-3. Inner product가 Norm을 낳습니다

---

### 정리 4.1 (Inner product 유도 Norm)

Inner product  $\langle \cdot, \cdot \rangle$ 이 있으면  $\|\mathbf{u}\| := \sqrt{\langle \mathbf{u}, \mathbf{u} \rangle}$ 는 Norm입니다.

**증명 골자:**

- (N1)(N2)는 (I3)와 정의에서 직접 따라옵니다.
- (N3)은 Cauchy-Schwarz를 거쳐 얻습니다 (다음 슬라이드).

**핵심 관찰:**  $\mathbb{R}^n$  표준 Inner product의 유도 Norm이 \*\*정확히  $\ell_2$ \*\*입니다.

$$\|\mathbf{u}\|_2 = \sqrt{\mathbf{u}^\top \mathbf{u}} = \sqrt{\sum u_i^2}$$

→  $\ell_2$ 가 표준인 이유: Inner product라는 더 풍부한 객체에서 유도되기 때문입니다 ( $\ell_1, \ell_\infty$ 는 그렇지 않습니다).

## E-4. Cauchy-Schwarz inequality

### 정리 4.2 (Cauchy-Schwarz)

$$|\mathbf{u}^\top \mathbf{v}| \leq \|\mathbf{u}\|_2 \|\mathbf{v}\|_2$$

등호  $\iff \mathbf{u}, \mathbf{v}$ 가 평행.

💡 **파인만식 비유:** 한 막대( $\mathbf{u}$ )를 다른 막대( $\mathbf{v}$ )의 방향으로 비추면 **그림자의 길이가 Inner product의 절댓값**입니다. 그림자는 절대 두 막대의 길이 곱( $\|\mathbf{u}\| \|\mathbf{v}\|$ )보다 길 수 없습니다. **평행하면 그림자가 막대 자체와 일치**합니다(등호).

**증명** (이차식 비음성  $\rightarrow$  판별식 패턴):

$\mathbf{v} \neq \mathbf{0}$  가정합니다. 임의의  $t \in \mathbb{R}$ 에 대해

$$\|\mathbf{u} - t\mathbf{v}\|^2 = \|\mathbf{u}\|^2 - 2t \mathbf{u}^\top \mathbf{v} + t^2 \|\mathbf{v}\|^2 \geq 0$$

이차식  $\geq 0$  모두  $t \iff$  판별식  $\leq 0$ :  $4(\mathbf{u}^\top \mathbf{v})^2 - 4\|\mathbf{u}\|^2 \|\mathbf{v}\|^2 \leq 0$

$\rightarrow |\mathbf{u}^\top \mathbf{v}| \leq \|\mathbf{u}\| \|\mathbf{v}\|$ . ■

이 증명 패턴 (이차식 비음성  $\rightarrow$  판별식)이 LA·최적화에서 반복됩니다.

## E-5. $\ell_2$ 의 Triangle inequality — Cauchy-Schwarz의 결과

$$\begin{aligned}\|\mathbf{u} + \mathbf{v}\|^2 &= \|\mathbf{u}\|^2 + 2\mathbf{u}^\top \mathbf{v} + \|\mathbf{v}\|^2 \\ &\leq \|\mathbf{u}\|^2 + 2\|\mathbf{u}\|\|\mathbf{v}\| + \|\mathbf{v}\|^2 = (\|\mathbf{u}\| + \|\mathbf{v}\|)^2\end{aligned}$$

따라서  $\|\mathbf{u} + \mathbf{v}\|_2 \leq \|\mathbf{u}\|_2 + \|\mathbf{v}\|_2$ . ■

→  $\ell_2$ 가 Norm이라는 사실의 (N3) 증명은 Cauchy-Schwarz가 핵심입니다.

Inner product (I1·I2·I3)

↓

유도 Norm (N1·N2 직접, N3는 ↓)

↓

Cauchy-Schwarz (이차식 판별식)

↓

$\ell_2$ 의 Triangle inequality

## E-6. 각도와 Cosine similarity

---

### 정의 4.3 (각도)

0이 아닌  $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$ 에 대해 각  $\theta \in [0, \pi]$ 를

$$\cos \theta = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{u}\|_2 \|\mathbf{v}\|_2}$$

으로 **정의**합니다. Cauchy-Schwarz로  $\cos \theta \in [-1, 1]$ 이 보장됩니다.

### 정의 4.4 (Orthogonal(직교))

$\mathbf{u}^\top \mathbf{v} = 0 \rightarrow \text{Orthogonal.}$

이렇게 정의하면 길이는 무시하고 방향만 보는 양이 됩니다 — BERT가 출력하는 Embedding 검색의 표준 거리입니다.

## E-7. 예제 + 주의

---

### 예제

$$\mathbf{a} = (3, 1, -2, 4)^\top, \mathbf{b} = (-1, 2, 5, 0)^\top:$$

- $\mathbf{a}^\top \mathbf{b} = -11$
- $\|\mathbf{a}\|_2 = \|\mathbf{b}\|_2 = \sqrt{30}$
- $\cos \theta = -11/30 \approx -0.367 \rightarrow$  둔각

### 주의

"Inner product가 0이면 둘 중 하나는 영Vector"  $\rightarrow$  거짓.

반례:  $\mathbf{u} = (1, 0)^\top, \mathbf{v} = (0, 1)^\top$ . 둘 다 영Vector가 아니지만 Inner product가 0입니다. (과제 1번에 정확히 묻습니다)

## 잠깐 풀어보기 — Inner product · 코사인

### 문제 1 (계산)

$\mathbf{u} = (1, 1, 1)^\top$  과  $\mathbf{v} = (1, -1, 0)^\top$  에 대해:

- (a)  $\mathbf{u}^\top \mathbf{v}$
- (b)  $\|\mathbf{u}\|_2, \|\mathbf{v}\|_2$
- (c) Cosine similarity  $\cos \theta$
- (d) 두 Vector는 Orthogonal합니까?

### 문제 2 (응용)

$\mathbf{a} = (3, 4)^\top$  를 단위Vector로 정규화하세요. 즉  $\mathbf{a}/\|\mathbf{a}\|_2$ .

→ 결과 Vector의  $\ell_2$  Norm이 1임을 확인하세요.

## 잠깐 풀어보기 — 답

### 문제 1

- (a)  $\mathbf{u}^\top \mathbf{v} = 1 - 1 + 0 = 0$
- (b)  $\|\mathbf{u}\|_2 = \sqrt{3}, \|\mathbf{v}\|_2 = \sqrt{2}$
- (c)  $\cos \theta = 0/(\sqrt{3}\sqrt{2}) = 0$
- (d) **Orthogonal합니다** (Inner product가 0)

### 문제 2

$\|\mathbf{a}\|_2 = \sqrt{9 + 16} = 5$ . 따라서

$$\hat{\mathbf{a}} = \mathbf{a}/5 = (0.6, 0.8)^\top$$

검증:  $\|\hat{\mathbf{a}}\|_2 = \sqrt{0.36 + 0.64} = \sqrt{1} = 1 \checkmark$

**메시지:** Embedding을 단위Vector로 정규화하면 Cosine similarity = 단순 Inner product가 됩니다. 이것이 BERT·CLIP이 출력 후 흔히 하는 처리입니다.

## F. CS·AI 적용

## F-1. Inner product = AI의 핵심 연산

대형 모델 = Inner product의 대규모 병렬 계산입니다.

| AI 객체                        | Inner product의 역할                                         |
|------------------------------|-----------------------------------------------------------|
| Transformer Attention (12회차) | $QK^{\top}$ = 모든 query-key 쌍의 Inner product               |
| Embedding 검색 (RAG)           | query와 모든 문서 Embedding의 Inner product $\rightarrow$ top-k |
| 추천 시스템                       | $\mathbf{u}^{\top} \mathbf{v}_i$ — 사용자·아이템 호환도            |
| 신경망 한 뉴런                     | $\mathbf{w}^{\top} \mathbf{x} + b$                        |

오늘의 Inner product 정의가 곧 LLM의 핵심 연산입니다.

## F-2. 왜 Cosine similarity인가

---

### Norm의 영향 (예시)

$\mathbf{d}_1 = (1, 1, 0, 0, \dots)$ ,  $\mathbf{d}_2 = (10, 10, 0, 0, \dots)$  — 같은 두 단어만, 길이 10배.

- 유클리드:  $\sqrt{162} \approx 12.7 \rightarrow$  "멀다"
- 코사인:  $\frac{20}{\sqrt{2}\sqrt{200}} = 1 \rightarrow$  "같다"

긴 문서·짧은 문서를 유클리드로 비교하면 길이 차이만으로 큰 거리가 됩니다.

### 스케일 불변성

양의  $\alpha, \beta > 0$ :

$$\cos(\alpha \mathbf{u}, \beta \mathbf{v}) = \frac{\alpha \beta \mathbf{u}^\top \mathbf{v}}{\alpha \beta \|\mathbf{u}\| \|\mathbf{v}\|} = \cos(\mathbf{u}, \mathbf{v})$$

방향만 보고 크기는 무시  $\rightarrow$  BERT Embedding 검색에 자연스럽습니다.

## G. 코딩 실습 + 정리 + 과제

## G-1. 코딩 실습 골자

---

→ 11\_주피터노트북/Part1/01\_벡터\_노름\_내적\_MNIST.ipynb

1. NumPy로 Vector 생성·덧셈·Scalar곱
2.  $\ell_1, \ell_2, \ell_\infty$  Norm을 직접 구현 (라이브러리 호출 X) + `np.allclose` 로 검증
3. Unit ball 시각화 — 마름모·원·정사각형
4. Inner product · Cosine similarity 직접 구현 + 스케일 불변성 수치 확인
5. MNIST 두 이미지의 Cosine similarity
6. Top-5 nearest neighbor — query 이미지와 가장 비슷한 5개

## G-2. 오늘 회차 핵심 5개

---

1. **Vector** = 데이터의 좌표 + 두 연산을 가진 객체 (8 axioms)
2. **Linear combination · Span** — 두 Vector가 평행이면 차원 1로 축소 (8회차 일차독립의 직관)
3. **Norm의 3 axioms** — 거리에서 본질만 추린 명세, Unit ball 모양이 정규화 종류를 결정합니다.
4. **Inner product** → **Norm** → **각도** 연쇄.  $\ell_2$ 가 표준인 이유 = Inner product에서 유도되기 때문입니다.
5. **Cauchy-Schwarz** — 이차식 비음성 → 판별식 증명 패턴, LA·최적화에서 반복됩니다.

## G-3. 자기 점검 질문

---

- $\text{span}((1, 2)^\top, (2, 4)^\top)$ 의 차원은 얼마입니까?
- Norm이 8개가 아니라 **3개** axioms로 정의되는 이유는?
- $\ell_1$  Unit ball의 꼭짓점이 좌표축 위라는 사실  sparse 해
- "Inner product가 0이면 둘 중 하나는 영Vector다" — 참/거짓·이유
- $\ell_2$ 가  $\ell_1, \ell_\infty$ 와 **본질적으로 다른** 한 가지 성질은?

## 오늘의 마무리 문제 — 즉석 풀이

오늘의 사슬(Vector → Norm → Inner product → 코사인 → Cauchy-Schwarz)을 **한 문제로** 종합합니다.

$\mathbf{u} = (3, 4)^\top$ ,  $\mathbf{v} = (1, 7)^\top$ 에 대해 다음을 구하세요.

- (a)  $\|\mathbf{u}\|_2$ ,  $\|\mathbf{v}\|_2$
- (b)  $\mathbf{u}^\top \mathbf{v}$
- (c)  $\cos \theta$
- (d) Cauchy-Schwarz inequality  $|\mathbf{u}^\top \mathbf{v}| \leq \|\mathbf{u}\|_2 \|\mathbf{v}\|_2$  수치 검증
- (e) 항등식 검증:  $\|\mathbf{u} - \mathbf{v}\|_2^2 = \|\mathbf{u}\|_2^2 + \|\mathbf{v}\|_2^2 - 2\mathbf{u}^\top \mathbf{v}$

**메시지:** (e)는 코사인 법칙의 Vector 버전입니다 — Norm·Inner product가 이 한 식 안에 모두 등장합니다.

## 오늘의 마무리 문제 — 답

- (a)  $\|\mathbf{u}\|_2 = \sqrt{9 + 16} = 5$ ,  $\|\mathbf{v}\|_2 = \sqrt{1 + 49} = \sqrt{50}$
- (b)  $\mathbf{u}^\top \mathbf{v} = 3 \cdot 1 + 4 \cdot 7 = 31$
- (c)  $\cos \theta = \frac{31}{5\sqrt{50}} = \frac{31}{\sqrt{1250}} \approx 0.877 \rightarrow$  두 Vector가 거의 같은 방향
- (d)  $|31| = 31 \leq 5\sqrt{50} = \sqrt{1250} \approx 35.36 \checkmark$  Cauchy-Schwarz 성립
- (e)  $\mathbf{u} - \mathbf{v} = (2, -3)^\top$ ,  $\|\mathbf{u} - \mathbf{v}\|_2^2 = 4 + 9 = 13$   
우변:  $25 + 50 - 2 \cdot 31 = 13 \checkmark$  항등식 성립

**핵심:** (e) 항등식은 오늘 본 모든 개념의 종합이고, 다음 회차 **Orthogonality**(피타고라스의 일반화)로 이어집니다.

## 다음 회차 Review용 숙제

---

위 마무리 문제의 유사 문제입니다. 강의 후 풀어 와서 2회차 Review 시간에 비교합니다.

3차원으로 확장:  $\mathbf{u} = (2, 2, 1)^\top$ ,  $\mathbf{v} = (1, -2, 2)^\top$ 에 대해 (a)~(e)를 동일하게 구하세요.

### 풀이 시 자기 점검

- (c)  $\cos \theta$ 의 값이 특별한 수가 나오는가?
- 그 의미는? (힌트: 두 Vector의 관계)
- (e) 항등식이 이 경우 어떻게 더 단순해지는가? — 피타고라스 정리가 등장합니다.

2회차 시작 시 함께 답을 맞추고, 그 결과가 2회차 본 주제(Matrix·Vector 곱)와 어떻게 이어지는지 봅니다.

## G-4. 과제 안내

---

04\_과제/Part1/01회차\_homework.md — 마감: 2회차 시작 전

### 수학 30점

- 진위 판정 (반례·등호 조건)
- Norm · Inner product · Cosine similarity 계산
- **Cauchy-Schwarz 재증명**
- Cosine similarity vs 유클리드 거리 비교 (수학적 증명)

### 코딩 20점

- Norm · Cosine similarity 직접 구현
- broadcasting vs for문 속도 비교 (  $n=10, 100, 1000$  )

## G-5. 다음 회차 (2회차) 예고

---

**주제:** Matrix · Matrix · Vector 곱의 두 해석 (행 방식·열 방식)

**연결:** 오늘 본 Linear combination이 그대로 Matrix·Vector 곱의 "열 방식 해석"이 됩니다.  $A\mathbf{x}$ 를  $A$ 의 열들의 Linear combination으로 보는 관점이 2~6회차의 Subspace 논의 전체를 지배합니다.

**사전 reading:**

- MML §2.2, §2.3.1
- Strang §1.3, §2.1
- 3Blue1Brown EoLA Ch.3 (Linear transformations and matrices)

## Q & A

오늘의 사슬:

Vector → 8 axioms → Linear combination → Norm(3 axioms) → Inner product → Cauchy-Schwarz → Cosine similarity

HANDOUT : 본 PDF + 01\_벡터\_노름\_내적\_MNIST.ipynb