

Part 1 2 회차

Norm·Dot product·Cosine similarity

MML §3.1-§3.4 (메인) · Strang Ch 1.2 (발췌 , Cauchy-Schwarz 판별식 풀이) · [EoLA Ch.9: Dot products and duality](#) · Part 1 (LA1)

이제 Vector(벡터) 사이의 **거리와 각도**를 정의합니다 .

지난 시간 (1 회차) 요약

흐름 : Vector → 두 연산 → Linear combination → Span → 데이터의 Vector 화

키워드	한 줄 정리
Vector $\in \mathbb{R}^n$	같은 차원 실수들의 순서 묶음 (성분 = 좌표)
두 연산	덧셈 (성분별 합)·Scalar 곱 (성분별 배) — 평행사변형 · 신축 · 반전
Linear combination	$\alpha_1 v_1 + \cdots + \alpha_k v_k$. " 선형 " = 두 연산만 사용
Span(직관)	만들 수 있는 모든 결과의 집합 . 개수 $\neq$ 차원 (평행하면 직선)
표준 단위 Vector	임의 $x = \sum_i x_i e_i$ — 모든 Vector 가 e_i 의 LC
데이터 = Vector	이미지 $\in \mathbb{R}^{784}$, 신경망 한 층 = $Wx + b$

오늘과의 연결 : 1 회차는 두 연산으로 Vector 를 만들었다. 본 회차는 그 Vector 의 길이 · 각도를 쟀다 .

Review: 1 회차 마무리 숙제

지난 회차에서 낸 숙제 (마무리 문제의 유사 문제) 를 함께 확인합니다 .

$\mathbb{R}^2$ 의 Vector $u_1 = (1, 2)^T$, $u_2 = (3, 4)^T$, $u_3 = (5, 6)^T$ 이 주어졌다 .

(a) $w = u_1 - 2u_2 + u_3$ 를 계산하시오 .

(b) u_3 를 u_1, u_2 의 Linear combination 으로 표현할 수 있는가 ? 가능하면 계수를 구하시오 . (힌트 : 연립방정식)

(c) $\text{span}(u_1, u_2, u_3)$ 는 $\mathbb{R}^2$ 의 어떤 모양인가 ?

(d) MNIST 한 장을 $\mathbb{R}^{784}$ Vector x 로 펼쳤을 때 , 표준 단위 Vector e_i 의 Linear combination 으로 x 를 **한 줄로** 표현하시오 .

Review: 답

- **(a)** $w = (1,2) - (6,8) + (5,6) = (0, 0)^T$. 즉 $u_1 - 2u_2 + u_3 = 0$.
- **(b)** $u_3 = -u_1 + 2u_2$, **계수 $(-1, 2)$** . (연립 $x_1 + 3x_2 = 5, 2x_1 + 4x_2 = 6$ 의 해)
- **(c)** u_1, u_2 가 평행이 아니므로 이미 $\mathbb{R}^2$ 전체를 Span 하고 , u_3 는 이들의 Linear combination 이라 기여하지 않는다 $\rightarrow \mathbb{R}^2$ 전체 .
- **(d)** $x = \sum_{i=1}^{784} x_i e_i$ ($x_i = i$ 번째 픽셀 값).

Review: 핵심 관찰

- u_3 가 u_1, u_2 의 Linear combination 이라는 (a)·(b)·(c) 의 사실은 하나를 가리킨다 : **한 Vector 가 나머지의 Linear combination 이면 Span 에 기여하지 않는다** (" 개수 $\neq$ 차원 ", 8 회차 일차독립으로 이어짐).
- (d) 는 모든 $\mathbb{R}^n$ Vector 가 표준 basis 의 Linear combination 임을 보인다 . 이 성분 표현이 본 회차 **Norm·Dot product** 를 성분별 계산으로 정의할 수 있게 하는 출발점이다 .

본 회차 핵심 질문

두 Vector 의 길이와 각도를 어떻게 정의해야 $\cos\theta$ 가 자연스럽게 등장합니까 ?

이 한 질문에 답하려면 네 단계가 필요합니다 .

1.Norm(노름): 한 Vector 의 **길이**가 무엇인가

2.Dot product(내적): 두 Vector 의 **관계**를 한 Scalar(스칼라) 로 잡는 도구

3.Cauchy-Schwarz inequality(코시 - 슈바르츠 부등식): $|u \cdot v| \leq \|u\| \|v\|$ (C-4 에서 증명)

4.Cosine similarity(코사인 유사도): 위 3 에서 자동으로 $\cos\theta \in [-1, 1]$ 이 보장된다 .

학습 목표

이번 회차가 끝나면 학생은 다음을 답할 수 있어야 합니다 .

- 1.Euclidean norm(유클리드 노름)** $\|x\|_2$ 를 정의하고 , $\mathbb{R}^n$ 에서 세 가지 성질 (양정성 (positive definiteness)· 절대 동차성 (absolute homogeneity)· 삼각부등식 (triangle inequality)) 을 확인할 수 있습니다 . (세 가지 Norm 성질 , B-3 에서 정식 도입)
- 2.Dot product** $u \cdot v = \sum u_i v_i$ 를 정의하고 , $u \cdot u = \|u\|_2^2$ 임을 손계산으로 확인할 수 있습니다 .
- 3.각도의 정의** $\cos\theta = u \cdot v / \|u\| \|v\|$ 가 2 차원 · 3 차원의 기하 직관과 일치함을 보일 수 있습니다 .
- 4.Cauchy-Schwarz inequality** 를 $\mathbb{R}^n$ 에서 **이차식 판별식**으로 직접 증명할 수 있습니다 .
- 5.Cosine similarity** 가 임베딩 비교의 표준인 이유 (스케일 불변성) 를 설명하고 , NumPy 로 두 이미지 · 두 단어 임베딩의 cosine similarity 를 계산할 수 있습니다 .

본 회차 학습 흐름

질문	답 (이 강의의 답)	도구
한 Vector 의 길이 ?	Euclidean norm $\ x\ _2 = \sqrt{(\sum x_i^2)}$	피타고라스
길이의 기본 성질은 ?	(N1) 양정성 (positive definiteness) (N2) 동차성 (absolute homogeneity) (N3) 삼각부등식 (triangle inequality)	세 검사 도구
두 Vector 의 관계 ?	Dot product $u \cdot v = \sum u_i v_i$	성분별 곱의 합
Norm 과 Dot product 의 관계 ?	$\ u\ _2^2 = u \cdot u$	정의에서 직접
각도를 어떻게 정의 ?	$\cos\theta := u \cdot v / \ u\ \ v\ $	2D·3D 기하 일치
$\cos\theta \in [-1, 1]$ 보장 ?	Cauchy-Schwarz	이차식 판별식
AI 임베딩 비교 ?	Cosine similarity	스케일 불변

B. 수학 1: Norm, " 길이 " 의 정확한 명세

1 회차에서 본 한 Vector 를 이제 하나의 숫자 (크기) 로 요약한다 .

문제 상황 : MNIST 평균 7 이미지 $m \in \mathbb{R}^{784}$ 와 새 이미지 $x \in \mathbb{R}^{784}$. 둘이 얼마나 비슷한가 ?

가장 자연스러운 답 : 두 점 사이 거리 $\|x - m\|$.

→ 따라서 " 거리 " 가 무엇인지부터 정의해야 한다 .

기하적 해석 : Norm $\|x\|$ 는 원점에서 점 x 까지의 거리이다 . $\mathbb{R}^2$ 에서 $x = (3, 4)$ 이면 $\|x\| = \sqrt{3^2 + 4^2} = 5$ (피타고라스 정리). $\mathbb{R}^n$ 에서의 Euclidean norm $\|x\|_2 = \sqrt{(\sum_i x_i^2)}$ 은 피타고라스 정리의 n 차원 일반화이다 .

B-2. Euclidean norm 의 정의

정의 2.1 (Euclidean norm, ℓ_2 Norm)

$\mathbf{x} = (x_1, \dots, x_n) \in \mathbb{R}^n$ 의 **Euclidean norm**:

표기 $\|\cdot\|_2$ 는 " 좌변을 우변으로 정의한다 " 는 기호 (등호 = 가 단순히 같음을 진술하는 것과 구별).

$$\|\mathbf{x}\|_2 := \sqrt{x_1^2 + x_2^2 + \dots + x_n^2} = \sqrt{\sum_{i=1}^n x_i^2}$$

본 강의에서 별도 표기가 없으면 $\|\mathbf{x}\| := \|\mathbf{x}\|_2$ 로 약속한다 . 이후 본문 · 증명 · 계산에서 단독 $\|\cdot\|$ 는 모두 ℓ_2 Norm 을 가리킨다 .

B-2. Euclidean norm: 피타고라스 확장

동기 : 피타고라스의 n 차원 확장

- $\mathbb{R}^2$: $\sqrt{x_1^2 + x_2^2}$, 직각삼각형 빗변 .
- $\mathbb{R}^3$: $\sqrt{x_1^2 + x_2^2 + x_3^2}$, 직육면체 대각선 .
- $\mathbb{R}^n$: 같은 공식이 그대로 자연스럽다 .
- $x = (3, 4)$: $\|x\| = \sqrt{9 + 16} = 5$
- $x = (1, 2, 2)$: $\|x\| = \sqrt{1 + 4 + 4} = 3$
- $x = (2, -3, 1, -4)$: $\|x\| = \sqrt{4 + 9 + 1 + 16} = \sqrt{30} \approx 5.48$

B-3. Norm 의 세 가지 성질 ($\mathbb{R}^n$ 에서 검증)

Euclidean norm 의 세 가지 성질 : " 길이 " 는 음수일 수 없고 , 2 배로 늘리면 길이도 2 배이며 , 직진이 우회보다 짧다 .

성질	식	의미
(N1) 양정성 (positive definiteness)	$\ x\ \geq 0, \ x\ = 0 \Leftrightarrow x = 0$	거리는 음수 X, 거리 0 은 같은 점
(N2) 절대 동차성 (absolute homogeneity)	$\ \alpha x\ = \alpha \ x\ $	α 배로 늘리면 길이도 $ \alpha $ 배
(N3) 삼각부등식 (triangle inequality)	$\ x + y\ \leq \ x\ + \ y\ $	직진 $\leq$ 우회

표기 $\Leftrightarrow$ 는 " 필요충분조건 " (양쪽이 동시에 참).

B-3. Norm 세 가지 성질 : (N1)·(N2) 검증

$\mathbb{R}^n$ 에서 (N1)·(N2) 검증

- **(N1)**: $x_i^2 \geq 0$ 이므로 $\sum x_i^2 \geq 0$ 이다 . 등호는 모든 $x_i = 0$ 일 때만 성립한다 .
- **(N2)**: $\|\alpha x\|^2 = \sum (\alpha x_i)^2 = \alpha^2 \sum x_i^2$. 제곱근을 씌우면 $|\alpha| \|x\|$ 이다 .

→ (N3) 삼각부등식 (triangle inequality) 은 **Cauchy-Schwarz** 의 결과로 C 섹션에서 증명한다 .

B-4. 보조 Norm: ℓ_1, ℓ_∞ (Strang 보조)

같은 Vector 의 " 크기 " 를 재는 다른 잣대들 :

Norm	정의	직관 · 응용
ℓ_1 (Manhattan)	$\sum_i x_i $	격자 도시 (택시) · Lasso (sparse)
ℓ_2 (Euclidean)	$\sqrt{(\sum_i x_i^2)}$	피타고라스 · 거의 모든 LA · Ridge
ℓ_∞ (Chebyshev)	$\max_i x_i $	최악 경우 · 안정성 분석

Lasso·Ridge 는 머신러닝의 정규화 기법 , Part 4 1 회차에서 본격 .

B-4. 보조 Norm: 예제

예제 : 같은 Vector, 세 가지 크기


$$a = (3, 1, -2, 4) \in \mathbb{R}^4:$$

- $\|a\|_1 = 3 + 1 + 2 + 4 = 10$, 성분 절댓값의 합
- $\|a\|_2 = \sqrt{9 + 1 + 4 + 16} = \sqrt{30} \approx 5.48$, 성분 제곱합의 제곱근 (Euclidean)
- $\|a\|_\infty = \max\{3, 1, 2, 4\} = 4$, 성분 절댓값의 최댓값

본 회차는 ℓ_2 중심이다. ℓ_1, ℓ_∞ 는 Part 2 2 회차 (정사영 · 정규화) 에서 본격적으로 다룬다 .

B-5. Unit ball(단위구) 의 모양

$\mathbb{R}^2$ 의 Unit ball $\{x : \|x\| = 1\}$ 은 Norm 마다 다르다 : $\ell_1 \rightarrow$ **마름모** (꼭짓점이 좌표축 위), $\ell_2 \rightarrow$ **원** , $\ell_\infty \rightarrow$ **정사각형** . 같은 " 크기 1" 이지만 모양이 다르며 , 어떤 Norm 을 쓰느냐가 " 어디까지가 가까운가 " 의 범위를 다르게 정의한다 .



B-5. Unit ball: 각 곡선의 유도

각 곡선은 정의 방정식에서 직접 나온다.

- ℓ_1 : $|x_1| + |x_2| = 1$. 제 1 사분면에서는 $x_1 + x_2 = 1$, 즉 $(1,0)$ 과 $(0,1)$ 을 잇는 직선이다. 네 사분면의 부호 대칭으로 직선 4 개가 모여 꼭짓점이 좌표축 위에 있는 **마름모**가 된다.
- ℓ_2 : $x_1^2 + x_2^2 = 1$. 반지름 1 인 **원**의 정의식 그 자체이다.
- ℓ_∞ : $\max(|x_1|, |x_2|) = 1$. 두 좌표 중 큰 쪽이 1 이라는 뜻이므로 $|x_1| = 1, |x_2| \leq 1$ (세로변 $x_1 = \pm 1$) 또는 $|x_2| = 1, |x_1| \leq 1$ (가로변 $x_2 = \pm 1$) 이다. 변이 좌표축에 평행한 한 변 길이 2 의 **정사각형**이 된다.

B-5. Unit ball: 정규화 (normalization)

$x \neq 0$ 에 대해

$$\hat{\mathbf{x}} := \frac{\mathbf{x}}{\|\mathbf{x}\|_2}$$

표기 $\hat{x}$ ('x hat') 은 단위 Vector 로 정규화한 결과를 가리키는 관례 표기입니다 .

는 $\|\hat{x}\| = 1$ 인 **단위 Vector**(unit vector) 이다 . (N2) 동차성 (absolute homogeneity) 의 직접 응용이다 .

→ Embedding(임베딩) 검색에서 표준 전처리이다 . D 섹션에서 본격적으로 다룬다 .

잠깐 풀어보기 : Norm

문제 1 (계산)

$x = (1, -2, 2, 0)$ 의 $\ell_1, \ell_2, \ell_\infty$ 를 각각 구하시오 . 또한 x 를 단위 Vector 로 정규화하시오 .

문제 2 (개념)

다음 함수 $g: \mathbb{R}^2 \rightarrow \mathbb{R}$ 가 **Norm** 의 세 가지 성질 (N1·N2·N3) 을 만족하는가 ? 각각 검사하시오 .

- (i) $g(x) = x_1^2 + x_2^2$
- (ii) $h(x) = |x_1| + 2|x_2|$

힌트 : (N2) 동차성 (absolute homogeneity) $\|\alpha x\| = |\alpha| \|x\|$ 검사가 가장 빠른 판별이다 .

잠깐 풀어보기 : 답

문제 1

- $\|x\|_1 = 1 + 2 + 2 + 0 = 5$
- $\|x\|_2 = \sqrt{1 + 4 + 4 + 0} = 3$
- $\|x\|_\infty = \max\{1, 2, 2, 0\} = 2$
- 단위 Vector: $\hat{x} = x/3 = (1/3, -2/3, 2/3, 0)$. 검증 : $\sqrt{(1/9 + 4/9 + 4/9 + 0)} = \sqrt{9/9} = 1 \checkmark$

잠깐 풀어보기 : 답 (문제 2)

문제 2

- (i) g 는 Norm 이 아니다 . (N2) 위배 : $g(2x) = (2x_1)^2 + (2x_2)^2 = 4(x_1^2 + x_2^2) = 4g(x)$ 이지만 $|2|g(x) = 2g(x)$. ℓ_2 의 제곱은 Norm 이 아니다 (제곱근을 빼면 안 된다).
- (ii) h 는 Norm 이다 . 가중치 다른 ℓ_1 변형 . (N1) $\sum a_i |x_i| \geq 0$ ✓, (N2) $h(\alpha x) = |\alpha| h(x)$ ✓, (N3) 삼각부등식 (triangle inequality) ✓.

메시지 : Norm 의 세 성질은 외우는 것이 아니라 **검사 도구**이다 . 새 함수를 마주치면 세 성질로 즉시 검증한다 .

C. 수학 2: Dot product · 각도 · Cauchy-Schwarz

두 Vector 를 한 Scalar 로 묶어 **각도**를 정의한다 .

C-1. Dot product 의 정의

정의 2.2 ($\mathbb{R}^n$ 의 Dot product)

$u, v \in \mathbb{R}^n$ 의 **Dot product**(내적 , inner product):

$$\mathbf{u} \cdot \mathbf{v} := u_1 v_1 + u_2 v_2 + \cdots + u_n v_n = \sum_{i=1}^n u_i v_i \in \mathbb{R}$$

다른 표기 : $u^\top v, \langle u, v \rangle$. 본 강의에서는 세 표기를 혼용한다 .

예제

- $u = (1, 2, 3), v = (4, -1, 2): u \cdot v = 4 - 2 + 6 = 8$

C-1. 내적의 기하 : 정사영 (projection)

Dot product 는 단순한 가중합을 넘어 한 **Vector** 를 다른 **Vector** 방향으로 정사영한 길이를 재는 도구이다 . C-3 에서 유도할 기하 표현

$$\mathbf{u} \cdot \mathbf{v} = \|\mathbf{u}\| \|\mathbf{v}\| \cos \theta = \|\mathbf{v}\| \times (\mathbf{u} \text{를 } \mathbf{v} \text{ 방향으로 정사영한 길이})$$

에서 , $\|\mathbf{u}\|\cos\theta$ 가 바로 $\mathbf{u}$ 의 그림자 길이이고 거기에 $\|\mathbf{v}\|$ 를 곱한 값이 Dot product 이다 .

직관 (그림자): 빛을 $\mathbf{v}$ 방향으로 비출 때 $\mathbf{u}$ 가 $\mathbf{v}$ 위에 드리우는 **그림자의 길이**가 $\|\mathbf{u}\|\cos\theta$ 이다 . 여기에 $\|\mathbf{v}\|$ 를 곱한 것이 $\mathbf{u} \cdot \mathbf{v}$ 이다 . 두 Vector 가 직각이면 그림자가 0 $\rightarrow$ Dot product 도 0 이다 .

$\rightarrow$ 이 정사영 관점이 Part 2 정사영 (projection) 의 복선이다 .

C-1. Dot product: 직교성과 Norm 과의 관계

- $e_1 \cdot e_2 = 0$, 표준 basis 는 서로 직교 (직교 (Orthogonal): $u \cdot v = 0$ 인 두 Vector, 정식 정의는 C-6 정의 2.4).

즉시 따라오는 사실 : Norm 과의 관계

$$\mathbf{u} \cdot \mathbf{u} = \sum u_i^2 = \|\mathbf{u}\|^2$$

→ ℓ_2 Norm 은 Dot product 에서 자동으로 유도된다 . 이 사실이 ℓ_2 가 LA 의 표준이 되는 이유이다 .

C-2. Dot product 의 대수적 성질

다음 셋은 $\mathbb{R}^n$ 에서 정의로부터 직접 따라온다 .

- (D1) 대칭 : $u \cdot v = v \cdot u$
- (D2) 선형 : $(\alpha u + \beta w) \cdot v = \alpha(u \cdot v) + \beta(w \cdot v)$
- (D3) 양정성 (positive definiteness): $u \cdot u \geq 0, u \cdot u = 0 \iff u = 0$

증명 골자 . 모두 실수의 덧셈 · 곱셈 성질을 성분별로 적용한다 . 예 : (D2) $\sum_i (\alpha u_i + \beta w_i) v_i = \alpha \sum u_i v_i + \beta \sum w_i v_i$. ■

C-2. Dot product: 직관 (가중합)


직관 (가중합): Dot product 는 성분별 곱의 합이다 . $p = (p_1, \dots, p_n)$ 을 가중치 , $q = (q_1, \dots, q_n)$ 을 측정값으로 두면 $p \cdot q = \sum_i p_i q_i$ 는 **가중합** (weighted sum) 이다 . 두 Vector 가 하나의 Scalar 로 요약되는 이유는 각 성분의 기여 $p_i q_i$ 를 모두 누적한 결과가 한 숫자이기 때문이다 . 신경망 한 뉴런의 출력 $w^T x + b$ 이 이 가중합의 전형적 예이다 .

C-3. 2D·3D 에서 기하 해석 : 극좌표 표현

평면 (2D) (Strang §1.2). 길이 $\|u\|$, x 축과 각 α 인 Vector 의 성분은 삼각비에서

$$\mathbf{u} = (\|u\| \cos \alpha, \|u\| \sin \alpha)$$

이다 (극좌표). 두 Vector 를 각 α, β 로 쓰면 Dot product 에 두 각의 차 $\alpha - \beta (= \text{사이각 } \theta)$ 가 나타난다 .



C-3. 2D 기하 해석 : $\cos\theta$ 가 등장하는 이유

$u = (\|u\|\cos\alpha, \|u\|\sin\alpha)$, $v = (\|v\|\cos\beta, \|v\|\sin\beta)$ 로 쓰면

$$\mathbf{u} \cdot \mathbf{v} = \|\mathbf{u}\| \|\mathbf{v}\| (\cos \alpha \cos \beta + \sin \alpha \sin \beta) = \|\mathbf{u}\| \|\mathbf{v}\| \cos(\alpha - \beta)$$

(고교 삼각함수 차의 공식)

즉 두 Vector 사이의 각 $\theta = \alpha - \beta$ 가 자연스럽게 나타나며

$$\mathbf{u} \cdot \mathbf{v} = \|\mathbf{u}\| \|\mathbf{v}\| \cos \theta$$

이것이 **2 차원 · 3 차원의 기하적 사실**이다 .

다른 유도 : 코사인 법칙 . 원점과 두 Vector 끝점이 이루는 삼각형 (세 변 $\|u\|, \|v\|, \|u-v\|$, 끼인각 θ) 에서 코사인 법칙 $\|u-v\|^2 = \|u\|^2 + \|v\|^2 - 2\|u\|\|v\|\cos\theta$ 와 , Dot product 전개 $\|u-v\|^2 = \|u\|^2 - 2(u \cdot v) + \|v\|^2$ 를 비교해도 **같은 결과**를 얻는다 .

C-3. 핵심 발상 : $\cos\theta$ 를 정의한다

이 식을 n 차원으로 확장할 때는 $\cos\theta$ 를 정의해야 한다. n 차원에서는 "각"이라는 기하 개념이 미리 있는 것이 아니기 때문이다.

$$\cos \theta := \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|} \quad (\mathbf{u}, \mathbf{v} \neq \mathbf{0})$$

→ 이 정의가 정당하려면 $\cos\theta \in [-1, 1]$ 이 보장되어야 한다. 그 보장이 곧 **Cauchy-Schwarz** 이다 (다음 슬라이드).

C-4. Cauchy-Schwarz inequality: 정리와 Strang 발췌

정리 2.1 (Cauchy-Schwarz, $\mathbb{R}^n$)

모든 $u, v \in \mathbb{R}^n$ 에 대해

$$|\mathbf{u} \cdot \mathbf{v}| \leq \|\mathbf{u}\|_2 \|\mathbf{v}\|_2$$

등호 $\Leftrightarrow u, v$ 가 **평행** (즉 한쪽이 다른 쪽의 Scalar 배).

Strang Ch 1.2 발췌 : Strang 은 $\|u - tv\|^2 \geq 0$ 이 t 에 대한 이차식이라는 한 줄에서 **판별식 조건**으로 Cauchy-Schwarz 를 한 페이지에 풀이한다 .

C-4. Cauchy-Schwarz: 증명 (이차식 비음성 → 판별식)

$v = 0$ 이면 양변이 0 이므로 자명하다. $v \neq 0$ 이라 가정한다.

임의의 $t \in \mathbb{R}$ 에 대해 $\|u - tv\|^2 \geq 0$ (Norm 의 (N1)) 이므로

$$\|u - tv\|^2 = (u - tv) \cdot (u - tv) = \|u\|^2 - 2t(u \cdot v) + t^2\|v\|^2 \geq 0$$

($\|w\|^2 = w \cdot w$ 와 D2 선형성을 적용)

이 식은 t 에 대한 이차식이다 (t^2 의 계수 $\|v\|^2 > 0$). 모든 t 에서 비음수하려면 **판별식** ≤ 0 (이차식 $at^2 + bt + c \geq 0$ 이 모든 t 에서 성립 $\Leftrightarrow b^2 - 4ac \leq 0$):

$$4(u \cdot v)^2 - 4\|u\|^2\|v\|^2 \leq 0 \implies (u \cdot v)^2 \leq \|u\|^2\|v\|^2$$

C-4. Cauchy-Schwarz: 마무리 · 등호 조건

마무리 : 양변에 제곱근 . $|u \cdot v| \leq \|u\| \|v\|$. ■

이 증명 패턴 (이차식 비음성 $\rightarrow$ 판별식) 은 LA· 최적화에서 반복됩니다 . 기억해 둘 것 .

C-5. Cauchy-Schwarz 의 두 결과 : 삼각부등식 (triangle inequality) 과 각도

결과 1: ℓ_2 의 삼각부등식 (triangle inequality) (Norm 성질 N3)

$$\|\mathbf{u} + \mathbf{v}\|^2 = \|\mathbf{u}\|^2 + 2(\mathbf{u} \cdot \mathbf{v}) + \|\mathbf{v}\|^2 \leq \|\mathbf{u}\|^2 + 2\|\mathbf{u}\|\|\mathbf{v}\| + \|\mathbf{v}\|^2 = (\|\mathbf{u}\| + \|\mathbf{v}\|)^2$$

(중간 부등은 Cauchy-Schwarz: $\mathbf{u} \cdot \mathbf{v} \leq |\mathbf{u} \cdot \mathbf{v}| \leq \|\mathbf{u}\|\|\mathbf{v}\|$.)

따라서 $\|\mathbf{u} + \mathbf{v}\| \leq \|\mathbf{u}\| + \|\mathbf{v}\|$. ■ (ℓ_2 의 (N3) 는 Cauchy-Schwarz 가 핵심 .)

결과 2: 각도가 잘 정의됨

$\mathbf{u}, \mathbf{v} \neq \mathbf{0}$ 이면 Cauchy-Schwarz 로 $-1 \leq \mathbf{u} \cdot \mathbf{v} / \|\mathbf{u}\|\|\mathbf{v}\| \leq 1$ 이므로 , 유일한 $\theta \in [0, \pi]$ 로 $\cos\theta$ 가 정해진다 . 이 θ 가 두 Vector 사이의 각이다 .

C-5. Cauchy-Schwarz: 정사영의 길이

기하적 해석 (Projection 의 길이): u 를 v 방향으로의 정사영의 길이는 $|u \cdot v| / \|v\|$ 이다 . 이 값은 본래 u 의 길이 $\|u\|$ 를 초과할 수 없다 (양변에 $\|v\|$ 를 곱한 부등식이 Cauchy-Schwarz 이다). 두 Vector 가 평행할 때만 등호가 성립한다 .
Part 2 1·2 회차 정사영의 출발점이다 .

C-6. 각도와 직교성 : 정리

정의 2.3 (각도)

$u, v \neq 0$ 의 각 $\theta \in [0, \pi]$ 를 다음으로 정의한다 :

$$\cos \theta = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\|_2 \|\mathbf{v}\|_2}$$

정의 2.4 (Orthogonal(직교))

$u \cdot v = 0$ 일 때 두 Vector 를 **Orthogonal** 이라 부른다 ($\theta = \pi/2$).

$u \cdot v$ 부호	$\cos \theta$	θ	의미
> 0	> 0	$0 \leq \theta < \pi/2$	예각 , 같은 방향
$= 0$	$= 0$	$\theta = \pi/2$	직각 , Orthogonal
< 0	< 0	$\pi/2 < \theta \leq \pi$	둔각 , 반대 방향

C-6. 각도와 직교성 : 흔한 오해

흔한 오해 : "Dot product 가 0 이면 둘 중 하나가 영 Vector" 는 거짓이다 . 반례 $e_1 \cdot e_2 = 0$ — 둘 다 영 Vector 가 아니다 .
Dot product = 0 은 영 Vector 의 표시가 아니라 **두 Vector 가 서로 직각**이라는 기하 사실 (Orthogonal, Part 2 1 회차 본격 정의) 이다 .

잠깐 풀어보기 : Dot product·Cauchy-Schwarz

문제 1 (계산)

$u = (1, 1, 1), v = (1, -1, 0)$:

(a) $u \cdot v$

(b) $\|u\|, \|v\|$

(c) $\cos\theta$

(d) Cauchy-Schwarz $|u \cdot v| \leq \|u\|\|v\|$ 수치 검증 .

잠깐 풀어보기 : Dot product·Cauchy-Schwarz

문제 2 (증명)

$u, v \in \mathbb{R}^n$ 에 대해 다음 항등식을 증명하시오 :

$$\|\mathbf{u} - \mathbf{v}\|^2 = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2 - 2(\mathbf{u} \cdot \mathbf{v})$$

→ 이것이 코사인 법칙의 **Vector 버전**이다 . $u \cdot v = 0$ 일 때 어떻게 단순해지는지 살핀다 .

잠깐 풀어보기 : 답

문제 1

- (a) $u \cdot v = 1 - 1 + 0 = 0$
- (b) $\|u\| = \sqrt{3}, \|v\| = \sqrt{2}$
- (c) $\cos\theta = 0/(\sqrt{3}\sqrt{2}) = 0 \rightarrow \theta = \pi/2$ (정확히 **90°**, **Orthogonal**)
- (d) $|0| = 0 \leq \sqrt{6} \approx 2.45 \checkmark$

잠깐 풀어보기 : 답 (문제 2 증명)

문제 2 (증명)

Dot product 의 분배 (D2) 로

$$\begin{aligned}\|\mathbf{u} - \mathbf{v}\|^2 &= (\mathbf{u} - \mathbf{v}) \cdot (\mathbf{u} - \mathbf{v}) = \mathbf{u} \cdot \mathbf{u} - 2\mathbf{u} \cdot \mathbf{v} + \mathbf{v} \cdot \mathbf{v} \\ &= \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2 - 2(\mathbf{u} \cdot \mathbf{v}). \blacksquare\end{aligned}$$

$\mathbf{u} \cdot \mathbf{v} = 0$ 일 때 : $\|\mathbf{u} - \mathbf{v}\|^2 = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2$, 즉 피타고라스 정리이다 .

메시지 : Dot product 가 0 이면 코사인 법칙이 피타고라스로 단순화된다 . 이것이 "Orthogonal 이 LA 에서 특별한 위상 " 인 이유의 출발점이다 (Part 2 1 회차 본격).

D. 수학 3: Cosine similarity 와 CS·AI 적용

정의된 각도를 그대로 **AI 임베딩 비교의 표준 도구**로 사용한다.

정의 2.5 (Cosine similarity)

$u, v \in \mathbb{R}^n (\neq 0)$ 에 대해

$$\text{cos_sim}(\mathbf{u}, \mathbf{v}) := \cos \theta = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\|_2 \|\mathbf{v}\|_2} \in [-1, 1]$$

Cauchy-Schwarz 가 값의 범위 $[-1, 1]$ 를 보장한다.

D-1. Cosine similarity: 값의 의미

값	의미
+1	완전 같은 방향 (평행 , 같은 부호)
0	직교 (관련 없음)
-1	완전 반대 방향

D-1. Cosine similarity: 스케일 불변 비교

직관 (스케일 불변성): Cosine similarity 는 두 Vector 를 길이 1 로 정규화한 뒤 비교한 값과 같다 . u 와 cu ($c > 0$) 의 cosine 은 항상 1 이다 . 즉 **Norm (크기) 의 차이를 무시하고 방향만 비교**한다 . 손글씨 인식에서 같은 7 을 굵게 쓴 이미지와 가늘게 쓴 이미지는 ℓ_2 Norm 은 다르지만 cosine 은 1 에 가깝다 . 크기보다 패턴 (방향) 이 중요한 비교에 cosine 을 사용한다 .

D-2. 스케일 불변성 : 수치 예시와 정규화

예시 : 같은 단어 , 다른 길이

$d_1 = (1, 1, 0, 0, \dots)$, $d_2 = (10, 10, 0, 0, \dots)$, 같은 두 단어만 등장하고 등장 횟수가 10 배 차이 난다 .

거리	값	해석
Euclidean $\ d_1 - d_2\ _2$	$\sqrt{(81 + 81)} = \sqrt{162} \approx 12.7$	" 멀다 "
Cosine similarity	$20/\sqrt{2}\sqrt{200} = 1$	" 같다 "

긴 문서와 짧은 문서를 Euclidean 으로 비교하면 **길이 차이만으로 큰 거리**가 되지만 , cosine 은 그렇지 않다 . 식으로도 모든 $\alpha, \beta > 0$ 에 대해

$$\text{cos_sim}(\alpha \mathbf{u}, \beta \mathbf{v}) = \frac{\alpha \beta (\mathbf{u} \cdot \mathbf{v})}{\alpha \beta \|\mathbf{u}\| \|\mathbf{v}\|} = \text{cos_sim}(\mathbf{u}, \mathbf{v}).$$

D-2. 스케일 불변성 : 정규화 후 Dot product

정규화 후 Dot product 와 같다

$\hat{u} = u/\|u\|$, $\hat{v} = v/\|v\|$ 일 때 $\text{cos_sim}(u, v) = \hat{u} \cdot \hat{v}$. 검색 시점엔
단순 Dot product 한 번으로 계산한다 . BERT(문장 임베딩
언어 모델)·CLIP(이미지 · 텍스트 공동 임베딩 모델) 이 출력
직후 흔히 L2 정규화를 하는 이유이다 (정식 분해는 Part 4).


D-3. Cosine similarity 의 AI 응용

분야	어떻게 쓰는가
문서 검색 (RAG)	query 임베딩과 문서 임베딩들의 cosine similarity $\rightarrow$ top-k 문서
Word2Vec · GloVe	"king - man + woman $\approx$ queen", 단어 임베딩 cosine 으로 유사어 검색
CLIP (이미지 · 텍스트)	텍스트 임베딩과 이미지 임베딩 cosine $\rightarrow$ zero-shot 분류
Recommendation	사용자 임베딩과 아이템 임베딩 cosine
Face recognition	두 얼굴 임베딩 cosine 임계값으로 동일인 판정

한 줄 결론

현대 AI 에서 " 두 객체가 얼마나 비슷한가 " 를 정량화하는 표준 도구가 cosine similarity 이다 . 그리고 그 정의의 정당성 ($[-1, 1]$ 범위) 이 Cauchy-Schwarz 이다 .

D-4. Attention



D-4. 최종 수식 : Scaled Dot-Product Attention

지금까지의 과정을 한 수식으로 :

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^{\top}}{\sqrt{d_k}}\right)V$$

단계	의미
$QK^{\top}$	단어 간 관련성 점수 계산
$\div \sqrt{d_k}$	점수 크기 조절 (Scale)
Softmax	참고 비율 계산
$\times V$	참고 비율대로 정보 가져오기

핵심 : Q·K 로 "누구를 참고할지"를 계산하고, 그 비율로 V를 섞어 문맥 벡터를 만든다.

D-4. Attention 은 " 어떤 단어를 얼마나 참고할까 ?" 를 계산한다

문장 예시 : 나는 사과를 먹었다

현재 단어가 " 먹었다 " 라면 , 모델은 " 나는 "." 사과를 "." 먹었다 " 중 어떤 단어를 가장 많이 참고해야 할까 ? 사람은 자연스럽게 " 사과를 " 이 중요하다고 본다 . Attention 은 이 판단을 숫자로 계산한다 .

핵심 : Attention 은 각 단어가 문장 안의 다른 단어들을 얼마나 참고해야 하는지 계산하는 구조이다 .

D-4. 먼저 단어를 임베딩 벡터로 바꾼다

세 단어를 2 차원 벡터로 단순화하면 :

$$X = \begin{bmatrix} 1 & 2 \\ 2 & 1 \\ 1 & 1 \end{bmatrix} \quad \begin{array}{l} \leftarrow [1, 2] = \text{나는} \\ \leftarrow [2, 1] = \text{사과를} \\ \leftarrow [1, 1] = \text{먹었다} \end{array}$$

각 행이 단어 하나다 . X 는 **입력 임베딩 행렬** .

핵심 : Attention 은 단어 자체가 아니라 , 단어를 숫자 벡터로 바꾼 뒤 계산한다 .

D-4. 같은 입력을 $Q \cdot K \cdot V$ 세 가지로 변환

입력 X 를 그대로 쓰지 않고 , 세 가중치 행렬을 곱해 Q, K, V 를 만든다 :

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V$$

W_Q, W_K, W_V 는 모델이 학습하는 가중치다 (사람이 의미를 넣는 게 아니라 학습으로 찾는다). 설명용으로 다음을 가정 :

$$W_Q = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}, \quad W_K = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}, \quad W_V = \begin{bmatrix} 1 & 0 \\ 1 & 2 \end{bmatrix}$$

핵심 : $Q \cdot K \cdot V$ 는 서로 다른 입력이 아니라 , 같은 X 를 서로 다른 학습 가중치로 변환한 결과다 .

D-4. 변환 결과 $Q \cdot K \cdot V$

앞의 X 와 W 들을 곱하면 :

$$Q = XW_Q = \begin{bmatrix} 2 & 2 \\ 4 & 1 \\ 2 & 1 \end{bmatrix}, \quad K = XW_K = \begin{bmatrix} 1 & 3 \\ 2 & 3 \\ 1 & 2 \end{bmatrix}, \quad V = XW_V = \begin{bmatrix} 3 & 4 \\ 3 & 2 \\ 2 & 2 \end{bmatrix}$$

각 행이 한 단어의 Query·Key·Value 벡터다 (1 행 = 나는 , 2 행 = 사과를 , 3 행 = 먹었다).

D-4. Q 는 검색어 , K 는 색인 , V 는 내용

구성	역할	비유
Q (Query)	무엇을 찾고 싶은가 ?	검색어
K (Key)	무엇과 관련 있는가 ?	책 제목 · 색인
V (Value)	실제로 전달할 정보	책 내용

도서관에서 책을 찾듯 : 검색어와 색인을 비교해 관련 책을 찾고 , 실제로 가져오는 건 책 내용이다 .

Attention 도 Q 와 K 를 비교해 " 누구를 참고할지 " 를 정하고 , 실제 정보는 V 에서 가져온다 .

핵심 : Q·K 는 참고 대상을 고르는 데 , V 는 실제 정보를 전달하는 데 쓰인다 .

D-4. 왜 QV 가 아니라 QKV 인가 ?

초보자가 가장 많이 하는 질문 : "Q 와 V 만 있으면 되지 않나 ? 왜 K 가 필요한가 ?"

QV 만 쓰면 — V 가 검색 기준과 전달할 정보를 동시에 맡아야 한다 (한 표현이 두 역할).

QKV 를 쓰면 — 역할을 나눈다 :

$QK^T \rightarrow$ 참고 비율, 참고 비율 $\times V \rightarrow$ 새 문맥 벡터

Q —————▶ K —————▶ V
검색어 검색용 단서 실제 내용
(누구를 볼지) (참고 비율) (정보 가져오기)

핵심 : K 와 V 를 분리하면 " 검색용 표현 " 과 " 정보 전달용 표현 " 을 목적에 맞게 따로 학습할 수 있다 .

D-4. bank 예시 : 문맥에 따라 의미가 달라지는 단어

영어 단어 **bank** 는 두 뜻이 있다 : 금융기관 / 강둑 .

문장 1: I went to the **bank** to withdraw money.

문장 2: I sat on the **bank** of the river.

모델은 문맥을 보고 **bank** 의 의미를 구분해야 한다 .

Q: 지금 문장에서 bank 는 어떤 의미인가 ?

K 후보 1: money, account, loan → 금융기관 문맥이면 Q·K ↑

K 후보 2: river, water, shore → 강둑 문맥이면 Q·K ↑

그다음 실제 정보 (V) 를 그 비율대로 가져온다 .

핵심 : K·V 를 분리했기에 **bank** 처럼 문맥으로 의미가 갈리는 단어도 잘 처리한다 .

D-4. " 먹었다 " 가 어떤 단어를 참고할지 계산

현재 단어 " 먹었다 " 의 Query 는 Q 의 3 행 : $Q_3 = [2, 1]$. 모든 Key 와 내적한다 .

$$Q_3 \cdot K_1 = [2, 1] \cdot [1, 3] = 5, \quad Q_3 \cdot K_2 = [2, 1] \cdot [2, 3] = 7, \quad Q_3 \cdot K_3 = [2, 1] \cdot [1, 2] = 4$$

현재 단어	참고 후보	점수
먹었다	나는	5
먹었다	사과를	7
먹었다	먹었다	4

가장 큰 값은 **7** $\rightarrow$ " 먹었다 " 는 " 사과를 " 을 가장 많이 참고한다 .

핵심 : Q·K 의 내적은 " 현재 단어가 다른 단어를 얼마나 참고할지 " 의 점수다 .

D-4. 왜 K^T 를 곱하는가 ?

Q 와 K 는 각각 3×2 다 . 그대로 QK 는 안 된다 ($(3 \times 2)(3 \times 2)$ 는 가운데 차원 불일치). 그래서 K 를 전치한다 .

$$K^T = \begin{bmatrix} 1 & 2 & 1 \\ 3 & 3 & 2 \end{bmatrix} \Rightarrow QK^T = (3 \times 2)(2 \times 3) = 3 \times 3$$

$$QK^T = \begin{bmatrix} 8 & 10 & 6 \\ 7 & 11 & 6 \\ 5 & 7 & 4 \end{bmatrix}$$

각 원소가 $Q_i \cdot K_j$ (모든 단어 쌍의 내적). 3 행이 앞서 본 " 먹었다 " 의 점수 [5,7,4].

핵심 : K^T 를 곱하는 건 모든 Query·Key 내적을 **행렬곱 한 번**으로 계산하기 위해서다 .

D-4. Scale 과 Softmax 로 참고 비율을 만든다

" 먹었다 " 의 점수 $[5, 7, 4]$ 를 바로 Softmax 에 넣지 않고 , 먼저 $\sqrt{d_k}$ 로 나눈다 ($d_k = \text{Key 차원} = 2$):


$$\frac{[5, 7, 4]}{\sqrt{2}} \approx [3.54, 4.95, 2.83] \xrightarrow{\text{Softmax}} [0.18, 0.73, 0.09]$$

Softmax 는 전체가 아니라 **각 행 (단어)** 마다 적용된다 → 단어마다 자기만의 참고 비율 .

핵심 : Scale 은 점수가 너무 커지는 것을 막고 , Softmax 는 점수를 합 1 의 참고 비율로 바꾼다 .

D-4. softmax 를 그림으로 (같은 예시)

점수 [5, 7, 4] → 스케일 → softmax [0.18, 0.73, 0.09] ('먹었다'의 참고 비율)



점수 [5,7,4] 가 $\sqrt{2}$ 로 완만해진 뒤 , Softmax 로 **합이 1 인 참고 비율** [0.18, 0.73, 0.09] 가 된다 . " 사과를 "(0.73) 에 크게
쏠리되 나머지도 몫을 받는다 .

D-4. 참고 비율로 V 를 섞는다

" 먹었다 " 의 참고 비율 $[0.18, 0.73, 0.09]$ 로 Value 들을 가중합한다 ($V_1=[3,4]$, $V_2=[3,2]$, $V_3=[2,2]$):

$$0.18 [3, 4] + 0.73 [3, 2] + 0.09 [2, 2] \approx [2.91, 2.36]$$

이 벡터가 새로운 " 먹었다 " 표현이다 . 원래는 단어 자체의 벡터였지만 , 이제 " 사과를 " 의 정보를 많이 반영한 **문맥 벡터**가 됐다 .

핵심 : Attention 의 출력은 정답이 아니라 , 문맥이 반영된 새로운 단어 벡터다 .

D-4. 최종 수식 : Scaled Dot-Product Attention

지금까지의 과정을 한 수식으로 :

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^{\top}}{\sqrt{d_k}}\right)V$$

단계	의미
$QK^{\top}$	단어 간 관련성 점수 계산
$\div \sqrt{d_k}$	점수 크기 조절 (Scale)
Softmax	참고 비율 계산
$\times V$	참고 비율대로 정보 가져오기

핵심 : Q·K 로 "누구를 참고할지"를 계산하고, 그 비율로 V를 섞어 문맥 벡터를 만든다.



D-4. 전체 흐름 요약

$$X \Rightarrow Q = XW_Q, K = XW_K, V = XW_V$$

$$QK^T \Rightarrow \text{관련성 점수} \xrightarrow{\div \sqrt{d_k}} \text{스케일} \xrightarrow{\text{Softmax}} \text{참고 비율} \xrightarrow{\times V} \text{문맥 벡터}$$

마지막 한 줄 : Attention 은 " 검색어 Q 로 색인 K 를 찾아보고 , 찾은 비율만큼 내용 V 를 가져오는 구조 " 다 .
W_Q, W_K, W_V 는 모두 학습되는 가중치이며 , 모델은 학습으로 좋은 변환을 스스로 찾는다 .

D-4. 실제 임베딩으로 확인



- (1) 뜻이 비슷한 단어는 **방향**이 비슷 → 내적 (Dot product) 이 크다 .
- (2) 그래서 attention 가중치도 **같은 무리끼리 커진다** (밝은 칸 : animal 무리 , run·jump 무리).
- → 본 회차 **Dot product·Norm** 이 곧 **LLM Attention** 의 심장 (Part 4 7 회차 정식).

잠깐 풀어보기 : Cosine similarity

문제 1 (계산)

다음 세 쌍의 cosine similarity 를 구하고 , 가장 비슷한 쌍과 가장 먼 쌍을 찾으시오 .

- $a = (1, 2, 2), b = (2, 4, 4)$
- $a = (1, 2, 2), c = (2, -1, 0)$
- $a = (1, 2, 2), d = (-1, -2, -2)$

→ 각각의 의미 (같은 방향 · 직교 · 반대 방향) 를 한 단어로 적으시오 .

잠깐 풀어보기 : 답 (1)

$$\|a\| = 3.$$

(a, b)

$$\|b\| = \sqrt{4+16+16} = 6, a \cdot b = 2+8+8 = 18.$$

$$\cos\theta = 18/(3 \cdot 6) = 1 \rightarrow \text{완전 같은 방향} \quad (b = 2a).$$

(a, c)

$$\|c\| = \sqrt{4+1+0} = \sqrt{5}, a \cdot c = 2 - 2 + 0 = 0.$$

$$\cos\theta = 0 \rightarrow \text{직교 (Orthogonal)}.$$

잠깐 풀어보기 : 답 (2)

(a, d)

$$\|d\| = 3, a \cdot d = -1 - 4 - 4 = -9.$$

$$\cos\theta = -9/(3 \cdot 3) = -1 \rightarrow \text{완전 반대 방향 } (d = -a).$$

→ 가장 비슷한 쌍 : (a, b). 가장 먼 쌍 : (a, d).

메시지 : cosine similarity 의 세 극단값 +1, 0, -1 이 각각 평행 · 직교 · 반평행에 정확히 대응한다 . Euclidean 거리에는 이런 깔끔한 해석이 없다 .

E. 코딩 실습 (필요 시) + 정리 + 과제

→ Colab으로 실행

Colab 실습 정책 : 매 회차 필수 X. 본 회차는 cosine similarity 의 AI 응용이 직관적이므로 시간이 허락하면 1-2 개 실습이 가치 있다 . 시간이 부족하면 수학 정리 · 마무리 문제로 마치고 코딩은 과제로 돌릴 수 있다 .

1. Norm 직접 구현 : $\ell_1, \ell_2, \ell_\infty$ 를 라이브러리 호출 없이 NumPy 로 작성 + `np.linalg.norm` 과

`np.allclose` 로 검증

2. Unit ball 시각화 : 마름모 · 원 · 정사각형 ($\mathbb{R}^2$)

3. Dot product · cosine similarity 직접 구현 + 스케일 불변성 수치 확인

E-1. 코딩 실습 골자 (계속)

1.두 MNIST 이미지의 **cosine similarity**: 같은 숫자 쌍 vs 다른 숫자 쌍 비교

2.사전 훈련 단어 임베딩 (gensim Word2Vec 또는 sentence-transformers): "king" · "queen" ·
"apple" 의 pairwise cosine similarity

3.임베딩 정렬 : query 단어 1 개와 어휘 전체의 cosine similarity → top-5 nearest neighbors

E-2. 본 회차 핵심 5 개

1. **Norm** 은 한 Vector 의 **길이**이다 . $\ell_2 = \sqrt{(\sum x_i^2)}$, 피타고라스의 n 차원 확장 .
2. **Dot product** 는 두 Vector 의 관계를 한 Scalar 로 묶는다 . $u \cdot u = \|u\|^2$ 이므로 ℓ_2 가 Dot product 에서 자동 유도된다 .
3. **각도**는 정의이다 . $\cos\theta := u \cdot v / \|u\| \|v\|$, 2D·3D 기하 사실의 n 차원 확장 .
4. **Cauchy-Schwarz** ($|u \cdot v| \leq \|u\| \|v\|$) 가 $\cos\theta \in [-1, 1]$ 과 ℓ_2 삼각부등식 (triangle inequality) 을 동시에 보장한다 . 증명 = **이차식 비음성** $\rightarrow$ **판별식 패턴** .
5. **Cosine similarity** 는 스케일 불변 . AI 임베딩 비교의 표준 도구이며 Word2Vec·CLIP·RAG·Attention 에서 쓰인다 .

E-3. 자기 점검 질문

- ℓ_2 가 ℓ_1, ℓ_∞ 와 **다른** 한 가지 성질은 무엇입니까 ? (힌트 : Dot product 와의 관계)
- Cauchy-Schwarz 증명에서 핵심 아이디어 한 줄 : "_____ 이 t 에 대해 비음수 $\rightarrow$ _____ ≤ 0 ".
- 두 Vector 가 **Orthogonal** 이라는 것은 cosine similarity 와 어떤 관계입니까 ?
- BERT 임베딩 비교에서 **L2 정규화를 먼저 한 다음 Dot product** 를 쓰는 이유는 ?
- 같은 두 단어만 들어 있고 등장 횟수만 10 배 다른 두 문서를 비교할 때 Euclidean 과 cosine 중 어느 쪽이 자연스럽습니까 ? 왜 ?

본 회차 마무리 문제 (즉석 풀이)

본 회차 학습 흐름 (Norm $\rightarrow$ Dot product $\rightarrow$ 각도 $\rightarrow$ Cauchy-Schwarz $\rightarrow$ cosine similarity) 을 한 문제로 종합한다 .

$u = (3, 4)$, $v = (1, 7)$ 에 대해 다음을 모두 구하시오 .

- **(a)** $\|u\|$, $\|v\|$
- **(b)** $u \cdot v$
- **(c)** $\cos\theta$, cosine similarity
- **(d)** Cauchy-Schwarz $|u \cdot v| \leq \|u\|\|v\|$ 수치 검증
- **(e)** 항등식 검증 : $\|u - v\|^2 = \|u\|^2 + \|v\|^2 - 2(u \cdot v)$

메시지 : (e) 는 코사인 법칙의 Vector 버전이다 . 본 회차에서 본 Norm·Dot product 가 한 식에 함께 등장한다 .

본 회차 마무리 문제 : 답

- **(a)** $\|u\| = \sqrt{9 + 16} = 5$, $\|v\| = \sqrt{1 + 49} = \sqrt{50}$
- **(b)** $u \cdot v = 3 \cdot 1 + 4 \cdot 7 = 31$
- **(c)** $\cos\theta = 31/5\sqrt{50} = 31/\sqrt{1250} \approx 0.877$. 두 Vector 가 거의 같은 방향 ($\theta \approx 28.7^\circ$).
- **(d)** $|31| = 31 \leq 5\sqrt{50} = \sqrt{1250} \approx 35.36$ ✓ Cauchy-Schwarz 성립 (등호는 아니므로 두 Vector 가 정확히 평행은 아님).
- **(e)** $u - v = (2, -3)$, $\|u-v\|^2 = 4 + 9 = 13$
 - 우변 : $25 + 50 - 2 \cdot 31 = 13$ ✓ 항등식 성립 .

핵심 : (e) 항등식은 본 회차 모든 개념의 종합이며 , 다음 회차 Matrix·Vector 곱 $\rightarrow$ 4 회차 Orthogonality (피타고라스의 일반화) 로 이어진다 .

다음 회차 Review 용 숙제

위 마무리 문제의 유사 문제이다. 강의 후 풀어 와서 **3 회차 Review** 시간에 비교한다.

3 차원으로 확장 : $u = (2, 2, 1)$, $v = (1, -2, 2)$ 에 대해 (a)~(e) 를 동일하게 구하시오.

풀이 시 자기 점검

- (c) $\cos\theta$ 의 값이 특별한 수인가? 그 의미는?
- (e) 항등식이 이 경우 어떻게 더 단순해지는가? 어떤 정리가 등장하는가?

E-5. 다음 회차 (3 회차) 예고

주제 : Matrix(행렬) 와 Matrix·Vector 곱의 두 해석 (Row picture · Column picture)

연결 : 본 회차에서 본 Dot product 가 그대로 **Matrix·Vector 곱의 Row picture** 해석이 됩니다 . Ax 의 i 번째 성분 = A 의 i 행과 x 의 **Dot product**. 즉 본 회차의 한 줄 정의 $u \cdot v$ 가 **모든 행에 대해 일괄 적용된 것이 곧 행렬 곱**입니다 .

그리고 또 다른 해석 (**Column picture**) 이 1 회차의 **Linear combination** 과 직접 연결됩니다 . 두 회차에서 본 도구가 3 회차 한 식 Ax 에서 함께 쓰입니다 .

E-6. 부록 : MML §3.1-§3.4 · Strang Ch 1.2 추천 연습문제

자기 학습용 (과제와 별도 , 자신의 페이스로):

- **MML §3.1-§3.4 Exercise:** Norms · Inner products · Cauchy-Schwarz · Cosine 정의 (메인)
- **Strang Ch 1.2 Problem 1-3:** Dot product 계산 · 각도 (워밍업)
- **Strang Ch 1.2 Problem 4-5:** 단위 Vector · 정규화
- **Strang Ch 1.2 Problem 11:** Cauchy-Schwarz 수치 검증
- **Strang Ch 1.2 Problem 15:** 삼각부등식 (triangle inequality) 수치 검증
- **Strang Ch 1.2 Problem 18-20:** cosine similarity 응용

MIT OCW 18.06 Lecture 1 (Strang 본인) 영상 : 첫 30 분이 본 회차 내용과 거의 일치한다 .

Q & A

본 회차 학습 흐름 :

Norm (ℓ_2) → Dot product → 각도 정의 → Cauchy-Schwarz → cosine similarity → 임베딩 비교

한 줄 결론 : Cauchy-Schwarz 부등식 하나가 AI 의 임베딩 검색 시스템 전체의 정당성을 보장한다 .

HANDOUT: 본 PDF + 02_노름 _내적 _코사인유사도 .ipynb