

Part 1 2회차

Norm·Dot product·Cosine similarity

MML §3.1-§3.4 (메인) · Strang Ch 1.2 (발췌, Cauchy-Schwarz 판별식 풀이) · [EoLA Ch.9: Dot products and duality](#) · Part 1 (LA1)

이제 Vector(벡터) 사이의 거리와 각도를 정의합니다.

Review: 1회차 마무리 숙제

지난 회차에서 제기한 문제:

$\mathbb{R}^3$ 의 Vector $\mathbf{u} = (1, 2, 2)$, $\mathbf{v} = (2, 0, 1)$ 이 주어졌다.

(a) $2\mathbf{u} - 3\mathbf{v}$ 를 계산하시오.

(b) $\mathbf{u}$ 를 $\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3$ 의 Linear combination(선형결합)으로 표기하시오.

답

- (a) $2\mathbf{u} - 3\mathbf{v} = (2, 4, 4) - (6, 0, 3) = (-4, 4, 1)$
- (b) $\mathbf{u} = 1 \cdot \mathbf{e}_1 + 2 \cdot \mathbf{e}_2 + 2 \cdot \mathbf{e}_3$. 좌표 자체가 표준 basis 계수이다.

핵심 관찰

(b)에서 "Vector = 좌표의 묶음"이라는 1회차 정의가 보여주는 사실: 모든 $\mathbb{R}^n$ Vector는 표준 basis의 Linear combination이다. 이 사실이 본 회차 Norm·Dot product를 성분별 계산으로 정의할 수 있게 한다.

→ 1회차에서 본 두 연산 (덧셈·Scalar곱)으로 충분히 풍부한 객체가 만들어졌다. 이제 두 Vector를 서로 비교한다.

본 회차 핵심 질문

두 Vector의 길이와 각도를 어떻게 정의해야 $\cos \theta$ 가 자연스럽게 등장합니까?

이 한 질문에 답하려면 네 단계가 필요합니다.

1. **Norm(노름)**: 한 Vector의 길이가 무엇인가
2. **Dot product(내적)**: 두 Vector의 관계를 한 Scalar(스칼라)로 잡는 도구
3. **Cauchy-Schwarz inequality(코시-슈바르츠 부등식)**: $|\mathbf{u} \cdot \mathbf{v}| \leq \|\mathbf{u}\| \|\mathbf{v}\|$ (C-4에서 증명)
4. **Cosine similarity(코사인 유사도)**: 위 3에서 자동으로 $\cos \theta \in [-1, 1]$ 이 보장된다.

본 회차의 모든 결과는 이 순서를 따른다.

학습 목표

이번 회차가 끝나면 학생은 다음을 답할 수 있어야 합니다.

1. **Euclidean norm(유클리드 노름)** $\|\mathbf{x}\|_2$ 를 정의하고, $\mathbb{R}^n$ 에서 세 가지 성질 (양정성(positive definiteness)·절대 동차성(absolute homogeneity)·삼각부등식(triangle inequality))을 확인할 수 있습니다. (세 가지 Norm 성질, B-3에서 정식 도입)
2. **Dot product** $\mathbf{u} \cdot \mathbf{v} = \sum u_i v_i$ 를 정의하고, $\mathbf{u} \cdot \mathbf{u} = \|\mathbf{u}\|_2^2$ 임을 손계산으로 확인할 수 있습니다.
3. 각도의 정의 $\cos \theta = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|}$ 가 2차원·3차원의 기하 직관과 일치함을 보일 수 있습니다.
4. **Cauchy-Schwarz inequality**를 $\mathbb{R}^n$ 에서 이차식 판별식으로 직접 증명할 수 있습니다.
5. **Cosine similarity**가 임베딩 비교의 표준인 이유 (스케일 불변성)를 설명하고, NumPy로 두 이미지·두 단어 임베딩의 cosine similarity를 계산할 수 있습니다.

본 회차 학습 흐름

질문	답 (이 강의의 답)	도구
한 Vector의 길이?	Euclidean norm $\ \mathbf{x}\ _2 = \sqrt{\sum x_i^2}$	피타고라스
길이의 본질적 성질은?	(N1) 양정성(positive definiteness) · (N2) 동차성(absolute homogeneity) · (N3) 삼각부등식(triangle inequality)	세 검사 도구
두 Vector의 관계?	Dot product $\mathbf{u} \cdot \mathbf{v} = \sum u_i v_i$	성분별 곱의 합
Norm과 Dot product의 관계?	$\ \mathbf{u}\ _2^2 = \mathbf{u} \cdot \mathbf{u}$	정의에서 직접
각도를 어떻게 정의?	$\cos \theta := \frac{\mathbf{u} \cdot \mathbf{v}}{\ \mathbf{u}\ \ \mathbf{v}\ }$	2D·3D 기하 일치
$\cos \theta \in [-1, 1]$ 보장?	Cauchy-Schwarz	이차식 판별식
AI 임베딩 비교?	Cosine similarity	스케일 불변

본 회차는 이 순서를 따라 진행한다.

수업 흐름

순서	단계	내용
①	A	오프닝: 핵심 질문 + 1회차 Review
②	B	Norm: 동기 · 정의 · 세 가지 성질 ($\mathbb{R}^n$ 에서 검증) · $\ell_1, \ell_2, \ell_\infty$
③	C	Dot product · 각도 · Cauchy-Schwarz ($\mathbb{R}^n$ 에서 증명)
④	D	Cosine similarity · 임베딩 정렬 · CS·AI 적용
⑤	E	코딩 실습 (필요 시) + 마무리 문제 + 숙제

표준 사이클: 핵심 질문 → Review → 본 강의 → 마무리 문제 → 숙제 (= 다음 회차 Review)

본 회차는 **C**가 핵심이다. Cauchy-Schwarz 증명 패턴 (이차식 → 판별식) 이 학기 전반에 반복된다.

B. 수학 1: Norm, "길이"의 정확한 명세

1회차에서 본 한 Vector를 이제 하나의 숫자 (크기)로 요약한다.

B-1. 길이를 정의해야 하는 이유

문제 상황: MNIST 평균 7 이미지 $\mathbf{m} \in \mathbb{R}^{784}$ 와 새 이미지 $\mathbf{x} \in \mathbb{R}^{784}$. 둘이 얼마나 비슷한가?

가장 자연스러운 답: 두 점 사이 거리 $\|\mathbf{x} - \mathbf{m}\|$.

→ 따라서 "거리"가 무엇인지부터 정의해야 한다.

기하적 해석: Norm $\|\mathbf{x}\|$ 는 원점에서 점 $\mathbf{x}$ 까지의 거리이다. $\mathbb{R}^2$ 에서 $\mathbf{x} = (3, 4)$ 이면 $\|\mathbf{x}\| = \sqrt{3^2 + 4^2} = 5$ (피타고라스 정리). $\mathbb{R}^n$ 에서의 Euclidean norm $\|\mathbf{x}\|_2 = \sqrt{\sum_i x_i^2}$ 은 피타고라스 정리의 n 차원 일반화이다.

B-1. 거리의 직관 3가지

1. 양수: 길이는 음수일 수 없다.
 2. 2배로 늘리면 길이도 2배: Scalar곱 비례.
 3. 직진이 우회보다 짧다: 삼각부등식(triangle inequality).
- 이 직관 3개를 그대로 명세(spec)로 적는다 (B-3에서 정식).

B-2. Euclidean norm의 정의

정의 2.1 (Euclidean norm, ℓ_2 Norm)

$\mathbf{x} = (x_1, \dots, x_n) \in \mathbb{R}^n$ 의 **Euclidean norm**:

표기 $:=$ 는 "좌변을 우변으로 정의한다"는 기호 (등호 $=$ 가 단순히 같음을 진술하는 것과 구별).

$$\|\mathbf{x}\|_2 := \sqrt{x_1^2 + x_2^2 + \dots + x_n^2} = \sqrt{\sum_{i=1}^n x_i^2}$$

본 강의에서 별도 표기가 없으면 $\|\mathbf{x}\| := \|\mathbf{x}\|_2$ 로 약속한다. 이후 본문·증명·계산에서 단독 $\|\cdot\|$ 는 모두 ℓ_2 Norm을 가리킨다.

동기: 피타고라스의 n 차원 확장

- $\mathbb{R}^2$: $\sqrt{x_1^2 + x_2^2}$, 직각삼각형 빗변.
- $\mathbb{R}^3$: $\sqrt{x_1^2 + x_2^2 + x_3^2}$, 직육면체 대각선.
- $\mathbb{R}^n$: 같은 공식이 그대로 자연스럽다.

B-2. Euclidean norm의 정의: 예제

- $\mathbf{x} = (3, 4)$: $\|\mathbf{x}\| = \sqrt{9 + 16} = 5$
- $\mathbf{x} = (1, 2, 2)$: $\|\mathbf{x}\| = \sqrt{1 + 4 + 4} = 3$
- $\mathbf{x} = (2, -3, 1, -4)$: $\|\mathbf{x}\| = \sqrt{4 + 9 + 1 + 16} = \sqrt{30} \approx 5.48$

→ 성분이 늘어도 같은 공식을 그대로 적용한다. 이것이 $\mathbb{R}^n$ 정의의 위력이다.

B-3. Norm의 세 가지 본질 성질 ($\mathbb{R}^n$ 에서 검증)

Strang의 관찰: Euclidean norm은 세 가지 성질을 만족한다.

성질	식	의미
(N1) 양정성 (positive definiteness)	$\ \mathbf{x}\ \geq 0, \ \mathbf{x}\ = 0 \iff \mathbf{x} = \mathbf{0}$	거리는 음수 X, 거리 0은 같은 점
(N2) 절대 동차성 (absolute homogeneity)	$\ \alpha\mathbf{x}\ = \alpha \ \mathbf{x}\ $	α 배로 늘리면 길이도 $ \alpha $ 배
(N3) 삼각부등식 (triangle inequality)	$\ \mathbf{x} + \mathbf{y}\ \leq \ \mathbf{x}\ + \ \mathbf{y}\ $	직진 $\leq$ 우회

표기 $\iff$ 는 "필요충분조건" (양쪽이 동시에 참).

$\mathbb{R}^n$ 에서 (N1)·(N2) 검증

- (N1): $x_i^2 \geq 0$ 이므로 $\sum x_i^2 \geq 0$ 이다. 등호는 모든 $x_i = 0$ 일 때만 성립한다.
- (N2): $\|\alpha\mathbf{x}\|^2 = \sum (\alpha x_i)^2 = \alpha^2 \sum x_i^2$. 제곱근을 씌우면 $|\alpha| \|\mathbf{x}\|$ 이다.

→ (N3) 삼각부등식(triangle inequality)은 **Cauchy-Schwarz**의 결과로 C 섹션에서 증명한다.

메시지: 6회차에서 일반 vector space의 norm을 정식 정의할 때 이 세 가지가 그대로 axioms(공리)로 격상됩니다. 본 회차에서는 $\mathbb{R}^n$ 에서 "성질"로 부르고 직접 확인합니다.

B-4. 보조 Norm: ℓ_1, ℓ_∞ (Strang 보조)

같은 Vector의 "크기"를 재는 다른 잣대들:

Norm	정의	직관·응용
ℓ_1 (Manhattan)	$\sum_i x_i $	격자 도시(택시) · Lasso (sparse)
ℓ_2 (Euclidean)	$\sqrt{\sum_i x_i^2}$	피타고라스 · 거의 모든 LA · Ridge
ℓ_∞ (Chebyshev)	$\max_i x_i $	최악 경우 · 안정성 분석

Lasso·Ridge는 머신러닝의 정규화 기법, Part 4 1회차에서 본격.

예제: 같은 Vector, 세 가지 크기

$\mathbf{a} = (3, 1, -2, 4)$:

- $\|\mathbf{a}\|_1 = 3 + 1 + 2 + 4 = 10$
- $\|\mathbf{a}\|_2 = \sqrt{9 + 1 + 4 + 16} = \sqrt{30} \approx 5.48$
- $\|\mathbf{a}\|_\infty = \max\{3, 1, 2, 4\} = 4$

본 회차는 ℓ_2 중심이다. ℓ_1, ℓ_∞ 는 Part 2 2회차 (정사영·정규화)에서 본격적으로 다룬다.

B-4. 보조 Norm: 직관

직관 (세 Norm의 비교): 같은 Vector $\mathbf{x} = (3, 1, 2, 4) \in \mathbb{R}^4$ 도 Norm 종류에 따라 크기 값이 달라진다.

- $\ell_1(\mathbf{x}) = |3| + |1| + |2| + |4| = 10$, 성분 절댓값의 합
- $\ell_2(\mathbf{x}) = \sqrt{9 + 1 + 4 + 16} = \sqrt{30}$, 성분 제곱합의 제곱근 (Euclidean)
- $\ell_\infty(\mathbf{x}) = \max(3, 1, 2, 4) = 4$, 성분 절댓값의 최댓값

어떤 Norm을 선택하는가에 따라 "거리"의 정의가 달라지고, 그에 따라 회귀의 손실 함수·정규화 항이 달라진다 (Part 2 2회차).

B-5. Unit ball(단위구)의 모양


$\mathbb{R}^2$ 의 Unit ball $\{\mathbf{x} : \|\mathbf{x}\| = 1\}$:

Norm	모양
ℓ_1	마름모 (꼭짓점이 좌표축 위)
ℓ_2	원
ℓ_∞	정사각형

→ 같은 "크기 1"이지만 모양이 다르다. 어떤 Norm을 쓰느냐가 "어디까지가 가까운가"의 범위를 다르게 정의한다.

B-5. Unit ball: 세 모양의 비교

Unit balls in $\mathbb{R}^2$: $\{x : \|x\| = 1\}$



각 곡선은 방정식 $|x_1| + |x_2| = 1$ (마름모), $x_1^2 + x_2^2 = 1$ (원), $\max(|x_1|, |x_2|) = 1$ (정사각형)을 그린 것이다. 같은 "크기 1"의 점들이 Norm 종류에 따라 다른 도형을 이룬다.

B-5. Unit ball: 정규화(normalization)

$\mathbf{x} \neq \mathbf{0}$ 에 대해

$$\hat{\mathbf{x}} := \frac{\mathbf{x}}{\|\mathbf{x}\|_2}$$

표기 $\hat{\mathbf{x}}$ ('x hat')은 단위 Vector로 정규화한 결과를 가리키는 관례 표기입니다.

는 $\|\hat{\mathbf{x}}\| = 1$ 인 단위 **Vector**(unit vector)이다. (N2) 동차성(absolute homogeneity)의 직접 응용이다.

→ Embedding(임베딩) 검색에서 표준 전처리이다. D 섹션에서 본격적으로 다룬다.

잠깐 풀어보기: Norm

옆 사람과 5분 토의 후 답을 종이에 적어보세요.

문제 1 (계산)

$\mathbf{x} = (1, -2, 2, 0)$ 의 $\ell_1, \ell_2, \ell_\infty$ 를 각각 구하시오. 또한 $\mathbf{x}$ 를 단위 Vector로 정규화하시오.

문제 2 (개념)

다음 함수 $g : \mathbb{R}^2 \rightarrow \mathbb{R}$ 가 **Norm**의 세 가지 성질 (N1·N2·N3)을 만족하는가? 각각 검사하시오.

- (i) $g(\mathbf{x}) = x_1^2 + x_2^2$
- (ii) $h(\mathbf{x}) = |x_1| + 2|x_2|$

힌트: (N2) 동차성(absolute homogeneity) $\|\alpha \mathbf{x}\| = |\alpha| \|\mathbf{x}\|$ 검사가 가장 빠른 판별이다.

잠깐 풀어보기: 답

문제 1

- $\|\mathbf{x}\|_1 = 1 + 2 + 2 + 0 = 5$
- $\|\mathbf{x}\|_2 = \sqrt{1 + 4 + 4 + 0} = 3$
- $\|\mathbf{x}\|_\infty = \max\{1, 2, 2, 0\} = 2$
- 단위 Vector: $\hat{\mathbf{x}} = \mathbf{x}/3 = (1/3, -2/3, 2/3, 0)$. 검증: $\sqrt{1/9 + 4/9 + 4/9 + 0} = \sqrt{9/9} = 1 \checkmark$

문제 2

- (i) g 는 Norm이 아니다. (N2) 위배: $g(2\mathbf{x}) = (2x_1)^2 + (2x_2)^2 = 4(x_1^2 + x_2^2) = 4g(\mathbf{x})$ 이지만 $|2| g(\mathbf{x}) = 2g(\mathbf{x})$. ℓ_2 의 제곱은 Norm이 아니다 (제곱근을 빼면 안 된다).
- (ii) h 는 Norm이다. 가중치 다른 ℓ_1 변형. (N1) $\sum a_i |x_i| \geq 0 \checkmark$, (N2) $h(\alpha\mathbf{x}) = |\alpha| h(\mathbf{x}) \checkmark$, (N3) 삼각부등식(triangle inequality) $\checkmark$.

메시지: Norm의 세 성질은 외우는 것이 아니라 검사 도구이다. 새 함수를 마주치면 세 성질로 즉시 검증한다.

C. 수학 2: Dot product · 각도 · Cauchy-Schwarz

본 회차의 핵심이다. 두 Vector를 한 Scalar로 묶어 각도를 정의한다.

C-1. Dot product의 정의

정의 2.2 ($\mathbb{R}^n$ 의 Dot product)

$\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$ 의 Dot product(내적, inner product):

$$\mathbf{u} \cdot \mathbf{v} := u_1v_1 + u_2v_2 + \cdots + u_nv_n = \sum_{i=1}^n u_iv_i \in \mathbb{R}$$

다른 표기: $\mathbf{u}^\top \mathbf{v}$, $\langle \mathbf{u}, \mathbf{v} \rangle$. 본 강의에서는 세 표기를 혼용한다.

표기 안내: $\mathbf{u}^\top \mathbf{v}$ 는 $\mathbf{u}$ 를 가로로 눕혀 행렬곱한 결과(=Dot product, 3회차에서 본격). $\langle \mathbf{u}, \mathbf{v} \rangle$ 는 일반화된 inner product 표기로, 6회차 axioms에서 본격 사용.

예제

- $\mathbf{u} = (1, 2, 3), \mathbf{v} = (4, -1, 2): \mathbf{u} \cdot \mathbf{v} = 4 - 2 + 6 = 8$

C-1. Dot product: 직교성과 Norm과의 관계

- $\mathbf{e}_1 \cdot \mathbf{e}_2 = 0$, 표준 basis는 서로 직교 (직교(Orthogonal): $\mathbf{u} \cdot \mathbf{v} = 0$ 인 두 Vector, 정식 정의는 C-6 정의 2.4).

즉시 따라오는 사실: Norm과의 관계

$$\mathbf{u} \cdot \mathbf{u} = \sum u_i^2 = \|\mathbf{u}\|^2$$

→ ℓ_2 Norm은 Dot product에서 자동으로 유도된다. 이 사실이 ℓ_2 가 LA의 표준이 되는 이유이다.

C-2. Dot product의 대수적 성질

다음 셋은 $\mathbb{R}^n$ 에서 정의로부터 직접 따라온다.

- (D1) 대칭: $\mathbf{u} \cdot \mathbf{v} = \mathbf{v} \cdot \mathbf{u}$
- (D2) 선형: $(\alpha \mathbf{u} + \beta \mathbf{w}) \cdot \mathbf{v} = \alpha(\mathbf{u} \cdot \mathbf{v}) + \beta(\mathbf{w} \cdot \mathbf{v})$
- (D3) 양정성(positive definiteness): $\mathbf{u} \cdot \mathbf{u} \geq 0, \mathbf{u} \cdot \mathbf{u} = 0 \iff \mathbf{u} = \mathbf{0}$

증명 골자. 모두 실수의 덧셈·곱셈 성질을 성분별로 적용한다. 예: (D2) $\sum_i (\alpha u_i + \beta w_i) v_i = \alpha \sum u_i v_i + \beta \sum w_i v_i$. ■

노트: 이 세 성질이 6회차에서 일반 inner product의 axioms(공리)로 격상됩니다. 본 회차에서는 $\mathbb{R}^n$ 의 구체 사실로만 다룹니다.

직관 (가중합): Dot product는 성분별 곱의 합이다. $\mathbf{p} = (p_1, \dots, p_n)$ 을 가중치, $\mathbf{q} = (q_1, \dots, q_n)$ 을 측정값으로 두면 $\mathbf{p} \cdot \mathbf{q} = \sum_i p_i q_i$ 는 가중합 (weighted sum) 이다. 두 Vector가 하나의 Scalar로 요약되는 이유는 각 성분의 기여 $p_i q_i$ 를 모두 누적한 결과가 한 숫자이기 때문이다. 신경망 한 뉴런의 출력 $\mathbf{w}^\top \mathbf{x} + b$ 이 이 가중합의 전형적 예이다.


C-3. 2D·3D에서 기하 해석: 극좌표 표현

평면(2D)에서의 사실 (Strang §1.2). 평면의 임의의 Vector는 길이와 방향만으로 결정된다. 길이 $\|\mathbf{u}\|$, x축과 이루는 각 α 인 Vector의 성분은 삼각비에서

$$\mathbf{u} = (\|\mathbf{u}\| \cos \alpha, \|\mathbf{u}\| \sin \alpha)$$

이다 (극좌표 표현). 두 Vector를 각각 각 α, β 로 나타내면 Dot product 계산에서 두 각의 차 $\alpha - \beta$ 가 직접 나타나고, 이것이 두 Vector 사이의 각 θ 이다.

angle of $\mathbf{u}, \mathbf{v}$: $\theta = \alpha - \beta$



C-3. 2D 기하 해석: $\cos \theta$ 가 등장하는 이유

$\mathbf{u} = (\|\mathbf{u}\| \cos \alpha, \|\mathbf{u}\| \sin \alpha)$, $\mathbf{v} = (\|\mathbf{v}\| \cos \beta, \|\mathbf{v}\| \sin \beta)$ 로 쓰면

$$\mathbf{u} \cdot \mathbf{v} = \|\mathbf{u}\| \|\mathbf{v}\| (\cos \alpha \cos \beta + \sin \alpha \sin \beta) = \|\mathbf{u}\| \|\mathbf{v}\| \cos(\alpha - \beta)$$

(고교 삼각함수 차의 공식)

즉 두 Vector 사이의 각 $\theta = \alpha - \beta$ 가 자연스럽게 나타나며

$$\mathbf{u} \cdot \mathbf{v} = \|\mathbf{u}\| \|\mathbf{v}\| \cos \theta$$

→ 2차원·3차원의 기하적 사실이다. 같은 결과를 코사인 법칙으로도 유도한다 (다음 슬라이드).

C-3. 코사인 법칙에 의한 유도

원점 O와 두 Vector의 끝점이 이루는 삼각형에서 세 변의 길이는 $\|\mathbf{u}\|$, $\|\mathbf{v}\|$, $\|\mathbf{u} - \mathbf{v}\|$ 이고, $\mathbf{u}$, $\mathbf{v}$ 사이 각이 θ 이다. 코사인 법칙은

$$\|\mathbf{u} - \mathbf{v}\|^2 = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2 - 2\|\mathbf{u}\|\|\mathbf{v}\|\cos\theta.$$

한편 Dot product의 전개로

$$\|\mathbf{u} - \mathbf{v}\|^2 = (\mathbf{u} - \mathbf{v}) \cdot (\mathbf{u} - \mathbf{v}) = \|\mathbf{u}\|^2 - 2(\mathbf{u} \cdot \mathbf{v}) + \|\mathbf{v}\|^2.$$

두 식을 비교하면

$$\boxed{\mathbf{u} \cdot \mathbf{v} = \|\mathbf{u}\|\|\mathbf{v}\|\cos\theta}$$

를 얻는다. 극좌표 유도와 같은 결과이다.

C-3. 핵심 발상: $\cos \theta$ 를 정의한다

이 식을 n 차원으로 확장할 때는 $\cos \theta$ 를 정의해야 한다. n 차원에서는 "각"이라는 기하 개념이 미리 있는 것이 아니기 때문이다.

$$\cos \theta := \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|} \quad (\mathbf{u}, \mathbf{v} \neq \mathbf{0})$$

→ 이 정의가 정당하려면 $\cos \theta \in [-1, 1]$ 이 보장되어야 한다. 그 보장이 곧 **Cauchy-Schwarz**이다 (다음 슬라이드).

C-4. Cauchy-Schwarz inequality: 증명

정리 2.1 (Cauchy-Schwarz, $\mathbb{R}^n$)

모든 $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$ 에 대해

$$|\mathbf{u} \cdot \mathbf{v}| \leq \|\mathbf{u}\|_2 \|\mathbf{v}\|_2$$

등호 $\iff \mathbf{u}, \mathbf{v}$ 가 **평행** (즉 한쪽이 다른 쪽의 Scalar배).

Strang Ch 1.2 발체 (시그니처): Strang은 $\|\mathbf{u} - t\mathbf{v}\|^2 \geq 0$ 이 t 에 대한 이차식이라는 한 줄에서 **판별식 조건**으로 Cauchy-Schwarz를 한 페이지에 풀이한다. 본 회차의 증명 흐름이 이 발체의 직역이다 (이차식 비음성 $\rightarrow$ 판별식 ≤ 0). 이 패턴은 학기 전반의 정리 증명에서 반복된다.

증명 (이차식 비음성 $\rightarrow$ 판별식 패턴)

$\mathbf{v} = \mathbf{0}$ 이면 양변이 0이므로 자명하다. $\mathbf{v} \neq \mathbf{0}$ 이라 가정한다.

임의의 $t \in \mathbb{R}$ 에 대해 $\|\mathbf{u} - t\mathbf{v}\|^2 \geq 0$ (Norm의 (N1))이므로

$$\|\mathbf{u} - t\mathbf{v}\|^2 = (\mathbf{u} - t\mathbf{v}) \cdot (\mathbf{u} - t\mathbf{v}) = \|\mathbf{u}\|^2 - 2t(\mathbf{u} \cdot \mathbf{v}) + t^2\|\mathbf{v}\|^2 \geq 0$$

($\|\mathbf{w}\|^2 = \mathbf{w} \cdot \mathbf{w}$ 와 D2 선형성을 적용)

이 식은 t 에 대한 이차식이다 (t^2 의 계수 $\|\mathbf{v}\|^2 > 0$). 모든 t 에서 비음수하려면 **판별식 ≤ 0** (이차식 $at^2 + bt + c \geq 0$ 이 모든 t 에서

생략 $\iff b^2 - 4ac \leq 0$).
 Part 2 회차 - Norm & dot product < Cosine similarity

C-4. Cauchy-Schwarz: 마무리·등호 조건

마무리: 양변에 제곱근. $|\mathbf{u} \cdot \mathbf{v}| \leq \|\mathbf{u}\| \|\mathbf{v}\|$. ■

등호 조건: 판별식 = 0 $\iff \|\mathbf{u} - t^* \mathbf{v}\|^2 = 0$ 인 t^* 존재 $\iff \mathbf{u} = t^* \mathbf{v}$ (평행).

이 증명 패턴 (이차식 비음성 $\rightarrow$ 판별식)은 LA·최적화에서 반복됩니다. 기억해 둘 것.

C-5. Cauchy-Schwarz의 두 결과: 삼각부등식(triangle inequality)과 각도

결과 1: ℓ_2 의 삼각부등식(triangle inequality) (Norm 성질 N3)

$$\|\mathbf{u} + \mathbf{v}\|^2 = \|\mathbf{u}\|^2 + 2(\mathbf{u} \cdot \mathbf{v}) + \|\mathbf{v}\|^2 \leq \|\mathbf{u}\|^2 + 2\|\mathbf{u}\|\|\mathbf{v}\| + \|\mathbf{v}\|^2 = (\|\mathbf{u}\| + \|\mathbf{v}\|)^2$$

(중간 부등은 Cauchy-Schwarz: $\mathbf{u} \cdot \mathbf{v} \leq |\mathbf{u} \cdot \mathbf{v}| \leq \|\mathbf{u}\|\|\mathbf{v}\|$.)

따라서 $\|\mathbf{u} + \mathbf{v}\| \leq \|\mathbf{u}\| + \|\mathbf{v}\|$. ■

→ ℓ_2 가 Norm이라는 사실의 (N3) 증명은 Cauchy-Schwarz가 핵심이다.

결과 2: 각도가 잘 정의됨

$\mathbf{u}, \mathbf{v} \neq \mathbf{0}$ 이면 Cauchy-Schwarz로

$$-1 \leq \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\|\|\mathbf{v}\|} \leq 1$$

→ 유일한 $\theta \in [0, \pi]$ 가 존재해 $\cos \theta = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\|\|\mathbf{v}\|}$ 가 성립한다. 이 θ 를 두 Vector 사이의 각이라 정의한다.

C-5. Cauchy-Schwarz: 정사영의 길이

기하적 해석 (Projection의 길이): $\mathbf{u}$ 를 $\mathbf{v}$ 방향으로의 정사영의 길이는 $|\mathbf{u} \cdot \mathbf{v}| / \|\mathbf{v}\|$ 이다. 이 값은 본래 $\mathbf{u}$ 의 길이 $\|\mathbf{u}\|$ 를 초과할 수 없다 (양변에 $\|\mathbf{v}\|$ 를 곱한 부등식이 Cauchy-Schwarz이다). 두 Vector가 평행할 때만 등호가 성립한다. Part 2 1·2회차 정사영의 출발점이다.

C-6. 각도와 직교성: 정리

정의 2.3 (각도)

$\mathbf{u}, \mathbf{v} \in \mathbb{R}^n (\neq \mathbf{0})$ 에 대해 각 $\theta \in [0, \pi]$ 를

$$\cos \theta = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\|_2 \|\mathbf{v}\|_2}$$

으로 정의한다.

정의 2.4 (Orthogonal(직교))

$\mathbf{u} \cdot \mathbf{v} = 0$ 일 때 두 Vector를 **Orthogonal**이라 부른다 ($\theta = \pi/2$).

$\mathbf{u} \cdot \mathbf{v}$ 부호	$\cos \theta$	θ	의미
> 0	> 0	$0 \leq \theta < \pi/2$	예각, 같은 방향
$= 0$	$= 0$	$\theta = \pi/2$	직각, Orthogonal
< 0	< 0	$\pi/2 < \theta \leq \pi$	둔각, 반대 방향

C-6. 각도와 직교성: 흔한 오해

오해: "Dot product가 0이면 둘 중 하나가 영Vector" → 거짓.

반례: $\mathbf{e}_1 \cdot \mathbf{e}_2 = 0$ 인데 둘 다 영Vector가 아니다. **Orthogonal**이라는 새 관계이다 (Part 2 1회차 본격 정의).

→ Dot product = 0은 영Vector의 표시가 아니라 두 **Vector**가 서로 직각이라는 기하 사실이다.

잠깐 풀어보기: Dot product·Cauchy-Schwarz

문제 1 (계산)

$\mathbf{u} = (1, 1, 1)$, $\mathbf{v} = (1, -1, 0)$ 에 대해:

- (a) $\mathbf{u} \cdot \mathbf{v}$
- (b) $\|\mathbf{u}\|$, $\|\mathbf{v}\|$
- (c) $\cos \theta$ 와 θ
- (d) Cauchy-Schwarz $|\mathbf{u} \cdot \mathbf{v}| \leq \|\mathbf{u}\| \|\mathbf{v}\|$ 수치 검증

문제 2 (증명)

$\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$ 에 대해 다음 항등식을 증명하시오:

$$\|\mathbf{u} - \mathbf{v}\|^2 = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2 - 2(\mathbf{u} \cdot \mathbf{v})$$

→ 이것이 코사인 법칙의 **Vector** 버전이다. $\mathbf{u} \cdot \mathbf{v} = 0$ 일 때 어떻게 단순해지는지 살핀다.

잠깐 풀어보기: 답

문제 1

- (a) $\mathbf{u} \cdot \mathbf{v} = 1 - 1 + 0 = 0$
- (b) $\|\mathbf{u}\| = \sqrt{3}, \|\mathbf{v}\| = \sqrt{2}$
- (c) $\cos \theta = 0/(\sqrt{3}\sqrt{2}) = 0 \rightarrow \theta = \pi/2$ (정확히 90° , Orthogonal)
- (d) $|0| = 0 \leq \sqrt{6} \approx 2.45 \checkmark$

문제 2 (증명)

Dot product의 분배 (D2)로

$$\begin{aligned}\|\mathbf{u} - \mathbf{v}\|^2 &= (\mathbf{u} - \mathbf{v}) \cdot (\mathbf{u} - \mathbf{v}) = \mathbf{u} \cdot \mathbf{u} - 2\mathbf{u} \cdot \mathbf{v} + \mathbf{v} \cdot \mathbf{v} \\ &= \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2 - 2(\mathbf{u} \cdot \mathbf{v}). \blacksquare\end{aligned}$$

$\mathbf{u} \cdot \mathbf{v} = 0$ 일 때: $\|\mathbf{u} - \mathbf{v}\|^2 = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2$, 즉 피타고라스 정리이다.

메시지: Dot product가 0이면 코사인 법칙이 피타고라스로 단순화된다. 이것이 "Orthogonal이 LA에서 특별한 위상"인 이유의 출발점이다 (Part 2 1회차 본격).

D. 수학 3: Cosine similarity와 CS·AI 적용

정의된 각도를 그대로 AI 임베딩 비교의 표준 도구로 사용한다.

D-1. Cosine similarity의 정의

정의 2.5 (Cosine similarity)

$\mathbf{u}, \mathbf{v} \in \mathbb{R}^n (\neq \mathbf{0})$ 에 대해

$$\text{cos_sim}(\mathbf{u}, \mathbf{v}) := \cos \theta = \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\|_2 \|\mathbf{v}\|_2} \in [-1, 1]$$

Cauchy-Schwarz가 값의 범위 $[-1, 1]$ 를 보장한다.

값	의미
+1	완전 같은 방향 (평행, 같은 부호)
0	직교 (관련 없음)
-1	완전 반대 방향

D-1. Cosine similarity: 스케일 불변 비교

직관 (스케일 불변성): Cosine similarity는 두 Vector를 길이 1로 정규화한 뒤 비교한 값과 같다. $\mathbf{u}$ 와 $c\mathbf{u}$ ($c > 0$)의 cosine은 항상 1이다. 즉 **Norm (크기)**의 차이를 무시하고 **방향만 비교**한다. 손글씨 인식에서 같은 7을 굵게 쓴 이미지와 가늘게 쓴 이미지는 ℓ_2 Norm은 다르지만 cosine은 1에 가깝다. 크기보다 패턴 (방향)이 중요한 비교에 cosine을 사용한다.

D-2. Cosine을 쓰는 이유: Norm의 영향과 스케일 불변성

예시: 같은 단어, 다른 길이

$\mathbf{d}_1 = (1, 1, 0, 0, \dots)$, $\mathbf{d}_2 = (10, 10, 0, 0, \dots)$, 같은 두 단어만 등장하고 등장 횟수가 10배 차이 난다.

거리	값	해석
Euclidean $\ \mathbf{d}_1 - \mathbf{d}_2\ _2$	$\sqrt{81 + 81} = \sqrt{162} \approx 12.7$	"멀다"
Cosine similarity	$\frac{20}{\sqrt{2}\sqrt{200}} = 1$	"같다"

긴 문서와 짧은 문서를 Euclidean으로 비교하면 길이 차이만으로 큰 거리가 된다.

스케일 불변성 (Scale invariance)

모든 $\alpha, \beta > 0$ 에 대해

$$\text{cos_sim}(\alpha \mathbf{u}, \beta \mathbf{v}) = \frac{\alpha \beta (\mathbf{u} \cdot \mathbf{v})}{\alpha \beta \|\mathbf{u}\| \|\mathbf{v}\|} = \text{cos_sim}(\mathbf{u}, \mathbf{v})$$

→ 방향만 보고 크기는 무시한다. BERT(문장 임베딩 언어 모델)·CLIP(이미지·텍스트 공동 임베딩 모델) 같은 Embedding 모델 출력 비교의 자연스러운 도구이다 (정식 분해는 Part 4).

D-2. 단위 Vector 정규화 후 Dot product

$\hat{\mathbf{u}} = \mathbf{u} / \|\mathbf{u}\|, \hat{\mathbf{v}} = \mathbf{v} / \|\mathbf{v}\|$ 일 때

$$\text{cos_sim}(\mathbf{u}, \mathbf{v}) = \hat{\mathbf{u}} \cdot \hat{\mathbf{v}}$$

→ 검색 시점에 단순 Dot product 한 번으로 계산한다. BERT·CLIP이 출력 직후 흔히 L2 정규화를 하는 이유이다.

D-3. Cosine similarity의 AI 응용

분야	어떻게 쓰는가
문서 검색 (RAG)	query 임베딩과 문서 임베딩들의 cosine similarity $\rightarrow$ top- k 문서
Word2Vec · GloVe	"king - man + woman $\approx$ queen", 단어 임베딩 cosine으로 유사어 검색
CLIP (이미지·텍스트)	텍스트 임베딩과 이미지 임베딩 cosine $\rightarrow$ zero-shot 분류
Recommendation	사용자 임베딩과 아이템 임베딩 cosine
Face recognition	두 얼굴 임베딩 cosine 임계값으로 동일인 판정

한 줄 결론

현대 AI에서 "두 객체가 얼마나 비슷한가"를 정량화하는 표준 도구가 cosine similarity이다. 그리고 그 정의의 정당성 ($[-1, 1]$ 범위)이 Cauchy-Schwarz이다.

→ 본 회차에서 본 한 부등식이 AI 검색 시스템 전체를 떠받친다.

D-4. 미리보기: Attention과의 연결 (Part 4 7회차)

Transformer Attention(어텐션) 한 줄:

표기 안내 (정식 도입은 Part 4 7회차):

Q, K, V : query·key·value 행렬, 한 입력 token이 어텐션 한 층에서 갖는 세 가지 역할.

d_k : key Vector의 차원.

softmax: 점수 Vector를 확률처럼 합 1로 정규화하는 함수.

$$\text{Attn}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right)V$$

- $QK^\top$ 의 (i, j) 원소 = i 번째 query와 j 번째 key의 Dot product. 본 회차에서 본 정의 그대로이다.
- $\sqrt{d_k}$ 로 나누는 이유: 고차원에서 Dot product 값이 커지는 것을 보정 (스케일 조절).
- softmax 가중치는 본질적으로 각 query가 어느 key와 얼마나 가까운 방향인가의 가중치이며, cosine similarity의 사촌이다.

→ 본 회차에서 본 Dot product와 Norm이 곧 LLM의 핵심 연산이다. Part 4 7회차에서 본격 다룬다.

잠깐 풀어보기: Cosine similarity

문제 1 (계산)

다음 세 쌍의 cosine similarity를 구하고, 가장 비슷한 쌍과 가장 먼 쌍을 찾으시오.

- $\mathbf{a} = (1, 2, 2), \mathbf{b} = (2, 4, 4)$
- $\mathbf{a} = (1, 2, 2), \mathbf{c} = (2, -1, 0)$
- $\mathbf{a} = (1, 2, 2), \mathbf{d} = (-1, -2, -2)$

→ 각각의 의미 (같은 방향·직교·반대 방향)를 한 단어로 적으시오.

잠깐 풀어보기: 답

$$\|\mathbf{a}\| = 3.$$

$(\mathbf{a}, \mathbf{b})$

$$\|\mathbf{b}\| = \sqrt{4 + 16 + 16} = 6, \mathbf{a} \cdot \mathbf{b} = 2 + 8 + 8 = 18.$$

$$\cos \theta = 18 / (3 \cdot 6) = 1 \rightarrow \text{완전 같은 방향 } (\mathbf{b} = 2\mathbf{a}).$$

$(\mathbf{a}, \mathbf{c})$

$$\|\mathbf{c}\| = \sqrt{4 + 1 + 0} = \sqrt{5}, \mathbf{a} \cdot \mathbf{c} = 2 - 2 + 0 = 0.$$

$$\cos \theta = 0 \rightarrow \text{직교 (Orthogonal)}.$$

$(\mathbf{a}, \mathbf{d})$

$$\|\mathbf{d}\| = 3, \mathbf{a} \cdot \mathbf{d} = -1 - 4 - 4 = -9.$$

$$\cos \theta = -9 / (3 \cdot 3) = -1 \rightarrow \text{완전 반대 방향 } (\mathbf{d} = -\mathbf{a}).$$

→ 가장 비슷한 쌍: $(\mathbf{a}, \mathbf{b})$. 가장 먼 쌍: $(\mathbf{a}, \mathbf{d})$.

메시지: cosine similarity의 세 극단값 $+1, 0, -1$ 이 각각 평행·직교·반평행에 정확히 대응한다. Euclidean 거리에는 이런 깔끔한 해석이 없다.

E. 코딩 실습 (필요 시) + 정리 + 과제

E-1. 코딩 실습 골자 (선택)

→ Colab으로 실행

Colab 실습 정책: 매 회차 필수 X. 본 회차는 cosine similarity의 AI 응용이 직관적이므로 시간이 허락하면 1-2개 실습이 가치 있다. 시간이 부족하면 수학 정리·마무리 문제로 마치고 코딩은 과제로 돌릴 수 있다.

1. **Norm** 직접 구현: $\ell_1, \ell_2, \ell_\infty$ 를 라이브러리 호출 없이 NumPy로 작성 + `np.linalg.norm` 과 `np.allclose` 로 검증
2. **Unit ball** 시각화: 마름모·원·정사각형 ($\mathbb{R}^2$)
3. **Dot product · cosine similarity** 직접 구현 + 스케일 불변성 수치 확인
4. 두 MNIST 이미지의 **cosine similarity**: 같은 숫자 쌍 vs 다른 숫자 쌍 비교
5. 사전 훈련 단어 임베딩 (gensim Word2Vec 또는 sentence-transformers): "king" · "queen" · "apple"의 pairwise cosine similarity
6. 임베딩 정렬: query 단어 1개와 어휘 전체의 cosine similarity → top-5 nearest neighbors

E-1. 핵심 NumPy 패턴

연산	NumPy 한 줄
Euclidean norm	<code>np.linalg.norm(x, ord=2)</code> 또는 <code>np.sqrt(x @ x)</code>
Dot product	<code>u @ v</code> 또는 <code>np.dot(u, v)</code>
행렬 형태로 일괄 cosine	<code>X @ Y.T / (norms_X[:, None] * norms_Y[None, :])</code>

→ 마지막 패턴 한 줄이 RAG 검색의 핵심이다. query 행렬 X 와 문서 행렬 Y 의 모든 쌍 cosine을 한 번에 계산한다.

E-2. 본 회차 핵심 5개

1. **Norm**은 한 Vector의 길이이다. $\ell_2 = \sqrt{\sum x_i^2}$, 피타고라스의 n 차원 확장.
2. **Dot product**는 두 Vector의 관계를 한 Scalar로 묶는다. $\mathbf{u} \cdot \mathbf{u} = \|\mathbf{u}\|^2$ 이므로 ℓ_2 가 Dot product에서 자동 유도된다.
3. 각도는 정의이다. $\cos \theta := \frac{\mathbf{u} \cdot \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|}$, 2D·3D 기하 사실의 n 차원 확장.
4. **Cauchy-Schwarz** ($|\mathbf{u} \cdot \mathbf{v}| \leq \|\mathbf{u}\| \|\mathbf{v}\|$)가 $\cos \theta \in [-1, 1]$ 과 ℓ_2 삼각부등식(triangle inequality)을 동시에 보장한다. 증명 = 이차식 비음성 $\rightarrow$ 판별식 패턴.
5. **Cosine similarity**는 스케일 불변. AI 임베딩 비교의 표준 도구이며 Word2Vec·CLIP·RAG·Attention의 핵심이다.

E-3. 자기 점검 질문

- ℓ_2 가 ℓ_1, ℓ_∞ 와 본질적으로 다른 한 가지 성질은 무엇입니까? (힌트: Dot product와의 관계)
- Cauchy-Schwarz 증명에서 핵심 아이디어 한 줄: "_____ 이 t 에 대해 비음수 $\rightarrow$ _____ ≤ 0 ".
- 두 Vector가 **Orthogonal**이라는 것은 cosine similarity와 어떤 관계입니까?
- BERT 임베딩 비교에서 **L2 정규화**를 먼저 한 다음 **Dot product**를 쓰는 이유는?
- 같은 두 단어만 들어 있고 등장 횟수만 10배 다른 두 문서를 비교할 때 Euclidean과 cosine 중 어느 쪽이 자연스럽습니까? 왜?

본 회차 마무리 문제 (즉석 풀이)

본 회차 학습 흐름 (Norm $\rightarrow$ Dot product $\rightarrow$ 각도 $\rightarrow$ Cauchy-Schwarz $\rightarrow$ cosine similarity)을 한 문제로 종합한다.

$\mathbf{u} = (3, 4)$, $\mathbf{v} = (1, 7)$ 에 대해 다음을 모두 구하시오.

- (a) $\|\mathbf{u}\|$, $\|\mathbf{v}\|$
- (b) $\mathbf{u} \cdot \mathbf{v}$
- (c) $\cos \theta$, cosine similarity
- (d) Cauchy-Schwarz $|\mathbf{u} \cdot \mathbf{v}| \leq \|\mathbf{u}\| \|\mathbf{v}\|$ 수치 검증
- (e) 항등식 검증: $\|\mathbf{u} - \mathbf{v}\|^2 = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2 - 2(\mathbf{u} \cdot \mathbf{v})$

메시지: (e)는 코사인 법칙의 Vector 버전이다. 본 회차에서 본 모든 객체 (Norm·Dot product)가 한 식 안에 모두 등장한다.

본 회차 마무리 문제: 답

- (a) $\|\mathbf{u}\| = \sqrt{9 + 16} = 5$, $\|\mathbf{v}\| = \sqrt{1 + 49} = \sqrt{50}$
- (b) $\mathbf{u} \cdot \mathbf{v} = 3 \cdot 1 + 4 \cdot 7 = 31$
- (c) $\cos \theta = \frac{31}{5\sqrt{50}} = \frac{31}{\sqrt{1250}} \approx 0.877$. 두 Vector가 거의 같은 방향 ($\theta \approx 28.7^\circ$).
- (d) $|31| = 31 \leq 5\sqrt{50} = \sqrt{1250} \approx 35.36$ ✓ Cauchy-Schwarz 성립 (등호는 아니므로 두 Vector가 정확히 평행은 아님).
- (e) $\mathbf{u} - \mathbf{v} = (2, -3)$, $\|\mathbf{u} - \mathbf{v}\|^2 = 4 + 9 = 13$
 우변: $25 + 50 - 2 \cdot 31 = 13$ ✓ 항등식 성립.

핵심: (e) 항등식은 본 회차 모든 개념의 종합이며, 다음 회차 Matrix·Vector 곱 → 4회차 Orthogonality (피타고라스의 일반화)로 이어진다.

다음 회차 Review용 숙제

위 마무리 문제의 유사 문제이다. 강의 후 풀어 와서 3회차 Review 시간에 비교한다.

3차원으로 확장: $\mathbf{u} = (2, 2, 1)$, $\mathbf{v} = (1, -2, 2)$ 에 대해 (a)~(e)를 동일하게 구하시오.

풀이 시 자기 점검

- (c) $\cos \theta$ 의 값이 특별한 수인가? 그 의미는?
- (e) 항등식이 이 경우 어떻게 더 단순해지는가? 어떤 정리가 등장하는가?

추가 (코딩)

`numpy` 로 위 결과를 모두 재현하고, `np.linalg.norm` · `np.dot` 를 사용한 결과가 손계산과 일치함을 `np.allclose` 로 검증하시오.

3회차 시작 시 함께 답을 맞추고, 그 결과가 3회차 본 주제 (Matrix·Vector 곱)에서 Row picture = Dot product 묶음으로 어떻게 직접 이어지는지 살핀다.

E-4. 과제 안내

04_과제/Part1/02회차_homework.md . 마감: 3회차 시작 전.

수학 30점

- 진위 판정. 예: "Dot product가 0이면 둘 중 하나가 영Vector" (반례 제시)
- Norm·Dot product·cosine similarity 계산 (4문제)
- **Cauchy-Schwarz 재증명** (이차식 판별식 패턴, 자신의 손으로)
- $\|\mathbf{u} + \mathbf{v}\|^2 + \|\mathbf{u} - \mathbf{v}\|^2 = 2(\|\mathbf{u}\|^2 + \|\mathbf{v}\|^2)$ **평행사변형 법칙 증명**

코딩 20점

- $\ell_1, \ell_2, \ell_\infty$ Norm 직접 구현 + `np.linalg.norm` 과 비교
- cosine similarity로 MNIST 한 query 이미지의 **top-5 nearest neighbors** 찾기
- 사전 훈련 단어 임베딩(gensim Word2Vec 또는 sentence-transformers)에서 한 단어와 가장 비슷한 10개 단어 찾기
- broadcasting vs for문 속도 비교 ($n = 100, 1000, 10000$ Vector 쌍)

E-5. 다음 회차 (3회차) 예고

주제: Matrix(행렬)와 Matrix·Vector 곱의 두 해석 (Row picture · Column picture)

연결: 본 회차에서 본 Dot product가 그대로 **Matrix·Vector 곱의 Row picture** 해석이 됩니다. $A\mathbf{x}$ 의 i 번째 성분 = A 의 i 행과 $\mathbf{x}$ 의 **Dot product**. 즉 본 회차의 한 줄 정의 $\mathbf{u} \cdot \mathbf{v}$ 가 모든 행에 대해 일괄 적용된 것이 곧 행렬 곱입니다.

그리고 더 본질적인 해석 (**Column picture**)이 1회차의 **Linear combination**과 직접 연결됩니다. 두 회차에서 본 도구들이 3회차 한 식 $A\mathbf{x}$ 안에 모두 들어옵니다.

사전 reading:

- MML §2.2 (Matrices) + §2.7 (Linear Mappings 도입), 메인
- Strang Ch 1.3·2.1 발췌 (Row picture vs Column picture, 시그니처), 본문 박스로 가져옴
- 3Blue1Brown EoLA Ch.3 (Linear transformations and matrices)

E-6. 부록: MML §3.1-§3.4 · Strang Ch 1.2 추천 연습문제

자기 학습용 (과제와 별도, 자신의 페이스로):

- **MML §3.1-§3.4 Exercise:** Norms · Inner products · Cauchy-Schwarz · Cosine 정의 (메인)
- **Strang Ch 1.2 Problem 1-3:** Dot product 계산·각도 (워밍업)
- **Strang Ch 1.2 Problem 4-5:** 단위 Vector·정규화
- **Strang Ch 1.2 Problem 11:** Cauchy-Schwarz 수치 검증
- **Strang Ch 1.2 Problem 15:** 삼각부등식(triangle inequality) 수치 검증
- **Strang Ch 1.2 Problem 18-20:** cosine similarity 응용

MIT OCW 18.06 Lecture 1 (Strang 본인) 영상: 첫 30분이 본 회차 내용과 거의 일치한다.

Q & A

본 회차 학습 흐름:

Norm (ℓ_2) → Dot product → 각도 정의 → Cauchy-Schwarz → cosine similarity → 임베딩 비교

한 줄 결론: Cauchy-Schwarz 부등식 하나가 AI의 임베딩 검색 시스템 전체의 정당성을 보장한다.

HANDOUT : 본 PDF + 02_노름_내적_코사인유사도.ipynb