

Part 1 3회차

Matrix와 Matrix·Vector 곱의 두 해석

MML §2.2·§2.7 (메인) · Strang Ch 1.3·2.1 (발췌, **Row picture vs Column picture** 시그니처) · EoLA Ch.3: Linear transformations and matrices · Part 1 (선형대수 1)

Review: 2회차 마무리 문제

$u = (2, 2, 1)^T$, $v = (1, -2, 2)^T$ 의 Norm·내적·코사인·Cauchy-Schwarz·항등식:

- **(a)** $\|u\|_2 = 3$, $\|v\|_2 = 3$
- **(b)** $u^T v = 2 - 4 + 2 = 0 \rightarrow \text{Orthogonal}$
- **(c)** $\cos\theta = 0 \rightarrow 90^\circ$ **(d)** $|0| \leq 9 \checkmark$
- **(e)** $\|u-v\|^2 = 18 = 9 + 9 - 0 \checkmark \rightarrow u^T v=0$ 이면 **피타고라스**로 단순화

$\rightarrow$ Orthogonal은 본 회차 Matrix 곱 해석에서 다시 나온다.

본 회차 핵심 질문 · 학습 목표

Matrix·Vector 곱 Ax 를 어떻게 해석해야 선형대수 전체 구조가 보입니까?

한 가지 정의 $(Ax)_i = \sum_j a_{ij} x_j$, 두 가지 해석 — **Row picture vs Column picture**. 본 회차의 답은 **Column picture**.

이번 회차가 끝나면:

- 1.Matrix·Vector 곱의 두 해석**을 정의대로 손계산한다 (Row = Inner product 묶음, Column = 열들의 Linear combination).
- 2. $Ax = b$ 의 해 존재** $\Leftrightarrow b \in \text{col}(A)$ 를 진술한다.
- 3.Matrix·Matrix 곱의 3가지 해석**(원소·열·행)과 **비가환성** $AB \neq BA$ 를 설명한다.

B. Matrix: 동기와 정의

(i) **Linear equation 묶음**: 미지수가 여러 개인 식들을 한 객체로

$$\begin{cases} 2x_1 + 3x_2 - x_3 = 5 \\ x_1 - x_2 + 4x_3 = 1 \end{cases} \Leftrightarrow \begin{pmatrix} 2 & 3 & -1 \\ 1 & -1 & 4 \end{pmatrix} \mathbf{x} = \mathbf{b}$$

(ii) **Linear transformation(선형변환)의 표현**: $x \mapsto Ax$, 한 Vector를 다른 Vector로 보내는 선형 함수의 표 (Part 2 9회차 본격 정의)

(iii) **데이터의 묶음**: n 개 샘플 $\times$ d 개 특징을 한 객체로

- 이미지 100장 $\times$ 784픽셀 $\rightarrow X \in \mathbb{R}^{100 \times 784}$
- 신경망 한 층의 가중치 $W \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}$

B-2. 형식적 정의

정의 2.1 ($m \times n$ Matrix)

m 행 n 열의 실수 표입니다.

$$A = \begin{pmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{pmatrix} \in \mathbb{R}^{m \times n}$$

표기: $A = (a_{ij})$, i 는 행 인덱스, j 는 열 인덱스. 행과 열의 혼동은 선형대수 초보가 흔히 범하는 실수이다.

B-2. 형식적 정의: 열 표현

정의 2.2 (열 표현)

A 의 j 번째 열을 $\mathbf{a}_j \in \mathbb{R}^m$ 이라 쓰면, 행렬을 **열벡터들을 옆으로 이어붙인 것으로 본다.**

$$A = [\mathbf{a}_1 \mid \mathbf{a}_2 \mid \cdots \mid \mathbf{a}_n]$$

→ Column picture 해석에서 매번 쓰는 표기이다. j 번째 열 $\mathbf{a}_j$ 가 " j 번째 입력이 출력에 기여하는 방향"이 된다.

B-2. Matrix의 의미: 입력을 출력으로 바꾸는 표

Matrix A 한 개는 곧 **하나의 변환 규칙**(함수)이다: 입력 $x \in \mathbb{R}^n$ 을 받아 출력 $Ax \in \mathbb{R}^m$ 을 내놓는다. 성분 a_{ij} 는 "j번째 입력이 i번째 출력에 섞이는 가중치"이다.

예시: 아래 A이면 입력 (x_1, x_2, x_3) 이 이렇게 변환된다.

$$A = \begin{pmatrix} 2 & 0 & 1 \\ 0 & 3 & 0 \end{pmatrix}$$

- 출력 1번 = $2x_1 + 0x_2 + 1x_3$ (1행이 정한다)
- 출력 2번 = $0x_1 + 3x_2 + 0x_3$ (2행이 정한다)

여기서 $a_{13} = 1$ 은 "입력 3번이 출력 1번에 1배로 기여"함을 뜻한다. 표 하나가 변환 전체를 담는다.

B-3. 기본 연산

덧셈·Scalar(스칼라)곱 (성분별)

$$(A + B)_{ij} = a_{ij} + b_{ij}, \quad (\alpha A)_{ij} = \alpha a_{ij}$$

Transpose(전치): 행과 열을 뒤집는다

$A \in \mathbb{R}^{m \times n}$ 의 Transpose $A^T \in \mathbb{R}^{n \times m}$ 은

$$(A^T)_{ij} = a_{ji} \quad (A^T \text{의 } i\text{행} = A \text{의 } i\text{열})$$

Symmetric matrix(대칭행렬)

$A^T = A$ 인 정사각 Matrix이다. 즉 $a_{ij} = a_{ji}$ (대각선 대칭).

C. 핵심: Matrix·Vector 곱의 두 해석

한 정의, 두 해석.

정의 2.3 (Matrix·Vector 곱)

$A \in \mathbb{R}^{m \times n}$, $x \in \mathbb{R}^n$ 에 대해 $Ax \in \mathbb{R}^m$ 의 i 성분:

$$(Ax)_i = \sum_{j=1}^n a_{ij} x_j$$

조건: A의 열 수 = x의 차원. 안 맞으면 곱이 정의되지 않는다.

이 한 식을 두 가지로 묶어 본다. 그것이 두 해석이다.

C-2. 해석 1: Row picture

Strang Ch 1.3·2.1 발췌 (시그니처 1): 각 행 $\mathbf{r}_i^\top \mathbf{x} = b_i$ 가 한 초평면이고, 해는 모든 초평면의 **교집합**이다 (2D면 두 직선의 교점).

정의 2.4 (Row picture 해석)

A의 i행을 $\mathbf{r}_i^\top \in \mathbb{R}^{1 \times n}$ 이라 하면

$$A\mathbf{x} = \begin{pmatrix} \mathbf{r}_1^\top \mathbf{x} \\ \mathbf{r}_2^\top \mathbf{x} \\ \vdots \\ \mathbf{r}_m^\top \mathbf{x} \end{pmatrix} = \begin{pmatrix} \mathbf{r}_1 \cdot \mathbf{x} \\ \mathbf{r}_2 \cdot \mathbf{x} \\ \vdots \\ \mathbf{r}_m \cdot \mathbf{x} \end{pmatrix}$$

$A\mathbf{x}$ 의 i성분 = A의 i행과 $\mathbf{x}$ 의 Inner product이다.

C-2. Row picture: 직관

직관 (Row picture의 의미): Ax 의 i 번째 출력 성분은 A 의 i 행 r_i 와 입력 x 의 Inner product 한 개이다. 즉 한 출력 성분 = 입력 전체와 한 행의 가중합. $Ax = b$ 를 한 줄씩 보면 각 줄이 $r_i \cdot x = b_i$ 라는 한 초평면 (hyperplane) 의 방정식이고, 해는 m 개 초평면의 교집합이다.

C-2b. Row picture로 직접 계산하기


$$A = \begin{pmatrix} 2 & 3 \\ 1 & -1 \end{pmatrix}, \quad A\mathbf{x} = \begin{pmatrix} 2x_1 + 3x_2 \\ x_1 - x_2 \end{pmatrix}$$

- **1행** $(2,3) \cdot (x_1, x_2) = 2x_1 + 3x_2 \rightarrow$ 출력 1번
- **2행** $(1,-1) \cdot (x_1, x_2) = x_1 - x_2 \rightarrow$ 출력 2번

$Ax = b$ 로 놓으면 각 행이 **방정식 한 줄**이 된다 ($2x_1 + 3x_2 = b_1, x_1 - x_2 = b_2$). $\rightarrow$ Row picture는 $Ax=b$ 를 "**행마다 방정식 하나인 연립방정식**"으로 본다.

C-2c. $Ax = b$ 는 직선(초평면)들의 교점

각 행 $r_i \cdot x = b_i$ 는 하나의 직선(2D)·평면(3D)·초평면(nD). 해는 그 교집합이다.



→ $Ax=b$ = "m개 제약을 동시에 만족하는 x 찾기".

C-3. 해석 2: Column picture [핵심]

Strang Ch 1.3·2.1 발췌 (시그니처 2): Strang은 **Column picture**가 선형대수의 핵심 구조임을 책 전반에서 반복한다. $Ax = b$ = "b를 A의 열들의 Linear combination으로 쓸 수 있는가". 이 한 발췌가 본 회차 D 섹션 (Column space)·7회차 4 fundamental subspaces·차원정리까지의 출발점이다.

정의 2.5 (Column picture 해석)

A의 j열을 $\mathbf{a}_j \in \mathbb{R}^m$ 이라 하면

$$A\mathbf{x} = x_1\mathbf{a}_1 + x_2\mathbf{a}_2 + \cdots + x_n\mathbf{a}_n$$

$A\mathbf{x}$ = A의 열들의 Linear combination이다 (계수가 $\mathbf{x}$ 의 성분).

→ 1회차 Linear combination과 동일한 식이다. $A\mathbf{x}$ 는 $\mathbf{x}$ 로 만든 레시피로 A의 열들을 섞은 결과이다.

C-3a. 비유: 레시피로 재료를 섞는다




- 각 실린더 = **A**의 열벡터(a_1, a_2, a_3). 채운 높이 = 계수 x_j (그 열을 얼마나 쓸지).
- 세 재료를 그 비율대로 부어 섞은 최종 색 = **Ax**.
- x 를 바꾸면 = 재료 비율을 바꾸면 → 만들 수 있는 색(결과)이 달라진다. 만들 수 있는 모든 색의 집합이 곧 $\text{col}(A)$.

C-3. Column picture: 직관

직관 (Column picture의 의미): $Ax = x_1 a_1 + \cdots + x_n a_n$ 은 A 의 열들의 Linear combination이다. 즉 Ax 로 도달 가능한 모든 결과의 집합은 A 의 열들이 만드는 Span이며, 이를 A 의 Column space $C(A)$ 라 부른다. $Ax = b$ 의 해가 존재할 필요충분조건이 $b \in C(A)$ 이다 (D 섹션·7회차에서 정식화).

C-3b. Column picture로 직접 계산하기


$$A = \begin{pmatrix} 1 & 2 \\ 3 & 2 \end{pmatrix}, \mathbf{x} = \begin{pmatrix} 1 \\ 1.5 \end{pmatrix} \Rightarrow A\mathbf{x} = 1 \begin{pmatrix} 1 \\ 3 \end{pmatrix} + 1.5 \begin{pmatrix} 2 \\ 2 \end{pmatrix} = \begin{pmatrix} 4 \\ 6 \end{pmatrix}$$



→ $\mathbf{x}$ 의 각 성분 = "그 열을 몇 배 쓸지". 두 열을 그 비율로 더한 것이 $A\mathbf{x}$.

C-3c. $Ax = b$ 를 Column picture로 보면

질문이 바뀐다: "**b**를 **A**의 열들을 섞어서 만들 수 있는가?" ($x_1a_1 + \cdots + x_na_n = b$)



$\rightarrow b$ 가 $\text{col}(A)$ 안이면 해 있음, 밖이면 해 없음. 즉 해 존재 $\Leftrightarrow b \in \text{col}(A)$.

C-4. 두 해석이 같다는 증명

성분별로 계산:

$$(x_1 \mathbf{a}_1 + \cdots + x_n \mathbf{a}_n)_i = x_1 a_{i1} + x_2 a_{i2} + \cdots + x_n a_{in} = \sum_j a_{ij} x_j = (A\mathbf{x})_i$$

같은 식, 다른 묶음이다. ■

해석	묶는 단위	결과
Row picture	한 행씩 ($r_i \cdot x$)	출력의 i성분
Column picture	한 열씩 ($x_j a_j$)	출력 Vector 전체

→ 두 해석은 결과가 같지만 주는 통찰이 다르다. 다음 슬라이드에서 그 차이를 본다.

C-5. Column picture가 선형대수의 핵심 구조인 이유

- **Row picture**는 "한 출력 성분을 어떻게 계산할 것인가"를 알려준다, **계산 알고리즘**의 관점.
- **Column picture**는 " Ax 로 도달 가능한 Vector들의 집합은 무엇인가"를 알려준다, **구조**의 관점.

$\{Ax : x \in \mathbb{R}^n\} = A$ 의 열들의 **모든 Linear combination** = $\text{span}(a_1, \dots, a_n)$.



이것을 **A의 Column space** $\text{col}(A)$ 라 부른다 (7회차 정식 정의).

결론: Row picture는 **계산**, Column picture는 **구조**이다. 선형대수의 핵심 구조 (Subspace · Rank · 해 존재)는 **Column picture**에서 시작된다.

C-6. 한 장으로 보는 두 해석

$$\begin{cases} x_1 + 2x_2 = 4 \\ 3x_1 + 2x_2 = 6 \end{cases} \quad \text{해} \quad (x_1, x_2) = (1, 1.5)$$

같은 해 $(x_1, x_2) = (1, 1.5)$, 두 가지 해석



Row picture = 두 직선의 교점. **Column picture** = 열 $\mathbf{a}_1, \mathbf{a}_2$ 를 1, 1.5배 섞어 $\mathbf{b}$ 도달.

잠깐 풀어보기: 두 해석

$$A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} 2 \\ -1 \end{pmatrix}$$

문제 1 (Row picture): 각 행과 $\mathbf{x}$ 의 Inner product로 $A\mathbf{x}$ 를 구하시오.

문제 2 (Column picture): A 의 두 열의 Linear combination으로 $A\mathbf{x}$ 를 구하시오.

문제 3 (사고): 두 결과가 같다는 사실에서 어떤 **구조적** 사실을 알 수 있는가? (A 의 열들이 $\mathbb{R}^3$ 의 어떤 부분집합을 만드는가)

잠깐 풀어보기: 답

문제 1 (Row picture)

행별 내적: $(1,2) \cdot (2,-1)=0$, $(3,4) \cdot (2,-1)=2$, $(5,6) \cdot (2,-1)=4 \therefore Ax=(0,2,4)^T$

문제 2 (Column picture)


$$Ax = 2 \cdot (1, 3, 5)^T + (-1) \cdot (2, 4, 6)^T = (2-2, 6-4, 10-6)^T = (0, 2, 4)^T \checkmark \text{ 같음}$$

문제 3 (사고)

A의 두 열 $(1,3,5)$, $(2,4,6)$ 은 서로 독립 $\rightarrow \mathbb{R}^3$ 안의 **평면**을 만든다. 어떤 x 든 Ax 는 이 평면 위에만 있다. (도달 가능 집합 = 열들이 만드는 Subspace, 6·7회차의 출발점.)

문제 3 자세히: $\text{col}(A)$ 는 어떤 평면인가

두 열 $\mathbf{a}_1=(1,3,5)$, $\mathbf{a}_2=(2,4,6)$ 가 만드는 평면이 $\text{col}(A)$. 평면식은 수직인 법선 $\mathbf{n}$ (두 열의 벡터곱)으로.



$$\mathbf{n} = \mathbf{a}_1 \times \mathbf{a}_2 = (1, -2, 1), \quad \mathbf{n} \cdot (x, y, z) = 0 \Rightarrow x - 2y + z = 0$$

확인: $\mathbf{n} \cdot \mathbf{a}_1 = 1 - 6 + 5 = 0$, $\mathbf{n} \cdot \mathbf{a}_2 = 2 - 8 + 6 = 0 \rightarrow$ 두 열도, 도달점 $A\mathbf{x} = 2\mathbf{a}_1 - \mathbf{a}_2 = (0, 2, 4)$ 도 모두 평면 위.

D. $Ax = b$ 와 Column space

1회차에서 본 "Vector로 데이터를 표현"이 이제 "방정식 풀이"로 발전한다.

$Ax = b$ 를 푼다 = **b 를 A 의 열들의 Linear combination으로 쓸 수 있는가?** (쓸 수 있으면 그 계수가 x)

$$x_1 \mathbf{a}_1 + x_2 \mathbf{a}_2 + \cdots + x_n \mathbf{a}_n = \mathbf{b}$$

즉시 따라오는 결론

- $Ax = b$ 해 존재 $\Leftrightarrow b \in \text{span}(\mathbf{a}_1, \dots, \mathbf{a}_n) = \text{col}(A)$
- b 가 Column space **밖에 있으면** 어떻게 잡아도 해가 없다.

D-2. 예시: 해의 존재가 갈리는 두 경우


$$A = \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix} \quad (\text{두 열이 평행: } \mathbf{a}_2 = 2\mathbf{a}_1)$$

Column space: $\text{col}(A) = \{t \cdot (1, 2)^T : t \in \mathbb{R}\} \text{ — } \mathbb{R}^2 \text{의 직선.}$

b	직선 위?	해
$(3, 6)^T$	✓ (t=3)	무수히 많은 해 ($x_1 + 2x_2 = 3$ 의 모든 점)
$(1, 3)^T$	×	해 없음

→ **A가 같아도 b의 위치에 따라 해 존재 여부가 결정된다.** 그 위치는 **A의 Column space**로 결정된다.

D-2b. Column space의 모양: 직선과 평면



열들이 **종속**이면 $\text{col}(A)$ 는 더 낮은 차원으로 무너진다 (왼쪽: 직선). 열들이 **독립**이면 온전한 차원을 채운다 (오른쪽: 평면). $Ax = b$ 의 해는 b 가 이 영역 **안에 있을 때만** 존재한다.

D-3. 해의 유일성과 Linear independence (예고)

해가 존재하면 유일한가? 무수히 많은가?

답: A의 열들이 Linear independence인가에 달려 있다.

- Linear independence → 유일한 표현 → 유일한 해
- Linear dependence → 무수히 많은 표현 → 무수히 많은 해 (해가 있는 경우)

→ 6회차에서 정식 정의한다. 본 회차에서는 직관까지 다룬다.

A의 열	해 존재 (b가 col 안)	해 유일성
Linear independence	있으면 유일	✓ 유일
Linear dependence	있으면 무수	× 무수

E. Matrix·Matrix 곱: 3가지 해석

$C = AB$ 를 세 가지로 본다 (원소·열·행).

정의 2.6 (Matrix·Matrix 곱)

$A \in \mathbb{R}^{m \times k}$, $B \in \mathbb{R}^{k \times n}$ 일 때 $C = AB \in \mathbb{R}^{m \times n}$:

$$c_{ij} = \sum_{p=1}^k a_{ip} b_{pj}$$

조건: A의 열 수 = B의 행 수 (=k, inner dimension). 결과 차원 $m \times n$ (outer dimension).

E-2. 해석 1·2: 원소 = Inner product, 열 묶음

해석 1: 원소

$$c_{ij} = (A \text{의 } i \text{행}) \cdot (B \text{의 } j \text{열})$$

손계산 표준. 예: 위 A,B의 (1,1) 원소 = (1,2)·(5,7) = 19.

해석 2: 열 묶음

AB의 j열 = A · (B의 j열)

$$AB = A[\mathbf{b}_1 \mid \cdots \mid \mathbf{b}_n] = [A\mathbf{b}_1 \mid \cdots \mid A\mathbf{b}_n]$$

Matrix·Vector 곱을 n번 반복한 것이며, 각 열이 A의 열들의 Linear combination이다. 이 해석으로 **AB의 Column space $\subseteq$ A의 Column space**가 즉시 따라온다.

E-3. 해석 3: 행 묶음

AB의 i행 = (A의 i행) · B

$$AB = \begin{pmatrix} \mathbf{r}_1^\top B \\ \mathbf{r}_2^\top B \\ \vdots \\ \mathbf{r}_m^\top B \end{pmatrix}$$

각 행이 B의 행들의 Linear combination이다. **AB의 행공간** $\subseteq$ **B의 행공간**.

F. 비가환성·결합·CS·AI 적용

예시

$$A = \begin{pmatrix} 0 & 1 \\ 0 & 0 \end{pmatrix}, \quad B = \begin{pmatrix} 0 & 0 \\ 1 & 0 \end{pmatrix}$$
$$AB = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}, \quad BA = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix}$$

완전히 다르다. (차원이 다르면 한쪽만 정의되기도 한다: $2 \times 3 \cdot 3 \times 4$ 는 되지만 역순은 불가.)

직관 (함수 합성으로서의 곱): AB 는 합성 $A \circ B$ 이다. $(AB)x = A(Bx)$ — 먼저 B , 그다음 A . 함수 합성이 일반적으로 비가환이므로 Matrix 곱도 비가환이다.

F-1. 결합·분배 법칙

결합·분배는 성립한다

- $(AB)C = A(BC)$ ✓ (곱하는 **순서**는 유지, 묶는 방법만 바뀌어도 됨)
- $A(B+C) = AB + AC$ ✓

전치는 순서가 뒤집힌다

$$(AB)^{\top} = B^{\top} A^{\top}$$

왜 뒤집히나? AB는 "먼저 B, 그다음 A"를 적용하는 합성이다. 전치를 하면 **적용 순서도 거꾸로** 돌아가야 하므로 $B^{\top}$ 이 앞, $A^{\top}$ 이 뒤로 온다.

비유: 옷 입기 → 벗기. 마지막에 입은 옷을 가장 먼저 벗듯, 순서가 반대로 뒤집힌다.

F-2. CS·AI 적용

신경망 한 층

$$\mathbf{y} = W\mathbf{x} + \mathbf{b}, \quad W \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}$$

- $W\mathbf{x}$ = **W의 열들의 Linear combination** (Column picture), "d_{in}개 입력 특징을 어떤 비율로 섞을 것인가"
- 또는 **d_{out}개 뉴런 각각의 가중 합** (Row picture)

2회차 Attention의 $QK^T \times V$ 도 모두 이 두 해석이다 (정식은 Part 3 9회차).

F-2a. 신경망 한 층: 숫자로

입력 3개 → 뉴런 2개인 층. W 는 2×3 , 입력 $x=(2,1,4)$, 편향 $b=(1,-1)$:

$$\mathbf{y} = \begin{pmatrix} 1 & 0 & 2 \\ 0 & 3 & 1 \end{pmatrix} \begin{pmatrix} 2 \\ 1 \\ 4 \end{pmatrix} + \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 10 \\ 7 \end{pmatrix} + \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \begin{pmatrix} 11 \\ 6 \end{pmatrix}$$


- **Row picture (뉴런별 가중합):** 뉴런1 = $1 \cdot 2 + 0 \cdot 1 + 2 \cdot 4 = 10$, 뉴런2 = $0 \cdot 2 + 3 \cdot 1 + 1 \cdot 4 = 7$.
- **Column picture (입력별 기여):** 열 $c_1=(1,0), c_2=(0,3), c_3=(2,1)$ 을 입력만큼 섞기 $\rightarrow 2c_1 + 1c_2 + 4c_3 = (10,7)$. 같은 답.

F-2b. 그래프 = Matrix: Adjacency matrix

노드 $i \rightarrow j$ 간선이 있으면 $a_{ij} = 1$ 인 Matrix가 **Adjacency matrix**(인접행렬)이다.

그래프 = Matrix: $(Ax)_i$ = 노드 i 가 가리키는 값들의 합

방향 그래프 (4개 노드)



Adjacency matrix A , $a_{ij} = 1 \Leftrightarrow i \rightarrow j$

1	0	1	1	0
2	0	0	1	0
3	0	0	0	1
4	1	0	0	0
	1	2	3	4

도착 노드 j

- Ax 의 i 성분 (Row picture) = 노드 i 가 가리키는 노드들의 합
- A^2 의 (i, j) = $i \rightarrow j$ 길이 2 경로의 수 (Matrix 곱의 의미)
- Graph Neural Network(그래프 신경망)는 A 를 반복 곱해 이웃 정보를 모은다.

F-3. GPU에서 빠른 이유

핵심: $C = AB$ 의 각 원소 c_{ij} 는 서로 의존하지 않는다 (c_{11} 계산에 c_{12} 가 필요 없다). 그래서 $m \times n$ 개를 동시에 계산할 수 있다.

- **CPU:** 코어 몇 개 → 대체로 순차 계산. **GPU:** 코어 수천 개 → 수천 개 c_{ij} 를 한꺼번에. "같은 연산을 데이터만 바꿔 대량 반복"이 GPU에 딱 맞는다.

해석	무엇을 독립 작업 단위로 쪼개나
원소 = Inner product	각 c_{ij} 하나 = 스레드 하나 (가장 잘게 쪼갬)
열 묶음	B의 각 열 → 독립 Matrix·Vector 곱

→ 딥러닝이 GPU를 쓰는 이유가 여기 있다: 신경망 연산이 거의 전부 **큰 행렬 곱**이라, 위치럼 잘게 나눠 동시에 처리된다.

G. 클로징

→ Colab으로 실행

이번 노트북은 계산 확인이 아니라 **두 그림을 직접 그려** 체득한다.

1.Column picture: $Ax = x_1a_1 + x_2a_2$ 를 벡터 합으로 그려 보기 (x를 바꿔가며 실험)

2.Column space: 모든 Ax 를 찍어 **열 독립=평면 / 종속=직선** 확인

G-2. 본 회차 핵심 5개

1. **Matrix** = 표 모양의 수의 배열, Linear transformation의 표현

2. **Matrix·Vector 곱의 두 해석**: Row picture (Inner product 묶음) / **Column picture (Linear combination)**

3. **Column picture가 선형대수의 핵심 구조**이다. Column space · Rank · 해 존재가 모두 여기서 따라온다
.

4. $Ax=b$ 의 해 존재 $\Leftrightarrow b \in \text{col}(A)$

5. **Matrix·Matrix 곱의 세 해석**: 원소(Inner product)·열 묶음·행 묶음.

본 회차 마무리 문제 (즉석 풀이)

본 회차 학습 흐름 (Matrix → 두 해석 → Column space → Matrix 곱)을 **한 문제**로 종합한다.

$$A = \begin{pmatrix} 1 & 2 \\ 2 & 4 \\ 3 & 6 \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} 3 \\ -1 \end{pmatrix}, \quad \mathbf{b}_1 = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \quad \mathbf{b}_2 = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$$

- **(a)** $A\mathbf{x}$ 를 **Row picture**로 구하시오.
- **(b)** 같은 $A\mathbf{x}$ 를 **Column picture**로 구하시오.
- **(c)** A 의 두 열의 관계는 무엇인가? $\text{col}(A)$ 는 $\mathbb{R}^3$ 의 어떤 모양인가?
- **(d)** $A\mathbf{x} = \mathbf{b}_1$ 의 해가 존재하는가? $A\mathbf{x} = \mathbf{b}_2$ 는 어떠한가?

본 회차 마무리 문제: 답

- **(a)** Row: $(1,2) \cdot (3,-1) = 1$, $(2,4) \cdot (3,-1) = 2$, $(3,6) \cdot (3,-1) = 3 \rightarrow Ax = (1, 2, 3)^T$
- **(b)** Column: $3 \cdot (1,2,3)^T + (-1) \cdot (2,4,6)^T = (1, 2, 3)^T \checkmark$
- **(c)** $a_2 = 2a_1$, 두 열이 평행하다. $\text{col}(A) = \{t \cdot (1,2,3)^T : t \in \mathbb{R}\}$, **1차원 직선**.
- **(d)** $b_1 = (1,2,3)^T$, 직선 위 ($t = 1$) $\rightarrow$ 해 있음 (무수히, Linear dependence). $b_2 = (1,1,1)^T$, 직선 위 아님
 $\rightarrow$ **해 없음**.

핵심: A의 행이 3이라고 도달 가능한 영역이 $\mathbb{R}^3$ 전체가 아니다. **Column space**가 실제 도달 영역이고, 이것이 7회차의 출발점이다.

Q & A

핵심 한 줄: $\mathbf{Ax} = \mathbf{b}$ 의 열들의 **Linear combination** (Column picture).

다음 회차(4회차): 가우스 소거·**RREF** — 해 존재를 알고리즘으로 본다.

사전 reading: MML §2.3.1-3 · Strang Ch 2.1-2.3 · EoLA Ch.7

HANDOUT: 본 PDF, 03_행렬_행렬벡터곱.ipynb