

선형대수 진단평가 해설집

12문항 · 6개 핵심역량 축

인공지능 전공자를 위한 선형대수학 · SW·AI 융합대학원

각 문항: 정답 · 풀이 · 오답 노트 · 연결 회차

진단의 구성과 채점

- **목적:** 6개 핵심역량 축에서 지금 내 수준이 어디인지 빠르게 진단하고, 약한 축을 곧바로 해당 강의 회차로 이어 주는 것입니다.
- **구성:** 6축 × 2문항 = **12문항** (입문·학부·심화 난이도가 섞여 있습니다).
- **채점:** 축별로 맞힌 수가 **0~2점**, 총점은 **0~12점**입니다. 결과는 6축 레이더 그래프로 표시됩니다.
- **이 해설집의 사용법:** 문항마다
 - ① 개념을 바닥부터 다지고
 - ② 정답에 이르는 과정을 단계별로 풀어 보며
 - ③ 틀린 보기가 왜 틀렸는지까지 짚습니다.
- **정답 암기가 아니라 "왜 그런지"를 이해하는 것이 목표입니다.**

이 진단은 12개 객관식으로 6개 개념 축을 점검합니다. 코딩·AI 응용 역량은 측정 대상이 아니며, 표본이 작을수록 일반화에 주의합니다.

6개 축 ↔ 연결 회차

아래 표는 "어떤 개념을 묻는 문항이 어느 강의 회차와 연결되는지"를 보여 줍니다. 진단 후 점수가 낮은 축을 찾아, 같은 줄의 **연결 회차**부터 복습하면 됩니다.

축	핵심역량	문항	주 연결 회차
1	벡터·내적공간 (노름·내적·직교)	1·2	Part 1 · 2회차
2	선형방정식·행렬 (Ax ·가역성)	3·4	Part 1 · 3·5회차
3	벡터공간·부분공간 (rank·4부분공간)	5·6	Part 1 · 7·8회차
4	직교성·정사영 (정사영·정규방정식)	7·8	Part 2 · 1·2회차
5	행렬식·고윳값 (det·고유분해)	9·10	Part 2 · 4·5회차
6	SVD·선형변환 (특잇값·Eckart-Young)	11·12	Part 2 · 8·9회차

문항 1 · 개념 다지기 — 내적과 직교

- **내적(inner product)**은 두 벡터가 **얼마나 같은 방향을 향하는지**를 하나의 숫자로 요약한 값입니다. 식: $u \cdot v = \|u\| \|v\| \cos\theta$ (θ 는 두 벡터 사이 각).
- **직교(orthogonal)**란 두 벡터가 **서로 수직**(각 90°)이라는 뜻입니다.

비유. 두 사람이 수레를 같은 방향으로 밀면 힘이 그대로 합쳐지고, 서로 **직각으로** 밀면 한 사람의 힘이 다른 방향 진행에 전혀 보탬이 되지 않습니다. 내적은 "한쪽 힘이 다른 쪽 방향에 얼마나 기여하는가"를 잴 값이고, **내적 0 = 서로 직각 = 기여 없음**입니다.

이게 왜 필요한가요? AI에서 두 데이터(벡터)가 "관련 없다 / 독립이다"를 수식 하나로 판별할 때 바로 이 **내적 = 0**을 씁니다.

문항 1 · 단계별 풀이

문제. 내적이 $u \cdot v = \|u\| \|v\| \cos\theta$ 로 주어질 때, 두 벡터가 **직교**(orthogonal)일 필요충분조건은?

- (a) $\|u\| = \|v\|$ — 노름이 같음
- (b) $u+v = 0$ — 합이 영벡터
- (c) $u \cdot v = \|u\| \|v\|$ — 내적이 최대
- **(d) ✓ $u \cdot v = 0$ — 내적이 0**

① 직교의 뜻은 두 벡터 사이 각이 $\theta = 90^\circ$ 라는 것입니다./

② 그런데 $\cos 90^\circ = 0$ 입니다.

③ 두 벡터가 영벡터가 아니면 길이는 양수, 즉 $\|u\| \|v\| > 0$ 입니다.

④ 따라서 $u \cdot v = \|u\| \|v\| \cos\theta$ 에서 0이 되려면 $\cos\theta = 0$, 곧 직교일 때뿐입니다. 그래서 **직교 $\Leftrightarrow$ 내적 = 0**입니다.

문항 1 · 보기 점검 & 연결

- **(d) 정답인 이유:** 위 ①~④에서 본 대로 "내적 = 0"과 "직교"는 완전히 같은 말(동치)입니다.
- **(a) 틀림:** 두 벡터의 길이가 같다는 것은 방향과 무관합니다. 같은 길이라도 평행할 수도, 비스듬할 수도 있습니다.
- **(b) 틀림:** $u+v=0$ 은 $v=-u$, 즉 정반대 방향($\theta=180^\circ$)이라 직교가 아닙니다.
- **(c) 틀림:** $u \cdot v = \|u\| \|v\|$ 이면 $\cos\theta=1$, 곧 같은 방향(평행)입니다.

오개념 주의. "노름(길이)이 같으면 직교다"는 거짓입니다. 직교는 **방향**(각)의 문제이지 길이의 문제가 아닙니다.

연결. Part 1 · 2회차 (노름·내적·코사인유사도). **한 줄 핵심:** "수직"이라는 기하적 개념을 "내적 = 0"이라는 대수식으로 바꿔 쓸 수 있다.

문항 2 · 개념 다지기 — 코시-슈바르츠 부등식

- 노름(norm) $\|u\|$ 은 벡터의 **길이**입니다.
- 코시-슈바르츠 부등식(Cauchy-Schwarz inequality): 두 벡터의 내적의 크기는, 두 길이를 곱한 값을 **절대 넘지 못한다**는 보장입니다. 식: $|u \cdot v| \leq \|u\| \|v\|$.

비유. 내적 $\|u\| \|v\| \cos\theta$ 에서 방향이 만드는 효과는 $\cos\theta$ 가 결정하는데, $\cos\theta$ 는 아무리 커도 1을 못 넘습니다(완전히 같은 방향일 때 최대). 그래서 내적은 "두 길이의 곱"이라는 **천장**을 절대 뚫지 못합니다.

이게 왜 필요한가요? 두 벡터의 닮은 정도를 -1~1로 나타내는 **코사인 유사도**(cosine similarity)가 항상 그 범위 안에 있음을 보장해 주는 근거입니다.

문항 2 · 단계별 풀이

문제. 임의의 $u, v \in \mathbb{R}^n$ 에 대해 항상 성립하는 코시-슈바르츠 부등식은?

- (a) $\checkmark \quad |u \cdot v| \leq \|u\| \|v\|$
- (b) $|u \cdot v| \geq \|u\| \|v\|$
- (c) $\|u+v\| \geq \|u\| + \|v\|$
- (d) $u \cdot v \leq \|u\| + \|v\|$

① 내적의 정의 $u \cdot v = \|u\| \|v\| \cos\theta$ 에서 출발합니다.

② 양변에 절댓값을 씌우면 $|u \cdot v| = \|u\| \|v\| |\cos\theta|$ 입니다(길이는 양수라 그대로).

③ 코사인의 절댓값은 항상 1 이하입니다: $|\cos\theta| \leq 1$.

④ 따라서 $|u \cdot v| \leq \|u\| \|v\|$. 등호는 $|\cos\theta|=1$, 곧 두 벡터가 **평행**일 때 성립합니다. 정답은 (a)입니다.

문항 2 · 보기 점검 & 연결

- **(a) 정답인 이유:** $|\cos\theta| \leq 1$ 이 만드는 천장을 그대로 옮긴 부등식입니다.
- **(b) 틀림:** 부등호 방향이 반대입니다. 내적이 길이 곱보다 **크다**는 보장은 존재하지 않습니다.
- **(c) 틀림:** 이것은 코시-슈바르츠가 아니라 **삼각부등식**을 잘못 쓴 것입니다. 올바른 삼각부등식은 $\|u+v\| \leq \|u\| + \|v\|$ 로 부등호 방향이 반대입니다.
- **(d) 틀림:** 좌변은 내적(곱 형태), 우변은 길이의 합입니다. 크기 비교의 기준이 서로 맞지 않아 일반적으로 성립하지 않습니다.

오개념 주의. 코시-슈바르츠($\leq$ 길이의 곱)와 삼각부등식($\leq$ 길이의 합)을 혼동하기 쉽습니다. "곱이냐 합이냐"로 구분하세요.

연결. Part 1 · 2회차. **한 줄 핵심:** 내적은 두 길이의 곱을 절대 넘지 못하며, 이것이 코사인 유사도가 $[-1,1]$ 에 머무는 이유다.

문항 3 · 개념 다지기 — 행렬 $\times$ 벡터

- 행렬과 벡터의 곱 Ax 를 계산하는 방법은 두 관점이 있습니다.
- 행별 내적 관점: 결과의 각 성분 = A의 그 행과 x 의 내적.
- 열의 일차결합 관점: $Ax = (x$ 의 성분들을 가중치로 한) A의 열들의 합.

비유. 행별 내적은 "성적표 한 줄(행) $\times$ 가중치"로 과목별 환산점수를 내는 것과 같습니다. 첫 번째 결과 성분은 첫 줄에만, 두 번째 결과 성분은 둘째 줄에만 영향을 받습니다. 줄과 줄은 서로 섞이지 않습니다.

이게 왜 필요한가요? 신경망의 한 층은 본질적으로 Ax 한 번입니다. 이 계산이 모든 선형대수의 기본 동작입니다.

문항 3 · 단계별 풀이

문제. $A = \begin{pmatrix} 2 & 1 \\ 0 & 3 \end{pmatrix}$, $x = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$ 일 때 Ax 는?

• (a) $\begin{pmatrix} 2 \\ 6 \end{pmatrix}^T$ · (b) $\begin{pmatrix} 3 \\ 5 \end{pmatrix}^T$ · **(c) ✓ $\begin{pmatrix} 4 \\ 6 \end{pmatrix}^T$** · (d) $\begin{pmatrix} 4 \\ 5 \end{pmatrix}^T$

① 결과 벡터의 **첫 성분**은 A의 첫 행 $(2, 1)$ 과 $x = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$ 의 내적입니다: $2 \cdot 1 + 1 \cdot 2 = 2 + 2 = 4$.

② 결과 벡터의 **둘째 성분**은 A의 둘째 행 $(0, 3)$ 과 x 의 내적입니다: $0 \cdot 1 + 3 \cdot 2 = 0 + 6 = 6$.

③ 두 결과를 세로로 쌓으면 $Ax = \begin{pmatrix} 4 \\ 6 \end{pmatrix}^T$. 전체를 한 식으로 쓰면:

$$A\mathbf{x} = \begin{pmatrix} 2 & 1 \\ 0 & 3 \end{pmatrix} \begin{pmatrix} 1 \\ 2 \end{pmatrix} = \begin{pmatrix} 2 \cdot 1 + 1 \cdot 2 \\ 0 \cdot 1 + 3 \cdot 2 \end{pmatrix} = \begin{pmatrix} 4 \\ 6 \end{pmatrix} \text{정답은 (c)입니다.}$$

문항 3 · 보기 점검 & 연결

- **(c) 정답인 이유:** 위 ①②의 행별 내적을 정확히 수행한 결과입니다.
- **(a) $(2,6)^T$ 틀림:** 첫 행에서 두 번째 항 1· 2를 빠뜨려 2만 남긴 실수입니다(성분 누락).
- **(b) $(3,5)^T$ 틀림:** 곱을 더하지 않고 행렬·벡터 성분을 잘못 짝지은 경우입니다.
- **(d) $(4,5)^T$ 틀림:** 첫 성분 4는 맞지만 둘째 행에서 $3 \cdot 2=6$ 을 5로 잘못 계산했습니다.

오개념 주의. 행과 열을 혼동해 "A의 첫 열과 x를 내적"하면 안 됩니다. 행별 내적에서는 결과의 i번째 성분에 A의 i번째 행을 씁니다.

연결. Part 1 · 3회차 (행렬·행렬벡터곱). **한 줄 핵심:** Ax 는 "행별 내적"이자 "열의 일차결합"이며, 둘은 같은 답을 준다.

문항 4 · 개념 다지기 — 가역성

- **가역**(invertible) 행렬이란, 곱했을 때 원래대로 되돌리는 **역행렬 A^{-1} 이 존재**하는 정방행렬입니다.
- 가역성은 여러 조건과 **동시에 성립하거나 동시에 깨집니다**(이를 "가역성 정리"라 합니다). 대표적으로: $\det(A) \neq 0$, 열이 일차독립, $Ax=0$ 의 해가 $x=0$ 뿐.

비유. 가역 행렬은 "되돌릴 수 있는 변환"입니다. 종이를 접었다가(=곱하기) 완벽히 펴서 원래대로 돌릴 수 있으면 가역, 한 번 눌러 정보가 뭉개지면(=납작해지면) 비가역입니다. 위 여러 조건은 모두 "정보가 뭉개지지 않았다"는 같은 사실을 다른 말로 표현한 것입니다.

이게 왜 필요한가요? $Ax=b$ 를 유일하게 풀 수 있는지가 가역성에 달려 있습니다.

문항 4 · 단계별 풀이

문제. 정방행렬 $A \in \mathbb{R}^{n \times n}$ 가 **가역**(invertible)일 필요충분조건이 **아닌** 것은?

- (a) $\det(A) \neq 0$ · (b) A 의 n 개 열이 일차독립
- **(c) ✓ A 가 대칭이다 ($A = A^T$)** · (d) $Ax=0$ 의 유일한 해가 $x=0$

① 이 문항은 가역성과 **동치가 아닌** 보기를 고르는 문제임에 주의합니다("아닌 것은?").

② (a)·(b)·(d)는 모두 가역성 정리의 표준 동치 조건입니다. 셋 중 하나가 참이면 나머지도 참, 하나가 거짓이면 모두 거짓입니다.

③ (c) 대칭성은 가역성과 **별개**입니다. 반례로 확인합니다.

④ 영행렬 O 는 $O=O^T$ 이라 대칭이지만 역행렬이 없어 **비가역**입니다. 거꾸로 $\begin{pmatrix} 2 & 1 & 0 & 3 \end{pmatrix}$ 는 대칭이 아니지만 $\det=6 \neq 0$ 이라 가역입니다. 따라서 대칭은 가역성을 보장하지도, 요구하지도 않습니다. 정답은 (c)입니다.

문항 4 · 보기 점검 & 연결

- **(c) 정답인 이유:** 위 ④의 두 반례처럼 대칭과 가역은 서로를 함의하지 않습니다. 그래서 "필요충분조건이 아닌 것"입니다.
- **(a) 동치(=가역 조건):** $\det(A) \neq 0$ 이면 정확히 가역입니다.
- **(b) 동치:** 열이 일차독립이면 변환이 정보를 뭉개지 않으므로 가역입니다.
- **(d) 동치:** $Ax=0$ 의 해가 자명해뿐이라는 것은 영공간이 $\{0\}$, 곧 가역과 같은 말입니다.

오개념 주의. "대칭 = 좋은 성질이니 가역"은 거짓입니다. 대칭성은 가역성이 아니라 **고윳값이 실수로 나온다** 같은 *다른* 성질과 연결됩니다(문항 10 참고).

연결. Part 1 · 5·8회차 (역행렬·LU 분해(Lower·Upper) / 가역성 동치). **한 줄 핵심:** 가역성의 여러 동치 조건을 한 묶음으로 외우되, 대칭성은 그 묶음에 들어가지 않는다.

문항 5 · 개념 다지기 — rank와 차원 정리

- **rank(계수) r :** A 의 열(또는 행) 중 서로 독립인 것의 개수, 곧 행렬이 가진 "진짜 정보의 차원"입니다.
- **영공간(null space) $N(A)$:** $Ax=0$ 을 만족하는 모든 x 의 집합. "변환이 0으로 뭉개 버리는 방향"들입니다.
- **차원 정리(rank-nullity):** $\text{rank}(A) + \dim N(A) = n$ (여기서 n = 열의 개수 = 입력(정의역) 차원).

비유. 입력 공간의 n 개 방향(자유도)이 들어오면, A 는 그중 r 개는 살려서 출력으로 내보내고(rank), 나머지 $n-r$ 개는 0으로 짓눌러 버립니다($\dim N(A)$). 살린 것 + 짓누른 것 = 들어온 전부(n)입니다.

이게 왜 필요한가요? 방정식의 해가 유일한지, 자유변수가 몇 개인지를 이 한 식으로 셉니다.

문항 5 · 단계별 풀이

문제. $A \in \mathbb{R}^{m \times n}$, $\text{rank}(A)=r$ 일 때 **차원 정리**(rank-nullity)가 주는 영공간 $N(A)$ 의 차원은?

• (a) ✓ **$n-r$** · (b) r · (c) $m-r$ · (d) $\min(m,n)-r$

① 차원 정리는 **입력 차원 n** (열의 개수)을 기준으로 합니다: $\text{rank}(A)+\dim N(A)=n$.

② 양변에서 $\text{rank}(A)=r$ 을 빼면 $\dim N(A)=n-r$.

③ 직관 점검: 입력 n 개 방향 중 r 개는 살아남고(rank), 나머지가 0으로 뭉개지는 방향($N(A)$)이므로 $n-r$ 이 맞습니다.

④ 따라서 정답은 (a) $n-r$ 입니다.

문항 5 · 보기 점검 & 연결

- (a) **정답인 이유**: 차원 정리에서 $\dim N(A)=n-r$ 이 바로 나옵니다.
- (b) **r 틀림**: r은 영공간이 아니라 **행공간·열공간의 차원**입니다(살아남은 쪽).
- (c) **m-r 틀림**: m-r은 출력 쪽 공간인 **좌영공간 $N(A^T)$ 의 차원**입니다. 기준이 n이 아니라 m이라 다른 공간입니다.
- (d) **min(m,n)-r 틀림**: 그럴듯해 보이지만 차원 정리는 항상 n을 기준으로 하며, 일반적으로 성립하지 않습니다.

오개념 주의. 영공간의 차원은 **열의 개수 n**에서 빼야 합니다. 행의 개수 m에서 빼면 엉뚱한 공간(좌영공간)이 됩니다.

연결. Part 1 · 8회차 (일차독립·기저·차원·4부분공간). **한 줄 핵심**: 입력 차원 n = 살아남는 차원 r + 0으로 뭉개지는 차원 $n-r$.

문항 6 · 개념 다지기 — 4대 부분공간과 직교 여공간

- 행렬 $A \in \mathbb{R}^{m \times n}$ 에는 **4대 기본 부분공간**이 있습니다. 입력 쪽($\mathbb{R}^n$)에 **행공간 $C(A^T)$ ·영공간 $N(A)$** , 출력 쪽($\mathbb{R}^m$)에 **열공간 $C(A)$ ·좌영공간 $N(A^T)$** .
- **직교 여공간**(orthogonal complement): 같은 전체공간 안에서, 한쪽의 모든 벡터가 다른 쪽 모든 벡터와 직교하고, 둘을 합치면 전체공간을 꽉 채우는 관계입니다.

비유. $\mathbb{R}^n$ 이라는 방을 정확히 두 벽으로 직각 분할하는 것과 같습니다. 행공간과 영공간이 입력 방($\mathbb{R}^n$)을 서로 수직으로 갈라 채웁니다. 단, 같은 방 안에 있어야 합니다 — 다른 방($\mathbb{R}^m$)에 있는 공간끼리는 "직각으로 나눈다"는 말 자체가 성립하지 않습니다.

이게 왜 필요한가요? 정사영·최소제곱(문항 7·8)이 바로 이 직교 분할 위에서 작동합니다.

문항 6 · 단계별 풀이

문제. $A \in \mathbb{R}^{m \times n}$ 의 4대 기본 부분공간 중, 기본정리에 의해 $\mathbb{R}^n$ 안에서 서로 직교 여공간(orthogonal complement)을 이루는 쌍은?

- (a) 열공간 $C(A)$ 와 행공간 $C(A^T)$ · (b) 열공간 $C(A)$ 와 좌영공간 $N(A^T)$
- (c) 영공간 $N(A)$ 와 좌영공간 $N(A^T)$ · **(d) ✓ 행공간 $C(A^T)$ 와 영공간 $N(A)$**

① 먼저 어느 공간이 $\mathbb{R}^n$ (입력 쪽)에 사는지 가립니다: 행공간 $C(A^T)$ 와 영공간 $N(A)$ 가 $\mathbb{R}^n$ 에, 열공간 $C(A)$ 와 좌영공간 $N(A^T)$ 가 $\mathbb{R}^m$ 에 삽니다.

② 직교 여공간은 **같은 공간 안에서만** 따질 수 있으므로, 후보는 $\mathbb{R}^n$ 에 사는 두 공간 $C(A^T)$ 와 $N(A)$ 입니다.

③ 선형대수 기본정리: $\mathbb{R}^n$ 에서 행공간과 영공간은 서로 직교하고 직합이 $\mathbb{R}^n$ 입니다. ($\mathbb{R}^m$ 에서는 $C(A) \perp N(A^T)$.)

④ 따라서 $\mathbb{R}^n$ 안의 직교 여공간 쌍은 (d) $C(A^T)$ 와 $N(A)$ 입니다.

문항 6 · 보기 점검 & 연결

- **(d) 정답인 이유:** 둘 다 $\mathbb{R}^n$ 에 살고, 기본정리가 둘을 직교·직합으로 보장합니다.
- **(b) 틀림(함정):** $C(A) \perp N(A^T)$ 자체는 옳지만, 그것은 $\mathbb{R}^m$ 안의 쌍입니다. 문제는 $\mathbb{R}^n$ 을 물었습니다.
- **(a) 틀림:** $C(A)$ 는 $\mathbb{R}^m$, $C(A^T)$ 는 $\mathbb{R}^n$ 에 살아 서로 다른 공간이라 여공간 관계가 아닙니다.
- **(c) 틀림:** $N(A)$ 는 $\mathbb{R}^n$, $N(A^T)$ 는 $\mathbb{R}^m$ 에 살아 역시 다른 공간입니다.

오개념 주의. 차원이 같다고 직교 여공간인 것이 아닙니다. 반드시 같은 전체공간 안에서 직합·직교를 이뤄야 합니다.

연결. Part 1 · 8회차. **한 줄 핵심:** 직교 여공간은 같은 공간 안에서만 따지며, $\mathbb{R}^n$ 에서는 행공간 $\perp$ 영공간이다.

문항 7 · 개념 다지기 — 정사영 행렬

- **정사영**(orthogonal projection): 벡터 b 를 어떤 공간(여기서는 열공간 $C(A)$)에 **수직으로 내린 그림자**를 찾는 것입니다.
- **정사영 행렬 P** : 그 그림자를 한 번에 계산해 주는 행렬, 곧 $p=Pb$ 입니다.
- 핵심 아이디어: b 에서 그림자 p 를 뺀 **잔차 $b-p$ 가 그 공간과 직교**해야 최단 거리(가장 좋은 근사)가 됩니다.

비유. 머리 위에서 해가 수직으로 내리쬐릴 때 막대가 땅에 만드는 그림자가 정사영입니다. 막대 끝과 그림자 끝을 잇는 선(잔차)은 땅에 **수직**입니다. 이 "수직" 조건이 식 전체를 만들어 냅니다.

이게 왜 필요한가요? 정확한 해가 없는 방정식에서 "가장 가까운 답"을 구하는 최소제곱(문항 8)의 토대입니다.

문항 7 · 단계별 풀이

문제. 열이 일차독립인 A 에 대해, b 를 열공간 $C(A)$ 로 정사영하는 정사영 행렬 P ($p=Pb$)는?

- (a) $P = AA^T$ · **(b) ✓ $P = A(A^T A)^{-1}A^T$**
- (c) $P = (A^T A)^{-1}$ · (d) $P = A^T(AA^T)^{-1}A$

① 그림자 p 는 $C(A)$ 안에 있으므로 어떤 계수 $\hat{x}$ 로 $p=A\hat{x}$ 로 쓸 수 있습니다.

② 잔차가 $C(A)$ 와 직교해야 하므로 $A^T(b-A\hat{x})=0$. 정리하면 $A^T A \hat{x}=A^T b$.

③ 열이 독립이면 $A^T A$ 가 가역이므로 $\hat{x}=(A^T A)^{-1}A^T b$.

④ 다시 $p=A\hat{x}=A(A^T A)^{-1}A^T b$. 따라서 $P=A(A^T A)^{-1}A^T$, 정답은 (b)입니다.

문항 7 · 보기 점검 & 연결

- **(b) 정답인 이유:** 잔차의 직교 조건에서 위 ②~④를 거쳐 유일하게 유도됩니다.
- **(a) AA^T 틀림:** 이 간단한 형태는 A 의 열이 정규직교일 때만 정사영이 됩니다(그때 $A^T A = I$). 일반적으로는 아닙니다.
- **(c) $(A^T A)^{-1}$ 틀림:** 이것은 $n \times n$ 행렬로, $b(m차원)$ 에 곱할 수조차 없고 정사영도 아닙니다.
- **(d) $A^T(AA^T)^{-1}A$ 틀림:** A 와 A^T 의 위치가 뒤바뀐 형태로, 차원도 역할도 맞지 않습니다.

오개념 주의. $A^T A$ 의 역과 AA^T 의 역을 헷갈리지 마세요. 정사영 행렬은 좌우를 $A \cdots A^T$ 로 감싸고 가운데에 $(A^T A)^{-1}$ 이 들어갑니다. 또한 정사영 행렬은 $P^2 = P$, $P^T = P$ 를 만족합니다.

연결. Part 2 · 1회차 (직교성·정사영). **한 줄 핵심:** 잔차가 직교해야 한다는 한 조건에서 정사영 행렬 $A(A^T A)^{-1}A^T$ 이 통째로 나온다.

문항 8 · 개념 다지기 — 최소제곱과 정규방정식

- 데이터가 많아 $Ax=b$ 를 **정확히**는 못 푸는 경우가 흔합니다(식이 점보다 많음). 이때 잔차 $\|b-Ax\|$ 를 **가장 작게** 하는 $\hat{x}$ 를 찾는 것이 **최소제곱**(least squares)입니다.
- 그 $\hat{x}$ 가 만족하는 식을 **정규방정식**(normal equation)이라 하며, $A^T A \hat{x}=A^T b$ 입니다.

비유. 흩어진 점들 사이로 자를 대 직선을 긋는다고 합시다. 모든 점을 정확히 지날 순 없으니, 점들과의 위아래 오차(잔차)의 제곱합이 최소가 되도록 맞춥니다. 문항 7의 정사영과 같은 그림입니다 — **잔차가 직교**할 때 최적입니다.

이게 왜 필요한가요? 이것이 곧 **선형회귀**(linear regression)이며, 머신러닝에서 가장 기본적인 학습 방법입니다.

문항 8 · 단계별 풀이

문제. 열이 일차독립인 A 에 대해 $Ax=b$ 가 정확한 해를 갖지 않을 때, 잔차 $\|b-Ax\|$ 를 최소로 하는 최소제곱 해 $\hat{x}$ 의 정규방정식은?

- (a) $A\hat{x}=b$ · **(b) $\checkmark A^T A \hat{x} = A^T b$**
- (c) $AA^T \hat{x}=b$ · (d) $A^T \hat{x}=b$

① 오차를 최소로 하려면 잔차 $b-A\hat{x}$ 가 열공간 $C(A)$ 와 직교해야 합니다(문항 7과 같은 조건).

② 직교를 식으로 쓰면 $A^T(b-A\hat{x})=0$ 입니다.

③ 괄호를 풀면 $A^Tb-A^T A \hat{x}=0$.

④ 이항하면 $A^T A \hat{x}=A^Tb$. 열이 독립이면 $A^T A$ 가 가역이라 유일한 해가 존재합니다. 정답은 (b)입니다.

문항 8 · 보기 점검 & 연결

- **(b) 정답인 이유:** 잔차의 직교 조건을 정리하면 그대로 나오는 식입니다.
- **(a) $A\hat{x}=b$ 틀림:** 이것은 "정확한 해"를 요구하는데, 문제 전제가 정확한 해가 **없는** 경우라 성립할 수 없습니다.
- **(c) $AA^T\hat{x}=b$ 틀림:** $A^T A$ 대신 AA^T 을 쓰고 양변 형태도 맞지 않습니다.
- **(d) $A^T\hat{x}=b$ 틀림:** A^T 만 곱한 형태로 차원조차 맞지 않습니다.

오개념 주의. 정확한 해가 없을 때 "그냥 $A^{-1}b$ 로 풀면 된다"고 생각하기 쉽지만, A 가 정방·가역이 아니라 A^{-1} 이 없습니다. 대신 양변에 A^T 을 곱해 $A^T A$ 를 만드는 것이 핵심 트릭입니다.

연결. Part 2 · 2회차 (최소제곱·정규방정식). **한 줄 핵심:** 정확히 못 풀면 잔차를 직교시켜 $A^T A \hat{x}=A^T b$ 로 "가장 가까운 답"을 구한다 — 이것이 선형회귀다.

문항 9 · 개념 다지기 — 행렬식

- **행렬식(determinant) $\det(\mathbf{A})$:** 행렬이 공간을 얼마나 늘리거나 줄이는지를 나타내는 하나의 숫자입니다. 2×2 행렬 $\begin{pmatrix} a & b \\ c & d \end{pmatrix}$ 에 서는 $\det = ad - bc$ (대각곱의 차).
- $|\det(\mathbf{A})|$ 는 변환이 만드는 **평행사변형의 넓이**(부피)이고, $\det(\mathbf{A}) = 0$ 이면 공간이 납작하게 짓눌렸다는 뜻 = **비가역**입니다.

비유. 단위 정사각형(넓이 1)을 행렬로 변환하면 평행사변형이 됩니다. 그 넓이가 곧 $|\det|$ 입니다. 넓이가 0이 되면(=평행사변형이 선으로 찢부러지면) 면적 정보가 사라져 되돌릴 수 없으니 비가역입니다.

이게 왜 필요한가요? 가역성 판정(문항 4)과 고윳값 계산(문항 10)의 기본 도구입니다.

문항 9 · 단계별 풀이

문제. $A = \begin{pmatrix} 3 & 1 \\ 2 & 4 \end{pmatrix}$ 의 행렬식 $\det(A)$ 는?

• (a) 7 · (b) 14 · **(c) ✓ 10** · (d) 2

① 2×2 행렬식 공식은 (왼쪽 위 $\times$ 오른쪽 아래) - (오른쪽 위 $\times$ 왼쪽 아래)입니다.

② 주대각 곱: $3 \cdot 4 = 12$.

③ 반대각 곱: $1 \cdot 2 = 2$.

④ 둘의 차: $12 - 2 = 10$. 한 식으로:

$$\det(A) = 3 \cdot 4 - 1 \cdot 2 = 12 - 2 = 10$$

정답은 (c)입니다.

문항 9 · 보기 점검 & 연결

- **(c) 정답인 이유:** 위 ②~④의 대각곱의 차를 정확히 계산한 값입니다.
- **(a) 7 틀림:** $7=3+4$ 는 주대각 성분의 합, 곧 대각합(trace)입니다. 행렬식이 아닙니다.
- **(b) 14 틀림:** 빼야 할 반대각 곱을 더해 버린($12+2$) 부호 실수입니다.
- **(d) 2 틀림:** 주대각 곱과 반대각 곱을 거꾸로 빼거나 성분을 잘못 짚은 계산 실수입니다.

오개념 주의. 행렬식($ad-bc$, 곱의 차)과 대각합 $\text{trace}(a+d, \text{합})$ 는 전혀 다른 양입니다. "대각선에 있는 수"라는 점만 보고 헷갈리지 마세요.

연결. Part 2 · 4회차 (행렬식). **한 줄 핵심:** $\det$ 은 부피 배율이며, $\det=0$ 이면 비가역, 2×2 는 "대각곱의 차"로 계산한다.

문항 10 · 개념 다지기 — 고윳값, trace, det

- **고윳값(eigenvalue) λ** : 변환 A가 어떤 특별한 방향(고유벡터)을 **방향은 그대로 둔 채 몇 배로 늘리는지** 나타내는 배율입니다.
- 고윳값들은 두 익숙한 양과 깔끔하게 연결됩니다: **합 = 대각합(trace, 주대각 성분의 합)**, **곱 = 행렬식(det)**.

비유. 고윳값은 변환의 "고유한 신축 배율" 목록입니다. 그 배율들을 모두 곱하면 전체 부피 배율 = det이 되고(문항 9의 부피 의미와 일치), 모두 더하면 trace가 됩니다. 부피는 배율의 곱이라는 점만 떠올리면 "곱 = det"이 자연스럽습니다.

이게 왜 필요한가요? PCA·안정성 분석 등에서 행렬의 성질을 고윳값으로 읽어 냅니다.

문항 10 · 단계별 풀이

문제. 정방행렬 A 의 고윳값을 $\lambda_1, \dots, \lambda_n$ 이라 할 때 항상 옳은 것은?

- (a) $\sum_i \lambda_i = \det(A)$, $\prod_i \lambda_i = \text{trace}(A)$
- **(b) $\checkmark \sum_i \lambda_i = \text{trace}(A)$, $\prod_i \lambda_i = \det(A)$**
- (c) $\sum_i \lambda_i = \text{rank}(A)$ · (d) 모든 λ_i 가 항상 실수이다

① 고윳값은 특성다항식 $\det(A - \lambda I) = 0$ 의 근입니다.

② 이 다항식을 전개해 근과 계수의 관계(비에트 공식)를 보면, **근의 합 = trace**가 나옵니다.

③ 같은 방식으로 **근의 곱 = det**가 나옵니다(부피 = 신축 배율들의 곱이라는 직관과도 일치).

④ 따라서 "합 = trace, 곱 = det"인 (b)가 정답입니다.

문항 10 · 보기 점검 & 연결

- **(b) 정답인 이유:** 특성다항식의 근과 계수 관계에서 합은 trace, 곱은 det로 정확히 나옵니다.
- **(a) 틀림:** 합과 곱의 대응이 서로 뒤바뀌었습니다(합에 det, 곱에 trace).
- **(c) 틀림:** 고윳값의 합은 trace이지 rank가 아닙니다. rank는 0이 아닌 고윳값의 개수와 관련될 뿐 합과는 무관합니다.
- **(d) 틀림:** 일반 행렬은 복소 고윳값을 가질 수 있습니다. 예를 들어 회전행렬의 고윳값은 복소수입니다.

오개념 주의. "고윳값은 항상 실수"는 거짓입니다. 실수임이 **보장되는 것은 실대칭 행렬일 때뿐**입니다(스펙트럼 정리). 문항 4에서 본 "대칭의 진짜 효용"이 바로 이것입니다.

연결. Part 2 · 5회차 (고윳값·고유벡터). **한 줄 핵심:** 고윳값의 합 = trace, 곱 = det이며, 실수 보장은 대칭일 때만이다.

문항 11 · 개념 다지기 — SVD와 저계수 근사

- **특이값 분해**(SVD, Singular Value Decomposition): 임의의 행렬을 $A = \sum_i \sigma_i u_i v_i^T$ 처럼, **중요도 σ_i** (특이값)가 큰 순서로 쌓은 단순 조각들의 합으로 분해합니다.
- **저계수 근사**(low-rank approximation): 이 합에서 **앞쪽(큰 σ_i) 몇 개만** 남겨 행렬을 가볍게 근사하는 것입니다.
- **Eckart-Young 정리**: 상위 k개만 남긴 절단 SVD가 **오차가 가장 작은** rank-k 근사임을 보장합니다.

비유. 사진을 용량을 줄여 저장할 때, 큰 윤곽(큰 σ)부터 담고 미세한 잡티(작은 σ)는 버립니다. 가장 큰 정보부터 k개만 남기면 같은 용량에서 가장 또렷한 그림이 나옵니다 — 그것이 Eckart-Young이 말하는 최적 근사입니다.

이게 왜 필요한가요? 이미지 압축·PCA·추천 시스템이 모두 이 원리로 작동합니다.

문항 11 · 단계별 풀이

문제. **Eckart-Young 정리**: 행렬 A 를 rank k 로 근사할 때 Frobenius(또는 스펙트럼) 노름에서 오차를 최소로 하는 근사 A_k 는?

- (a) ✓ SVD 상위 k 개 특잇값만 남긴 $A_k = \sum_{i=1}^k \sigma_i u_i v_i^T$
- (b) A 의 처음 k 개 행·열만 잘라낸 부분행렬
- (c) A 의 RREF(기약 행 사다리꼴)에서 추축 k 개에 해당하는 행
- (d) A 의 고윳값 중 가장 작은 k 개로 만든 행렬

① SVD는 A 를 $\sigma_1 \geq \sigma_2 \geq \dots$ 순으로 정렬된 rank-1 조각들의 합으로 씁니다.

② 각 조각 $\sigma_i u_i v_i^T$ 의 "기여 크기"가 바로 σ_i 이므로, 오차를 줄려면 **큰 σ_i** 부터 남겨야 합니다.

③ Eckart-Young 정리는 이렇게 상위 k 개만 남긴 절단 SVD가 Frobenius·스펙트럼 노름 **모두**에서 최적 rank- k 근사임을 증명합니다.

④ 따라서 $A_k = \sum_{i=1}^k \sigma_i u_i v_i^T$ 인 (a)가 정답입니다.

문항 11 · 보기 점검 & 연결

- **(a) 정답인 이유:** 큰 특잇값부터 k 개를 남긴 절단 SVD가 정리에 의해 오차 최소임이 보장됩니다.
- **(b) 틀림:** 그냥 처음 k 개 행·열을 잘라낸 부분행렬은 중요도를 고려하지 않으므로 일반적으로 최적이지 않습니다.
- **(c) 틀림:** RREF는 해를 구하는 행 연산일 뿐, 행렬의 근사·압축과는 무관합니다.
- **(d) 틀림:** 방향이 거꾸로입니다. **작은** 특잇값을 버리고 **큰** 것을 남겨야 정보가 보존됩니다(고윳값이 아니라 특잇값을 다룬다는 점도 주의).

오개념 주의. "작은 값을 남긴다"가 아니라 "큰 값을 남긴다"입니다. 또한 여기서 다루는 것은 고윳값이 아니라 **특잇값**입니다.

연결. Part 2 · 9회차 (저계수 근사). **한 줄 핵심:** 큰 특잇값 k 개만 남긴 절단 SVD가 최적 rank- k 근사다 — 이미지 압축·PCA의 원리.

문항 12 · 개념 다지기 — 특잇값의 정체

- 특이값 분해 $A=U\Sigma V^T$ 에서 Σ 의 대각에 놓이는 특잇값(singular value) σ_i 는 그 방향의 신축 배율입니다.
- 특잇값은 정방행렬이 아닌 A 에서도 정의되어야 합니다. 그래서 항상 정방·대칭인 $A^T A$ 를 만들어, 그 고유값 λ_i 의 음이 아닌 제곱근으로 정의합니다: $\sigma_i = \sqrt{\lambda_i} \geq 0$.

비유. A 자체는 직사각형이라 "고유값"을 직접 말하기 어렵습니다. 그래서 $A^T A$ 라는 반듯한 정사각·대칭 행렬로 바꿔(항상 가능) 거기서 고유값을 구한 뒤, 길이 척도로 되돌리려 제곱근을 취합니다. $A^T A$ 는 준양정치라 고유값이 음수가 안 되어 제곱근이 늘 실수입니다.

이게 왜 필요한가요? 특잇값의 크기 순서가 곧 정보의 중요도이며(문항 11), 그 정의의 출발점입니다.

문항 12 · 단계별 풀이

문제. 임의의 $A \in \mathbb{R}^{m \times n}$ 의 특이값 분해 $A=U\Sigma V^T$ 에서 특이값 σ_i 에 대해 옳은 것은?

- (a) σ_i 는 $A^T A$ 의 고윳값과 같다
- **(b) ✓ σ_i 는 $A^T A$ 고윳값의 음이 아닌 제곱근이다**
- (c) σ_i 는 음수가 될 수 있다 · (d) SVD는 정방행렬에만 존재한다

① $A=U\Sigma V^T$ 를 이용해 $A^T A$ 를 계산하면 $A^T A=V\Sigma^T\Sigma V^T$ 이 됩니다.

② 이는 $A^T A$ 의 고윳값이 $\Sigma^T\Sigma$ 의 대각, 곧 σ_i^2 임을 뜻합니다: $\lambda_i(A^T A)=\sigma_i^2$.

③ $A^T A$ 는 대칭이고 준양정치라 모든 고윳값 $\lambda_i \geq 0$ 입니다.

④ 양변에 제곱근을 취하면 $\sigma_i=\sqrt{\lambda_i} \geq 0$. 따라서 "고윳값의 음이 아닌 제곱근"인 (b)가 정답입니다.

문항 12 · 보기 점검 & 연결

- **(b) 정답인 이유:** $\lambda_i(A^T A) = \sigma_i^2$ 이고 $\lambda_i \geq 0$ 이므로 $\sigma_i = \sqrt{\lambda_i}$ 입니다.
- **(a) 틀림:** 특잇값은 고윳값 **자체**가 아니라 그 **제곱근**입니다($\sigma_i = \sqrt{\lambda_i}$). 한 단계를 빠뜨린 함정입니다.
- **(c) 틀림:** 특잇값은 정의상 음이 아닌 제곱근이므로 항상 $\sigma_i \geq 0$ 입니다.
- **(d) 틀림:** SVD는 임의의 $m \times n$ 행렬에 항상 존재합니다. 정방·대칭 조건이 필요한 것은 고유분해이지 SVD가 아닙니다.

오개념 주의. 특잇값과 고윳값을 같은 것으로 보면 안 됩니다. 관계는 "제곱하면 $A^T A$ 의 고윳값"입니다($\sigma_i^2 = \lambda_i$).

연결. Part 2 · 8회차 (SVD). **한 줄 핵심:** 특잇값은 $A^T A$ 고윳값의 음이 아닌 제곱근이며, 임의의 직사각 행렬에서도 늘 존재한다.

약점 축별 보강 가이드

약점 축	먼저 잡을 핵심 개념	복습 회차
1 벡터·내적	내적·노름·직교·코사인 유사도	Part 1 · 2
2 선형방정식·행렬	Ax ·가역성 동치·역행렬	Part 1 · 3·5
3 부분공간	rank·차원 정리·4대 부분공간	Part 1 · 7·8
4 직교성·정사영	정사영 행렬·정규방정식·QR 분해	Part 2 · 1·2·3
5 행렬식·고윳값	det·고유분해·대각화	Part 2 · 4·5·6
6 SVD	SVD·특잇값·Eckart–Young	Part 2 · 8·9

점수가 낮은 축부터 **연결 회차 1~2개를 복습**한 뒤 진단을 다시 풀어 변화를 확인하세요.

정리

약점 축 → 연결 회차 복습 → 진단 재응시

한 문항이 막히면 정답 암기가 아니라, 그 축의 **정의 한 줄**로 돌아가 보세요.

강의 사이트: [ONOMONODCCBJOPNBCCONMOMJNNOMAEOM](#)